



**Politechnika
Śląska**

PRACA MAGISTERSKA

Przekształcanie nagrań dźwiękowych na zapis nutowy

Łukasz KRAWCZYK

Nr albumu: 296657

Kierunek: Informatyka

Specjalność: Internet i technologie sieciowe

PROWADZĄCY PRACĘ

Dr inż. Paweł Benecki

**KATEDRA Katedra Informatyki Stosowanej
Wydział Automatyki, Elektroniki i Informatyki**

Gliwice 2025

Tytuł pracy

Przekształcanie nagrań dźwiękowych na zapis nutowy

Streszczenie

(Streszczenie pracy – odpowiednie pole w systemie APD powinno zawierać kopię tego streszczenia.)

Słowa kluczowe

(2-5 słów (fraz) kluczowych, oddzielonych przecinkami)

Thesis title

Converting audio recordings to musical notation

Abstract

(Thesis abstract – to be copied into an appropriate field during an electronic submission – in English.)

Key words

(2-5 keywords, separated by commas)

Spis treści

1	Wstęp	1
1.1	Osadzenie problemu w dziedzinie naukowej	3
1.2	Cel pracy	6
1.3	Zakres pracy	6
1.4	Zwięzła charakterystyka rozdziałów	8
1.5	Jednoznaczne określenie wkładu autora	9
2	Analiza Tematu: Podstawy i Specyfika Transkrypcji Gitarowej	11
2.1	Definicja Problemu Automatycznej Transkrypcji Muzycznej (ATM) i Jego Znaczenie	11
2.1.1	Sformułowanie problemu	11
2.1.2	Znaczenie badań nad ATM dla gitary	12
2.1.3	Kontekst naukowy i interdyscyplinarny charakter ATM	12
2.2	Podstawy Teoretyczne: Dźwięk Muzyczny i Jego Cyfrowa Reprezentacja . .	13
2.2.1	Percepcyjne i fizyczne atrybuty dźwięku muzycznego	13
2.2.2	Reprezentacja sygnału audio w dziedzinie czasu i częstotliwości . .	13
2.2.3	Analiza czasowo-częstotliwościowa i jej znaczenie dla ATM	14
2.3	Rdzeń Automatycznej Transkrypcji Muzycznej: Zadania, Poziomy i Wyzwania	16
2.3.1	Definicja, zadania składowe i poziomy abstrakcji w ATM	16
2.3.2	Transkrypcja monofoniczna vs. polifoniczna – złożoność i główne wyzwania	16
2.4	Przegląd Metod Stosowanych w Automatycznej Transkrypcji Muzycznej . .	17
2.4.1	Tradycyjne metody oparte na przetwarzaniu sygnałów	17
2.4.2	Metody oparte na uczeniu maszynowym	18
2.5	Specyfika Transkrypcji Muzyki Gitarowej na Zapis Tabulaturowy (GTT) .	20
2.5.1	Akustyczna charakterystyka sygnału gitary i jej implikacje dla trans- krypcji	20
2.5.2	Porównanie notacji standardowej i tabulaturowej dla gitary	23
2.5.3	Kluczowe wyzwania w automatycznej transkrypcji gitary na tabula- turę (GTT)	23
2.5.4	Przegląd istniejących podejść i narzędzi do GTT	26

2.6	Podsumowanie i Otwarte Problemy	28
3	Przedmiot Pracy: Projekt i Implementacja Systemu Transkrypcji Gitarowej	31
3.1	Opis Zaimplementowanego Rozwiązania	31
3.1.1	Architektura Ogólna Systemu	31
3.1.2	Przetwarzanie Wstępne i Przygotowanie Danych	32
3.1.3	Model Transkrypcji (CRNN)	35
3.1.4	Proces Treningu Modelu	38
3.1.5	Ewaluacja i Generowanie Wyników	39
3.1.6	Wizualizacja	40
3.2	Analiza Teoretyczna Rozwiązania	41
3.2.1	Wybór Architektury CRNN w Kontekście GTT	41
3.2.2	Reprezentacja Sygnału Wejściowego	42
3.2.3	Funkcja Straty i Optymalizacja Wielozadaniowa	42
3.2.4	Techniki Augmentacji Danych	43
3.3	Uzasadnienie Wyboru Zastosowanych Metod, Algorytmów i Narzędzi	43
3.3.1	Zbiór Danych GuitarSet	43
3.3.2	Wybór Reprezentacji Czasowo-Częstotliwościowych	44
3.3.3	Architektura CRNN jako Model Transkrypcji	44
3.3.4	Wykorzystane Biblioteki Programistyczne	44
3.4	Podsumowanie Rozdziału	45
4	Badania	47
5	Podsumowanie	49
	Bibliografia	51
	Dokumentacja techniczna	53
	Spis skrótów i symboli	55
	Spis rysunków	58
	Spis tabel	59

Rozdział 1

Wstęp

Automatyczna Transkrypcja Muzyczna (ATM) (*Automatic Music Transcription*) stanowi jedno z kluczowych i jednocześnie najbardziej złożonych zadań w dziedzinie komputerowej analizy muzyki. W swej istocie, ATM jest procesem konwersji sygnału akustycznego, będącego fizyczną manifestacją muzyki, na jego symboliczną, strukturalną reprezentację [KlapuriDavy2006SignalProcessing, Benetos2019AutomaticMusicTranscription]. Celem tego procesu jest przekształcenie ciągłego sygnału audio w dyskretny zestaw symboli muzycznych, takich jak tradycyjne nuty określające wysokość i czas trwania dźwięku, lub – co jest przedmiotem szczególnego zainteresowania w niniejszej pracy – w zapis tabulaturowy. Interdyscyplinarny charakter Automatycznej Transkrypcji Muzycznej jest niezaprzeczalny, gdyż skuteczna realizacja jej zadań wymaga integracji wiedzy i metodologii pochodzących z wielu, pozornie odległych, dziedzin nauki i techniki. Do najważniejszych z nich należą:

- **Cyfrowe Przetwarzanie Sygnałów (CPS)** (*Digital Signal Processing – DSP*): Dostarcza ono fundamentalnych narzędzi do analizy, transformacji i manipulacji sygnałem audio w dziedzinie czasu i częstotliwości. Techniki takie jak filtracja, analiza spektralna czy transformacje czasowo-częstotliwościowe są nieodzowne w procesie ekstrakcji informacji z surowego sygnału dźwiękowego [KlapuriDavy2006SignalProcessing]. Zaawansowane metody CPS pozwalają na wstępne przygotowanie sygnału, redukcję szumów oraz identyfikację podstawowych cech akustycznych, które następnie mogą być interpretowane w kontekście muzycznym. Przykładem fundamentalnego narzędzia CPS, ilustrującego przejście z dziedziny czasu do dziedziny częstotliwości, jest dyskretna transformata Fouriera (DFT) (*Discrete Fourier Transform*). Dla skończonego ciągu próbek sygnału x_n o długości N , jej k -ty współczynnik X_k jest zdefiniowany jako:

$$X_k = \sum_{n=0}^{N-1} x_n \cdot e^{-i\frac{2\pi}{N}kn} \quad (1.1)$$


gdzie n jest indeksem próbki w dziedzinie czasu, k jest indeksem częstotliwości, a i jest jednostką urojoną. Wzór ten jest podstawą wielu algorytmów analizy częstotli-

wościowej stosowanych w ATM.

- **Rozpoznawanie Wzorców** (*Pattern Recognition*) oraz **Uczenie Maszynowe** (UM) (*Machine Learning – ML*): Te dziedziny odgrywają kluczową rolę w identyfikacji złożonych struktur muzycznych, takich jak pojedyncze nuty, akordy, rytmy czy motywy melodyczne, w często zaszumionym i polifonicznym sygnale audio [Benetos2019AutomaticMusicTranscription]. Współczesne systemy ATM w coraz większym stopniu opierają się na zaawansowanych modelach uczenia maszynowego, w szczególności na sieciach neuronowych i głębokim uczeniu (*Deep Learning*), które potrafią automatycznie uczyć się hierarchicznych reprezentacji cech muzycznych bezpośrednio z danych [BurletHindle2017IsolatedGuitarTranscription]. Dynamiczny rozwój w obszarze głębokiego uczenia bezpośrednio przekłada się na postępy w ATM, umożliwiając tworzenie modeli zdolnych do przetwarzania coraz bardziej skomplikowanych sygnałów muzycznych z niespotykaną dotąd dokładnością.
- **Sztuczna Inteligencja (SI)** (*Artificial Intelligence – AI*): Jako szersza dziedzina, obejmuje ona uczenie maszynowe, ale także inne aspekty, takie jak reprezentacja wiedzy muzycznej oraz procesy poznawcze związane z percepcją i wnioskowaniem w kontekście muzycznym [Benetos2019AutomaticMusicTranscription]. Rozwój SI dostarcza ram koncepcyjnych i narzędziowych dla budowy inteligentnych systemów transkrypcji.
- **Muzykologia**: Dostarcza niezbędnej wiedzy teoretycznej o strukturze muzyki, notacji, harmonii, rytmie oraz praktykach wykonawczych [Holzapfel2019Ethnomusicology]. Zrozumienie zasad muzycznych jest kluczowe nie tylko dla interpretacji wyników generowanych przez systemy ATM, ale również dla projektowania algorytmów, które uwzględniają kontekst muzyczny i dążą do tworzenia transkrypcji użytecznych z perspektywy muzykologicznej i wykonawczej.

Potencjalne obszary zastosowań systemów ATM są szerokie i różnorodne, co podkreśla ich rosnące znaczenie zarówno w badaniach naukowych, jak i w praktyce muzycznej. Do najważniejszych aplikacji należą: wsparcie w edukacji muzycznej, na przykład poprzez tworzenie systemów do automatyzacji ćwiczeń gry na instrumencie, analizę postępów ucznia czy generowanie spersonalizowanych materiałów dydaktycznych [Benetos2019AutomaticMusicTranscription]. Systemy ATM mogą również znacząco ułatwić proces tworzenia i aranżacji muzyki, na przykład poprzez wspieranie modyfikacji i rearanżacji istniejących utworów [ArndtLi2012AutomatedTranscription]. Dla producentów muzycznych, ATM oferuje narzędzia do wizualizacji treści muzycznej i inteligentnej edycji nagrań [Benetos2019AutomaticMusicTranscription]. Ponadto, technologie te są wykorzystywane w systemach wyszukiwania i kategoryzacji muzyki w dużych zbiorach danych, na przykład poprzez umożliwienie wyszukiwania utworów na podstawie ich melodii,

harmonii czy rytmu [Benetos2019AutomaticMusicTranscription]. Tytuł niniejszej pracy, „Przekształcanie nagrań dźwiękowych na zapis nutowy”, odnosi się do centralnego problemu ATM. Należy jednak podkreślić, że termin „zapis nutowy” jest pojęciem szerokim, obejmującym różnorodne systemy notacji muzycznej. W kontekście niniejszego opracowania, szczególna uwaga zostanie poświęcona specyficznej formie zapisu, jaką jest tabulatura gitarowa. Tabulatura, w odróżnieniu od tradycyjnej notacji nutowej skupiającej się *primarnie* na wysokości i czasie trwania dźwięku, jest graficzną reprezentacją wskazującą bezpośrednio pozycje palców na gryfie instrumentu – konkretne struny i progi, które należy nacisnąć, aby uzyskać pożądany dźwięk [Wiggins2019TabCNN].



Rysunek 1.1: Porównanie fragmentu zapisu nutowego i odpowiadającej mu tabulatury gitarowej dla motywu muzycznego.


Wybór tabulatury jako docelowej formy zapisu w tej pracy nie jest przypadkowy. Wynika on ze specyfiki gitary jako instrumentu oraz z ogromnej popularności tej formy notacji wśród gitarzystów [Wiggins2019TabCNN]. Rosnąca popularność tabulatur, często udostępnianych online, stwarza specyficzne zapotrzebowanie na systemy ATM zdolne do generowania tego właśnie formatu. Nie jest to jedynie kwestia preferencji użytkowników; tabulatura często zawiera informacje o charakterze performatywnym, takie jak konkretne opalcowanie czy użycie technik gitarowych, których brakuje w standardowej notacji nutowej. Skuteczne systemy ATM generujące tabulatury mogą zatem zdemokratyzować proces nauki gry na gitarze oraz tworzenia muzyki, obniżając barierę wejścia dla osób, które nie posługują się biegle tradycyjnym zapisem nutowym, ale rozumieją intuicyjny charakter tabulatury. Ten wybór stanowi naturalne przejście do dalszych, bardziej szczegółowych rozważań przedstawionych w kolejnych rozdziałach pracy.

1.1 Osadzenie problemu w dziedzinie naukowej

Przedmiotem niniejszej pracy jest zagadnienie automatycznej transkrypcji muzyki gitarowej do postaci tabulatury, co sytuuje ją w szerokim kontekście badań prowadzonych w ramach dziedziny naukowej znanej jako *Music Information Retrieval (MIR)*. MIR, czyli komputerowe pozyskiwanie informacji muzycznej, jest interdyscyplinarnym polem badawczym zajmującym się analizą, przetwarzaniem, wyszukiwaniem, organizacją i dostępem do informacji zawartej w muzyce, zarówno w jej formie akustycznej, jak i

symbolicznej. Obserwowany w ostatnich dekadach gwałtowny wzrost ilości dostępnych cyfrowych treści muzycznych, na przykład w ramach cyfrowych bibliotek muzycznych i serwisów streamingowych [Benetos2019AutomaticMusicTranscription], generuje rosnące zapotrzebowanie na zautomatyzowane narzędzia do ich analizy. Narzędzia te są niezbędne do efektywnego zarządzania ogromnymi repozytoriami muzyki, ich przeszukiwania, kategoryzacji oraz personalizacji dostępu dla użytkowników. ATM jest jednym z kluczowych zadań w ramach MIR, umożliwiającym transformację sygnału audio na bogatszą, symboliczną reprezentację, która może być dalej przetwarzana i analizowana. Szczególną uwagę w kontekście niniejszej pracy należy poświęcić wyzwaniom związanym z transkrypcją muzyki gitarowej. Gitara, będąca instrumentem niezwykle popularnym i wszechstronnym, wykorzystywanym w niemal każdym gatunku muzycznym, stawia przed systemami ATM szereg specyficznych trudności:

- **Polifoniczność:** Gitara jest instrumentem polifonicznym, co oznacza zdolność do jednoczesnego wydawania wielu dźwięków (standardowo do sześciu, po jednym na każdej strunie) [BurletHindle2017IsolatedGuitarTranscription]. Nakładanie się składowych harmonicznym wielu jednocześnie brzmiących dźwięków w sygnale audio znacząco komplikuje proces ich separacji i identyfikacji.



Rysunek 1.2: Schematyczny przykład spektrogramu polifonicznego sygnału gitarowego, ukazujący nakładające się struktury harmoniczne (prążki reprezentujące częstotliwość podstawową i jej alikwoty) dla kilku jednocześnie brzmiących nut.

- **Bogactwo technik artykulacyjnych:** Gitarzyści wykorzystują szeroki wachlarz technik artykulacyjnych, takich jak podciąganie strun (*bending*), ślizgi (*sliding*), młoteczkowanie (*hammer-on*), odrywanie (*pull-off*), wibrato (*vibrato*) czy tłumienie strun dłonią (*palm-muting*). Każda z tych technik w unikalny sposób modyfikuje

charakterystykę sygnału akustycznego (np. jego wysokość, amplitudę, barwę w czasie) i jest kluczowa dla wiernej transkrypcji, zwłaszcza do formatu tabulatury, który często zawiera symbole oznaczające te techniki.

- **Duża zmienność barwy dźwięku (*timbre*):** Barwa dźwięku gitary jest niezwykle zróżnicowana i zależy od wielu czynników, takich jak typ instrumentu (np. gitara akustyczna, klasyczna, elektryczna), rodzaj użytych strun, sposób ich pobudzenia (kostką, palcami), a w przypadku gitar elektrycznych – od ustawień wzmacniacza i zastosowanych efektów gitarowych [Wiggins2019TabCNN]. Ta duża wariabilność barwy stanowi poważne wyzwanie dla modeli uczenia maszynowego, które muszą generalizować swoją wiedzę na różne instancje dźwięków gitarowych.
- **Identyczność wysokości dźwięku na różnych strunach i progach:** Jedną z charakterystycznych cech gitary jest możliwość zagrania dźwięku o tej samej wysokości w wielu różnych pozycjach na gryfie (tj. na różnych kombinacjach struny i progu) [Wiggins2019TabCNN]. O ile dla tradycyjnej notacji nutowej ta wieloznaczność nie jest problemem, o tyle dla generowania tabulatury, która musi precyzyjnie wskazać miejsce zagrania dźwięku, jest to fundamentalne wyzwanie. Wybór odpowiedniej pozycji często zależy od kontekstu muzycznego, grywalności (łatwości wykonania) i preferencji wykonawcy.

Pomimo znaczących postępów, jakie dokonały się w dziedzinie ATM w ostatnich latach, zwłaszcza dzięki zastosowaniu zaawansowanych technik uczenia maszynowego, istniejące systemy wciąż borykają się z ograniczeniami, prowadzącymi do typowych błędów, takich jak pomyłki oktawowo, niepoprawne detekcje nut czy niedokładności czasowe [Benetos2019AutomaticMusicTranscription]. Człowiek, dokonując transkrypcji, opiera się nie tylko na percepcji sygnału akustycznego, ale również na swojej rozległej wiedzy muzycznej, znajomości teorii muzyki, konwencji stylistycznych oraz kontekstu kulturowego. Maszyny, mimo coraz doskonalszych algorytmów, wciąż mają trudności z pełnym uwzględnieniem tych aspektów [Holzapfel2019Ethnomusicology]. Ograniczenia te są szczególnie widoczne w przypadku transkrypcji muzyki polifonicznej, wykonywanej na instrumentach o złożonej charakterystyce akustycznej, takich jak gitara [BurletHindle2017IsolatedGuitarTranscription]. Niedoskonałość obecnych systemów, zwłaszcza w kontekście precyzyjnego odwzorowania niuansów wykonawczych gitary i generowania użytecznych, grywalnych tabulatur, stanowi silny impuls do poszukiwania nowych, bardziej efektywnych rozwiązań. Ta luka badawcza jest główną motywacją do podjęcia tematu niniejszej pracy. Popularność gitary oraz ogromna ilość dostępnych nagrań gitarowych, często pozbawionych wiarygodnych transkrypcji, tworzą naturalne zapotrzebowanie na narzędzia MIR, w tym ATM. Postępy w tej dziedzinie mogą z kolei stymulować dalsze tworzenie i udostępnianie muzyki, tworząc pozytywną pętlę sprzężenia zwrotnego. Co więcej, rozwój precyzyjnych systemów ATM dla gitary może odegrać

istotną rolę w dokumentacji i archiwizacji unikalnych stylów gitarowych oraz technik wykonawczych, stanowiących ważne elementy dziedzictwa kulturowego. Otwartym problemem pozostaje również ocena jakości transkrypcji, zwłaszcza w kontekście tabulatur, co zostało zasygnalizowane w literaturze [Zang2023SynthTab].

1.2 Cel pracy

Głównym celem niniejszej pracy magisterskiej jest zaprojektowanie, implementacja oraz weryfikacja eksperymentalna systemu służącego do automatycznej transkrypcji polifonicznych nagrań audio gitary na zapis tabulaturowy. Kluczowym elementem realizacji tego celu jest wykorzystanie publicznie dostępnego zbioru danych Guitarset. Zbiór ten, opisany i wykorzystany w badaniach nad transkrypcją gitarową (np. [Wiggins2019TabCNN]), został specjalnie przygotowany do tego celu i charakteryzuje się unikalnymi cechami, takimi jak dostarczanie nagrań heksafonicznych (sygnału z każdej struny osobno) wraz z precyzyjnymi adnotacjami dotyczącymi wysokości dźwięku, czasu jego trwania oraz, co szczególnie istotne, informacji o strunie i progu, na którym dany dźwięk został nagrany [Wiggins2019TabCNN]. Wybór zbioru Guitarset jest zatem nieprzypadkowy; jego struktura bezpośrednio adresuje problem niejednoznaczności przypisania dźwięku do konkretnej pozycji na gryfie, co jest fundamentalne przy tworzeniu wiarygodnych danych uczących i testowych dla zadania generowania tabulatury. System opracowany w ramach tej pracy ma dążyć do precyzyjnego odwzorowania partii gitarowych w formie tabulatury. Oznacza to nie tylko poprawną identyfikację atrybutów muzycznych takich jak wysokość i czas trwania dźwięków, ale przede wszystkim ich prawidłowe przypisanie do odpowiednich strun i progów na gryfie gitary. Dążenie do precyzji obejmuje również próbę radzenia sobie z wyzwaniami specyficznymi dla transkrypcji gitary, które zostały omówione w poprzednim podrozdziale, takimi jak wysoki stopień polifonii, zróżnicowane techniki artykulacyjne oraz konieczność generowania tabulatury uwzględniającej aspekty grywalności. Realizacja tak zdefiniowanego celu pracy, czyli stworzenie efektywnego systemu transkrypcji nagrań gitarowych do postaci tabulatury, może przyczynić się do powstania nowych narzędzi wspierających kreatywność i edukację gitarzystów. Przykładowo, taki system mógłby służyć do automatycznego generowania tabulatur z improwizowanych fragmentów muzycznych, ułatwiać analizę złożonych partii gitarowych znanych wykonawców, czy też stanowić cenne wsparcie w procesie nauki gry na instrumencie.

1.3 Zakres pracy

Realizacja postawionego celu badawczego obejmuje następujące, kluczowe etapy:

- Przeprowadzenie szczegółowej analizy literatury naukowej dotyczącej automatycznej

transkrypcji muzycznej, ze szczególnym naciskiem na metody stosowane w transkrypcji muzyki gitarowej, specyfikę sygnału generowanego przez ten instrument oraz różne aspekty notacji tabulaturowej, w tym jej strukturę i konwencje zapisu.

- Zaprojektowanie architektury systemu do automatycznej transkrypcji, która będzie uwzględniać specyfikę zadania, charakterystykę danych wejściowych (polifoniczne nagrania gitary akustycznej) i wyjściowych (zapis tabulaturowy) oraz dostępne narzędzia i technologie, w tym potencjalne wykorzystanie modeli głębokiego uczenia.
- Implementacja kluczowych modułów składowych systemu, obejmujących co najmniej:
 - Moduł przetwarzania wstępnego sygnału audio (*audio preprocessing*), mający na celu przygotowanie sygnału do dalszej analizy, np. poprzez normalizację, segmentację czy redukcję szumów.
 - Moduł ekstrakcji cech akustycznych (*acoustic feature extraction*), odpowiedzialny za przekształcenie przetworzonego sygnału audio w reprezentację numeryczną, która efektywnie koduje informacje istotne dla rozpoznawania dźwięków gitarowych i ich atrybutów. Rozważone zostaną zarówno klasyczne cechy akustyczne [KlapuriDavy2006SignalProcessing], jak i cechy uzyskiwane automatycznie z wykorzystaniem metod głębokiego uczenia [BurletHindle2017IsolatedGuitarT
 - Moduł predykcyjny, oparty na wybranych technikach uczenia maszynowego, którego zadaniem będzie generowanie sekwencji zdarzeń tabulaturowych (struna, próg, czas rozpoczęcia, czas trwania) na podstawie wyekstrahowanych cech akustycznych.
- Adaptacja i wykorzystanie publicznie dostępnego zbioru danych Guitarset, opisanego m.in. w [Wiggins2019TabCNN], do procesu trenowania, walidacji oraz testowania opracowanego systemu. Etap ten będzie obejmował przygotowanie danych do formatu wymaganego przez zaimplementowany model, w tym potencjalne techniki augmentacji danych w celu zwiększenia robustości modelu.
- Zdefiniowanie i dobór odpowiednich metryk oceny jakości transkrypcji tabulaturowej. Metryki te muszą uwzględniać nie tylko poprawność wykrytych nut pod względem ich wysokości, czasu rozpoczęcia i czasu trwania, ale także, co kluczowe dla tego zadania, poprawność przypisania poszczególnych dźwięków do konkretnych strun i progów gitary.
- Przeprowadzenie kompleksowych badań eksperymentalnych mających na celu weryfikację skuteczności i wydajności zaproponowanego rozwiązania. Wyniki uzyskane przez system będą porównywane z adnotacjami referencyjnymi ze zbioru Guitarset oraz, w miarę możliwości, z wynikami innych istniejących metod lub systemów transkrypcji

gitarowej, aby ocenić postęp względem aktualnego stanu wiedzy (*state-of-the-art*) [Benetos2019AutomaticMusicTranscription].

- Dokładna analiza uzyskanych wyników eksperymentalnych, obejmująca zarówno ocenę ilościową (na podstawie zdefiniowanych metryk), jak i jakościową (np. poprzez analizę typowych błędów popełnianych przez system). Na tej podstawie zostaną zidentyfikowane mocne i słabe strony opracowanego systemu oraz sformułowane wnioski końcowe i rekomendacje dotyczące potencjalnych ulepszeń oraz dalszych kierunków badań w tej dziedzinie.

Niniejsza praca będzie koncentrować się na rozwiązaniu konkretnego problemu o charakterze naukowo-badawczym. Osiągnięcie tego celu nastąpi poprzez opracowanie innowacyjnego rozwiązania technicznego, jakim jest system do automatycznej transkrypcji gitarowej na tabulaturę, oraz udokumentowanie kompetencji inżynierskich autora w zakresie projektowania, implementacji i weryfikacji systemów opartych na przetwarzaniu sygnałów i uczeniu maszynowym. Przedstawiony zakres pracy odzwierciedla standardowy cykl życia projektu badawczo-rozwojowego w dziedzinie uczenia maszynowego, co zapewnia metodyczne i kompleksowe podejście do postawionego problemu. Szczególny nacisk położony na adaptację zbioru Guitarset oraz zdefiniowanie specyficznych metryk oceny jakości transkrypcji tabulaturowej wskazuje na potencjalny wkład pracy nie tylko w sam system, ale również w metodykę badań nad transkrypcją gitarową.

1.4 Zwięzła charakterystyka rozdziałów

Struktura niniejszej pracy magisterskiej została zaprojektowana w sposób umożliwiający logiczne i spójne przedstawienie podjętej problematyki, przeprowadzonych badań oraz uzyskanych wyników. Poniżej przedstawiono zwięzłą charakterystykę poszczególnych rozdziałów:

Rozdział 1 (Wstęp) Prezentowany rozdział. Wprowadza on w problematykę pracy, definiuje automatyczną transkrypcję muzyczną (ATM) i jej specyfikę w kontekście gitary i tabulatury. Osadza problem w dziedzinie naukowej *Music Information Retrieval (MIR)*, omawia wyzwania związane z transkrypcją gitarową. Formułuje cel i zakres pracy, przedstawia strukturę kolejnych rozdziałów oraz jednoznacznie określa wkład autora.

Rozdział 2 (Analiza Tematu) Rozdział ten poświęcony będzie dogłębnemu przedstawieniu podstaw teoretycznych niezbędnych do zrozumienia problematyki pracy. Omówione zostaną fundamentalne pojęcia dotyczące dźwięku muzycznego, jego cyfrowej reprezentacji [KlapuriDavy2006SignalProcessing] oraz podstawowych metod jego analizy. Następnie, zaprezentowane zostaną ogólne zagadnienia związane

z automatyczną transkrypcją muzyczną, po czym szczegółowa uwaga zostanie skupiona na specyfice transkrypcji gitarowej. Dokładnie scharakteryzowany zostanie sygnał gitary, jego cechy akustyczne oraz notacja tabulaturowa. Rozdział ten płynnie przejdzie do sprecyzowania problematyki badawczej podejmowanej w niniejszej pracy.

Rozdział 3 (Przedmiot Pracy) W tym rozdziale opisane zostanie autorskie rozwiązanie problemu automatycznej transkrypcji polifonicznych nagrań gitarowych na zapis tabulaturowy. Zaprezentowana zostanie szczegółowa architektura zaimplementowanego systemu, wraz z opisem poszczególnych jego modułów. Dokładnie scharakteryzowany zostanie wykorzystany zbiór danych Guitarset, którego cechy i zastosowanie w badaniach opisano m.in. w [Wiggins2019TabCNN], oraz proces jego adaptacji na potrzeby systemu. Uzasadniony zostanie również wybór zastosowanych metod przetwarzania sygnału, ekstrakcji cech, algorytmów uczenia maszynowego oraz wykorzystanych narzędzi programistycznych.

Rozdział 4 (Badania) Ten rozdział będzie poświęcony prezentacji metodyki oraz wyników przeprowadzonych badań eksperymentalnych. Opisane zostanie środowisko badawcze, sposób przygotowania danych testowych oraz zdefiniowane metryki oceny jakości transkrypcji. Uzyskane wyniki zostaną zaprezentowane w sposób ilościowy (np. w postaci tabel i wykresów) oraz jakościowy. Następnie wyniki te zostaną poddane szczegółowej analizie i dyskusji, w tym identyfikacji typowych błędów popełnianych przez system oraz porównaniu z istniejącymi rozwiązaniami lub stanem wiedzy.

Rozdział 5 (Podsumowanie) Ostatni rozdział pracy będzie zawierał syntetyczne podsumowanie wszystkich zrealizowanych prac. Zaprezentowane zostaną kluczowe wnioski końcowe wynikające z przeprowadzonych badań i analiz. Oceniony zostanie stopień realizacji postawionego celu pracy. Wskazane zostaną również potencjalne kierunki dalszego rozwoju opracowanego systemu oraz możliwe przyszłe badania w tej dziedzinie, być może w nawiązaniu do otwartych problemów i wyzwań identyfikowanych w literaturze.

Przedstawiona struktura pracy jest zgodna ze standardami pisania prac naukowo-badawczych w dziedzinach technicznych, co zapewnia jej spójność i kompletność. Wyraźne oddzielenie rozdziału poświęconego analizie tematu od rozdziału opisującego przedmiot pracy pozwala na klarowne rozróżnienie między przeglądem istniejącej wiedzy a oryginalnym wkładem autora, co jest kluczowe dla rzetelnej oceny pracy magisterskiej.

1.5 Jednoznaczne określenie wkładu autora

W tej części precyzyjnie określony zostaje indywidualny wkład autora w realizację niniejszej pracy. Obejmuje on następujące kluczowe aspekty, za które autor był samodzielnie

odpowiedzialny:

- Samodzielne przeprowadzenie gruntownych studiów literaturowych oraz krytyczną analizę aktualnego stanu wiedzy i badań w dziedzinie automatycznej transkrypcji muzycznej, ze szczególnym uwzględnieniem problematyki transkrypcji muzyki gitarowej oraz specyfiki zapisu tabulaturowego.
- Opracowanie oryginalnej koncepcji oraz zaprojektowanie architektury systemu przeznaczonego do automatycznej transkrypcji polifonicznych nagrań gitarowych na postać tabulatury, uwzględniającej specyficzne wyzwania związane z tym zadaniem.
- Implementacja algorytmów przetwarzania sygnału audio, metod ekstrakcji cech akustycznych oraz modeli uczenia maszynowego, które stanowią rdzeń funkcjonalny opracowanego systemu transkrypcji.
- Adaptacja, przygotowanie oraz analiza publicznie dostępnego zbioru danych Guitarset na potrzeby procesu trenowania, walidacji i kompleksowej ewaluacji zaprojektowanego i zaimplementowanego systemu.
- Zaprojektowanie metodyki oraz samodzielne przeprowadzenie kompleksowych badań eksperymentalnych, mających na celu weryfikację skuteczności, wydajności oraz ograniczeń opracowanego rozwiązania w kontekście transkrypcji gitarowej na tabulaturę.
- Krytyczna analiza i interpretacja uzyskanych wyników eksperymentalnych, w tym identyfikacja mocnych i słabych stron systemu, oraz ocena istotności tych wyników w kontekście istniejących rozwiązań i aktualnego stanu wiedzy w dziedzinie.
- Sformułowanie wniosków końcowych podsumowujących całość przeprowadzonych prac badawczych i implementacyjnych, a także przedstawienie propozycji dotyczących potencjalnych ulepszeń systemu oraz możliwych kierunków dalszych badań.

Powyższe wyszczególnienie ma na celu jednoznaczne wyodrębnienie oryginalnego wkładu studenta w identyfikację i rozwiązanie postawionego problemu badawczego, a także w opracowanie, implementację i weryfikację opisanego systemu informatycznego. Wymienione punkty pokrywają cały proces badawczy, od fazy koncepcyjnej, poprzez realizację techniczną, aż po analizę wyników i formułowanie wniosków, co świadczy o kompleksowym i samodzielnym charakterze pracy, zgodnie z oczekiwaniami stawianymi pracom magisterskim. Nacisk na „oryginalną koncepcję” oraz „krytyczną analizę” podkreśla aspiracje pracy do wniesienia wartościowego wkładu w rozwój dziedziny, wykraczającego poza jedynie odtwórcze zastosowanie znanych metod.

Rozdział 2

Analiza Tematu: Teoretyczne Podstawy Transkrypcji Muzycznej i Specyfika Transkrypcji Gitarowej

Niniejszy rozdział stanowi dogłębną analizę problematyki automatycznej transkrypcji muzycznej (ATM), ze szczególnym uwzględnieniem jej zastosowania do muzyki gitarowej i generowania zapisu tabulaturowego. Celem jest osadzenie tematyki pracy w szerszym kontekście naukowym oraz identyfikacja kluczowych wyzwań związanych z tym zagadnieniem. Przedstawione zostaną podstawy teoretyczne, omówione główne podejścia i technologie stosowane w ATM, a także zidentyfikowane zostaną obszary wymagające dalszych badań w dziedzinie transkrypcji gitarowej, co pozwoli na pełniejsze zrozumienie złożoności podejmowanego problemu. Należy przy tym zaznaczyć, że choć celem jest identyfikacja obszarów wymagających dalszych badań, niniejszy rozdział skupia się na przeglądzie istniejącego stanu wiedzy.

2.1 Definicja Problemu Automatycznej Transkrypcji Muzycznej (ATM) i Jego Znaczenie

Automatyczna transkrypcja muzyczna jest fundamentalnym zagadnieniem w dziedzinie komputerowej analizy muzyki, którego zrozumienie wymaga precyzyjnego zdefiniowania problemu oraz określenia jego wagi w kontekście naukowym i praktycznym. Poniższe podrozdziały szczegółowo omawiają te aspekty.

2.1.1 Sformułowanie problemu

Automatyczna transkrypcja muzyczna (ATM) (*Automatic Music Transcription*) jest procesem przekształcania sygnału audio zawierającego muzykę na symboliczną repre-

zentację muzyczną, najczęściej w postaci zapisu nutowego, jego odpowiednika (np. w formie piano-roll) lub bezpośrednio w formacie specyficznym dla danego instrumentu [KlapuriDavy2006SignalProcessing, Benetos2019AutomaticMusicTranscription]. W kontekście muzyki gitarowej, problem ten precyzuje się jako automatyczną transkrypcję polifonicznych nagrań gitarowych na zapis tabulaturowy (*Guitar Tablature Transcription, GTT*). Zadanie to wykracza poza prostą identyfikację wysokości i czasu trwania dźwięków; obejmuje również ich precyzyjne przypisanie do konkretnych strun i progów na gryfie gitary [Wiggins2019TabCNN]. Pełna transkrypcja tabulaturowa dąży także do rozpoznania technik artykulacyjnych charakterystycznych dla gitary, takich jak podciągnięcia strun (*bends*), *hammer-on*, *pull-off* czy *vibrato* [Reboursiere2011GuitarController]. Techniki te są kluczowe dla wiernego odtworzenia utworu i mają istotny wpływ na jego brzmienie oraz interpretację.

2.1.2 Znaczenie badań nad ATM dla gitary

Badania nad automatyczną transkrypcją muzyki gitarowej posiadają wielowymiarowe znaczenie. Przede wszystkim, dostarczają narzędzi wspierających muzyków i proces edukacji muzycznej, ułatwiając dostęp do notacji, umożliwiając efektywniejszą naukę gry oraz pogłębioną analizę utworów [Benetos2019AutomaticMusicTranscription, ArndtLi2012AutomatedTranscription]. Mają również istotne zastosowanie w archiwizacji i dokumentacji dziedzictwa muzycznego, pozwalając na zachowanie unikalnych stylów wykonawczych i technik gitarowych, które mogłyby inaczej ulec zapomnieniu [Holzapfel2019Ethnomusicology]. Należy jednak zauważyć, że pomimo potencjału, obecne systemy ATM mogą nie zawsze oferować przewagę ilościową dla doświadczonych transkrybentów w specyficznych kontekstach, np. etnomuzykologicznych, gdzie krytyczna jest dokładność rytmiczna i precyzja notacji [Holzapfel2019Ethnomusicology]. Systemy ATM mogą ponadto stanowić wartościowe wsparcie dla kompozytorów i producentów muzycznych, oferując nowe możliwości w procesie twórczym i produkcyjnym [Benetos2019AutomaticMusicTranscription, ArndtLi2012AutomatedTranscription]. Nie bez znaczenia jest fakt, że rozwój GTT odpowiada na realne zapotrzebowanie rynku, wynikające z globalnej popularności gitary jako instrumentu oraz tabulatury jako preferowanej przez wielu gitarzystów formy zapisu muzycznego [Wiggins2019TabCNN].

2.1.3 Kontekst naukowy i interdyscyplinarny charakter ATM

Automatyczna transkrypcja muzyczna jest integralną częścią szerszej dziedziny badawczej znanej jako *Music Information Retrieval (MIR)* [Benetos2019AutomaticMusicTranscription], która zajmuje się pozyskiwaniem, analizą i zarządzaniem informacją muzyczną. ATM jest jednym z najbardziej złożonych zadań w MIR, wymagającym synergii wiedzy i metod z wielu dyscyplin. Fundamentalne znaczenie ma tu cyfrowe przetwarzanie sygnałów (CPS),

dostarczające narzędzi do analizy sygnału audio [KlapuriDavy2006SignalProcessing]. Równie istotne są uczenie maszynowe (UM) i szeroko pojęta sztuczna inteligencja (SI), które umożliwiają tworzenie modeli zdolnych do nauki złożonych wzorców muzycznych i podejmowania decyzji transkrypcyjnych na podstawie danych [Benetos2019AutomaticMusicTranscription, Jamshidi2024SurveyAMT, BurletHindle2017IsolatedGuitarTranscription]. Wiedza z zakresu muzykologii, dotycząca teorii muzyki, notacji i praktyk wykonawczych, jest niezbędna do projektowania systemów generujących transkrypcje poprawne i użyteczne muzycznie, a także do krytycznej oceny ich wyników [Holzapfel2019Ethnomusicology].

2.2 Podstawy Teoretyczne: Dźwięk Muzyczny i Jego Cyfrowa Reprezentacja

Zrozumienie procesów leżących u podstaw automatycznej transkrypcji muzycznej wymaga uprzedniego zapoznania się z fundamentalnymi właściwościami dźwięku muzycznego oraz sposobami jego cyfrowej reprezentacji i analizy. Niniejsza sekcja przybliży te kluczowe koncepcje.


2.2.1 Percepcyjne i fizyczne atrybuty dźwięku muzycznego

Dźwięk muzyczny, z perspektywy percepcji, charakteryzowany jest przez cztery podstawowe atrybuty: wysokość, głośność, barwę i czas trwania [KlapuriDavy2006SignalProcessing]. Wysokość jest bezpośrednio związana z częstotliwością podstawową (F_0) drgań źródła dźwięku. Głośność to subiektywna ocena natężenia dźwięku. Barwa, określana jako „kolor” dźwięku, pozwala odróżnić dźwięki o tej samej wysokości i głośności, lecz pochodzące z różnych instrumentów lub generowane różnymi technikami; jest ona ściśle powiązana ze spektrum harmonicznym dźwięku (rozkładem i względnymi amplitudami składowych harmonicznym) oraz jego obwiednią czasową. Czas trwania definiuje, jak długo dźwięk jest postrzegany. Obwiednia amplitudy dźwięku, często modelowana jako ADSR (*Attack, Decay, Sustain, Release*), odgrywa kluczową rolę w kształtowaniu charakteru brzmieniowego, zwłaszcza dla instrumentów szarpanych, takich jak gitara [KlapuriDavy2006SignalProcessing]. Fazy ataku (narastania), początkowego zaniku, podtrzymania i końcowego wybrzmiewania definiują dynamiczny profil dźwięku, przy czym dla gitary fazy zaniku i wybrzmiewania są szczególnie złożone i zależne od instrumentu oraz techniki gry.

2.2.2 Reprezentacja sygnału audio w dziedzinie czasu i częstotliwości

Cyfrowy sygnał audio jest sekwencją próbek reprezentujących amplitudę fali akustycznej w kolejnych, dyskretnych punktach czasu [KlapuriDavy2006SignalProcessing].

Analiza wyłącznie w dziedzinie czasu nie ujawnia jednak w pełni struktury muzycznej sygnału. Kluczowa jest analiza częstotliwościowa, pozwalająca zidentyfikować składowe częstotliwościowe. Przejście z dziedziny czasu do dziedziny częstotliwości realizowane jest za pomocą transformaty Fouriera, która dekomponuje sygnał na sumę składowych sinusoidalnych o różnych częstotliwościach i amplitudach, tworząc jego widmo częstotliwościowe [KlapuriDavy2006SignalProcessing]. Dyskretna transformata Fouriera (DFT), zdefiniowana wzorem (1.1) w Rozdziale 1, jest podstawowym narzędziem tej analizy.



Rysunek 2.1: Po lewej: fragment sygnału audio pojedynczego dźwięku gitary w dziedzinie czasu. Po prawej: odpowiadające mu widmo amplitudowe uzyskane za pomocą transformaty Fouriera, ukazujące częstotliwość podstawową (F_0) oraz jej kolejne alikwoty (składowe harmoniczne).


2.2.3 Analiza czasowo-częstotliwościowa i jej znaczenie dla ATM

Charakterystyki częstotliwościowe muzyki zmieniają się w czasie, dlatego w ATM niezbędne są metody analizy czasowo-częstotliwościowej. Krótkoczasowa transformata Fouriera (STFT) jest jedną z fundamentalnych technik, polegającą na analizie Fouriera krótkich, nakładających się segmentów sygnału [KlapuriDavy2006SignalProcessing, BurletHindle2017IsolatedGuitarTranscription]. Wynikiem STFT jest spektrogram – dwuwymiarowa reprezentacja energii sygnału w funkcji czasu i częstotliwości, która stanowi podstawę dla wielu systemów ATM. Należy pamiętać o inherentnym kompromisie STFT między rozdzielczością czasową a częstotliwościową.

Alternatywą, często lepiej dostosowaną do percepcji muzyki, jest transformata *Constant-Q* (*CQT*) [Benetos2019AutomaticMusicTranscription, Wiggins2019TabCNN, Zang2023Synt]. CQT wykorzystuje pasma częstotliwości o szerokościach proporcjonalnych do ich częstotliwości środkowych, co odpowiada logarytmicznej naturze ludzkiej percepcji wysokości dźwięku i organizacji skal muzycznych.

Skala Mel, również oparta na badaniach percepcyjnych, jest kolejną nieliniową skalą czę-

stotliwości powszechnie stosowaną w MIR [Benetos2019AutomaticMusicTranscription]. Mel-spektrogramy, czyli spektrogramy z osią częstotliwości przekształconą na skalę Mel, są standardowym wejściem dla wielu modeli głębokiego uczenia w ATM, gdyż lepiej odzwierciedlają ludzką wrażliwość na zmiany wysokości dźwięku. Ewolucja od STFT, poprzez CQT, do Mel-spektrogramów odzwierciedla dążenie do tworzenia reprezentacji cech bardziej zgodnych z ludzką percepcją i efektywniejszych dla algorytmów uczenia maszynowego.



Rysunek 2.2: Wizualizacja różnych reprezentacji czasowo-częstotliwościowych dla tego samego polifonicznego fragmentu gitarowego: (a) Spektrogram STFT z liniową skalą częstotliwości, (b) Spektrogram Constant-Q (CQT) z logarytmiczną skalą częstotliwości, (c) Mel-spektrogram z osią częstotliwości w skali Mel.

2.3 Rdzeń Automatycznej Transkrypcji Muzycznej: Zadania, Poziomy i Wyzwania


Automatyczna transkrypcja muzyczna, mimo swej pozornie prostej definicji, jest procesem wieloetapowym, obejmującym szereg skomplikowanych zadań cząstkowych. Zrozumienie tych zadań, poziomów abstrakcji na jakich operują oraz inherentnych wyzwań jest kluczowe dla oceny istniejących rozwiązań i projektowania nowych.

2.3.1 Definicja, zadania składowe i poziomy abstrakcji w ATM

Formalnie, ATM można zdefiniować jako proces estymacji parametrów nut, takich jak czas rozpoczęcia, wysokość i czas trwania, bezpośrednio z sygnału audio [KlapuriDavy2006SignalProcessing, Benetos2019AutomaticMusicTranscription]. Jest to zadanie hierarchiczne, które można zdekomponować na kilka kluczowych zadań składowych. Do najważniejszych należą: estymacja wielokrotnej wysokości dźwięku (*Multiple Pitch Estimation, MPE*), czyli identyfikacja wszystkich częstotliwości podstawowych obecnych w danym momencie; detekcja początku i końca dźwięku (*Onset/Offset Detection*), czyli precyzyjne lokalizowanie w czasie momentów rozpoczęcia i zakończenia poszczególnych zdarzeń muzycznych; oraz, w bardziej zaawansowanych systemach, rozpoznawanie instrumentów, analiza rytmu i metrum, czy interpretacja ekspresji wykonawczej [Benetos2019AutomaticMusicTranscription, Hawthorne2018Onsets]. Wyniki transkrypcji mogą być prezentowane na różnych poziomach abstrakcji: od predykcji na poziomie krótkich ramek czasowych (np. wskazanie aktywnych wysokości dźwięku w oknie kilkudziesięciu milisekund), przez symboliczną reprezentację nutową (zestaw nut z określonymi atrybutami), aż po bardziej złożone struktury, takie jak strumienie melodyczne czy pełna partytura muzyczna uwzględniająca elementy notacji standardowej [Benetos2019AutomaticMusicTranscription].

2.3.2 Transkrypcja monofoniczna vs. polifoniczna – złożoność i główne wyzwania

Złożoność zadania ATM znacząco wzrasta przy przejściu od transkrypcji monofonicznej (pojedyncza linia melodyczna) do polifonicznej (wiele współbrzmiących dźwięków) [KlapuriDavy2006SignalProcessing, Benetos2019AutomaticMusicTranscription]. Muzyka gitarowa, ze względu na możliwość gry akordowej i prowadzenia wielu niezależnych linii melodycznych, jest w przeważającej mierze polifoniczna, co czyni jej transkrypcję szczególnie trudną [BurletHindle2017IsolatedGuitarTranscription]. Główne wyzwania w AMT, które ulegają intensyfikacji w kontekście polifonii, to przede wszystkim: interferencja harmoniczných składowych różnych dźwięków (szczególnie w interwałach konsonansowych), maskowanie cichszych dźwięków przez głośniejsze, trudności w precyzyj-



Rysunek 2.3: Uproszczony schemat potoku przetwarzania w systemie ATM: od sygnału audio, poprzez ekstrakcję cech, zadania składowe (MPE, detekcja onsetów/offsetów, estymacja instrumentu), aż po generowanie wyjściowej reprezentacji symbolicznej na różnych poziomach abstrakcji (ramki, nuty, partytura).

nej detekcji czasów rozpoczęcia i zakończenia dźwięków w gęstych fakturach, zmienność barwy dźwięku zależna od artykulacji i dynamiki, oraz częste błędy w estymacji wysokości, takie jak pomyłki oktawowo [Benetos2019AutomaticMusicTranscription]. Dodatkowo, efektywne trenowanie modeli uczenia maszynowego wymaga dostępu do dużych, dokładnie zaanotowanych zbiorów danych, których tworzenie jest procesem czasochłonnym i kosztownym.

2.4 Przegląd Metod Stosowanych w Automatycznej Transkrypcji Muzycznej

Rozwój metod automatycznej transkrypcji muzycznej jest procesem ciągłym, odzwierciedlającym postęp w dziedzinach przetwarzania sygnałów i uczenia maszynowego. Poniżej przedstawiono ewolucję tych podejść, od metod klasycznych po najnowsze techniki oparte na głębokim uczeniu.

2.4.1 Tradycyjne metody oparte na przetwarzaniu sygnałów

Historycznie pierwsze podejścia do automatycznej transkrypcji muzycznej opierały się w dużej mierze na technikach cyfrowego przetwarzania sygnałów [KlapuriDavy2006SignalProcessing]. W przypadku transkrypcji muzyki monofonicznej, gdzie w danym momencie występuje tylko jeden dźwięk, opracowano szereg metod detekcji jego częstotliwości podstawowej (F_0). Do klasycznych algorytmów należą te bazujące na analizie funkcji autokorelacji

sygnału (ACF), uśrednionej funkcji różnicowej amplitudy (AMDF), technice *Harmonic Product Spectrum (HPS)*, która wzmacnia częstotliwość podstawową poprzez mnożenie widma z jego skompresowanymi wersjami, oraz na analizie cepstralnej, pozwalającej na separację składowej związanej z pobudzeniem od składowej związanej z traktem wokalnym lub rezonansem instrumentu [KlapuriDavy2006SignalProcessing]. Rozwijano również systemy bazujące na modelach harmonicznym dźwięku oraz systemy ekspertowe, wykorzystujące predefiniowane reguły i wiedzę muzykologiczną. Metody te, choć wносиły istotny wkład w rozwój dziedziny, wykazywały znaczne ograniczenia w kontekście analizy złożonej muzyki polifonicznej, gdzie jednoczesne występowanie wielu dźwięków i ich alikwotów znacząco komplikuje sygnał, prowadząc m.in. do niemożności separacji nakładających się szeregów harmonicznym. Ograniczenia te stały się motywacją do poszukiwania bardziej zaawansowanych rozwiązań w ramach uczenia maszynowego.

2.4.2 Metody oparte na uczeniu maszynowym

Przełom w skuteczności systemów ATM przyniosło zastosowanie metod uczenia maszynowego, które pozwoliły na tworzenie modeli zdolnych do nauki złożonych zależności bezpośrednio z danych [Jamshidi2024SurveyAMT, BurletHindle2017IsolatedGuitarTranscription]. W ramach tego paradygmatu można wyróżnić kilka głównych kierunków.

Nienadzorowane metody faktoryzacji macierzy

Wśród metod nienadzorowanych, popularność zdobyła nieujemna faktoryzacja macierzy (*Non-negative Matrix Factorization, NMF*) [Benetos2019AutomaticMusicTranscription]. Technika ta polega na dekompozycji macierzy wejściowej (np. macierzy spektrogramu amplitudowego) na iloczyn dwóch macierzy o niższych wymiarach, których elementy są nieujemne. W kontekście ATM, macierze te mogą być interpretowane jako zbiór bazowych szablonów spektralnych (odpowiadających np. poszczególnym wysokościom dźwięków lub barwom instrumentów) oraz macierz kodująca aktywacje tych szablonów w czasie. Zaletą NMF jest zdolność do automatycznego odkrywania struktur w danych bez potrzeby etykietowania. Istotnym wyzwaniem jest jednak dobór odpowiedniej rangi faktoryzacji (liczby komponentów) oraz fakt, że NMF może mieć trudności z separacją źródeł o silnie nakładających się charakterystykach spektralnych. W celu rozwiązania tych problemów opracowano liczne rozszerzenia NMF, takie jak nadzorowane NMF (gdzie słownik jest predefiniowany) czy harmoniczne NMF (narzucające harmoniczną strukturę na szablony) [Benetos2019AutomaticMusicTranscription].

Modele probabilistyczne i Bayesowskie

Ukryte modele Markowa (*Hidden Markov Models, HMM*) były przez wiele lat intensywnie badane i stosowane w ATM, głównie ze względu na ich naturalną zdolność do

modelowania sekwencyjnego charakteru muzyki [KlapuriDavy2006SignalProcessing, Cazau2017HMM, Raphael2002PianoTranscription]. W typowym podejściu, ukryte stany HMM mogą odpowiadać poszczególnym nutom lub stanom ciszy, a obserwacje emitowane przez te stany to wektory cech akustycznych wyekstrahowanych z kolejnych ramek sygnału audio. Prace Raphaella (2002) [Raphael2002PianoTranscription] stanowią wczesny przykład zastosowania HMM do transkrypcji muzyki fortepianowej, gdzie modelowano proces generowania nut z uwzględnieniem prawdopodobieństw przejść między nimi. Cazau i Nuel (2017) [Cazau2017HMM] eksplorowali różne warianty HMM, w tym ich integrację z metodami dekompozycji spektralnej jak PLCA (*Probabilistic Latent Component Analysis*), w celu poprawy jakości transkrypcji, np. poprzez modelowanie trwania nut lub wykorzystanie wiedzy o tonalności do modelowania przejść harmonicznych. Podejścia Bayesowskie, stanowiące szerszą klasę modeli, pozwalają na formalne włączenie do modelu wcześniejszej wiedzy (np. reguł harmonii, typowych progresji akordów) w postaci rozkładów a priori. Mimo pewnych sukcesów, modele te często wymagają starannej inżynierii cech i mogą mieć trudności z modelowaniem bardzo złożonych zależności w muzyce polifonicznej.

Głębokie sieci neuronowe (*Deep Learning*)

W ostatnich latach metody oparte na głębokim uczeniu (*Deep Learning, DL*) zdominowały badania nad ATM, osiągając stanowiące aktualny stan wiedzy wyniki w wielu aspektach tego zadania [Benetos2019AutomaticMusicTranscription, Jamshidi2024SurveyAMT]. Zdolność głębokich sieci neuronowych do automatycznego uczenia się hierarchicznych, wielopoziomowych reprezentacji cech bezpośrednio z danych wejściowych (np. surowych spektrogramów) okazała się kluczowa dla postępu. Wśród najczęściej wykorzystywanych architektur znajdują się splotowe sieci neuronowe (CNN), efektywnie przetwarzające dane o strukturze siatki, takie jak spektrogramy [Wiggins2019TabCNN, Zang2023SynthTab]; rekurencyjne sieci neuronowe (RNN), w szczególności warianty LSTM (*Long Short-Term Memory*) i GRU (*Gated Recurrent Unit*), przystosowane do modelowania zależności czasowych w sekwencjach muzycznych [Benetos2019AutomaticMusicTranscription]; oraz architektury hybrydowe, takie jak CRNN, łączące zalety obu tych podejść [Hawthorne2018Onsets]. Najnowsze badania eksplorują również potencjał architektur opartych na mechanizmach uwagi, takich jak Transformer [Jamshidi2024SurveyAMT, Hawthorne2021Seq2SeqTranscription]. Dostępność dużych, publicznych zbiorów danych adnotowanych, takich jak MAESTRO dla muzyki fortepianowej [Hawthorne2018Onsets, Zang2023SynthTab] (zawierający nagrania z konkursów pianistycznych wraz z precyzyjnymi plikami MIDI) oraz GuitarSet dla muzyki gitarowej [Wiggins2019TabCNN, Zang2023SynthTab, Benetos2019AutomaticMusicTr] (oferujący nagrania z sześciu osobnych przetworników heksafonicznych dla każdej struny oraz zsynchronizowane adnotacje MIDI i tabulaturowe), była katalizatorem rozwoju modeli DL. To właśnie te obszerne i dokładnie zaanotowane zbiory danych umożliwiły trenowanie

złożonych modeli DL na skalę niezbędną do osiągnięcia wysokiej dokładności, podkreślając, że postęp w tej dziedzinie jest równie mocno zależny od inżynierii danych, co od innowacji algorytmicznych. Model „Onsets and Frames” [Hawthorne2018Onsets], zaprojektowany do transkrypcji muzyki fortepianowej, jest przykładem systemu DL, który osiągnął wysoką skuteczność. Wykorzystuje on architekturę konwolucyjno-rekurencyjną do jednoczesnej predykcji czasów rozpoczęcia dźwięków (*onsets*) oraz aktywności poszczególnych nut w kolejnych ramkach czasowych. „Basic Pitch” [Bittner2022BasicPitch] to z kolei narzędzie typu audio-to-MIDI, opracowane przez Spotify, które charakteryzuje się lekkością i zdolnością do detekcji zmian wysokości dźwięku (*pitch bends*). Opiera się na modelach sieci neuronowych, a jego priorytetem jest szybkość działania i dostępność, co czyni je użytecznym w wielu praktycznych zastosowaniach, chociaż może nie osiągać takiej samej szczegółowości transkrypcji jak bardziej złożone systemy w przypadku skomplikowanych fragmentów polifonicznych. Mimo imponujących wyników, metody DL nie są pozbawione ograniczeń. Ich skuteczność jest silnie uzależniona od ilości i jakości danych treningowych. Modele te często działają na zasadzie „czarnej skrzynki”, co utrudnia interpretację ich wewnętrznych mechanizmów decyzyjnych. Ponadto, trening i inferencja złożonych modeli DL mogą być wymagające obliczeniowo [Jamshidi2024SurveyAMT].

2.5 Specyfika Transkrypcji Muzyki Gitarowej na Zapis Tabulaturowy (GTT)

Transkrypcja muzyki gitarowej, zwłaszcza z celem wygenerowania zapisu tabulaturowego, wprowadza szereg specyficznych problemów i wymagań, które odróżniają ją od ogólnego zadania ATM. Niniejsza sekcja poświęcona jest analizie tych unikalnych aspektów.

2.5.1 Akustyczna charakterystyka sygnału gitary i jej implikacje dla transkrypcji

Sygnał generowany przez gitarę posiada szereg unikalnych cech akustycznych, które czynią jego automatyczną transkrypcję zadaniem szczególnie złożonym [Wiggins2019TabCNN, BurletHindle2017IsolatedGuitarTranscription]. Obwiednia dźwięku gitary, zwłaszcza akustycznej, charakteryzuje się zazwyczaj bardzo szybkim atakiem i relatywnie długim, stopniowym wybrzmiewaniem, co może utrudniać precyzyjną detekcję czasów zakończenia dźwięków (*offsets*). Barwa dźwięku gitary jest niezwykle zróżnicowana i zależy od wielu czynników, takich jak konstrukcja instrumentu (np. gitara akustyczna z pudłem rezonansowym, gitara elektryczna typu *solid-body*), rodzaj i wiek strun, technika artykulacji (np. gra kostką, palcami, *slap*), a w przypadku gitar elektrycznych – w decydującym stopniu od ustawień wzmacniacza oraz zastosowanych efektów gitarowych (np. *distor-*

tion, overdrive, chorus, flanger, delay, reverb) [Wiggins2019TabCNN]. Ta inherentna zmienność i bogactwo barwowe, choć stanowią o atrakcyjności instrumentu, komplikują proces tworzenia uogólnionych modeli transkrypcyjnych. Kluczowe dla GTT jest również adekwatne uwzględnienie licznych, specyficznych dla gitary technik wykonawczych, które nie tylko znacząco wpływają na charakterystykę akustyczną sygnału, ale także mają swoje bezpośrednie odzwierciedlenie w zapisie tabulaturowym.

Tabela 2.1: Akustyczne Manifestacje Wybranych Technik Gitarowych Istotnych dla Transkrypcji na Tabulaturę

Technika	Opis	Akustyczna Manifestacja (Przykładowa)
<i>Hammer-on</i>	Uderzenie palcem lewej ręki (dla praworęcznych gitarzystów) w strunę na wyższym progu w celu wydobycia dźwięku bez ponownego szarpania struny prawą ręką.	Zazwyczaj łagodniejszy atak spektralny w porównaniu do dźwięku szarpniętego; możliwy spadek amplitudy po wykonaniu techniki, szczególnie na cieńszych strunach [Nasution2023HammerOn]; poprzedzający dźwięk (jeśli był) może wybrzmiewać w tle z niższą amplitudą [Nasution2023HammerOn, Su2014SparseCepstral]. Brak wyraźnego „dołka” w amplitudzie między nutami w sekwencji legato [Reboursiere2011GuitarController].
<i>Pull-off</i>	Oderwanie palca lewej ręki od struny (zazwyczaj z lekkim jej szarpnięciem) w celu wydobycia niższego dźwięku, który już brzmi (np. na pustej strunie lub przytrzymywany innym palcem na niższym progu).	Podobnie jak <i>hammer-on</i> , charakteryzuje się łagodniejszym atakiem w porównaniu do dźwięku szarpniętego; zmiana wysokości następuje na niższą; może towarzyszyć krótki, szerokopasmowy szum związany z mechanicznym ruchem odrywania palca [Su2014SparseCepstral].

Technika	Opis	Akustyczna Manifestacja (Przykładowa)
<i>Slide</i> (ślizg)	Płynne przesunięcie palca lewej ręki wzdłuż struny pomiędzy dwoma progami, podczas gdy struna wibruje.	Ciągła, płynna zmiana częstotliwości podstawowej (F_0) i jej harmonicznym (<i>glissando</i>) między wysokością początkową a końcową [Su2014SparseCepstral, Reboursiere2011GuitarController]; zachowanie energii sygnału i jego ciągłości spektralnej; charakterystyczny profil przejścia między wysokościami, odróżniający od <i>bend</i> [Su2014SparseCepstral].
<i>Bend</i> (podciągnięcie)	Poprzeczne podciągnięcie struny na gryfie palcem lewej ręki, co zwiększa jej napięcie i w rezultacie podwyższa wysokość dźwięku.	Płynna zmiana wysokości dźwięku (F_0) w górę, często z następującym powrotem do oryginalnej wysokości lub przejściem do innej [Su2014SparseCepstral, Reboursiere2011GuitarController]; mogą pojawić się charakterystyczne zmiany w natężeniu alikwotów oraz subtelne zmiany barwy.
<i>Palm-muting</i>	Delikatne tłumienie strun krawędzią dłoni prawej ręki (dla gitarzystów praworęcznych) w pobliżu mostka gitary, bezpośrednio po ich szarpnięciu.	Znaczne skrócenie czasu wybrzmiewania dźwięku (szybszy zanik energii); stłumiony, bardziej perkusyjny i mniej rezonujący charakter; redukcja udziału wyższych harmonicznym w spektrum, co prowadzi do „ciemniejszego”, „cichszego” brzmienia [Su2014SparseCepstral].

Technika	Opis	Akustyczna Manifestacja (Przykładowa)
<i>Vibrato</i>	Cykliczna, subtelna modulacja wysokości dźwięku, uzyskiwana przez oscylacyjny ruch palca przytrzymującego strunę na progu lub za pomocą ramienia tremolo.	Okresowe, stosunkowo wolne (typowo 5-7 Hz) fluktuacje częstotliwości podstawowej (F_0) i jej harmonicznym wokół centralnej wysokości dźwięku [Anand2012Vibrato, HyrkasSmyth2024Vibrato]; może również występować sprzężona z tym modulacja amplitudy [Anand2012Vibrato, HyrkasSmyth2024Vibrato].

Dokładne rozpoznanie tych i innych technik jest kluczowe dla stworzenia kompletnej, wiernej i użytecznej dla muzyka tabulatury.

2.5.2 Porównanie notacji standardowej i tabulaturowej dla gitary

W praktyce muzycznej gitaryści posługują się dwoma głównymi systemami notacji: tradycyjną notacją muzyczną opartą na pięciolinii oraz tabulaturą gitarową. Każdy z tych systemów posiada swoje unikalne cechy, które determinują jego adekwatność w różnych zastosowaniach i dla różnych grup użytkowników [Wiggins2019TabCNN]. Tabela 2.2 przedstawia zwięzłe porównanie obu systemów. Wybór tabulatury jako docelowej formy zapisu w wielu współczesnych systemach GTT jest motywowany jej dużą popularnością, zwłaszcza wśród gitarzystów samouków i w muzyce rozrywkowej, oraz jej bezpośrednim, instruktażowym charakterem, który ułatwia naukę i wykonanie utworu na instrumencie.

2.5.3 Kluczowe wyzwania w automatycznej transkrypcji gitary na tabulaturę (GTT)


Transkrypcja na tabulaturę wprowadza szereg specyficznych wyzwań, które wykraczają poza ogólne problemy AMT:

- **Wysoka polifonia i nakładanie się dźwięków:** Gitara, jako instrument harmoniczny, często generuje złożone współbrzmienia, co intensyfikuje problem separacji i identyfikacji poszczególnych dźwięków w sygnale audio [BurletHindle2017IsolatedGuitarTrans
- **Niejednoznaczność reprezentacji dźwięku na gryfie (*Tablature Inference / Fingering Estimation*):** Jest to jedno z fundamentalnych wyzwań w GTT.

Tabela 2.2: Porównanie Standardowej Notacji Muzycznej i Tabulatury Gitarowej

Cecha	Standardowa Notacja Muzyczna	Tabulatura Gitarowa
Reprezentacja wysokości	Abstrakcyjna, poprzez pozycję nuty na pięciolinii, wymagająca znajomości klucza i zasad teorii muzyki [Wiggins2019TabCNN].	Bezpośrednia, poprzez wskazanie numeru progu na linii reprezentującej konkretną strunę gitary [Wiggins2019TabCNN].
Reprezentacja rytmu	Precyzyjnie zdefiniowana za pomocą wartości rytmicznych nut, pauz i oznaczeń metrycznych [Wiggins2019TabCNN].	Często uproszczona lub nieobecna; główny nacisk kładziony jest na wysokość i sposób opalcowania. Rytm bywa jednak dodawany za pomocą symboli podobnych do notacji standardowej lub poprzez odniesienie do nagrania [Wiggins2019TabCNN].
Czytelność dla gitarzystów	Wymaga dłuższego procesu nauki i praktyki w czytaniu nut na pięciolinii [Wiggins2019TabCNN].	Zazwyczaj bardzo intuicyjna i łatwa do szybkiego opanowania, szczególnie dla początkujących gitarzystów i samouków; bezpośrednio pokazuje, gdzie umieścić palce na gryfie [Wiggins2019TabCNN].
Notacja technik gry	Możliwa za pomocą licznych dodatkowych symboli i oznaczeń słownych, ale czasami może być mniej jednoznaczna lub intuicyjna dla specyficznych technik gitarowych.	Bardzo dobrze przystosowana do notowania szerokiego spektrum specyficznych technik gitarowych (<i>bends, slides, hammer-ons, pull-offs, vibrato</i> itp.) za pomocą dedykowanych symboli graficznych.
Niejednoznaczność opalcowania	Istnieje – ten sam dźwięk (wysokość) może być zagrany na gitarze na kilku różnych strunach i progach; wybór konkretnego opalcowania jest pozostawiony wykonawcy [Wiggins2019TabCNN].	Zazwyczaj jednoznacznie określa zarówno strunę, jak i próg, na którym dany dźwięk ma być zagrany, tym samym eliminując problem wyboru opalcowania dla danej nuty [Wiggins2019TabCNN].

Ten sam dźwięk (o tej samej wysokości muzycznej) może być zagrany w wielu różnych pozycjach na gryfie gitary (tj. na różnych kombinacjach struny i progu) [Wiggins2019TabCNN]. Wybór konkretnej pozycji przez gitarzystę zależy od wielu czynników, takich jak kontekst muzyczny (np. sąsiednie dźwięki), grywalność (łatwość wykonania danego pochodzenia dźwięków), preferencje stylistyczne, a nawet subtelne różnice w barwie dźwięku uzyskiwane na różnych strunach. System GTT musi więc nie tylko poprawnie zidentyfikować wysokość i czas trwania nuty, ale również podjąć decyzję co do jej najbardziej prawdopodobnego i/lub optymalnego opalcowania na gryfie.



Rysunek 2.4: Przykład tej samej nuty (E4, MIDI 64) możliwej do zagrania w wielu pozycjach na gryfie gitary standardowo strojonej. Ilustracja przedstawia dźwięk E4 na strunie G (9. próg), strunie B (5. próg) oraz pustej strunie wysokiej E. Obrazuje to fundamentalne wyzwanie estymacji opalcowania w GTT. Źródło: [obrazGitaraNiejednoznaczność]

- **Zmienność barwy jako potencjalna wskazówka i problem:** Chociaż subtelne różnice w barwie dźwięku tej samej nuty granej na różnych strunach mogą teoretycznie dostarczać pewnych wskazówek dla algorytmów estymacji opalcowania, to wszechobecne i często intensywne stosowanie efektów gitarowych (szczególnie w muzyce rockowej, metalowej, jazzowej i elektronicznej) może całkowicie modyfikować oryginalną barwę instrumentu, maskując te subtelne różnice lub wprowadzając własne artefakty, co znacząco komplikuje analizę [Wiggins2019TabCNN].
- **Detekcja i notacja technik wykonawczych:** Wierne odtworzenie partii gitarowej w formie tabulatury wymaga nie tylko transkrypcji samych nut, ale również rozpoznania i odpowiedniego zanotowania licznych, specyficznych dla gitary technik artykulacyjnych (patrz Tabela 2.1) [Reboursiere2011GuitarController, Su2014SparseCepstral]. Jest to zadanie trudne, gdyż akustyczne manifestacje tych technik bywają subtelne i zmienne.
- **Ograniczenia dostępnych zbiorów danych:** Rozwój systemów GTT opartych na uczeniu maszynowym, zwłaszcza na modelach głębokiego uczenia, jest w dużej mierze uzależniony od dostępności obszernych, publicznych zbiorów danych zawierających nagrania gitarowe wraz z precyzyjnymi, zsynchronizowanymi czasowo adnotacjami tabulaturowymi (obejmującymi informacje o strunie, progu, a idealnie także o zastosowanych technikach wykonawczych) [Wiggins2019TabCNN,

Zang2023SynthTab]. Tworzenie takich zbiorów jest procesem niezwykle pracochłonnym.

- **Problem „przesunięcia dziedziny” (*domain shift*)**: Modele GTT trenowane na danych pochodzących z jednej domeny (np. czyste, studyjne nagrania gitar akustycznych lub dane syntetyczne) mogą wykazywać znaczący spadek skuteczności, gdy są stosowane do danych z innej domeny (np. nagrania koncertowe, amatorskie, partie gitar elektrycznych z efektami) [**Zang2023SynthTab**]. Praca Zang i in. (2023) nad zbiorem SynthTab [**Zang2023SynthTab**] stanowi próbę zaadresowania problemu niedoboru zróżnicowanych danych rzeczywistych poprzez wykorzystanie dużych ilości danych syntetycznych do wstępnego treningu modeli, które następnie mogą być dostrajane na mniejszych zbiorach danych rzeczywistych.

2.5.4 Przegląd istniejących podejść i narzędzi do GTT

Współczesne podejścia do automatycznej transkrypcji gitary na tabulaturę można generalnie podzielić na dwuetapowe oraz zintegrowane, określane jako *end-to-end*. Każde z nich ma swoje charakterystyczne cechy i stawia czoła opisanym wyzwaniom w odmienny sposób. Podejścia dwuetapowe realizują zadanie GTT w dwóch oddzielnych krokach. W pierwszym etapie dokonuje się ogólnej transkrypcji muzycznej, czyli estymacji wielokrotnej wysokości dźwięku (MPE), w wyniku czego powstaje reprezentacja nutowa utworu (np. w formacie piano-roll lub MIDI), bez informacji o konkretnym opalcowaniu [**BurletHindle2017IsolatedGuitarTranscription**]. W drugim etapie, nazywanym aranżacją tabulatury lub inferencją opalcowania, system próbuje przypisać te wcześniej wykryte nuty do najbardziej prawdopodobnych lub optymalnych pozycji (strun i progów) na gryfie gitary. Ten etap często wykorzystuje modele optymalizacyjne, przeszukiwanie grafowe lub funkcje kosztu, które uwzględniają takie czynniki jak fizyczna grywalność (np. minimalizacja odległości ruchów ręki na gryfie, unikanie niemożliwych do zagrania kombinacji), typowe dla danego stylu muzycznego wzorce opalcowania, czy też subtelne różnice w barwie dźwięku między strunami. Zaletą tego podejścia jest jego modularność. Główną wadą jest natomiast ryzyko propagacji błędów z etapu MPE do etapu aranżacji tabulatury. Podejścia zintegrowane, opierające się w przeważającej mierze na zaawansowanych modelach głębokiego uczenia, dążą do nauczenia się bezpośredniego mapowania z surowego sygnału audio (lub jego reprezentacji czasowo-częstotliwościowej) na finalną reprezentację tabulaturową w jednym, zintegrowanym kroku. Wykorzystują one złożone architektury sieci neuronowych, takie jak:

- Modele oparte na splotowych sieciach neuronowych (CNN), czego przykładem jest TabCNN [**Wiggins2019TabCNN**]. Architektura ta typowo przetwarza wejściowy spektrogram (np. Constant-Q) i generuje na wyjściu predykcje dotyczące aktywności

poszczególnych progów na każdej ze strun gitary, często w formie wielowymiarowej macierzy binarnej („six-hot encoding” dla sześciu strun i określonej liczby progów). Praca Zang i in. (2023) [Zang2023SynthTab] również wykorzystuje architekturę zbliżoną do TabCNN jako jeden z modeli bazowych w swoich badaniach nad wykorzystaniem danych syntetycznych.

- Modele oparte na architekturze Transformer, które dzięki zastosowaniu mechanizmów uwagi (*attention mechanisms*) są zdolne do efektywnego modelowania długoterminowych zależności w danych sekwencyjnych. Znalazły one zastosowanie w GTT, szczególnie w połączeniu z dużymi zbiorami danych, w tym syntetycznymi, takimi jak SynthTab [Zang2023SynthTab].
- Inne architektury sieci neuronowych, w tym sieci rekurencyjne (RNN) lub ich bardziej zaawansowane warianty jak LSTM czy GRU, często stosowane w połączeniu z CNN (tworząc architektury CRNN), aby wykorzystać zdolności CNN do ekstrakcji lokalnych cech ze spektrogramów oraz zdolności RNN do modelowania kontekstu czasowego. Przykładowo, praca Burlet i Hindle (2017) [BurletHindle2017IsolatedGuitarTranscription] badała zastosowanie głębokich sieci przekonań (*Deep Belief Networks*) dla transkrypcji izolowanych dźwięków gitarowych, co stanowiło wczesny przykład wykorzystania metod głębokiego uczenia w tym obszarze.

Zaletą podejść zintegrowanych jest ich potencjalna zdolność do uczenia się bardzo złożonych i subtelnych mapowań bezpośrednio z danych, co może prowadzić do lepszych wyników końcowych niż w podejściach dwuetapowych, szczególnie jeśli model jest w stanie jednocześnie uwzględniać zarówno informacje akustyczne, jak i ograniczenia wynikające z grywalności. Wymagają one jednak zazwyczaj znacznie większych i bardziej szczegółowych zbiorów danych treningowych. Niezależnie od podejścia, kluczową rolę w rozwoju systemów GTT odgrywają zbiory danych. GuitarSet [Wiggins2019TabCNN, Zang2023SynthTab] jest jednym z najważniejszych publicznie dostępnych zbiorów, zawierającym około 3 godzin muzyki gitarowej granej w różnych stylach, z precyzyjnymi adnotacjami MIDI oraz, co unikalne, informacjami o strunie i progu dla każdej nuty, uzyskanymi dzięki zastosowaniu przetworników heksafonicznych (rejestrujących sygnał z każdej struny osobno) oraz starannej ręcznej weryfikacji. Zbiór DadaGP [Zang2023SynthTab] to z kolei duży zbiór danych w formie symbolicznej (pliki Guitar Pro), który jest często wykorzystywany w badaniach nad GTT, szczególnie w kontekście modelowania i generowania tabulatur z uwzględnieniem bogatego zestawu technik wykonawczych i artykulacji. SynthTab [Zang2023SynthTab] to natomiast obszerny zbiór syntetycznych danych (par audio-tabulatura), stworzony w celu przezwyciężenia ograniczeń związanych z rozmiarem i różnorodnością dostępnych zbiorów danych rzeczywistych. Został on wygenerowany poprzez syntezę audio z plików Guitar Pro pochodzących ze zbioru DadaGP, z wykorzystaniem zaawansowanych symulatorów wzmacniaczy gitarowych i efektów w celu uzyskania realistycznie brzmiących nagrań. Badania

wykazały, że modele GTT wstępnie trenowane na dużych zbiorach danych syntetycznych, a następnie dostrajane (*fine-tuned*) na mniejszych zbiorach danych rzeczywistych, mogą osiągać znaczącą poprawę wyników transkrypcji [**Zang2023SynthTab**]. Ten paradygmat pre-trainingu na danych syntetycznych i fine-tuningu na danych rzeczywistych staje się potężnym narzędziem poprawy odporności i generalizacji w GTT. Pomimo znaczących postępów, jakie dokonały się w dziedzinie GTT, obecne rozwiązania wciąż napotykają na istotne ograniczenia.

Do głównych nierozwiązanych problemów należą: osiągnięcie wysokiej dokładności transkrypcji w przypadku bardzo gęstych faktur polifonicznych i szybkich pasażów technicznych, opracowanie wiarygodnych metod inferencji tabulatury (opalcowania) w złożonych kontekstach muzycznych, które uwzględniałyby nie tylko poprawność nut, ale także grywalność i naturalność wykonania, precyzyjne rozpoznawanie i notacja szerokiego spektrum subtelnych technik artykulacyjnych, zapewnienie dobrej generalizacji modeli na różne style muzyczne, brzmienia gitar (w tym instrumenty z silnie zmodyfikowanym sygnałem za pomocą efektów) oraz różne jakości nagrań, a także sformułowanie obiektywnych i wszechstronnych metryk oceny jakości wygenerowanych tabulatur, które korelowałyby z percepcją i oceną przez doświadczonych gitarzystów [**Zang2023SynthTab**, **Wiggins2019TabCNN**].

W procesie tworzenia i ewaluacji systemów AMT i GTT szeroko wykorzystuje się specjalistyczne biblioteki programistyczne do przetwarzania sygnałów audio i implementacji modeli uczenia maszynowego, takie jak Librosa, Essentia, a także frameworki głębokiego uczenia jak TensorFlow czy PyTorch.

2.6 Podsumowanie i Otwarte Problemy

Automatyczna transkrypcja muzyczna, a w jej ramach transkrypcja muzyki gitarowej na zapis tabulaturowy, pozostaje aktywnym i wymagającym obszarem badań naukowych. Znaczenie praktyczne skutecznych systemów GTT jest nie do przecenienia, obejmując wsparcie dla muzyków, edukację, archiwizację oraz przemysł muzyczny [**Benetos2019AutomaticMusicTranscription**]. Jak wykazano w niniejszym rozdziale, główne wyzwania logiczne koncentrują się wokół przetwarzania złożonych sygnałów polifonicznych, radzenia sobie z dużą zmiennością barwy i artykulacji charakterystyczną dla gitary, a w przypadku GTT – dodatkowo wokół fundamentalnego problemu niejednoznaczności opalcowania oraz precyzyjnej detekcji i notacji specyficznych technik wykonawczych [**Wiggins2019TabCNN**]. Przegląd stosowanych metod ukazuje wyraźną ewolucję od klasycznych technik opartych na przetwarzaniu sygnałów do zaawansowanych modeli uczenia maszynowego, ze szczególnym uwzględnieniem głębokich sieci neuronowych, które obecnie definiują stan wiedzy w tej dziedzinie [**KlapuriDavy2006SignalProcessing**, **Jamshidi2024SurveyAMT**]. Rozwiązania takie jak „Onsets and Frames” [**Hawthorne2018Onsets**] czy „Basic Pitch” [**Bittner2022BasicPitch**] dla ogólnych zadań AMT, oraz systemy

dedykowane GTT, jak TabCNN [**Wiggins2019TabCNN**] i nowsze podejścia wykorzystujące duże zbiory danych, w tym syntetyczne, jak w przypadku badań nad SynthTab [**Zang2023SynthTab**], demonstrują znaczący postęp. Systemy te osiągają coraz wyższą skuteczność, jednakże wciąż istnieją liczne obszary wymagające dalszych, intensywnych badań. Do kluczowych otwartych problemów w dziedzinie GTT, które wyznaczają kierunki przyszłych prac, należą przede wszystkim:

- Dalsza poprawa dokładności i robustności transkrypcji w kontekście bardzo gęstej polifonii, szybkich pasażów muzycznych oraz sygnałów o niskiej jakości lub z silnymi zniekształceniami.
- Rozwój bardziej zaawansowanych i kontekstowych metod inferencji opalcowania na gryfie gitary, które lepiej odzwierciedlałyby rzeczywiste praktyki wykonawcze i zapewniały grywalność generowanych tabulatur.
- Zwiększenie zdolności systemów do rozpoznawania i poprawnej notacji szerokiego spektrum subtelnych technik gitarowych, które mają kluczowe znaczenie dla ekspresji muzycznej.
- Poprawa generalizacji modeli GTT na różne, nie widziane wcześniej w procesie treningu, brzmienia gitar (akustycznych, elektrycznych, z różnymi efektami), style muzyczne i warunki nagraniowe.
- Opracowanie bardziej kompleksowych i percepcyjnie adekwatnych metryk oceny jakości transkrypcji tabulaturowej, które wykraczałyby poza proste porównanie poprawności nut i uwzględniałyby aspekty takie jak grywalność, czytelność i wierność stylistyczną. Kwestia ta nawiązuje do obserwacji, że wyniki ilościowe nie zawsze w pełni odzwierciedlają praktyczną użyteczność systemu dla końcowego użytkownika [**Holzapfel2019Ethnomusicology**].
- Kontynuacja prac nad tworzeniem i udostępnianiem większych, bardziej zróżnicowanych i precyzyjnie adnotowanych zbiorów danych dla GTT, w tym eksploracja metod efektywnego wykorzystania danych syntetycznych i technik transferu wiedzy.

Rozwiązanie tych problemów przybliży nas do stworzenia systemów GTT, które będą mogły stać się prawdziwie użytecznymi i powszechnie akceptowanymi narzędziami dla szerokiej społeczności gitarzystów.

Rozdział 3

Przedmiot Pracy: Projekt i Implementacja Systemu Transkrypcji Gitarowej

Niniejszy rozdział stanowi szczegółowe omówienie projektu i implementacji autorskiego systemu do automatycznej transkrypcji polifonicznych nagrań gitarowych na zapis tabulaturowy (GTT). Celem prac było stworzenie oraz ewaluacja systemu zdolnego do przekształcania sygnału audio gitary w symboliczną reprezentację tabulaturową, z wykorzystaniem technik głębokiego uczenia. Kluczowym aspektem projektu jest możliwość eksperymentalnego porównania dwóch odmiennych metod reprezentacji sygnału wejściowego: tradycyjnych mel-spektrogramów oraz transformaty Constant-Q (CQT), celem zbadania ich efektywności w zadaniu GTT. Opierając się na fundamentach teoretycznych i przeglądzie stanu wiedzy przedstawionym w poprzednich rozdziałach, w tej części pracy opisana zostanie architektura i logika działania opracowanego rozwiązania. Prezentacja ta ma na celu nie tylko techniczny opis zrealizowanych prac, ale również analityczne osadzenie podjętych decyzji projektowych w kontekście literatury naukowej.

3.1 Opis Zaimplementowanego Rozwiązania

W tej sekcji przedstawiono szczegółowy opis systemu GTT zaimplementowanego w ramach niniejszej pracy. Opis koncentruje się na funkcjonalności poszczególnych komponentów systemu, poczynwszy od przygotowania danych, poprzez architekturę modelu, aż po proces treningu i ewaluacji.

3.1.1 Architektura Ogólna Systemu

Zaproponowany system GTT charakteryzuje się modułową architekturą potokową (*pipeline*), co umożliwia elastyczne zarządzanie poszczególnymi etapami przetwarzania

oraz systematyczne prowadzenie eksperymentów. Główny skrypt sterujący, zrealizowany w formie interaktywnego notatnika, pełni rolę centrum zarządzania całym projektem, orkiestrując proces od przygotowania danych, przez trening modelu z przeszukiwaniem hiperparametrów, aż po ewaluację i wizualizację wyników. Centralnym elementem systemu jest mechanizm konfiguracyjny, który agreguje wszystkie globalne stałe i parametry. Obejmują one definicje ścieżek dostępu do danych wejściowych, przetworzonych oraz wyników, parametry przetwarzania sygnału audio (takie jak częstotliwość próbkowania, długość kroku analizy), specyficzne ustawienia dla generowania mel-spektrogramów (rozmiar okna FFT, liczba pasm Mel) oraz dla transformaty CQT (minimalna częstotliwość, liczba prążków, liczba prążków na oktawę). Ponadto, konfiguracja zawiera parametry dotyczące tworzenia zbiorów danych, w tym ustawienia augmentacji, oczekiwane wymiary tensorów dla celów walidacyjnych, domyślne ustawienia architektury modelu (np. liczba kanałów wyjściowych w warstwach splotowych) oraz parametry procesu treningu (np. domyślna liczba epok, rozmiar wsadu, metryka wyboru najlepszego modelu) i generowania plików wynikowych w formatach MIDI i tabulatur tekstowych. Taka centralizacja parametrów ułatwia ich modyfikację i zapewnia spójność w całym systemie.

3.1.2 Przetwarzanie Wstępne i Przygotowanie Danych

Staranne przygotowanie danych jest fundamentalnym etapem w procesie uczenia maszynowego. W ramach systemu obejmuje ono podział zbioru danych, ekstrakcję cech akustycznych z plików audio, przetwarzanie adnotacji oraz zapis przetworzonych danych w formie tensorów.

Podział Zbioru Danych

System wykorzystuje publicznie dostępny zbiór danych GuitarSet [**Wiggins2019TabCNN**], który zawiera nagrania gitarowe wraz z precyzyjnymi adnotacjami. Proces podziału zbioru na części treningową, walidacyjną i testową jest zautomatyzowany. Na początku, z ogólnej listy utworów eliminowane są nagrania zidentyfikowane jako problematyczne. W ramach tej pracy, zgodnie z doniesieniami społeczności, ze zbioru wyłączono dwa pliki: 04_BN3-154-E_comp oraz 04_Jazz1-200-B_comp. Powodem tej decyzji były minimalne błędy w adnotacjach, polegające na stałym przesunięciu czasowym wszystkich nut, co mogłoby negatywnie wpłynąć na proces treningu modelu [**Riley2023GuitarSetIssue**]. Następnie, przy użyciu standardowych narzędzi do selekcji modeli, identyfikatory utworów są dzielone na trzy zbiory: treningowy, walidacyjny i testowy. Zastosowano standardowy w praktyce uczenia maszynowego podział w proporcjach 80:10:10. Użycie stałego zarodka losowości na tym etapie gwarantuje powtarzalność i porównywalność wyników eksperymentów. Wynikowe listy identyfikatorów dla każdego zbioru są zapisywane do plików tekstowych, które są następnie wykorzystywane przez komponent ładujący dane.

Ekstrakcja Cech Akustycznych i Przetwarzanie Adnotacji

System umożliwia ekstrakcję dwóch typów cech czasowo-częstotliwościowych: mel-spektrogramów oraz spektrogramów Constant-Q (CQT). Dla potoku opartego na mel-spektrogramach, proces przetwarzania pojedynczego utworu obejmuje wczytanie pliku audio z docelową częstotliwością próbkowania (np. 22050 Hz) przy użyciu biblioteki Librosa [McFee2022Librosa]. Następnie obliczany jest log-mel-spektrogram poprzez zastosowanie krótkoczasowej transformaty Fouriera (STFT) z określonym rozmiarem okna i krokiem, a następnie projekcję na skalę Mel i konwersję na skalę decybelową. Liczba pasm Mel jest parametrem konfiguracyjnym (np. 128). Równolegle przetwarzane są adnotacje dla danego utworu, dostarczane w formacie JAMS. Z pliku JAMS ekstrahowane są informacje o poszczególnych nutach: czas rozpoczęcia, czas trwania oraz wysokość dźwięku MIDI. Na podstawie wysokości dźwięku MIDI i standardowego strojenia gitary obliczany jest również numer progu dla każdej struny. Zarówno wyekstrahowany mel-spektrogram, jak i przetworzone adnotacje są następnie zapisywane jako dwa osobne pliki binarne zawierające tensory, gotowe do dalszego wykorzystania. Ten proces jest powtarzany dla wszystkich utworów w poszczególnych podziałach zbioru danych. Alternatywna ścieżka, wykorzystująca transformatę Constant-Q (CQT), jest realizowana w locie przez komponent zbioru danych, co zostanie opisane w kolejnej sekcji.

Komponent Zbioru Danych i Augmentacja

Dedykowany komponent zbioru danych, zgodny ze standardowym interfejsem frameworka PyTorch, odpowiada za ładowanie i przygotowywanie danych dla modelu. Jego kluczową cechą jest elastyczność pozwalająca na obsługę dwóch scenariuszy ekstrakcji cech:

- Wczytywanie wstępnie przetworzonych mel-spektrogramów z plików tensorowych (głównie dla zbiorów walidacyjnego i testowego).
- Generowanie spektrogramów CQT w locie z surowych plików audio (głównie dla zbioru treningowego, co umożliwia efektywne stosowanie augmentacji audio przed transformacją). Parametry CQT, takie jak minimalna częstotliwość (np. odpowiadająca dźwiękowi E2 gitary), liczba prążków (np. 192) oraz liczba prążków na oktawę (np. 24), są przekazywane podczas inicjalizacji i pochodzą z centralnej konfiguracji [Wiggins2019TabCNN, Zang2023SynthTab]. Transformata CQT jest obliczana przy użyciu biblioteki Librosa, a jej wynik konwertowany na skalę decybelową.

Dla zbioru treningowego, komponent ten implementuje również augmentację danych w locie, mającą na celu zwiększenie różnorodności danych i poprawę zdolności generalizacyjnych modelu [Zang2023SynthTab, Su2014SparseCepstral].


- **Augmentacje audio** (stosowane do surowego sygnału przed obliczeniem CQT):

- Rozciąganie w czasie (*time stretching*): modyfikuje tempo nagrania w zdefiniowanym zakresie, z odpowiednią korektą czasów w etykietach.
- Dodawanie szumu (*noise addition*): do sygnału dodawany jest szum o losowo wybranej amplitudzie.
- Losowe wzmocnienie (*random gain*): amplituda sygnału jest mnożona przez losowy współczynnik.

Prawdopodobieństwa zastosowania każdej z tych augmentacji oraz zakresy losowanych parametrów są konfigurowalne.

- **Augmentacja spektrogramu** (SpecAugment): stosowana do wygenerowanych spektrogramów (Mel lub CQT). Polega na losowym maskowaniu pewnych zakresów częstotliwości oraz fragmentów czasowych. Parametry maskowania są również konfigurowalne.

Niezależnie od źródła cech (plik tensorowy lub generacja w locie), komponent zbioru danych przekształca wczytane surowe adnotacje nutowe na format ramkowy. Dla każdej ramki czasowej spektrogramu tworzone są dwie macierze etykiet (dla sześciu strun gitary): jedna dla onsetów (wartość 1.0 oznacza początek nuty na danej strunie w danej ramce, 0.0 w przeciwnym przypadku) i jedna dla numerów progów (liczba całkowita reprezentująca aktywny próg, ze specjalną wartością dla ciszy). Liczba ramek w etykietach jest synchronizowana z liczbą ramek w tensorze cech.



Rysunek 3.1: Wizualizacja etykiet ramkowych dla fragmentu utworu. Górny panel przedstawia macierz onsetów, gdzie pionowe linie oznaczają moment rozpoczęcia nuty na danej strunie. Dolny panel pokazuje macierz aktywności progów, gdzie czarne obszary reprezentują czas trwania dźwięku na danej strunie.

Przetwarzanie Wsadowe i Walidacja Danych

Do efektywnego treningu modelu, próbki danych są grupowane we wsady (*batches*). Ponieważ poszczególne próbki (utwory) mogą mieć różną długość, zaimplementowano mechanizm dopełniania (*padding*). Dedykowana funkcja agregująca, używana przez mechanizm ładowania danych, uzupełnia tensory cech i etykiet w ramach wsadu do długości

najdłuższej sekwencji w tym wsadzie, wykorzystując standardowe narzędzia frameworka PyTorch. System zawiera również zestaw narzędzi diagnostycznych do weryfikacji poprawności i spójności przetworzonych danych. Funkcje te sprawdzają, czy kształty i typy danych tensorów (np. CQT, Mel, etykiet onsetów i progów) są zgodne z oczekiwaniami zdefiniowanymi w konfiguracji, oraz czy wartości w tensorach mieszczą się w oczekiwanych zakresach (np. wartości binarne, brak wartości nieokreślonych). Możliwe jest przeprowadzenie pełnej walidacji na całym zbiorze danych, agregując statystyki i drukując podsumowanie.


3.1.3 Model Transkrypcji (CRNN)

Sercem systemu transkrypcji jest konwolucyjno-rekurencyjna sieć neuronowa (CRNN), zaimplementowana w frameworku PyTorch. Architektura ta, przedstawiona na rysunku 3.2, została zaprojektowana z myślą o przetwarzaniu dwuwymiarowych reprezentacji czasowo-częstotliwościowych (mel-spektrogramów lub CQT) i modelowaniu zależności czasowych. Model składa się z dwóch głównych komponentów:

- **Frontend konwolucyjny (CNN):** Ta część, inspirowana architekturą TabCNN [Wiggins2019TabCNN], jest odpowiedzialna za ekstrakcję cech z wejściowego spektrogramu. Składa się z sekwencji bloków, gdzie każdy blok zawiera warstwę splotową 2D (Conv2d), po której następuje normalizacja wsadowa (BatchNorm2d), nieliniowa funkcja aktywacji ReLU oraz opcjonalnie warstwa redukcji wymiaru poprzez wybór wartości maksymalnej (MaxPool2d). Parametry tych warstw, takie jak liczba kanałów wejściowych i wyjściowych, rozmiary kerneli, krok oraz parametry poolingu, są definiowane w centralnej konfiguracji.
- **Backend rekurencyjny (RNN):** Wyjście z części CNN, po odpowiednim przekształceniu wymiarów (permutacja i spłaszczenie), jest podawane na wejście dwukierunkowej sieci LSTM (*Long Short-Term Memory*). Sieć LSTM ma za zadanie analizować sekwencję cech w czasie, ucząc się zależności długoterminowych. Warto zaznaczyć, że jako alternatywę dla LSTM można by zastosować sieć z bramkowanymi jednostkami rekurencyjnymi (GRU, *Gated Recurrent Unit*). GRU, posiadając prostszą architekturę z dwiema bramkami (w przeciwieństwie do trzech w LSTM), jest często bardziej wydajna obliczeniowo i szybsza w treningu, oferując porównywalną skuteczność, zwłaszcza przy mniejszych zbiorach danych. Mimo to, w niniejszym projekcie zdecydowano się na wykorzystanie LSTM ze względu na jego udokumentowaną zdolność do modelowania bardzo długich zależności w danych sekwencyjnych [Chung2014GRU]. Kluczowe parametry LSTM, takie jak rozmiar wejściowy (obliczany na podstawie wymiarów wyjściowych z CNN), rozmiar stanu ukrytego, liczba warstw oraz współczynnik dropout dla regularyzacji, są konfigurowalne.
- **Warstwy Wyjściowe:** Przetworzone przez RNN sekwencje cech są następnie po-

dawane na dwie oddzielne, w pełni połączone warstwy liniowe (**Linear**). Jedna warstwa (**onset_fc**) generuje logity dla predykcji onsetów dla każdej z sześciu strun. Druga warstwa (**fret_fc**) generuje logity dla predykcji klas progów (włączając klasę ciszy) dla każdej struny. Logity dla progów są następnie przekształcane do ostatecznego kształtu odpowiadającego wymiarom: wsad, czas, struny, klasy progów. Takie podejście wielozadaniowe jest inspirowane pracą "Onsets and Frames"[**Hawthorne2018Onsets**].

System zawiera również funkcję pomocniczą do ładowania zapisanego stanu modelu z pliku, tworząc nową instancję modelu z odpowiednimi parametrami i wczytując do niej zapisane wagi.



Rysunek 3.2: Schemat architektury zaimplementowanego modelu CRNN. Przedstawia przepływ danych od wejściowego tensora spektrogramu, przez frontend konwolucyjny, backend rekurencyjny, aż po rozdzielenie na dwie głowice wyjściowe dla predykcji onsetów i progów.

3.1.4 Proces Treningu Modelu

Proces treningu modelu jest zarządzany przez dedykowany moduł, który orkiestruje cały cykl dla pojedynczego zestawu hiperparametrów.

Inicjalizacja i Pętla Treningowa

Dla każdego przebiegu w ramach przeszukiwania hiperparametrów tworzony jest unikalny katalog na artefakty. Następnie inicjalizowany jest model CRNN, funkcja straty oraz optymalizator. Zdecydowano się na użycie optymalizatora AdamW [Loshchilov2019AdamW]. Jest to udoskonalona wersja popularnego optymalizatora Adam, która inaczej implementuje mechanizm regularyzacji (zaniku wag, *weight decay*). W AdamW zanik wag jest oddzielony od kroku aktualizacji gradientu, co prowadzi do bardziej stabilnego treningu i lepszej generalizacji modelu w porównaniu do standardowej implementacji L2 w Adam. Na podstawie tych parametrów inicjowany jest również, opcjonalnie, mechanizm harmonogramowania współczynnika uczenia. Główna pętla treningowa iteruje przez zdefiniowaną liczbę epok. W każdej epoce wykonywane są dwie fazy:

- **Faza treningowa:** Model jest ustawiany w tryb treningowy. Dla każdego wsadu danych ze zbioru treningowego zerowane są gradienty, wykonywane jest przejście w przód przez model, obliczana jest złożona funkcja straty, a następnie wykonywana jest propagacja wsteczna i aktualizacja wag modelu przez optymalizator.
- **Faza walidacyjna:** Model jest ustawiany w tryb ewaluacyjny, a obliczanie gradientów jest wyłączane. Dla każdego wsadu danych ze zbioru walidacyjnego wykonywane jest przejście w przód, obliczana jest funkcja straty oraz szeroki zestaw metryk wydajności.

Wszystkie straty i metryki są zapisywane w historii treningu. Postępy są logowane do pliku tekstowego oraz wyświetlane na konsoli. Stosowany jest mechanizm harmonogramowania współczynnika uczenia (np. redukcja po okresie braku poprawy metryki walidacyjnej) oraz mechanizm wczesnego zatrzymywania, który przerywa trening, jeśli ślędzona metryka walidacyjna nie poprawia się przez określoną liczbę epok. Najlepszy model (na podstawie metryki walidacyjnej) jest zapisywany. Na koniec generowany jest wykres historii treningu.

Funkcja Straty i Optymalizacja Progów

Zastosowano niestandardową, złożoną funkcję straty, która jest ważoną sumą dwóch komponentów, co przedstawia wzór 3.1:

- **Strata Onsetów:** Obliczana przy użyciu binarnej entropii krzyżowej z logitami (`BCEWithLogitsLoss`) dla zadania binarnej klasyfikacji onsetów. Strata jest maskowana, aby uwzględniać tylko rzeczywiste dane w sekwencjach (bez dopełnienia).

Opcjonalnie można zastosować ważenie klas dodatnich (`pos_weight`) w celu przeciwdziałania niezbalansowaniu klas.

- **Strata Progów:** Obliczana przy użyciu entropii krzyżowej (`CrossEntropyLoss`) dla zadania wieloklasowej klasyfikacji progów. Wykorzystuje się ignorowanie określonego indeksu (`ignore_index`) do pomijania wartości dopełniających.

Wagi obu składników straty są konfigurowalnymi hiperparametrami.

$$\mathcal{L}_{\text{total}} = \lambda_{\text{onset}} \cdot \mathcal{L}_{\text{onset}} + \lambda_{\text{fret}} \cdot \mathcal{L}_{\text{fret}} \quad (3.1)$$

gdzie $\mathcal{L}_{\text{total}}$ to całkowita strata, $\mathcal{L}_{\text{onset}}$ i $\mathcal{L}_{\text{fret}}$ to straty dla predykcji onsetów i progów, a λ_{onset} i λ_{fret} to odpowiadające im wagi. Podczas fazy walidacyjnej, dla predykcji onsetów, stosowany jest mechanizm optymalizacji progu decyzyjnego. Iteruje on po zdefiniowanym zakresie możliwych wartości progów prawdopodobieństwa i dla każdego progu oblicza metryki klasyfikacji binarnej (precyzja, czułość, F1, dokładność). Wybierany jest próg, który maksymalizuje miarę F1, i ten optymalny próg jest używany do dalszych obliczeń metryk oraz w fazie testowania.

3.1.5 Ewaluacja i Generowanie Wyników

Po zakończeniu treningu, najlepszy model jest poddawany finalnej ewaluacji na zbiorze testowym. System umożliwia również generowanie wyników w formatach ułatwiających analizę jakościową.

Konwersja Predykcji na Nuty i Metryki Ewaluacyjne

Ramkowe predykcje modelu (prawdopodobieństwa onsetów i klasy progów) są przekształcane w listę dyskretnych zdarzeń nutowych. Proces ten iteruje po każdej strunie i ramce czasowej. Wykorzystuje prostą logikę maszyny stanów: wykrycie onetu (prawdopodobieństwo powyżej zoptymalizowanego progu) dla aktywnego progu inicjuje nową nutę. Nuta jest kontynuowana, dopóki na tej samej strunie nie pojawi się nowy onset, nie zostanie wykryta cisza, nie zmieni się numer progu, lub sekwencja się nie zakończy. Każda przewidziana nuta jest reprezentowana przez czas początku, końca, wysokość MIDI, numer struny i progu. Do oceny jakości transkrypcji wykorzystywane są metryki zarówno na poziomie ramek, jak i na poziomie nut.

Metryki na poziomie ramek Podstawowe metryki dla detekcji onsetów na poziomie ramek, takie jak Precyzja, Czułość i F1-Score, są obliczane zgodnie ze standardowymi definicjami (wzory 3.2–3.4), gdzie TP (prawdziwie pozytywne), FP (fałszywie pozytywne) i FN (fałszywie negatywne) odnoszą się do liczby poprawnie, błędnie i niewykrytych

ramek z onsetami.

$$\text{Precyzja}_{\text{ramka}} = \frac{TP}{TP + FP} \quad (3.2)$$

$$\text{Czułość}_{\text{ramka}} = \frac{TP}{TP + FN} \quad (3.3)$$

$$\text{F1-Score}_{\text{ramka}} = 2 \cdot \frac{\text{Precyzja}_{\text{ramka}} \cdot \text{Czułość}_{\text{ramka}}}{\text{Precyzja}_{\text{ramka}} + \text{Czułość}_{\text{ramka}}} \quad (3.4)$$

Dodatkowo, zaimplementowano metrykę F-score dla tabulatury (FTab) na poziomie ramek, która ocenia poprawność predykcji progów tylko w tych ramkach, które są aktywne (tzn. w których faktycznie jest grany dźwięk). Jej składowe, Precyzja (P-Tab) i Czułość (R-Tab), zdefiniowano we wzorach 3.5-3.6.

$$\text{P-Tab}_{\text{ramka}} = \frac{\sum TP_{\text{ftab}}}{\sum \text{Predykcje Aktywne}} \quad (3.5)$$

$$\text{R-Tab}_{\text{ramka}} = \frac{\sum TP_{\text{ftab}}}{\sum \text{Etykiety Aktywne}} \quad (3.6)$$

gdzie TP_{ftab} to ramki, w których zarówno predykcja jak i etykieta są aktywne i mają ten sam numer prog.

Metryki na poziomie nut Metryki na poziomie nut są obliczane z wykorzystaniem biblioteki `mir_eval` oraz przez dedykowane implementacje. Obejmują one ocenę detekcji onsetów z tolerancją czasową (50 ms) oraz metrykę TDR (*Tablature Detection Rate*), która jest miarą F1-score dla poprawnie zidentyfikowanych nut (zgodność czasu rozpoczęcia, numeru struny i prog).

Generowanie Wyników i Analiza Końcowa

System pozwala na generowanie plików MIDI z predykcji modelu dla wybranych próbek, co umożliwia odsłuchanie wyników. Dodatkowo, tworzone są tabulatury w formacie tekstowym (ASCII), zarówno dla etykiet referencyjnych, jak i dla predykcji modelu, co ułatwia wizualne porównanie i obliczenie prostych metryk dopasowania. Po zakończeniu całego procesu przeszukiwania hiperparametrów, moduł analizy końcowej identyfikuje najlepszy przebieg, ładuje odpowiadający mu model i generuje wspomniane pliki MIDI oraz tabulatury tekstowe dla kilku próbek ze zbioru testowego, używając optymalnego progów onsetu znalezionej podczas walidacji.

3.1.6 Wizualizacja

System zawiera zestaw funkcji do tworzenia różnego rodzaju wykresów przy użyciu biblioteki Matplotlib. Umożliwiają one wizualizację:

- Spektrogramów wejściowych (Mel lub CQT).

- Etykiet i predykcji onsetów w formie grafu typu "piano roll".
- Etykiet i predykcji progów w formie kolorowej mapy.
- Zbiorczych wykresów dla pojedynczych próbek, pokazujących spektrogram oraz odpowiadające mu etykiety i predykcje.
- Ewolucji strat i metryk wydajności w kolejnych epokach treningu.

Te narzędzia wizualizacyjne są wykorzystywane zarówno do weryfikacji poprawności danych, jak i do analizy wyników działania modelu i procesu treningu.

3.2 Analiza Teoretyczna Rozwiązania

W tej sekcji dokonano analizy teoretycznej zaimplementowanego systemu, odnosząc poszczególne komponenty do ugruntowanych koncepcji teoretycznych i literatury naukowej, bazując na przedstawionych faktach implementacyjnych.

3.2.1 Wybór Architektury CRNN w Kontekście GTT

Zastosowanie architektury konwolucyjno-rekurencyjnej (CRNN) jest dobrze uzasadnione specyfiką zadania automatycznej transkrypcji tabulatur gitarowych (GTT). Połączenie splotowych sieci neuronowych (CNN) jako ekstraktora cech z wejściowych reprezentacji czasowo-częstotliwościowych oraz rekurencyjnych sieci neuronowych (RNN) do modelowania sekwencji czasowych tych cech jest sprawdzonym podejściem w dziedzinie transkrypcji muzycznej [**Hawthorne2018Onsets**, **Wiggins2019TabCNN**].

- Warstwy konwolucyjne (CNN), zaimplementowane jako TabCNN, efektywnie uczą się hierarchicznych, lokalnych cech z dwuwymiarowych spektrogramów (Mel lub CQT). Są zdolne do identyfikacji wzorców istotnych dla rozpoznawania dźwięków gitarowych, takich jak struktury harmoniczne czy transjenty [**Wiggins2019TabCNN**, **Benetos2019AutomaticMusicTranscription**].
- Warstwy rekurencyjne, w tym przypadku dwukierunkowe LSTM, są wyspecjalizowane w modelowaniu zależności czasowych w sekwencjach cech dostarczonych przez CNN [**Benetos2019AutomaticMusicTranscription**]. Dwukierunkowość pozwala na analizę każdej ramki w kontekście zarówno przeszłych, jak i przyszłych zdarzeń, co jest korzystne dla precyzji transkrypcji [**Hawthorne2018Onsets**]. Ich alternatywą są jednostki GRU, które dzięki prostszej budowie mogą być bardziej efektywne obliczeniowo, jednak LSTM często wykazują przewagę w modelowaniu zależności długoterminowych [**Chung2014GRU**].

Podejście wielozadaniowe, polegające na jednoczesnej predykcji onsetów i progów przez oddzielne głowice wyjściowe, inspirowane pracą [Hawthorne2018Onsets], pozwala modelowi uczyć się bardziej kompletnych reprezentacji.

3.2.2 Reprezentacja Sygnału Wejściowego

System umożliwia eksperymentalne porównanie dwóch typów reprezentacji czasowo-częstotliwościowych, co stanowi istotny element badawczy.

- **Mel-spektrogramy** są standardowym wyborem w wielu zadaniach MIR ze względu na ich psychoakustyczną motywację – skala Mel aproksymuje ludzką percepcję wysokości dźwięku [Benetos2019AutomaticMusicTranscription].
- **Spektrogramy Constant-Q (CQT)** oferują logarytmiczne skalowanie osi częstotliwości, co bezpośrednio odpowiada strukturze skal muzycznych. Taka reprezentacja, gdzie rozdzielczość częstotliwościowa jest proporcjonalna do częstotliwości (np. stała liczba prążków na oktawę), może być bardziej naturalna dla modeli CNN w zadaniach muzycznych, potencjalnie ułatwiając naukę cech niezmienniczych względem wysokości dźwięku [Wiggins2019TabCNN, Zang2023SynthTab]. Użycie parametrów CQT (np. 192 prążki, 24 prążki na oktawę) jest zgodne z praktykami stosowanymi w literaturze dla transkrypcji gitarowej [Wiggins2019TabCNN].

Możliwość generowania CQT w locie dla zbioru treningowego, w połączeniu z augmentacją audio, pozwala na efektywne wykorzystanie tej reprezentacji bez konieczności wstępnego przetwarzania i przechowywania dużych ilości danych.

3.2.3 Funkcja Straty i Optymalizacja Wielozadaniowa

Zastosowanie złożonej funkcji straty, będącej ważoną sumą strat dla predykcji onsetów i progów, jest przykładem uczenia wielozadaniowego (*multi-task learning*). Takie podejście często prowadzi do poprawy jakości predykcji, ponieważ model uczy się współdzielonych reprezentacji, które są korzystne dla obu powiązanych zadań [Hawthorne2018Onsets].

- Użycie binarnej entropii krzyżowej dla predykcji onsetów jest standardem dla zadań klasyfikacji binarnej.
- Użycie entropii krzyżowej dla predykcji progów jest odpowiednie dla zadań klasyfikacji wieloklasowej.

Maskowanie strat w celu ignorowania dopełnionych części sekwencji oraz możliwość ważenia poszczególnych komponentów straty są istotnymi elementami zapewniającymi stabilny i efektywny trening. Optymalizacja progu decyzyjnego dla onsetów na zbiorze walidacyjnym pozwala na dostosowanie modelu do specyfiki danych i maksymalizację wybranej metryki (np. F1-score).

3.2.4 Techniki Augmentacji Danych

Zastosowane techniki augmentacji danych odgrywają kluczową rolę w procesie treningu, szczególnie przy pracy ze zbiorami danych o ograniczonej wielkości, takimi jak GuitarSet [Wiggins2019TabCNN, Zang2023SynthTab].

- **Augmentacje audio** (rozciąganie w czasie, dodawanie szumu, losowe wzmocnienie), stosowane przed ekstrakcją cech CQT, symulują naturalne wariacje występujące w rzeczywistych nagraniach gitarowych, takie jak zmiany tempa, różne poziomy szumu czy dynamiki gry [Su2014SparseCepstral].
- **Augmentacja spektrogramu (SpecAugment)**, polegająca na maskowaniu fragmentów w dziedzinie czasu i częstotliwości, zmusza model do nauki bardziej robustnych i rozproszonych cech, zwiększając jego odporność na częściowe zakłócenia sygnału lub niewielkie zmiany w artykulacji [Zang2023SynthTab].

Stosowanie tych technik wyłącznie na zbiorze treningowym i w locie jest efektywnym sposobem na zwiększenie efektywnego rozmiaru zbioru treningowego bez konieczności generowania i przechowywania dodatkowych danych.

3.3 Uzasadnienie Wyboru Zastosowanych Metod, Algorytmów i Narzędzi

W tej sekcji przedstawiono uzasadnienie decyzji dotyczących wyboru konkretnych metod, algorytmów i narzędzi programistycznych, opierając się na przedstawionych faktach implementacyjnych.

3.3.1 Zbiór Danych GuitarSet

Wybór zbioru danych GuitarSet [Wiggins2019TabCNN] jest podyktowany jego unikalnymi cechami, które są kluczowe dla zadania automatycznej transkrypcji na tabulaturę. GuitarSet dostarcza nie tylko nagrania audio, ale przede wszystkim precyzyjne adnotacje na poziomie strun, określające numer struny i progu dla każdej zagranej nuty. Te informacje, uzyskane dzięki zastosowaniu przetworników heksafonicznych, są niezbędne do uczenia modelu zdolnego do rozwiązywania problemu niejednoznaczności opalcowania [Wiggins2019TabCNN, obrazGitaraNiejednoznacznośc]. Mimo ograniczeń co do rozmiaru i zidentyfikowanych drobnych błędów w adnotacjach niektórych plików [Riley2023GuitarSetIssue], GuitarSet pozostaje standardem w badaniach nad GTT.

3.3.2 Wybór Reprezentacji Czasowo-Częstotliwościowych

Decyzja o zaimplementowaniu i umożliwieniu porównania mel-spektrogramów oraz spektrogramów CQT jest motywowana chęcią empirycznej weryfikacji skuteczności tych dwóch popularnych reprezentacji w kontekście GTT. Mel-spektrogramy są standardem w wielu zadaniach MIR ze względu na ich psychoakustyczną motywację [Benetos2019AutomaticMusicTranscrip]. Z kolei CQT, z logarytmiczną skalą częstotliwości, jest teoretycznie lepiej dopasowana do natury muzyki i może ułatwiać modelom CNN naukę cech istotnych dla transkrypcji gitarowej [Wiggins2019TabCNN, Zang2023SynthTab]. Możliwość eksperymentowania z obiema reprezentacjami w ramach jednego systemu jest jego istotną zaletą badawczą.

3.3.3 Architektura CRNN jako Model Transkrypcji

Wybór architektury CRNN, łączącej konwolucyjny front-end (TabCNN) z rekurencyjnym back-endem (LSTM), jest uzasadniony jej udokumentowaną skutecznością w zadaniach transkrypcji muzycznej [Hawthorne2018Onsets, Wiggins2019TabCNN]. CNN efektywnie ekstrahuje cechy z dwuwymiarowych spektrogramów, podczas gdy dwukierunkowe LSTM modelują zależności czasowe w tych cechach. Takie połączenie pozwala na kompleksową analizę sygnału audio. Architektura ta oferuje dobry kompromis między zdolnościami modelowania a złożonością obliczeniową, co jest istotne przy ograniczonych zasobach i rozmiarze zbioru danych, w porównaniu do bardziej zasobożernych modeli, np. opartych w całości na Transformerach [Hawthorne2021Seq2SeqTranscription]. Zastosowanie optymalizatora AdamW zamiast Adam jest motywowane jego lepszą obsługą zaniku wag, co często przekłada się na lepszą generalizację modelu [Loshchilov2019AdamW].

3.3.4 Wykorzystane Biblioteki Programistyczne

Dobór narzędzi programistycznych odzwierciedla aktualne standardy w badaniach z zakresu MIR i uczenia maszynowego.

- **PyTorch** został wybrany jako główny framework do głębokiego uczenia ze względu na jego elastyczność, dynamiczne grafy obliczeniowe oraz bogaty ekosystem narzędzi wspierających rozwój modeli uczenia maszynowego [Paszke2019PyTorch].
- **Librosa** jest standardową biblioteką do analizy sygnałów audio i muzyki w Pythonie, dostarczającą implementacje funkcji do wczytywania audio, ekstrakcji cech (STFT, mel-spektrogramy, CQT) oraz augmentacji [McFee2022Librosa].
- **Mirdata** ułatwia standaryzowaną pracę ze zbiorami danych MIR, takimi jak GuitarSet, promując powtarzalność badań [Wiggins2019TabCNN].

- Inne biblioteki, takie jak NumPy, Scikit-learn, Matplotlib, JAMS i PrettyMIDI, dostarczają niezbędnych narzędzi na różnych etapach projektu, od operacji numerycznych, przez podział danych i wizualizację, po pracę z adnotacjami i generowanie plików MIDI.

Korzystanie z tych sprawdzonych narzędzi pozwoliło na skupienie się na aspektach badawczych projektu.

3.4 Podsumowanie Rozdziału

W niniejszym rozdziale przedstawiono szczegółowy opis projektu i implementacji systemu do automatycznej transkrypcji muzyki gitarowej na tabulaturę. Rdzeniem systemu jest konwolucyjno-rekurencyjna sieć neuronowa (CRNN), składająca się z konwolucyjnego ekstraktora cech oraz dwukierunkowej sieci LSTM, która przetwarza reprezentacje czasowo-częstotliwościowe sygnału audio – mel-spektrogramy lub, eksperymentalnie, spektrogramy Constant-Q. Model jest trenowany w sposób wielozadaniowy do jednoczesnej predykcji onsetów oraz numerów progów dla każdej struny gitary. Omówiono kluczowe etapy działania systemu: przygotowanie danych, w tym podział zbioru GuitarSet i ekstrakcję cech; architekturę modelu CRNN; proces treningu z wykorzystaniem złożonej funkcji straty, optymalizatora AdamW oraz technik augmentacji danych (audio i spektrogramów); a także mechanizmy ewaluacji i generowania wyników w formatach MIDI i tabulatur tekstowych. Podkreślono elastyczność systemu w zakresie wyboru reprezentacji wejściowej oraz konfiguracji parametrów. Analiza teoretyczna oraz uzasadnienie wyboru zastosowanych metod, algorytmów i narzędzi wykazały, że przyjęte rozwiązania są zgodne z aktualnym stanem wiedzy i najlepszymi praktykami w dziedzinie automatycznej transkrypcji muzycznej i uczenia maszynowego. Zaimplementowany system, dzięki swojej modułowości i oparciu na sprawdzonych technologiach, stanowi solidną platformę do przeprowadzenia dalszych badań eksperymentalnych.

Rozdział 4

Badania

Rozdział 5

Podsumowanie

Dodatki

Dokumentacja techniczna

Spis skrótów i symboli

- ATM – Automatyczna Transkrypcja Muzyczna (*Automatic Music Transcription*)
- GTT – Transkrypcja Gitarowa na Tabulaturę (*Guitar Tablature Transcription*)
- MIR – Komputerowe Pozyskiwanie Informacji Muzycznej (*Music Information Retrieval*)
- CPS – Cyfrowe Przetwarzanie Sygnałów (*Digital Signal Processing – DSP*)
- UM – Uczenie Maszynowe (*Machine Learning – ML*)
- SI – Sztuczna Inteligencja (*Artificial Intelligence – AI*)
- DFT – Dyskretna Transformata Fouriera (*Discrete Fourier Transform*)
- STFT – Krótkoczasowa Transformata Fouriera (*Short-Time Fourier Transform*)
- CQT – Transformata *Constant-Q* (*Constant-Q Transform*)
- MPE – Estymacja Wielokrotnej Wysokości Dźwięku (*Multiple Pitch Estimation*)
- NMF – Nieujemna Faktoryzacja Macierzy (*Non-negative Matrix Factorization*)
- HMM – Ukryte Modele Markowa (*Hidden Markov Models*)
- PLCA – Probabilistyczna Analiza Składowych Ukrytych (*Probabilistic Latent Component Analysis*)
- DL – Głębokie Uczenie (*Deep Learning*)
- CNN – Splotowe Sieci Neuronowe (*Convolutional Neural Networks*)
- RNN – Rekurencyjne Sieci Neuronowe (*Recurrent Neural Networks*)
- LSTM – Długa Pamięć Krótkoterminowa (*Long Short-Term Memory*)
- GRU – Bramkowana Jednostka Rekurencyjna (*Gated Recurrent Unit*)
- CRNN – Konwolucyjno-Rekurencyjne Sieci Neuronowe (*Convolutional Recurrent Neural Networks*)

- F_0 – Częstotliwość podstawowa
- X_k – k -ty współczynnik dyskretnej transformaty Fouriera
- x_n – n -ta próbka sygnału w dziedzinie czasu
- N – długość ciągu próbek sygnału (w kontekście DFT)
- i – jednostka urojona

Spis rysunków

1.1	Porównanie fragmentu zapisu nutowego i odpowiadającej mu tabulatury gitarowej dla motywu muzycznego.	3
1.2	Schematyczny przykład spektrogramu polifonicznego sygnału gitarowego, ukazujący nakładające się struktury harmoniczne (prążki reprezentujące częstotliwość podstawową i jej alikwoty) dla kilku jednocześnie brzmiących nut.	4
2.1	Po lewej: fragment sygnału audio pojedynczego dźwięku gitary w dziedzinie czasu. Po prawej: odpowiadające mu widmo amplitudowe uzyskane za pomocą transformaty Fouriera, ukazujące częstotliwość podstawową (F_0) oraz jej kolejne alikwoty (składowe harmoniczne).	14
2.2	Wizualizacja różnych reprezentacji czasowo-częstotliwościowych dla tego samego polifonicznego fragmentu gitarowego: (a) Spektrogram STFT z liniową skalą częstotliwości, (b) Spektrogram Constant-Q (CQT) z logarytmiczną skalą częstotliwości, (c) Mel-spektrogram z osią częstotliwości w skali Mel.	15
2.3	Uproszczony schemat potoku przetwarzania w systemie ATM: od sygnału audio, poprzez ekstrakcję cech, zadania składowe (MPE, detekcja onsetów/offsetów, estymacja instrumentu), aż po generowanie wyjściowej reprezentacji symbolicznej na różnych poziomach abstrakcji (ramki, nuty, partytura).	16
2.4	Przykład tej samej nuty (E4, MIDI 64) możliwej do zagrania w wielu pozycjach na gryfie gitary standardowo strojonej. Ilustracja przedstawia dźwięk E4 na strunie G (9. próg), strunie B (5. próg) oraz pustej strunie wysokiej E. Obrazuje to fundamentalne wyzwanie estymacji opalcowania w GTT. Źródło: [obrazGitaraNiejednoznaczosc]	24
3.1	Wizualizacja etykiet ramkowych dla fragmentu utworu. Górny panel przedstawia macierz onsetów, gdzie pionowe linie oznaczają moment rozpoczęcia nuty na danej strunie. Dolny panel pokazuje macierz aktywności progów, gdzie czarne obszary reprezentują czas trwania dźwięku na danej strunie.	32

3.2	Schemat architektury zaimplementowanego modelu CRNN. Przedstawia przepływ danych od wejściowego tensora spektrogramu, przez frontend konwolucyjny, backend rekurencyjny, aż po rozdzielenie na dwie głowice wyjściowe dla predykcji onsetów i progów.	35
-----	---	----

Spis tabel

2.1	Wybrane techniki gitarowe i ich manifestacje akustyczne	21
2.2	Porównanie Standardowej Notacji Muzycznej i Tabulatury Gitarowej . . .	23