



**Politechnika
Śląska**

PRACA MAGISTERSKA

Przekształcanie nagrań dźwiękowych na zapis nutowy

Łukasz KRAWCZYK

Nr albumu: 296657

Kierunek: Informatyka

Specjalność: Internet i technologie sieciowe

PROWADZĄCY PRACĘ

Dr inż. Paweł Benecki

**KATEDRA Katedra Informatyki Stosowanej
Wydział Automatyki, Elektroniki i Informatyki**

Gliwice 2025

Tytuł pracy

Przekształcanie nagrań dźwiękowych na zapis nutowy

Streszczenie

(Streszczenie pracy – odpowiednie pole w systemie APD powinno zawierać kopię tego streszczenia.)

Słowa kluczowe

(2-5 słów (fraz) kluczowych, oddzielonych przecinkami)

Thesis title

Converting audio recordings to musical notation

Abstract

(Thesis abstract – to be copied into an appropriate field during an electronic submission – in English.)

Key words

(2-5 keywords, separated by commas)

Spis treści

1	Wstęp	1
1.1	Osadzenie problemu w dziedzinie naukowej	3
1.2	Cel pracy	6
1.3	Zakres pracy	6
1.4	Zwięzła charakterystyka rozdziałów	8
1.5	Jednoznaczne określenie wkładu autora	9
2	Analiza Tematu: Podstawy i Specyfika Transkrypcji Gitarowej	11
2.1	Definicja Problemu Automatycznej Transkrypcji Muzycznej (ATM) i Jego Znaczenie	11
2.1.1	Sformułowanie problemu	11
2.1.2	Znaczenie badań nad ATM dla gitary	12
2.1.3	Kontekst naukowy i interdyscyplinarny charakter ATM	12
2.2	Podstawy Teoretyczne: Dźwięk Muzyczny i Jego Cyfrowa Reprezentacja . .	13
2.2.1	Percepcyjne i fizyczne atrybuty dźwięku muzycznego	13
2.2.2	Reprezentacja sygnału audio w dziedzinie czasu i częstotliwości . .	13
2.2.3	Analiza czasowo-częstotliwościowa i jej znaczenie dla ATM	14
2.3	Rdzeń Automatycznej Transkrypcji Muzycznej: Zadania, Poziomy i Wyzwania	15
2.3.1	Definicja, zadania składowe i poziomy abstrakcji w ATM	15
2.3.2	Transkrypcja monofoniczna vs. polifoniczna – złożoność i główne wyzwania	16
2.4	Przegląd Metod Stosowanych w Automatycznej Transkrypcji Muzycznej . .	17
2.4.1	Tradycyjne metody oparte na przetwarzaniu sygnałów	17
2.4.2	Metody oparte na uczeniu maszynowym	17
2.5	Specyfika Transkrypcji Muzyki Gitarowej na Zapis Tabulaturowy (GTT) .	20
2.5.1	Akustyczna charakterystyka sygnału gitary i jej implikacje dla trans- krypcji	20
2.5.2	Porównanie notacji standardowej i tabulaturowej dla gitary	22
2.5.3	Kluczowe wyzwania w automatycznej transkrypcji gitary na tabula- turę (GTT)	24
2.5.4	Przegląd istniejących podejść i narzędzi do GTT	25

2.6 Podsumowanie i Otwarte Problemy	27
3 [Tytuł rozdziału]	29
4 Badania	31
5 Podsumowanie	33
Bibliografia	37
Dokumentacja techniczna	41
Spis skrótów i symboli	43
Spis rysunków	45
Spis tabel	47

Rozdział 1

Wstęp

Automatyczna Transkrypcja Muzyczna (ATM) (*Automatic Music Transcription*) stanowi jedno z kluczowych i jednocześnie najbardziej złożonych zadań w dziedzinie komputerowej analizy muzyki. W swej istocie, ATM jest procesem konwersji sygnału akustycznego, będącego fizyczną manifestacją muzyki, na jego symboliczną, strukturalną reprezentację [14, 3]. Celem tego procesu jest przekształcenie ciągłego sygnału audio w dyskretny zestaw symboli muzycznych, takich jak tradycyjne nuty określające wysokość i czas trwania dźwięku, lub – co jest przedmiotem szczególnego zainteresowania w niniejszej pracy – w zapis tabulaturowy. Interdyscyplinarny charakter Automatycznej Transkrypcji Muzycznej jest niezaprzeczalny, gdyż skuteczna realizacja jej zadań wymaga integracji wiedzy i metodologii pochodzących z wielu, pozornie odległych, dziedzin nauki i techniki. Do najważniejszych z nich należą:

- **Cyfrowe Przetwarzanie Sygnałów (CPS)** (*Digital Signal Processing – DSP*): Dostarcza ono fundamentalnych narzędzi do analizy, transformacji i manipulacji sygnałem audio w dziedzinie czasu i częstotliwości. Techniki takie jak filtracja, analiza spektralna czy transformacje czasowo-częstotliwościowe są nieodzowne w procesie ekstrakcji informacji z surowego sygnału dźwiękowego [14]. Zaawansowane metody CPS pozwalają na wstępne przygotowanie sygnału, redukcję szumów oraz identyfikację podstawowych cech akustycznych, które następnie mogą być interpretowane w kontekście muzycznym. Przykładem fundamentalnego narzędzia CPS, ilustrującego przejście z dziedziny czasu do dziedziny częstotliwości, jest dyskretna transformata Fouriera (DFT) (*Discrete Fourier Transform*). Dla skończonego ciągu próbek sygnału x_n o długości N , jej k -ty współczynnik X_k jest zdefiniowany jako:

$$X_k = \sum_{n=0}^{N-1} x_n \cdot e^{-i \frac{2\pi}{N} kn} \quad (1.1)$$


gdzie n jest indeksem próbki w dziedzinie czasu, k jest indeksem częstotliwości, a i jest jednostką urojoną. Wzór ten jest podstawą wielu algorytmów analizy częstotli-

wościowej stosowanych w ATM.

- **Rozpoznawanie Wzorców** (*Pattern Recognition*) oraz **Uczenie Maszynowe** (UM) (*Machine Learning – ML*): Te dziedziny odgrywają kluczową rolę w identyfikacji złożonych struktur muzycznych, takich jak pojedyncze nuty, akordy, rytmy czy motywy melodyczne, w często zaszumionym i polifonicznym sygnale audio [3]. Współczesne systemy ATM w coraz większym stopniu opierają się na zaawansowanych modelach uczenia maszynowego, w szczególności na sieciach neuronowych i głębokim uczeniu (*Deep Learning*), które potrafią automatycznie uczyć się hierarchicznych reprezentacji cech muzycznych bezpośrednio z danych [5]. Dynamiczny rozwój w obszarze głębokiego uczenia bezpośrednio przekłada się na postępy w ATM, umożliwiając tworzenie modeli zdolnych do przetwarzania coraz bardziej skomplikowanych sygnałów muzycznych z niespotykaną dotąd dokładnością.
- **Sztuczna Inteligencja (SI)** (*Artificial Intelligence – AI*): Jako szersza dziedzina, obejmuje ona uczenie maszynowe, ale także inne aspekty, takie jak reprezentacja wiedzy muzycznej oraz procesy poznawcze związane z percepcją i wnioskowaniem w kontekście muzycznym [3]. Rozwój SI dostarcza ram koncepcyjnych i narzędziowych dla budowy inteligentnych systemów transkrypcji.
- **Muzykologia**: Dostarcza niezbędnej wiedzy teoretycznej o strukturze muzyki, notacji, harmonii, rytmie oraz praktykach wykonawczych [10]. Zrozumienie zasad muzycznych jest kluczowe nie tylko dla interpretacji wyników generowanych przez systemy ATM, ale również dla projektowania algorytmów, które uwzględniają kontekst muzyczny i dążą do tworzenia transkrypcji użytecznych z perspektywy muzykologicznej i wykonawczej.

Potencjalne obszary zastosowań systemów ATM są szerokie i różnorodne, co podkreśla ich rosnące znaczenie zarówno w badaniach naukowych, jak i w praktyce muzycznej. Do najważniejszych aplikacji należą: wsparcie w edukacji muzycznej, na przykład poprzez tworzenie systemów do automatyzacji ćwiczeń gry na instrumencie, analizę postępów ucznia czy generowanie spersonalizowanych materiałów dydaktycznych [3]. Systemy ATM mogą również znacząco ułatwić proces tworzenia i aranżacji muzyki, na przykład poprzez wspieranie modyfikacji i rearanżacji istniejących utworów [2]. Dla producentów muzycznych, ATM oferuje narzędzia do wizualizacji treści muzycznej i inteligentnej edycji nagrań [3]. Ponadto, technologie te są wykorzystywane w systemach wyszukiwania i kategoryzacji muzyki w dużych zbiorach danych, na przykład poprzez umożliwienie wyszukiwania utworów na podstawie ich melodii, harmonii czy rytmu [3]. Tytuł niniejszej pracy, „Przekształcanie nagrań dźwiękowych na zapis nutowy”, odnosi się do centralnego problemu ATM. Należy jednak podkreślić, że termin „zapis nutowy” jest pojęciem szerokim, obejmującym różnorodne systemy notacji muzycznej. W kontekście niniejszego opracowania, szczególna uwaga

zostanie poświęcona specyficznej formie zapisu, jaką jest tabulatura gitarowa. Tabulatura, w odróżnieniu od tradycyjnej notacji nutowej skupiającej się *primarnie* na wysokości i czasie trwania dźwięku, jest graficzną reprezentacją wskazującą bezpośrednio pozycje palców na gryfie instrumentu – konkretne struny i progi, które należy nacisnąć, aby uzyskać pożądany dźwięk [18].



Rysunek 1.1: Porównanie fragmentu zapisu nutowego i odpowiadającej mu tabulatury gitarowej dla motywu muzycznego.


Wybór tabulatury jako docelowej formy zapisu w tej pracy nie jest przypadkowy. Wynika on ze specyfiki gitary jako instrumentu oraz z ogromnej popularności tej formy notacji wśród gitarzystów [18]. Rosnąca popularność tabulatur, często udostępnianych online, stwarza specyficzne zapotrzebowanie na systemy ATM zdolne do generowania tego właśnie formatu. Nie jest to jedynie kwestia preferencji użytkowników; tabulatura często zawiera informacje o charakterze performatywnym, takie jak konkretne opalcowanie czy użycie technik gitarowych, których brakuje w standardowej notacji nutowej. Skuteczne systemy ATM generujące tabulatury mogą zatem zdemokratyzować proces nauki gry na gitarze oraz tworzenia muzyki, obniżając barierę wejścia dla osób, które nie posługują się biegle tradycyjnym zapisem nutowym, ale rozumieją intuicyjny charakter tabulatury. Ten wybór stanowi naturalne przejście do dalszych, bardziej szczegółowych rozważań przedstawionych w kolejnych rozdziałach pracy.

1.1 Osadzenie problemu w dziedzinie naukowej

Przedmiotem niniejszej pracy jest zagadnienie automatycznej transkrypcji muzyki gitarowej do postaci tabulatury, co sytuuje ją w szerokim kontekście badań prowadzonych w ramach dziedziny naukowej znanej jako *Music Information Retrieval (MIR)*. MIR, czyli komputerowe pozyskiwanie informacji muzycznej, jest interdyscyplinarnym polem badawczym zajmującym się analizą, przetwarzaniem, wyszukiwaniem, organizacją i dostępem do informacji zawartej w muzyce, zarówno w jej formie akustycznej, jak i symbolicznej. Obserwowany w ostatnich dekadach gwałtowny wzrost ilości dostępnych cyfrowych treści muzycznych, na przykład w ramach cyfrowych bibliotek muzycznych i serwisów streamingowych [3], generuje rosnące zapotrzebowanie na zautomatyzowane narzędzia do ich analizy. Narzędzia te są niezbędne do efektywnego zarządzania ogromnymi repozytoriami muzyki,

ich przeszukiwania, kategoryzacji oraz personalizacji dostępu dla użytkowników. ATM jest jednym z kluczowych zadań w ramach MIR, umożliwiającym transformację sygnału audio na bogatszą, symboliczną reprezentację, która może być dalej przetwarzana i analizowana. Szczególną uwagę w kontekście niniejszej pracy należy poświęcić wyzwaniom związanym z transkrypcją muzyki gitarowej. Gitara, będąca instrumentem niezwykle popularnym i wszechstronnym, wykorzystywanym w niemal każdym gatunku muzycznym, stawia przed systemami ATM szereg specyficznych trudności:

- **Polifoniczność:** Gitara jest instrumentem polifonicznym, co oznacza zdolność do jednoczesnego wydawania wielu dźwięków (standardowo do sześciu, po jednym na każdej strunie) [5]. Nakładanie się składowych harmonicznym wielu jednocześnie brzmiących dźwięków w sygnale audio znacząco komplikuje proces ich separacji i identyfikacji.



Rysunek 1.2: Schematyczny przykład spektrogramu polifonicznego sygnału gitarowego, ukazujący nakładające się struktury harmoniczne (prążki reprezentujące częstotliwość podstawową i jej alikwoty) dla kilku jednocześnie brzmiących nut.

- **Bogactwo technik artykulacyjnych:** Gitarzyści wykorzystują szeroki wachlarz technik artykulacyjnych, takich jak podciąganie strun (*bending*), ślizgi (*sliding*), młoteczkowanie (*hammer-on*), odrywanie (*pull-off*), vibrato (*vibrato*) czy tłumienie strun dłonią (*palm-muting*). Każda z tych technik w unikalny sposób modyfikuje charakterystykę sygnału akustycznego (np. jego wysokość, amplitudę, barwę w czasie) i jest kluczowa dla wiernej transkrypcji, zwłaszcza do formatu tabulatury, który często zawiera symbole oznaczające te techniki.
- **Duża zmienność barwy dźwięku (*timbre*):** Barwa dźwięku gitary jest niezwykle zróżnicowana i zależy od wielu czynników, takich jak typ instrumentu (np. gitara

akustyczna, klasyczna, elektryczna), rodzaj użytych strun, sposób ich pobudzenia (kostką, palcami), a w przypadku gitar elektrycznych – od ustawień wzmacniacza i zastosowanych efektów gitarowych [18]. Ta duża wariabilność barwy stanowi poważne wyzwanie dla modeli uczenia maszynowego, które muszą generalizować swoją wiedzę na różne instancje dźwięków gitarowych.

- **Identyczność wysokości dźwięku na różnych strunach i progach:** Jedną z charakterystycznych cech gitary jest możliwość zagrania dźwięku o tej samej wysokości w wielu różnych pozycjach na gryfie (tj. na różnych kombinacjach struny i progu) [18]. O ile dla tradycyjnej notacji nutowej ta wieloznaczność nie jest problemem, o tyle dla generowania tabulatury, która musi precyzyjnie wskazać miejsce zagrania dźwięku, jest to fundamentalne wyzwanie. Wybór odpowiedniej pozycji często zależy od kontekstu muzycznego, grywalności (łatwości wykonania) i preferencji wykonawcy.

Pomimo znaczących postępów, jakie dokonały się w dziedzinie ATM w ostatnich latach, zwłaszcza dzięki zastosowaniu zaawansowanych technik uczenia maszynowego, istniejące systemy wciąż borykają się z ograniczeniami, prowadzącymi do typowych błędów, takich jak pomyłki oktawowo, niepoprawne detekcje nut czy niedokładności czasowe [3]. Człowiek, dokonując transkrypcji, opiera się nie tylko na percepcji sygnału akustycznego, ale również na swojej rozległej wiedzy muzycznej, znajomości teorii muzyki, konwencji stylistycznych oraz kontekstu kulturowego. Maszyny, mimo coraz doskonalszych algorytmów, wciąż mają trudności z pełnym uwzględnieniem tych aspektów [10]. Ograniczenia te są szczególnie widoczne w przypadku transkrypcji muzyki polifonicznej, wykonywanej na instrumentach o złożonej charakterystyce akustycznej, takich jak gitara [5]. Niedoskonałość obecnych systemów, zwłaszcza w kontekście precyzyjnego odwzorowania niuansów wykonawczych gitary i generowania użytecznych, grywalnych tabulatur, stanowi silny impuls do poszukiwania nowych, bardziej efektywnych rozwiązań. Ta luka badawcza jest główną motywacją do podjęcia tematu niniejszej pracy. Popularność gitary oraz ogromna ilość dostępnych nagrań gitarowych, często pozbawionych wiarygodnych transkrypcji, tworzą naturalne zapotrzebowanie na narzędzia MIR, w tym ATM. Postępy w tej dziedzinie mogą z kolei stymulować dalsze tworzenie i udostępnianie muzyki, tworząc pozytywną pętlę sprzężenia zwrotnego. Co więcej, rozwój precyzyjnych systemów ATM dla gitary może odegrać istotną rolę w dokumentacji i archiwizacji unikalnych stylów gitarowych oraz technik wykonawczych, stanowiących ważne elementy dziedzictwa kulturowego. Otwartym problemem pozostaje również ocena jakości transkrypcji, zwłaszcza w kontekście tabulatur, co zostało zasygnalizowane w literaturze [19].

1.2 Cel pracy

Głównym celem niniejszej pracy magisterskiej jest zaprojektowanie, implementacja oraz weryfikacja eksperymentalna systemu służącego do automatycznej transkrypcji polifonicznych nagrań audio gitary na zapis tabulaturowy. Kluczowym elementem realizacji tego celu jest wykorzystanie publicznie dostępnego zbioru danych Guitarset. Zbiór ten, opisany i wykorzystany w badaniach nad transkrypcją gitarową (np. [18]), został specjalnie przygotowany do tego celu i charakteryzuje się unikalnymi cechami, takimi jak dostarczanie nagrań heksafonicznych (sygnału z każdej struny osobno) wraz z precyzyjnymi adnotacjami dotyczącymi wysokości dźwięku, czasu jego trwania oraz, co szczególnie istotne, informacji o strunie i progu, na którym dany dźwięk został zagrany [18]. Wybór zbioru Guitarset jest zatem nieprzypadkowy; jego struktura bezpośrednio adresuje problem niejednoznaczności przypisania dźwięku do konkretnej pozycji na gryfie, co jest fundamentalne przy tworzeniu wiarygodnych danych uczących i testowych dla zadania generowania tabulatury. System opracowany w ramach tej pracy ma dążyć do precyzyjnego odwzorowania partii gitarowych w formie tabulatury. Oznacza to nie tylko poprawną identyfikację atrybutów muzycznych takich jak wysokość i czas trwania dźwięków, ale przede wszystkim ich prawidłowe przypisanie do odpowiednich strun i progów na gryfie gitary. Dążenie do precyzji obejmuje również próbę radzenia sobie z wyzwaniami specyficznymi dla transkrypcji gitary, które zostały omówione w poprzednim podrozdziale, takimi jak wysoki stopień polifonii, zróżnicowane techniki artykulacyjne oraz konieczność generowania tabulatury uwzględniającej aspekty grywalności. Realizacja tak zdefiniowanego celu pracy, czyli stworzenie efektywnego systemu transkrypcji nagrań gitarowych do postaci tabulatury, może przyczynić się do powstania nowych narzędzi wspierających kreatywność i edukację gitarzystów. Przykładowo, taki system mógłby służyć do automatycznego generowania tabulatur z improwizowanych fragmentów muzycznych, ułatwiać analizę złożonych partii gitarowych znanych wykonawców, czy też stanowić cenne wsparcie w procesie nauki gry na instrumencie.

1.3 Zakres pracy

Realizacja postawionego celu badawczego obejmuje następujące, kluczowe etapy:

- Przeprowadzenie szczegółowej analizy literatury naukowej dotyczącej automatycznej transkrypcji muzycznej, ze szczególnym naciskiem na metody stosowane w transkrypcji muzyki gitarowej, specyfikę sygnału generowanego przez ten instrument oraz różne aspekty notacji tabulaturowej, w tym jej strukturę i konwencje zapisu.
- Zaprojektowanie architektury systemu do automatycznej transkrypcji, która będzie uwzględniać specyfikę zadania, charakterystykę danych wejściowych (polifoniczne

nagrania gitary akustycznej) i wyjściowych (zapis tabulaturowy) oraz dostępne narzędzia i technologie, w tym potencjalne wykorzystanie modeli głębokiego uczenia.

- Implementacja kluczowych modułów składowych systemu, obejmujących co najmniej:
 - Moduł przetwarzania wstępnego sygnału audio (*audio preprocessing*), mający na celu przygotowanie sygnału do dalszej analizy, np. poprzez normalizację, segmentację czy redukcję szumów.
 - Moduł ekstrakcji cech akustycznych (*acoustic feature extraction*), odpowiedzialny za przekształcenie przetworzonego sygnału audio w reprezentację numeryczną, która efektywnie koduje informacje istotne dla rozpoznawania dźwięków gitarowych i ich atrybutów. Rozważone zostaną zarówno klasyczne cechy akustyczne [14], jak i cechy uzyskiwane automatycznie z wykorzystaniem metod głębokiego uczenia [5].
 - Moduł predykcyjny, oparty na wybranych technikach uczenia maszynowego, którego zadaniem będzie generowanie sekwencji zdarzeń tabulaturowych (struna, próg, czas rozpoczęcia, czas trwania) na podstawie wyekstrahowanych cech akustycznych.
- Adaptacja i wykorzystanie publicznie dostępnego zbioru danych Guitarset, opisanego m.in. w [18], do procesu trenowania, walidacji oraz testowania opracowanego systemu. Etap ten będzie obejmował przygotowanie danych do formatu wymaganego przez zaimplementowany model, w tym potencjalne techniki augmentacji danych w celu zwiększenia robustości modelu.
- Zdefiniowanie i dobór odpowiednich metryk oceny jakości transkrypcji tabulaturowej. Metryki te muszą uwzględniać nie tylko poprawność wykrytych nut pod względem ich wysokości, czasu rozpoczęcia i czasu trwania, ale także, co kluczowe dla tego zadania, poprawność przypisania poszczególnych dźwięków do konkretnych strun i progów gitary.
- Przeprowadzenie kompleksowych badań eksperymentalnych mających na celu weryfikację skuteczności i wydajności zaproponowanego rozwiązania. Wyniki uzyskane przez system będą porównywane z adnotacjami referencyjnymi ze zbioru Guitarset oraz, w miarę możliwości, z wynikami innych istniejących metod lub systemów transkrypcji gitarowej, aby ocenić postęp względem aktualnego stanu wiedzy (*state-of-the-art*) [3].
- Dokładna analiza uzyskanych wyników eksperymentalnych, obejmująca zarówno ocenę ilościową (na podstawie zdefiniowanych metryk), jak i jakościową (np. poprzez analizę typowych błędów popełnianych przez system). Na tej podstawie zostaną

zidentyfikowane mocne i słabe strony opracowanego systemu oraz sformułowane wnioski końcowe i rekomendacje dotyczące potencjalnych ulepszeń oraz dalszych kierunków badań w tej dziedzinie.

Niniejsza praca będzie koncentrować się na rozwiązaniu konkretnego problemu o charakterze naukowo-badawczym. Osiągnięcie tego celu nastąpi poprzez opracowanie innowacyjnego rozwiązania technicznego, jakim jest system do automatycznej transkrypcji gitarowej na tabulaturę, oraz udokumentowanie kompetencji inżynierskich autora w zakresie projektowania, implementacji i weryfikacji systemów opartych na przetwarzaniu sygnałów i uczeniu maszynowym. Przedstawiony zakres pracy odzwierciedla standardowy cykl życia projektu badawczo-rozwojowego w dziedzinie uczenia maszynowego, co zapewnia metodyczne i kompleksowe podejście do postawionego problemu. Szczególny nacisk położony na adaptację zbioru Guitarset oraz zdefiniowanie specyficznych metryk oceny jakości transkrypcji tabulaturowej wskazuje na potencjalny wkład pracy nie tylko w sam system, ale również w metodykę badań nad transkrypcją gitarową.

1.4 Zwięzła charakterystyka rozdziałów

Struktura niniejszej pracy magisterskiej została zaprojektowana w sposób umożliwiający logiczne i spójne przedstawienie podjętej problematyki, przeprowadzonych badań oraz uzyskanych wyników. Poniżej przedstawiono zwięzłą charakterystykę poszczególnych rozdziałów:

Rozdział 1 (Wstęp) Prezentowany rozdział. Wprowadza on w problematykę pracy, definiuje automatyczną transkrypcję muzyczną (ATM) i jej specyfikę w kontekście gitary i tabulatury. Osadza problem w dziedzinie naukowej *Music Information Retrieval (MIR)*, omawia wyzwania związane z transkrypcją gitarową. Formułuje cel i zakres pracy, przedstawia strukturę kolejnych rozdziałów oraz jednoznacznie określa wkład autora.

Rozdział 2 (Analiza Tematu) Rozdział ten poświęcony będzie dogłębnemu przedstawieniu podstaw teoretycznych niezbędnych do zrozumienia problematyki pracy. Omówione zostaną fundamentalne pojęcia dotyczące dźwięku muzycznego, jego cyfrowej reprezentacji [14] oraz podstawowych metod jego analizy. Następnie, zaprezentowane zostaną ogólne zagadnienia związane z automatyczną transkrypcją muzyczną, po czym szczegółowa uwaga zostanie skupiona na specyfice transkrypcji gitarowej. Dokładnie scharakteryzowany zostanie sygnał gitary, jego cechy akustyczne oraz notacja tabulaturowa. Rozdział ten płynnie przejdzie do sprecyzowania problematyki badawczej podejmowanej w niniejszej pracy.

Rozdział 3 (Przedmiot Pracy) W tym rozdziale opisane zostanie autorskie rozwiązanie problemu automatycznej transkrypcji polifonicznych nagrań gitarowych na zapis tabulaturowy. Zaprezentowana zostanie szczegółowa architektura zaimplementowanego systemu, wraz z opisem poszczególnych jego modułów. Dokładnie scharakteryzowany zostanie wykorzystany zbiór danych Guitarset, którego cechy i zastosowanie w badaniach opisano m.in. w [18], oraz proces jego adaptacji na potrzeby systemu. Uzasadniony zostanie również wybór zastosowanych metod przetwarzania sygnału, ekstrakcji cech, algorytmów uczenia maszynowego oraz wykorzystanych narzędzi programistycznych.

Rozdział 4 (Badania) Ten rozdział będzie poświęcony prezentacji metodyki oraz wyników przeprowadzonych badań eksperymentalnych. Opisane zostanie środowisko badawcze, sposób przygotowania danych testowych oraz zdefiniowane metryki oceny jakości transkrypcji. Uzyskane wyniki zostaną zaprezentowane w sposób ilościowy (np. w postaci tabel i wykresów) oraz jakościowy. Następnie wyniki te zostaną poddane szczegółowej analizie i dyskusji, w tym identyfikacji typowych błędów popełnianych przez system oraz porównaniu z istniejącymi rozwiązaniami lub stanem wiedzy.

Rozdział 5 (Podsumowanie) Ostatni rozdział pracy będzie zawierał syntetyczne podsumowanie wszystkich zrealizowanych prac. Zaprezentowane zostaną kluczowe wnioski końcowe wynikające z przeprowadzonych badań i analiz. Oceniony zostanie stopień realizacji postawionego celu pracy. Wskazane zostaną również potencjalne kierunki dalszego rozwoju opracowanego systemu oraz możliwe przyszłe badania w tej dziedzinie, być może w nawiązaniu do otwartych problemów i wyzwań identyfikowanych w literaturze.

Przedstawiona struktura pracy jest zgodna ze standardami pisania prac naukowo-badawczych w dziedzinach technicznych, co zapewnia jej spójność i kompletność. Wyraźne oddzielenie rozdziału poświęconego analizie tematu od rozdziału opisującego przedmiot pracy pozwala na klarowne rozróżnienie między przeglądem istniejącej wiedzy a oryginalnym wkładem autora, co jest kluczowe dla rzetelnej oceny pracy magisterskiej.

1.5 Jednoznaczne określenie wkładu autora

W tej części precyzyjnie określony zostaje indywidualny wkład autora w realizację niniejszej pracy. Obejmuje on następujące kluczowe aspekty, za które autor był samodzielnie odpowiedzialny:

- Samodzielne przeprowadzenie gruntownych studiów literaturowych oraz krytyczną analizę aktualnego stanu wiedzy i badań w dziedzinie automatycznej transkrypcji mu-

zycznej, ze szczególnym uwzględnieniem problematyki transkrypcji muzyki gitarowej oraz specyfiki zapisu tabulaturowego.

- Opracowanie oryginalnej koncepcji oraz zaprojektowanie architektury systemu przeznaczonego do automatycznej transkrypcji polifonicznych nagrań gitarowych na postać tabulatury, uwzględniającej specyficzne wyzwania związane z tym zadaniem.
- Implementacja algorytmów przetwarzania sygnału audio, metod ekstrakcji cech akustycznych oraz modeli uczenia maszynowego, które stanowią rdzeń funkcjonalny opracowanego systemu transkrypcji.
- Adaptacja, przygotowanie oraz analiza publicznie dostępnego zbioru danych Guitarset na potrzeby procesu trenowania, walidacji i kompleksowej ewaluacji zaprojektowanego i zaimplementowanego systemu.
- Zaprojektowanie metodyki oraz samodzielne przeprowadzenie kompleksowych badań eksperymentalnych, mających na celu weryfikację skuteczności, wydajności oraz ograniczeń opracowanego rozwiązania w kontekście transkrypcji gitarowej na tabulaturę.
- Krytyczna analiza i interpretacja uzyskanych wyników eksperymentalnych, w tym identyfikacja mocnych i słabych stron systemu, oraz ocena istotności tych wyników w kontekście istniejących rozwiązań i aktualnego stanu wiedzy w dziedzinie.
- Sformułowanie wniosków końcowych podsumowujących całość przeprowadzonych prac badawczych i implementacyjnych, a także przedstawienie propozycji dotyczących potencjalnych ulepszeń systemu oraz możliwych kierunków dalszych badań.

Powyższe wyszczególnienie ma na celu jednoznaczne wyodrębnienie oryginalnego wkładu studenta w identyfikację i rozwiązanie postawionego problemu badawczego, a także w opracowanie, implementację i weryfikację opisanego systemu informatycznego. Wymienione punkty pokrywają cały proces badawczy, od fazy koncepcyjnej, poprzez realizację techniczną, aż po analizę wyników i formułowanie wniosków, co świadczy o kompleksowym i samodzielnym charakterze pracy, zgodnie z oczekiwaniami stawianymi pracom magisterskim. Nacisk na „oryginalną koncepcję” oraz „krytyczną analizę” podkreśla aspiracje pracy do wniesienia wartościowego wkładu w rozwój dziedziny, wykraczającego poza jedynie odtwórcze zastosowanie znanych metod.

Rozdział 2

Analiza Tematu: Teoretyczne Podstawy Transkrypcji Muzycznej i Specyfika Transkrypcji Gitarowej

Niniejszy rozdział stanowi dogłębną analizę problematyki automatycznej transkrypcji muzycznej (ATM), ze szczególnym uwzględnieniem jej zastosowania do muzyki gitarowej i generowania zapisu tabulaturowego. Celem jest osadzenie tematyki pracy w szerszym kontekście naukowym oraz identyfikacja kluczowych wyzwań związanych z tym zagadnieniem. Przedstawione zostaną podstawy teoretyczne, omówione główne podejścia i technologie stosowane w ATM, a także zidentyfikowane zostaną obszary wymagające dalszych badań w dziedzinie transkrypcji gitarowej, co pozwoli na pełniejsze zrozumienie złożoności podejmowanego problemu. Należy przy tym zaznaczyć, że choć celem jest identyfikacja obszarów wymagających dalszych badań, niniejszy rozdział skupia się na przeglądzie istniejącego stanu wiedzy.

2.1 Definicja Problemu Automatycznej Transkrypcji Muzycznej (ATM) i Jego Znaczenie

Automatyczna transkrypcja muzyczna jest fundamentalnym zagadnieniem w dziedzinie komputerowej analizy muzyki, którego zrozumienie wymaga precyzyjnego zdefiniowania problemu oraz określenia jego wagi w kontekście naukowym i praktycznym. Poniższe podrozdziały szczegółowo omawiają te aspekty.

2.1.1 Sformułowanie problemu

Automatyczna transkrypcja muzyczna (ATM) (*Automatic Music Transcription*) jest procesem przekształcania sygnału audio zawierającego muzykę na symboliczną reprezenta-

cję muzyczną, najczęściej w postaci zapisu nutowego, jego odpowiednika (np. w formacie piano-roll) lub bezpośrednio w formacie specyficznym dla danego instrumentu [14, 3]. W kontekście muzyki gitarowej, problem ten precyzuje się jako automatyczną transkrypcję polifonicznych nagrań gitarowych na zapis tabulaturowy (*Guitar Tablature Transcription, GTT*). Zadanie to wykracza poza prostą identyfikację wysokości i czasu trwania dźwięków; obejmuje również ich precyzyjne przypisanie do konkretnych strun i progów na gryfie gitary [18]. Pełna transkrypcja tabulaturowa dąży także do rozpoznania technik artykulacyjnych charakterystycznych dla gitary, takich jak podciągnięcia strun (*bends*), *hammer-on*, *pull-off* czy *vibrato* [16]. Techniki te są kluczowe dla wiernego odtworzenia utworu i mają istotny wpływ na jego brzmienie oraz interpretację.

2.1.2 Znaczenie badań nad ATM dla gitary

Badania nad automatyczną transkrypcją muzyki gitarowej posiadają wielowymiarowe znaczenie. Przede wszystkim, dostarczają narzędzi wspierających muzyków i proces edukacji muzycznej, ułatwiając dostęp do notacji, umożliwiając efektywniejszą naukę gry oraz pogłębioną analizę utworów [3, 2]. Mają również istotne zastosowanie w archiwizacji i dokumentacji dziedzictwa muzycznego, pozwalając na zachowanie unikalnych stylów wykonawczych i technik gitarowych, które mogłyby inaczej ulec zapomnieniu [10]. Należy jednak zauważyć, że pomimo potencjału, obecne systemy ATM mogą nie zawsze oferować przewagę ilościową dla doświadczonych transkrybentów w specyficznych kontekstach, np. etnomuzykologicznych, gdzie krytyczna jest dokładność rytmiczna i precyzja notacji [10]. Systemy ATM mogą ponadto stanowić wartościowe wsparcie dla kompozytorów i producentów muzycznych, oferując nowe możliwości w procesie twórczym i produkcyjnym [3, 2]. Nie bez znaczenia jest fakt, że rozwój GTT odpowiada na realne zapotrzebowanie rynku, wynikające z globalnej popularności gitary jako instrumentu oraz tabulatury jako preferowanej przez wielu gitarzystów formy zapisu muzycznego [18].

2.1.3 Kontekst naukowy i interdyscyplinarny charakter ATM

Automatyczna transkrypcja muzyczna jest integralną częścią szerszej dziedziny badawczej znanej jako *Music Information Retrieval (MIR)* [3], która zajmuje się pozyskiwaniem, analizą i zarządzaniem informacją muzyczną. ATM jest jednym z najbardziej złożonych zadań w MIR, wymagającym synergii wiedzy i metod z wielu dyscyplin. Fundamentalne znaczenie ma tu cyfrowe przetwarzanie sygnałów (CPS), dostarczające narzędzi do analizy sygnału audio [14]. Równie istotne są uczenie maszynowe (UM) i szeroko pojęta sztuczna inteligencja (SI), które umożliwiają tworzenie modeli zdolnych do nauki złożonych wzorców muzycznych i podejmowania decyzji transkrypcyjnych na podstawie danych [3, 13, 5]. Wiedza z zakresu muzykologii, dotycząca teorii muzyki, notacji i praktyk wykonawczych, jest niezbędna do projektowania systemów generujących transkrypcje poprawne i użyteczne

muzycznie, a także do krytycznej oceny ich wyników [10].

2.2 Podstawy Teoretyczne: Dźwięk Muzyczny i Jego Cyfrowa Reprezentacja


Zrozumienie procesów leżących u podstaw automatycznej transkrypcji muzycznej wymaga uprzedniego zapoznania się z fundamentalnymi właściwościami dźwięku muzycznego oraz sposobami jego cyfrowej reprezentacji i analizy. Niniejsza sekcja przybliży te kluczowe koncepcje.

2.2.1 Percepcyjne i fizyczne atrybuty dźwięku muzycznego

Dźwięk muzyczny, z perspektywy percepcji, charakteryzowany jest przez cztery podstawowe atrybuty: wysokość, głośność, barwę i czas trwania [14]. Wysokość jest bezpośrednio związana z częstotliwością podstawową (F_0) drgań źródła dźwięku. Głośność to subiektywna ocena natężenia dźwięku. Barwa, określana jako „kolor” dźwięku, pozwala odróżnić dźwięki o tej samej wysokości i głośności, lecz pochodzące z różnych instrumentów lub generowane różnymi technikami; jest ona ściśle powiązana ze spektrum harmonicznym dźwięku (rozkładem i względnymi amplitudami składowych harmonicznymi) oraz jego obwiednią czasową. Czas trwania definiuje, jak długo dźwięk jest postrzegany. Obwiednia amplitudy dźwięku, często modelowana jako ADSR (*Attack, Decay, Sustain, Release*), odgrywa kluczową rolę w kształtowaniu charakteru brzmieniowego, zwłaszcza dla instrumentów szarpanych, takich jak gitara [14]. Fazy ataku (narastania), początkowego zaniku, podtrzymania i końcowego wybrzmiewania definiują dynamiczny profil dźwięku, przy czym dla gitary fazy zaniku i wybrzmiewania są szczególnie złożone i zależne od instrumentu oraz techniki gry.

2.2.2 Reprezentacja sygnału audio w dziedzinie czasu i częstotliwości

Cyfrowy sygnał audio jest sekwencją próbek reprezentujących amplitudę fali akustycznej w kolejnych, dyskretnych punktach czasu [14]. Analiza wyłącznie w dziedzinie czasu nie ujawnia jednak w pełni struktury muzycznej sygnału. Kluczowa jest analiza częstotliwościowa, pozwalająca zidentyfikować składowe częstotliwościowe. Przejście z dziedziny czasu do dziedziny częstotliwości realizowane jest za pomocą transformaty Fouriera, która dekomponuje sygnał na sumę składowych sinusoidalnych o różnych częstotliwościach i amplitudach, tworząc jego widmo częstotliwościowe [14]. Dyskretna transformata Fouriera (DFT), zdefiniowana wzorem (1.1) w Rozdziale 1, jest podstawowym narzędziem tej analizy.




Rysunek 2.1: Po lewej: fragment sygnału audio pojedynczego dźwięku gitary w dziedzinie czasu. Po prawej: odpowiadające mu widmo amplitudowe uzyskane za pomocą transformaty Fouriera, ukazujące częstotliwość podstawową (F_0) oraz jej kolejne alikwoty (składowe harmoniczne).

2.2.3 Analiza czasowo-częstotliwościowa i jej znaczenie dla ATM

Charakterystyki częstotliwościowe muzyki zmieniają się w czasie, dlatego w ATM niezbędne są metody analizy czasowo-częstotliwościowej. Krótkoczasowa transformata Fouriera (STFT) jest jedną z fundamentalnych technik, polegającą na analizie Fouriera krótkich, nakładających się segmentów sygnału [14, 5]. Wynikiem STFT jest spektrogram – dwuwymiarowa reprezentacja energii sygnału w funkcji czasu i częstotliwości, która stanowi podstawę dla wielu systemów ATM. Należy pamiętać o inherentnym kompromisie STFT między rozdzielczością czasową a częstotliwościową.

Alternatywą, często lepiej dostosowaną do percepcji muzyki, jest transformata *Constant-Q* (CQT) [3, 18, 19]. CQT wykorzystuje pasma częstotliwości o szerokościach proporcjonalnych do ich częstotliwości środkowych, co odpowiada logarytmicznej naturze ludzkiej percepcji wysokości dźwięku i organizacji skal muzycznych.

Skala Mel, również oparta na badaniach percepcyjnych, jest kolejną nieliniową skalą częstotliwości powszechnie stosowaną w MIR [3]. Mel-spektrogramy, czyli spektrogramy z osią częstotliwości przekształconą na skalę Mel, są standardowym wejściem dla wielu modeli głębokiego uczenia w ATM, gdyż lepiej odzwierciedlają ludzką wrażliwość na zmiany wysokości dźwięku. Ewolucja od STFT, poprzez CQT, do Mel-spektrogramów odzwierciedla dążenie do tworzenia reprezentacji cech bardziej zgodnych z ludzką percepcją i efektywniejszych dla algorytmów uczenia maszynowego.



Rysunek 2.2: Wizualizacja różnych reprezentacji czasowo-częstotliwościowych dla tego samego polifonicznego fragmentu gitarowego: (a) Spektrogram STFT z liniową skalą częstotliwości, (b) Spektrogram Constant-Q (CQT) z logarytmiczną skalą częstotliwości, (c) Mel-spektrogram z osią częstotliwości w skali Mel.


2.3 Rdzeń Automatycznej Transkrypcji Muzycznej: Zadania, Poziomy i Wyzwania

Automatyczna transkrypcja muzyczna, mimo swej pozornie prostej definicji, jest procesem wieloetapowym, obejmującym szereg skomplikowanych zadań cząstkowych. Zrozumienie tych zadań, poziomów abstrakcji na jakich operują oraz inherentnych wyzwań jest kluczowe dla oceny istniejących rozwiązań i projektowania nowych.

2.3.1 Definicja, zadania składowe i poziomy abstrakcji w ATM

Formalnie, ATM można zdefiniować jako proces estymacji parametrów nut, takich jak czas rozpoczęcia, wysokość i czas trwania, bezpośrednio z sygnału audio [14, 3]. Jest to

zadanie hierarchiczne, które można zdekomponować na kilka kluczowych zadań składowych. Do najważniejszych należą: estymacja wielokrotnej wysokości dźwięku (*Multiple Pitch Estimation, MPE*), czyli identyfikacja wszystkich częstotliwości podstawowych obecnych w danym momencie; detekcja początku i końca dźwięku (*Onset/Offset Detection*), czyli precyzyjne lokalizowanie w czasie momentów rozpoczęcia i zakończenia poszczególnych zdarzeń muzycznych; oraz, w bardziej zaawansowanych systemach, rozpoznawanie instrumentów, analiza rytmu i metrum, czy interpretacja ekspresji wykonawczej [3, 8]. Wyniki transkrypcji mogą być prezentowane na różnych poziomach abstrakcji: od predykcji na poziomie krótkich ramek czasowych (np. wskazanie aktywnych wysokości dźwięku w oknie kilkudziesięciu milisekund), przez symboliczną reprezentację nutową (zestaw nut z określonymi atrybutami), aż po bardziej złożone struktury, takie jak strumienie melodyczne czy pełna partytura muzyczna uwzględniająca elementy notacji standardowej [3].



Rysunek 2.3: Uproszczony schemat potoku przetwarzania w systemie ATM: od sygnału audio, poprzez ekstrakcję cech, zadania składowe (MPE, detekcja onsetów/offsetów, estymacja instrumentu), aż po generowanie wyjściowej reprezentacji symbolicznej na różnych poziomach abstrakcji (ramki, nuty, partytura).

2.3.2 Transkrypcja monofoniczna vs. polifoniczna – złożoność i główne wyzwania

Złożoność zadania ATM znacząco wzrasta przy przejściu od transkrypcji monofonicznej (pojedyncza linia melodyczna) do polifonicznej (wiele współbrzmiących dźwięków) [14, 3]. Muzyka gitarowa, ze względu na możliwość gry akordowej i prowadzenia wielu niezależnych linii melodycznych, jest w przeważającej mierze polifoniczna, co czyni jej transkrypcję szczególnie trudną [5]. Główne wyzwania w AMT, które ulegają intensyfikacji w kontekście polifonii, to przede wszystkim: interferencja harmonicznym składowym różnych dźwięków

(szczególnie w interwałach konsonansowych), maskowanie cichszych dźwięków przez głośniejsze, trudności w precyzyjnej detekcji czasów rozpoczęcia i zakończenia dźwięków w gęstych fakturach, zmienność barwy dźwięku zależna od artykulacji i dynamiki, oraz częste błędy w estymacji wysokości, takie jak pomyłki oktawowo [3]. Dodatkowo, efektywne trenowanie modeli uczenia maszynowego wymaga dostępu do dużych, dokładnie zaanotowanych zbiorów danych, których tworzenie jest procesem czasochłonnym i kosztownym.

2.4 Przegląd Metod Stosowanych w Automatycznej Transkrypcji Muzycznej

Rozwój metod automatycznej transkrypcji muzycznej jest procesem ciągłym, odzwierciedlającym postęp w dziedzinach przetwarzania sygnałów i uczenia maszynowego. Poniżej przedstawiono ewolucję tych podejść, od metod klasycznych po najnowsze techniki oparte na głębokim uczeniu.

2.4.1 Tradycyjne metody oparte na przetwarzaniu sygnałów

Historycznie pierwsze podejścia do automatycznej transkrypcji muzycznej opierały się w dużej mierze na technikach cyfrowego przetwarzania sygnałów [14]. W przypadku transkrypcji muzyki monofonicznej, gdzie w danym momencie występuje tylko jeden dźwięk, opracowano szereg metod detekcji jego częstotliwości podstawowej (F_0). Do klasycznych algorytmów należą te bazujące na analizie funkcji autokorelacji sygnału (ACF), uśrednionej funkcji różnicowej amplitudy (AMDF), technice *Harmonic Product Spectrum (HPS)*, która wzmacnia częstotliwość podstawową poprzez mnożenie widma z jego skompresowanymi wersjami, oraz na analizie cepstralnej, pozwalającej na separację składowej związanej z pobudzeniem od składowej związanej z traktem wokalnym lub rezonansem instrumentu [14]. Rozwijano również systemy bazujące na modelach harmonicznym dźwięku oraz systemy ekspertowe, wykorzystujące predefiniowane reguły i wiedzę muzykologiczną. Metody te, choć wносиły istotny wkład w rozwój dziedziny, wykazywały znaczne ograniczenia w kontekście analizy złożonej muzyki polifonicznej, gdzie jednoczesne występowanie wielu dźwięków i ich alikwotów znacząco komplikuje sygnał, prowadząc m.in. do niemożności separacji nakładających się szeregów harmonicznym. Ograniczenia te stały się motywacją do poszukiwania bardziej zaawansowanych rozwiązań w ramach uczenia maszynowego.

2.4.2 Metody oparte na uczeniu maszynowym

Przełom w skuteczności systemów ATM przyniosło zastosowanie metod uczenia maszynowego, które pozwoliły na tworzenie modeli zdolnych do nauki złożonych zależności

bezpośrednio z danych [13, 5]. W ramach tego paradygmatu można wyróżnić kilka głównych kierunków.

Nienadzorowane metody faktoryzacji macierzy

Wśród metod nienadzorowanych, popularność zdobyła nieujemna faktoryzacja macierzy (*Non-negative Matrix Factorization, NMF*) [3]. Technika ta polega na dekompozycji macierzy wejściowej (np. macierzy spektrogramu amplitudowego) na iloczyn dwóch macierzy o niższych wymiarach, których elementy są nieujemne. W kontekście ATM, macierze te mogą być interpretowane jako zbiór bazowych szablonów spektralnych (odpowiadających np. poszczególnym wysokościami dźwięków lub barwom instrumentów) oraz macierz kodująca aktywacje tych szablonów w czasie. Zaletą NMF jest zdolność do automatycznego odkrywania struktur w danych bez potrzeby etykietowania. Istotnym wyzwaniem jest jednak dobór odpowiedniej rangi faktoryzacji (liczby komponentów) oraz fakt, że NMF może mieć trudności z separacją źródeł o silnie nakładających się charakterystykach spektralnych. W celu rozwiązania tych problemów opracowano liczne rozszerzenia NMF, takie jak nadzorowane NMF (gdzie słownik jest predefiniowany) czy harmoniczne NMF (narzucające harmoniczną strukturę na szablony) [3].

Modele probabilistyczne i Bayesowskie

Ukryte modele Markowa (*Hidden Markov Models, HMM*) były przez wiele lat intensywnie badane i stosowane w ATM, głównie ze względu na ich naturalną zdolność do modelowania sekwencyjnego charakteru muzyki [14, 6, 15]. W typowym podejściu, ukryte stany HMM mogą odpowiadać poszczególnym nutom lub stanom ciszy, a obserwacje emitowane przez te stany to wektory cech akustycznych wyekstrahowanych z kolejnych ramek sygnału audio. Prace Raphaëla (2002) [15] stanowią wczesny przykład zastosowania HMM do transkrypcji muzyki fortepianowej, gdzie modelowano proces generowania nut z uwzględnieniem prawdopodobieństw przejść między nimi. Cazau i Nuel (2017) [6] eksplorowali różne warianty HMM, w tym ich integrację z metodami dekompozycji spektralnej jak PLCA (*Probabilistic Latent Component Analysis*), w celu poprawy jakości transkrypcji, np. poprzez modelowanie trwania nut lub wykorzystanie wiedzy o tonalności do modelowania przejść harmoniczych. Podejścia Bayesowskie, stanowiące szerszą klasę modeli, pozwalają na formalne włączenie do modelu wcześniejszej wiedzy (np. reguł harmonii, typowych progresji akordów) w postaci rozkładów a priori. Mimo pewnych sukcesów, modele te często wymagają starannej inżynierii cech i mogą mieć trudności z modelowaniem bardzo złożonych zależności w muzyce polifonicznej.

Głębokie sieci neuronowe (*Deep Learning*)

W ostatnich latach metody oparte na głębokim uczeniu (*Deep Learning*, *DL*) zdominowały badania nad ATM, osiągając stanowiące aktualny stan wiedzy wyniki w wielu aspektach tego zadania [3, 13]. Zdolność głębokich sieci neuronowych do automatycznego uczenia się hierarchicznych, wielopoziomowych reprezentacji cech bezpośrednio z danych wejściowych (np. surowych spektrogramów) okazała się kluczowa dla postępu. Wśród najczęściej wykorzystywanych architektur znajdują się spłotowe sieci neuronowe (CNN), efektywnie przetwarzające dane o strukturze siatki, takie jak spektrogramy [18, 19]; rekurencyjne sieci neuronowe (RNN), w szczególności warianty LSTM (*Long Short-Term Memory*) i GRU (*Gated Recurrent Unit*), przystosowane do modelowania zależności czasowych w sekwencjach muzycznych [3]; oraz architektury hybrydowe, takie jak CRNN, łączące zalety obu tych podejść [8]. Najnowsze badania eksplorują również potencjał architektur opartych na mechanizmach uwagi, takich jak Transformer [13, 9]. Dostępność dużych, publicznych zbiorów danych adnotowanych, takich jak MAESTRO dla muzyki fortepianowej [8, 19] (zawierający nagrania z konkursów pianistycznych wraz z precyzyjnymi plikami MIDI) oraz GuitarSet dla muzyki gitarowej [18, 19, 3] (oferujący nagrania z sześciu osobnych przetworników heksafonicznych dla każdej struny oraz zsynchronizowane adnotacje MIDI i tabulaturowe), była katalizatorem rozwoju modeli DL. To właśnie te obszerne i dokładnie zaanotowane zbiory danych umożliwiły trenowanie złożonych modeli DL na skalę niezbędną do osiągnięcia wysokiej dokładności, podkreślając, że postęp w tej dziedzinie jest równie mocno zależny od inżynierii danych, co od innowacji algorytmicznych. Model „Onsets and Frames” [8], zaprojektowany do transkrypcji muzyki fortepianowej, jest przykładem systemu DL, który osiągnął wysoką skuteczność. Wykorzystuje on architekturę konwolucyjno-rekurencyjną do jednoczesnej predykcji czasów rozpoczęcia dźwięków (*onsets*) oraz aktywności poszczególnych nut w kolejnych ramkach czasowych. „Basic Pitch” [4] to z kolei narzędzie typu audio-to-MIDI, opracowane przez Spotify, które charakteryzuje się lekkością i zdolnością do detekcji zmian wysokości dźwięku (*pitch bends*). Opiera się na modelach sieci neuronowych, a jego priorytetem jest szybkość działania i dostępność, co czyni je użytecznym w wielu praktycznych zastosowaniach, chociaż może nie osiągać takiej samej szczegółowości transkrypcji jak bardziej złożone systemy w przypadku skomplikowanych fragmentów polifonicznych. Mimo imponujących wyników, metody DL nie są pozbawione ograniczeń. Ich skuteczność jest silnie uzależniona od ilości i jakości danych treningowych. Modele te często działają na zasadzie „czarnej skrzynki”, co utrudnia interpretację ich wewnętrznych mechanizmów decyzyjnych. Ponadto, trening i inferencja złożonych modeli DL mogą być wymagające obliczeniowo [13].

2.5 Specyfika Transkrypcji Muzyki Gitarowej na Zapis Tabulaturowy (GTT)

Transkrypcja muzyki gitarowej, zwłaszcza z celem wygenerowania zapisu tabulaturowego, wprowadza szereg specyficznych problemów i wymagań, które odróżniają ją od ogólnego zadania ATM. Niniejsza sekcja poświęcona jest analizie tych unikalnych aspektów.

2.5.1 Akustyczna charakterystyka sygnału gitary i jej implikacje dla transkrypcji

Sygnał generowany przez gitarę posiada szereg unikalnych cech akustycznych, które czynią jego automatyczną transkrypcję zadaniem szczególnie złożonym [18, 5]. Obwiednia dźwięku gitary, zwłaszcza akustycznej, charakteryzuje się zazwyczaj bardzo szybkim atakiem i relatywnie długim, stopniowym wybrzmiewaniem, co może utrudniać precyzyjną detekcję czasów zakończenia dźwięków (*offsets*). Barwa dźwięku gitary jest niezwykle zróżnicowana i zależy od wielu czynników, takich jak konstrukcja instrumentu (np. gitara akustyczna z pudłem rezonansowym, gitara elektryczna typu *solid-body*), rodzaj i wiek strun, technika artykulacji (np. gra kostką, palcami, *slap*), a w przypadku gitar elektrycznych – w decydującym stopniu od ustawień wzmacniacza oraz zastosowanych efektów gitarowych (np. *distortion*, *overdrive*, *chorus*, *flanger*, *delay*, *reverb*) [18]. Ta inherentna zmienność i bogactwo barwowe, choć stanowią o atrakcyjności instrumentu, komplikują proces tworzenia uogólnionych modeli transkrypcyjnych. Kluczowe dla GTT jest również adekwatne uwzględnienie licznych, specyficznych dla gitary technik wykonawczych, które nie tylko znacząco wpływają na charakterystykę akustyczną sygnału, ale także mają swoje bezpośrednie odzwierciedlenie w zapisie tabulaturowym.

Tabela 2.1: Akustyczne Manifestacje Wybranych Technik Gitarowych Istotnych dla Transkrypcji na Tabulaturę

Technika	Opis	Akustyczna Manifestacja (Przykładowa)
<i>Hammer-on</i>	Uderzenie palcem lewej ręki (dla praworęcznych gitarzystów) w strunę na wyższym progu w celu wydobywania dźwięku bez ponownego szarpania struny prawą ręką.	Zazwyczaj łagodniejszy atak spektralny w porównaniu do dźwięku szarpniętego; możliwy spadek amplitudy po wykonaniu techniki, szczególnie na cieńszych strunach [11]; poprzedzający dźwięk (jeśli był) może wybrzmiewać w tle z niższą amplitudą [11, 17]. Brak wyraźnego „dołka” w amplitudzie między nutami w sekwencji legato [16].
<i>Pull-off</i>	Oderwanie palca lewej ręki od struny (zazwyczaj z lekkim jej szarpnięciem) w celu wydobywania niższego dźwięku, który już brzmi (np. na pustej strunie lub przytrzymywany innym palcem na niższym progu).	Podobnie jak <i>hammer-on</i> , charakteryzuje się łagodniejszym atakiem w porównaniu do dźwięku szarpniętego; zmiana wysokości następuje na niższą; może towarzyszyć krótki, szerokopasmowy szum związany z mechanicznym ruchem odrywania palca [17].
<i>Slide</i> (ślizg)	Płynne przesunięcie palca lewej ręki wzdłuż struny pomiędzy dwoma progami, podczas gdy struna wibruje.	Ciągła, płynna zmiana częstotliwości podstawowej (F_0) i jej harmoniczných (<i>glissando</i>) między wysokością początkową a końcową [17, 16]; zachowanie energii sygnału i jego ciągłości spektralnej; charakterystyczny profil przejścia między wysokościami, odróżniający od <i>bend</i> [17].

Technika	Opis	Akustyczna Manifestacja (Przykładowa)
<i>Bend</i> (podciągnięcie)	Poprzeczne podciągnięcie struny na gryfie palcem lewej ręki, co zwiększa jej napięcie i w rezultacie podwyższa wysokość dźwięku.	Płynna zmiana wysokości dźwięku (F_0) w górę, często z następującym powrotem do oryginalnej wysokości lub przejściem do innej [17, 16]; mogą pojawić się charakterystyczne zmiany w natężeniu alikwotów oraz subtelne zmiany barwy.
<i>Palm-muting</i>	Delikatne tłumienie strun krawędzią dłoni prawej ręki (dla gitarzystów praworęcznych) w pobliżu mostka gitary, bezpośrednio po ich szarpnięciu.	Znaczne skrócenie czasu wybrzmiewania dźwięku (szybszy zanik energii); stłumiony, bardziej perkusyjny i mniej rezonujący charakter; redukcja udziału wyższych harmonicznych w spektrum, co prowadzi do „ciemniejszego”, „cichszego” brzmienia [17].
<i>Vibrato</i>	Cykliczna, subtelna modulacja wysokości dźwięku, uzyskiwana przez oscylacyjny ruch palca przytrzymującego strunę na progu lub za pomocą ramienia tremolo.	Okresowe, stosunkowo wolne (typowo 5-7 Hz) fluktuacje częstotliwości podstawowej (F_0) i jej harmonicznych wokół centralnej wysokości dźwięku [1, 12]; może również występować sprzężona z tym modulacja amplitudy [1, 12].

Dokładne rozpoznanie tych i innych technik jest kluczowe dla stworzenia kompletnej, wiernej i użytecznej dla muzyka tabulatury.

2.5.2 Porównanie notacji standardowej i tabulaturowej dla gitary

W praktyce muzycznej gitaryści posługują się dwoma głównymi systemami notacji: tradycyjną notacją muzyczną opartą na pięciolinii oraz tabulaturą gitarową. Każdy z tych systemów posiada swoje unikalne cechy, które determinują jego adekwatność w różnych zastosowaniach i dla różnych grup użytkowników [18]. Tabela 2.2 przedstawia zwięzłe porównanie obu systemów. Wybór tabulatury jako docelowej formy zapisu w wielu

współczesnych systemach GTT jest motywowany jej dużą popularnością, zwłaszcza wśród gitarzystów samouków i w muzyce rozrywkowej, oraz jej bezpośrednim, instruktażowym charakterem, który ułatwia naukę i wykonanie utworu na instrumencie.


Tabela 2.2: Porównanie Standardowej Notacji Muzycznej i Tabulatury Gitarowej

Cecha	Standardowa Notacja Muzyczna	Tabulatura Gitarowa
Reprezentacja wysokości	Abstrakcyjna, poprzez pozycję nuty na pięciolinii, wymagająca znajomości klucza i zasad teorii muzyki [18].	Bezpośrednia, poprzez wskazanie numeru progu na linii reprezentującej konkretną strunę gitary [18].
Reprezentacja rytmu	Precyzyjnie zdefiniowana za pomocą wartości rytmicznych nut, pauz i oznaczeń metrycznych [18].	Często uproszczona lub nieobecna; główny nacisk kładziony jest na wysokość i sposób opalcowania. Rytm bywa jednak dodawany za pomocą symboli podobnych do notacji standardowej lub poprzez odniesienie do nagrania [18].
Czytelność dla gitarzystów	Wymaga dłuższego procesu nauki i praktyki w czytaniu nut na pięciolinii [18].	Zazwyczaj bardzo intuicyjna i łatwa do szybkiego opanowania, szczególnie dla początkujących gitarzystów i samouków; bezpośrednio pokazuje, gdzie umieścić palce na gryfie [18].
Notacja technik gry	Możliwa za pomocą licznych dodatkowych symboli i oznaczeń słownych, ale czasami może być mniej jednoznaczna lub intuicyjna dla specyficznych technik gitarowych.	Bardzo dobrze przystosowana do notowania szerokiego spektrum specyficznych technik gitarowych (<i>bends, slides, hammer-ons, pull-offs, vibrato</i> itp.) za pomocą dedykowanych symboli graficznych.
Niejednoznaczność opalcowania	Istnieje – ten sam dźwięk (wysokość) może być zagrany na gitarze na kilku różnych strunach i progach; wybór konkretnego opalcowania jest pozostawiony wykonawcy [18].	Zazwyczaj jednoznacznie określa zarówno strunę, jak i próg, na którym dany dźwięk ma być zagrany, tym samym eliminując problem wyboru opalcowania dla danej nuty [18].

2.5.3 Kluczowe wyzwania w automatycznej transkrypcji gitary na tabulaturę (GTT)

Transkrypcja na tabulaturę wprowadza szereg specyficznych wyzwań, które wykraczają poza ogólne problemy AMT:

- **Wysoka polifonia i nakładanie się dźwięków:** Gitara, jako instrument harmoniczny, często generuje złożone współbrzmienia, co intensyfikuje problem separacji i identyfikacji poszczególnych dźwięków w sygnale audio [5].
- **Niejednoznaczność reprezentacji dźwięku na gryfie (*Tablature Inference / Fingering Estimation*):** Jest to jedno z fundamentalnych wyzwań w GTT. Ten sam dźwięk (o tej samej wysokości muzycznej) może być zagrany w wielu różnych pozycjach na gryfie gitary (tj. na różnych kombinacjach struny i progu) [18]. Wybór konkretnej pozycji przez gitarzystę zależy od wielu czynników, takich jak kontekst muzyczny (np. sąsiednie dźwięki), grywalność (łatwość wykonania danego pochodzenia dźwięków), preferencje stylistyczne, a nawet subtelne różnice w barwie dźwięku uzyskiwane na różnych strunach. System GTT musi więc nie tylko poprawnie zidentyfikować wysokość i czas trwania nuty, ale również podjąć decyzję co do jej najbardziej prawdopodobnego i/lub optymalnego opalcowania na gryfie.



Rysunek 2.4: Przykład tej samej nuty (E4, MIDI 64) możliwej do zagraenia w wielu pozycjach na gryfie gitary standardowo strojonej. Ilustracja przedstawia dźwięk E4 na strunie G (9. próg), strunie B (5. próg) oraz pustej strunie wysokiej E. Obrazuje to fundamentalne wyzwanie estymacji opalcowania w GTT. Źródło: [7]

- **Zmienność barwy jako potencjalna wskazówka i problem:** Chociaż subtelne różnice w barwie dźwięku tej samej nuty granej na różnych strunach mogą teoretycznie dostarczać pewnych wskazówek dla algorytmów estymacji opalcowania, to wszechobecne i często intensywne stosowanie efektów gitarowych (szczególnie w muzyce rockowej, metalowej, jazzowej i elektronicznej) może całkowicie modyfikować oryginalną barwę instrumentu, maskując te subtelne różnice lub wprowadzając własne artefakty, co znacząco komplikuje analizę [18].
- **Detekcja i notacja technik wykonawczych:** Wierne odtworzenie partii gitarowej w formie tabulatury wymaga nie tylko transkrypcji samych nut, ale również

rozpoznania i odpowiedniego zanotowania licznych, specyficznych dla gitary technik artykulacyjnych (patrz Tabela 2.1) [16, 17]. Jest to zadanie trudne, gdyż akustyczne manifestacje tych technik bywają subtelne i zmienne.

- **Ograniczenia dostępnych zbiorów danych:** Rozwój systemów GTT opartych na uczeniu maszynowym, zwłaszcza na modelach głębokiego uczenia, jest w dużej mierze uzależniony od dostępności obszernych, publicznych zbiorów danych zawierających nagrania gitarowe wraz z precyzyjnymi, zsynchronizowanymi czasowo adnotacjami tabulaturowymi (obejmującymi informacje o strunie, progu, a idealnie także o zastosowanych technikach wykonawczych) [18, 19]. Tworzenie takich zbiorów jest procesem niezwykle pracochłonnym.
- **Problem „przesunięcia dziedziny” (*domain shift*):** Modele GTT trenowane na danych pochodzących z jednej domeny (np. czyste, studyjne nagrania gitar akustycznych lub dane syntetyczne) mogą wykazywać znaczący spadek skuteczności, gdy są stosowane do danych z innej domeny (np. nagrania koncertowe, amatorskie, partie gitar elektrycznych z efektami) [19]. Praca Zang i in. (2023) nad zbiorem SynthTab [19] stanowi próbę zaadresowania problemu niedoboru zróżnicowanych danych rzeczywistych poprzez wykorzystanie dużych ilości danych syntetycznych do wstępnego treningu modeli, które następnie mogą być dostrajane na mniejszych zbiorach danych rzeczywistych.

2.5.4 Przegląd istniejących podejść i narzędzi do GTT

Współczesne podejścia do automatycznej transkrypcji gitary na tabulaturę można generalnie podzielić na dwuetapowe oraz zintegrowane, określane jako *end-to-end*. Każde z nich ma swoje charakterystyczne cechy i stawia czoła opisanym wyzwaniom w odmienny sposób. Podejścia dwuetapowe realizują zadanie GTT w dwóch oddzielnych krokach. W pierwszym etapie dokonuje się ogólnej transkrypcji muzycznej, czyli estymacji wielokrotnej wysokości dźwięku (MPE), w wyniku czego powstaje reprezentacja nutowa utworu (np. w formacie piano-roll lub MIDI), bez informacji o konkretnym opalcowaniu [5]. W drugim etapie, nazywanym aranżacją tabulatury lub inferencją opalcowania, system próbuje przypisać te wcześniej wykryte nuty do najbardziej prawdopodobnych lub optymalnych pozycji (strun i progów) na gryfie gitary. Ten etap często wykorzystuje modele optymalizacyjne, przeszukiwanie grafowe lub funkcje kosztu, które uwzględniają takie czynniki jak fizyczna grywalność (np. minimalizacja odległości ruchów ręki na gryfie, unikanie niemożliwych do zagrania kombinacji), typowe dla danego stylu muzycznego wzorce opalcowania, czy też subtelne różnice w barwie dźwięku między strunami. Zaletą tego podejścia jest jego modularność. Główną wadą jest natomiast ryzyko propagacji błędów z etapu MPE do etapu aranżacji tabulatury. Podejścia zintegrowane, opierające się w przeważającej mierze

na zaawansowanych modelach głębokiego uczenia, dążą do nauczenia się bezpośredniego mapowania z surowego sygnału audio (lub jego reprezentacji czasowo-częstotliwościowej) na finalną reprezentację tabulaturową w jednym, zintegrowanym kroku. Wykorzystują one złożone architektury sieci neuronowych, takie jak:

- Modele oparte na splotowych sieciach neuronowych (CNN), czego przykładem jest TabCNN [18]. Architektura ta typowo przetwarza wejściowy spektrogram (np. Constant-Q) i generuje na wyjściu predykcje dotyczące aktywności poszczególnych progów na każdej ze strun gitary, często w formie wielowymiarowej macierzy binarnej („six-hot encoding” dla sześciu strun i określonej liczby progów). Praca Zang i in. (2023) [19] również wykorzystuje architekturę zbliżoną do TabCNN jako jeden z modeli bazowych w swoich badaniach nad wykorzystaniem danych syntetycznych.
- Modele oparte na architekturze Transformer, które dzięki zastosowaniu mechanizmów uwagi (*attention mechanisms*) są zdolne do efektywnego modelowania długoterminowych zależności w danych sekwencyjnych. Znalazły one zastosowanie w GTT, szczególnie w połączeniu z dużymi zbiorami danych, w tym syntetycznymi, takimi jak SynthTab [19].
- Inne architektury sieci neuronowych, w tym sieci rekurencyjne (RNN) lub ich bardziej zaawansowane warianty jak LSTM czy GRU, często stosowane w połączeniu z CNN (tworząc architektury CRNN), aby wykorzystać zdolności CNN do ekstrakcji lokalnych cech ze spektrogramów oraz zdolności RNN do modelowania kontekstu czasowego. Przykładowo, praca Burlet i Hindle (2017) [5] badała zastosowanie głębokich sieci przekonań (*Deep Belief Networks*) dla transkrypcji izolowanych dźwięków gitarowych, co stanowiło wczesny przykład wykorzystania metod głębokiego uczenia w tym obszarze.

Zaletą podejść zintegrowanych jest ich potencjalna zdolność do uczenia się bardzo złożonych i subtelnych mapowań bezpośrednio z danych, co może prowadzić do lepszych wyników końcowych niż w podejściach dwuetapowych, szczególnie jeśli model jest w stanie jednocześnie uwzględniać zarówno informacje akustyczne, jak i ograniczenia wynikające z grywalności. Wymagają one jednak zazwyczaj znacznie większych i bardziej szczegółowych zbiorów danych treningowych. Niezależnie od podejścia, kluczową rolę w rozwoju systemów GTT odgrywają zbiory danych. GuitarSet [18, 19] jest jednym z najważniejszych publicznie dostępnych zbiorów, zawierającym około 3 godzin muzyki gitarowej granej w różnych stylach, z precyzyjnymi adnotacjami MIDI oraz, co unikalne, informacjami o strunie i progu dla każdej nuty, uzyskanymi dzięki zastosowaniu przetworników heksafonicznych (rejestrujących sygnał z każdej struny osobno) oraz starannej ręcznej weryfikacji. Zbiór DadaGP [19] to z kolei duży zbiór danych w formie symbolicznej (pliki Guitar Pro), który jest często wykorzystywany w badaniach nad GTT, szczególnie w kontekście modelowania i generowania tabulatur z uwzględnieniem bogatego zestawu technik

wykonawczych i artykulacji. SynthTab [19] to natomiast obszerny zbiór syntetycznych danych (par audio-tabulatura), stworzony w celu przewyższenia ograniczeń związanych z rozmiarem i różnorodnością dostępnych zbiorów danych rzeczywistych. Został on wygenerowany poprzez syntezę audio z plików Guitar Pro pochodzących ze zbioru DadaGP, z wykorzystaniem zaawansowanych symulatorów wzmacniaczy gitarowych i efektów w celu uzyskania realistycznie brzmiących nagrań. Badania wykazały, że modele GTT wstępnie trenowane na dużych zbiorach danych syntetycznych, a następnie dostrajane (*fine-tuned*) na mniejszych zbiorach danych rzeczywistych, mogą osiągać znaczącą poprawę wyników transkrypcji [19]. Ten paradygmat pre-trainingu na danych syntetycznych i fine-tuningu na danych rzeczywistych staje się potężnym narzędziem poprawy odporności i generalizacji w GTT. Pomimo znaczących postępów, jakie dokonały się w dziedzinie GTT, obecne rozwiązania wciąż napotykają na istotne ograniczenia.

Do głównych nierozwiązanych problemów należą: osiągnięcie wysokiej dokładności transkrypcji w przypadku bardzo gęstych faktur polifonicznych i szybkich pasaży technicznych, opracowanie wiarygodnych metod inferencji tabulatury (opalcowania) w złożonych kontekstach muzycznych, które uwzględniałyby nie tylko poprawność nut, ale także grywalność i naturalność wykonania, precyzyjne rozpoznawanie i notacja szerokiego spektrum subtelnych technik artykulacyjnych, zapewnienie dobrej generalizacji modeli na różne style muzyczne, brzmienia gitar (w tym instrumenty z silnie zmodyfikowanym sygnałem za pomocą efektów) oraz różne jakości nagrań, a także sformułowanie obiektywnych i wszechstronnych metryk oceny jakości wygenerowanych tabulatur, które korelowałyby z percepcją i oceną przez doświadczonych gitarzystów [19, 18].

W procesie tworzenia i ewaluacji systemów AMT i GTT szeroko wykorzystuje się specjalistyczne biblioteki programistyczne do przetwarzania sygnałów audio i implementacji modeli uczenia maszynowego, takie jak Librosa, Essentia, a także frameworki głębokiego uczenia jak TensorFlow czy PyTorch.

2.6 Podsumowanie i Otwarte Problemy

Automatyczna transkrypcja muzyczna, a w jej ramach transkrypcja muzyki gitarowej na zapis tabulaturowy, pozostaje aktywnym i wymagającym obszarem badań naukowych. Znaczenie praktyczne skutecznych systemów GTT jest nie do przecenienia, obejmując wsparcie dla muzyków, edukację, archiwizację oraz przemysł muzyczny [3]. Jak wykazano w niniejszym rozdziale, główne wyzwania logiczne koncentrują się wokół przetwarzania złożonych sygnałów polifonicznych, radzenia sobie z dużą zmiennością barwy i artykulacji charakterystyczną dla gitary, a w przypadku GTT – dodatkowo wokół fundamentalnego problemu niejednoznaczności opalcowania oraz precyzyjnej detekcji i notacji specyficznych technik wykonawczych [18]. Przegląd stosowanych metod ukazuje wyraźną ewolucję od klasycznych technik opartych na przetwarzaniu sygnałów do zaawansowanych modeli

uczenia maszynowego, ze szczególnym uwzględnieniem głębokich sieci neuronowych, które obecnie definiują stan wiedzy w tej dziedzinie [14, 13]. Rozwiązania takie jak „Onsets and Frames” [8] czy „Basic Pitch” [4] dla ogólnych zadań AMT, oraz systemy dedykowane GTT, jak TabCNN [18] i nowsze podejścia wykorzystujące duże zbiory danych, w tym syntetyczne, jak w przypadku badań nad SynthTab [19], demonstrują znaczący postęp. Systemy te osiągają coraz wyższą skuteczność, jednakże wciąż istnieją liczne obszary wymagające dalszych, intensywnych badań. Do kluczowych otwartych problemów w dziedzinie GTT, które wyznaczają kierunki przyszłych prac, należą przede wszystkim:

- Dalsza poprawa dokładności i robustności transkrypcji w kontekście bardzo gęstej polifonii, szybkich pasażów muzycznych oraz sygnałów o niskiej jakości lub z silnymi zniekształceniami.
- Rozwój bardziej zaawansowanych i kontekstowych metod inferencji opalcowania na gryfie gitary, które lepiej odzwierciedlałyby rzeczywiste praktyki wykonawcze i zapewniały grywalność generowanych tabulatur.
- Zwiększenie zdolności systemów do rozpoznawania i poprawnej notacji szerokiego spektrum subtelnych technik gitarowych, które mają kluczowe znaczenie dla ekspresji muzycznej.
- Poprawa generalizacji modeli GTT na różne, nie widziane wcześniej w procesie treningu, brzmienia gitar (akustycznych, elektrycznych, z różnymi efektami), style muzyczne i warunki nagraniowe.
- Opracowanie bardziej kompleksowych i percepcyjnie adekwatnych metryk oceny jakości transkrypcji tabulaturowej, które wykraczałyby poza proste porównanie poprawności nut i uwzględniałyby aspekty takie jak grywalność, czytelność i wierność stylistyczną. Kwestia ta nawiązuje do obserwacji, że wyniki ilościowe nie zawsze w pełni odzwierciedlają praktyczną użyteczność systemu dla końcowego użytkownika [10].
- Kontynuacja prac nad tworzeniem i udostępnianiem większych, bardziej zróżnicowanych i precyzyjnie adnotowanych zbiorów danych dla GTT, w tym eksploracja metod efektywnego wykorzystania danych syntetycznych i technik transferu wiedzy.

Rozwiązanie tych problemów przybliży nas do stworzenia systemów GTT, które będą mogły stać się prawdziwie użytecznymi i powszechnie akceptowanymi narzędziami dla szerokiej społeczności gitarzystów.

Rozdział 3

[Tytuł rozdziału]

Rozdział 4

Badania

Rozdział 5

Podsumowanie

Bibliografia

- [1] Supraja Anand, Judith M. Wingate, Brenda Smith i Rahul Shrivastav. „Acoustic Parameters Critical for an Appropriate Vibrato”. W: *Journal of Voice* 26.6 (2012), 820.e19–820.e25. DOI: 10.1016/j.jvoice.2012.06.004.
- [2] Carl-Fredrik Arndt i Lewis Li. *Automated Transcription of Guitar Music*. Spraw. tech. CS229 (Machine Learning) Project Report. Stanford University, 2012. URL: https://www.academia.edu/73426275/Automated_Transcription_of_Guitar_Music?hb-sb-sw=4413367.
- [3] Emmanouil Benetos, Simon Dixon, Zhiyao Duan i Sebastian Ewert. „Automatic Music Transcription: An Overview”. W: *IEEE Signal Processing Magazine* 36.1 (2019), s. 20–30. DOI: 10.1109/MSP.2018.2869928.
- [4] Rachel M. Bittner, Gabriel Meseguer-Brocal, Adam Ragheb i Juan José Bosch. „A Lightweight Instrument-Agnostic Model for Polyphonic Note Transcription and Multipitch Estimation”. W: 2022, s. 750–757. URL: <https://ieeexplore.ieee.org/document/9746549>.
- [5] Gregory Burlet i Abram Hindle. „Isolated guitar transcription using a deep belief network”. W: *PeerJ Computer Science* 3 (2017), e109. DOI: 10.7717/peerj-cs.109.
- [6] D. Cazau i G. Nuel. „Investigation on the use of Hidden-Markov Models in automatic transcription of music”. W: *arXiv preprint* (2017). eprint: 1704.03711. URL: <https://arxiv.org/pdf/1704.03711.pdf>.
- [7] Google Image Search Result. *Ilustracja niejednoznaczności opalcowania na gryfie gitary*. http://googleusercontent.com/image_collection/image_retrieval/6630293268132984900. Adres URL obrazu dostarczony przez narzędzie wyszukiwania Google. Dostęp: 5 czerwca 2025. 2025.
- [8] Curtis Hawthorne, Erich Elsen, Jialin Song, Adam Roberts, Ian Simon, Colin Raffel, Jesse Engel, Sageev Oore i Douglas Eck. „Onsets and frames: Dual-objective piano transcription”. W: *Proceedings of the 19th International Society for Music Information Retrieval Conference (ISMIR)*. Paris, France, 2018, s. 50–57. URL: <https://archives.ismir.net/ismir2018/paper/000019.pdf>.

- [9] Curtis Hawthorne, Ian Simon, Rigel Swavely, Ethan Manilow i Jesse Engel. „Sequence-to-Sequence Piano Transcription with Transformers”. W: *Proceedings of the 22nd International Society for Music Information Retrieval Conference (ISMIR)*. Online: ISMIR, 2021, s. 240–247. URL: <https://archives.ismir.net/ismir2021/paper/000027.pdf>.
- [10] Andre Holzapfel i Emmanouil Benetos. „Automatic Music Transcription and Ethnomusicology: A User Study”. W: *Proceedings of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. Delft, The Netherlands, 2019, s. 677–684. URL: <https://archives.ismir.net/ismir2019/paper/000082.pdf>.
- [11] Abd Husin, Koharudin Koharudin, Sidikrubadi Pramudito, Sitti Yani i Rima Fitria Adiati. „Analysis and Synthesis of Guitar Sounds with Hammer on Strumming Technique”. W: *Pillar of Physics* 16.2 (2023), s. 162–168. DOI: 10.24036/15354171074.
- [12] Jeremy Hyrkas i Tamara Smyth. „On Vibrato and Frequency (De)Modulation in Musical Sounds”. W: *Proceedings of the 27th International Conference on Digital Audio Effects (DAFx24)*. Guildford, United Kingdom, 2024. URL: <https://dafx.de/paper-archive/details/vta7009LDd8QNZLW70eEXw>.
- [13] Fatemeh Jamshidi, Gary Pike, Amit Das i Richard Chapman. „Machine Learning Techniques in Automatic Music Transcription: A Systematic Survey”. W: *arXiv preprint* (2024). eprint: 2406.15249. URL: <https://arxiv.org/pdf/2406.15249.pdf>.
- [14] Anssi Klapuri i Manuel Davy, red. *Signal Processing Methods for Music Transcription*. Springer, 2006. ISBN: 978-0387306674. DOI: 10.1007/0-387-32845-9.
- [15] Christopher Raphael. „Automatic Transcription of Piano Music”. W: *Proceedings of the 3rd International Society for Music Information Retrieval Conference (ISMIR)*. Paris, France, 2002, s. 177–184. URL: https://music.informatics.indiana.edu/~craphael/papers/ismir02_rev.pdf.
- [16] Loic Reboursiere, Otso Tapio Lähdeoja, Ricardo Chessini, Thomas Drugman, Stéphane Dupont, Cécile Picard i Nicolas Riche. „Guitar As Controller”. W: *Numediart Research Program QPSR 3* (2011). URL: https://www.researchgate.net/publication/235678844_Guitar_As_Controller.
- [17] Li Su, Li-Fan Yu i Yi-Hsuan Yang. „Sparse Cepstral and Phase Codes for Guitar Playing Technique Classification”. W: *Proceedings of the 15th International Society for Music Information Retrieval Conference (ISMIR)*. Taipei, Taiwan, 2014, s. 9–14. URL: <https://archives.ismir.net/ismir2014/paper/000213.pdf>.

- [18] Andrew Wiggins i Youngmoo Kim. „Guitar Tablature Estimation with a Convolutional Neural Network”. W: *Proceedings of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. Delft, The Netherlands, 2019, s. 284–291. URL: <https://archives.ismir.net/ismir2019/paper/000033.pdf>.
- [19] Yongyi Zang, Yi Zhong, Frank Cwitkowitz i Zhiyao Duan. „SynthTab: Leveraging Synthesized Data for Guitar Tablature Transcription”. W: *Proceedings of the 24th International Society for Music Information Retrieval Conference (ISMIR)*. Milan, Italy, 2023. URL: <https://arxiv.org/abs/2309.09085>.

Dodatki

Dokumentacja techniczna

Spis skrótów i symboli

- ATM – Automatyczna Transkrypcja Muzyczna (*Automatic Music Transcription*)
- GTT – Transkrypcja Gitarowa na Tabulaturę (*Guitar Tablature Transcription*)
- MIR – Komputerowe Pozyskiwanie Informacji Muzycznej (*Music Information Retrieval*)
- CPS – Cyfrowe Przetwarzanie Sygnałów (*Digital Signal Processing – DSP*)
- UM – Uczenie Maszynowe (*Machine Learning – ML*)
- SI – Sztuczna Inteligencja (*Artificial Intelligence – AI*)
- DFT – Dyskretna Transformata Fouriera (*Discrete Fourier Transform*)
- STFT – Krótkoczasowa Transformata Fouriera (*Short-Time Fourier Transform*)
- CQT – Transformata *Constant-Q* (*Constant-Q Transform*)
- MPE – Estymacja Wielokrotnej Wysokości Dźwięku (*Multiple Pitch Estimation*)
- NMF – Nieujemna Faktoryzacja Macierzy (*Non-negative Matrix Factorization*)
- HMM – Ukryte Modele Markowa (*Hidden Markov Models*)
- PLCA – Probabilistyczna Analiza Składowych Ukrytych (*Probabilistic Latent Component Analysis*)
- DL – Głębokie Uczenie (*Deep Learning*)
- CNN – Splotowe Sieci Neuronowe (*Convolutional Neural Networks*)
- RNN – Rekurencyjne Sieci Neuronowe (*Recurrent Neural Networks*)
- LSTM – Długa Pamięć Krótkoterminowa (*Long Short-Term Memory*)
- GRU – Bramkowana Jednostka Rekurencyjna (*Gated Recurrent Unit*)
- CRNN – Konwolucyjno-Rekurencyjne Sieci Neuronowe (*Convolutional Recurrent Neural Networks*)

- F_0 – Częstotliwość podstawowa
- X_k – k -ty współczynnik dyskretnej transformaty Fouriera
- x_n – n -ta próbka sygnału w dziedzinie czasu
- N – długość ciągu próbek sygnału (w kontekście DFT)
- i – jednostka urojona

Spis rysunków

1.1	Porównanie fragmentu zapisu nutowego i odpowiadającej mu tabulatury gitarowej dla motywu muzycznego.	3
1.2	Schematyczny przykład spektrogramu polifonicznego sygnału gitarowego, ukazujący nakładające się struktury harmoniczne (prążki reprezentujące częstotliwość podstawową i jej alikwoty) dla kilku jednocześnie brzmiących nut.	4
2.1	Po lewej: fragment sygnału audio pojedynczego dźwięku gitary w dziedzinie czasu. Po prawej: odpowiadające mu widmo amplitudowe uzyskane za pomocą transformaty Fouriera, ukazujące częstotliwość podstawową (F_0) oraz jej kolejne alikwoty (składowe harmoniczne).	14
2.2	Wizualizacja różnych reprezentacji czasowo-częstotliwościowych dla tego samego polifonicznego fragmentu gitarowego: (a) Spektrogram STFT z liniową skalą częstotliwości, (b) Spektrogram Constant-Q (CQT) z logarytmiczną skalą częstotliwości, (c) Mel-spektrogram z osią częstotliwości w skali Mel.	15
2.3	Uproszczony schemat potoku przetwarzania w systemie ATM: od sygnału audio, poprzez ekstrakcję cech, zadania składowe (MPE, detekcja onsetów/offsetów, estymacja instrumentu), aż po generowanie wyjściowej reprezentacji symbolicznej na różnych poziomach abstrakcji (ramki, nuty, partytura).	16
2.4	Przykład tej samej nuty (E4, MIDI 64) możliwej do zagrania w wielu pozycjach na gryfie gitary standardowo strojonej. Ilustracja przedstawia dźwięk E4 na strunie G (9. próg), strunie B (5. próg) oraz pustej strunie wysokiej E. Obrazuje to fundamentalne wyzwanie estymacji opalcowania w GTT. Źródło: [7]	24

Spis tabel

2.1	Wybrane techniki gitarowe i ich manifestacje akustyczne	21
2.2	Porównanie Standardowej Notacji Muzycznej i Tabulatury Gitarowej . . .	23