



**Politechnika
Śląska**

PRACA MAGISTERSKA

Przekształcanie nagrań dźwiękowych na zapis nutowy

Łukasz KRAWCZYK

Nr albumu: 296657

Kierunek: Informatyka

Specjalność: Internet i technologie sieciowe

PROWADZĄCY PRACĘ

Dr inż. Paweł Benecki

**KATEDRA Katedra Informatyki Stosowanej
Wydział Automatyki, Elektroniki i Informatyki**

Gliwice 2025

Tytuł pracy

Przekształcanie nagrań dźwiękowych na zapis nutowyPrzekształcanie nagrań dźwiękowych na zapis nutowy

Streszczenie

Niniejsza praca magisterska porusza problematykę przekształcania nagrań dźwiękowych na zapis nutowy, skupiając się na szczegółowym przypadku automatycznej transkrypcji polifonicznych nagrań gitarowych na zapis tabulaturowy (GTT). W ramach pracy zaprojektowano, zaimplementowano i zweryfikowano eksperymentalnie system oparty na architekturze konwolucyjno-rekurencyjnej sieci neuronowej (CRNN), która uczy się bezpośredniego mapowania z reprezentacji czasowo-częstotliwościowej sygnału audio na symboliczną postać tabulatury. Kluczowym elementem projektu jest wielozadaniowe uczenie, w którym model jednocześnie przewiduje momenty rozpoczęcia dźwięków (onsets) oraz numery aktywnych progów na poszczególnych strunach gitary.

Proces badawczy, przeprowadzony na publicznie dostępnym zbiorze danych GuitarSet, obejmował ponad 70 iteracyjnych eksperymentów. Wykazały one, że decydujący wpływ na skuteczność modelu miała innowacyjna strategia intensywnej augmentacji danych, symulująca niedoskonałości nagrań realizowanych w warunkach amatorskich, takie jak pogłos, szum czy zniekształcenia mikrofonowe. Zastosowanie tej data-centricznej strategii pozwoliło na osiągnięcie wyników przewyższających aktualny stan wiedzy.

Finalny model, oceniany na zbiorze testowym, uzyskał wynik MPE F1-Score na poziomie 0.8736, co jest wynikiem lepszym od rezultatów raportowanych w kluczowych publikacjach w tej dziedzinie dla modeli trenowanych wyłącznie na zbiorze GuitarSet. Analiza jakościowa potwierdziła wysoką zdolność modelu do poprawnej estymacji wysokości dźwięków, jednocześnie wskazując, że głównym pozostałym wyzwaniem jest precyzyjne rozwiązywanie problemu wieloznaczności opalcowania, wynikającego z trudności w klasyfikacji subtelnych różnic w barwie dźwięku między strunami. Praca dowodzi, że opracowane rozwiązanie stanowi skuteczną i obiecującą metodę dla GTT, otwierając nowe kierunki dalszych badań.

Słowa kluczowe

przekształcanie sygnału audio, automatyczna transkrypcja muzyczna, notacja muzyczna, transkrypcja gitary, tabulatura

Thesis title

Converting audio recordings to musical notationTransforming Audio Recordings into Musical Notation

Abstract

This master’s thesis addresses the problem of transforming audio recordings into musical notation, focusing on the specific case of automatic transcription of polyphonic guitar recordings into tablature notation (GTT). The project involved the design, implementation, and experimental verification of a system based on a Convolutional Recurrent Neural Network (CRNN) architecture, which learns to directly map a time-frequency representation of an audio signal to a symbolic tablature format. A key element of the project is multi-task learning, where the model simultaneously predicts note onsets and the corresponding fret numbers on individual guitar strings.

The research process, conducted on the publicly available GuitarSet dataset, comprised over 70 iterative experiments. These revealed that the decisive factor for the model’s effectiveness was an innovative and aggressive data augmentation strategy. This strategy simulated imperfections of amateur recordings, such as reverb, noise, and microphone distortions. The application of this data-centric approach led to results surpassing the current state-of-the-art.

The final model, evaluated on the test set, achieved an MPE F1-Score of 0.8736, which is superior to results reported in key publications for models trained exclusively on the GuitarSet dataset. Qualitative analysis confirmed the model’s high accuracy in pitch estimation, while also indicating that the main remaining challenge is the precise resolution of fingering ambiguity, stemming from the difficulty in classifying subtle timbre differences between strings. The thesis demonstrates that the developed solution constitutes an effective and promising method for GTT, opening new avenues for future research.

Key words

audio signal processing, automatic music transcription, music notation, guitar transcription, tablature

Spis treści

1	Wstęp	1
1.1	Osadzenie problemu w dziedzinie naukowej	3
1.2	Cel pracy	6
1.3	Zakres pracy	6
1.4	Zwięzła charakterystyka rozdziałów	8
1.5	Jednoznaczne określenie wkładu autora	9
2	Analiza Tematu: Podstawy i Specyfika Transkrypcji Gitarowej	11
2.1	Definicja Problemu Automatycznej Transkrypcji Muzycznej (ATM) i Jego Znaczenie	11
2.1.1	Sformułowanie problemu	11
2.1.2	Znaczenie badań nad ATM dla gitary	12
2.1.3	Kontekst naukowy i interdyscyplinarny charakter ATM	12
2.2	Podstawy Teoretyczne: Dźwięk Muzyczny i Jego Cyfrowa Reprezentacja . .	13
2.2.1	Percepcyjne i fizyczne atrybuty dźwięku muzycznego	13
2.2.2	Reprezentacja sygnału audio w dziedzinie czasu i częstotliwości . .	13
2.2.3	Analiza czasowo-częstotliwościowa i jej znaczenie dla ATM	14
2.3	Rdzeń Automatycznej Transkrypcji Muzycznej: Zadania, Poziomy i Wyzwania	15
2.3.1	Definicja, zadania składowe i poziomy abstrakcji w ATM	15
2.3.2	Transkrypcja monofoniczna vs. polifoniczna – złożoność i główne wyzwania	16
2.4	Przegląd Metod Stosowanych w Automatycznej Transkrypcji Muzycznej . .	17
2.4.1	Tradycyjne metody oparte na przetwarzaniu sygnałów	17
2.4.2	Metody oparte na uczeniu maszynowym	17
2.5	Specyfika Transkrypcji Muzyki Gitarowej na Zapis Tabulaturowy (GTT) .	20
2.5.1	Akustyczna charakterystyka sygnału gitary i jej implikacje dla trans- krypcji	20
2.5.2	Porównanie notacji standardowej i tabulaturowej dla gitary	22
2.5.3	Kluczowe wyzwania w automatycznej transkrypcji gitary na tabula- turę (GTT)	24
2.5.4	Przegląd istniejących podejść i narzędzi do GTT	25

2.6	Podsumowanie i Otwarte Problemy	27
3	Przedmiot Pracy: Projekt i Implementacja Systemu Transkrypcji Gitarowej	29
3.1	Opis Zaimplementowanego Rozwiązania	30
3.1.1	Architektura Ogólna Systemu	30
3.1.2	Przetwarzanie Wstępne i Przygotowanie Danych	31
3.1.3	Model Transkrypcji (CRNN)	35
3.1.4	Proces Treningu Modelu	37
3.1.5	Ewaluacja i Generowanie Wyników	39
3.1.6	Wizualizacja	41
3.2	Analiza Teoretyczna Rozwiązania	42
3.2.1	Wybór Architektury CRNN w Kontekście GTT	42
3.2.2	Reprezentacja Sygnału Wejściowego	42
3.2.3	Funkcja Straty i Optymalizacja Wielozadaniowa	43
3.2.4	Techniki Augmentacji Danych	43
3.3	Uzasadnienie Wyboru Zastosowanych Metod, Algorytmów i Narzędzi	44
3.3.1	Zbiór Danych GuitarSet	44
3.3.2	Wybór Reprezentacji Czasowo-Częstotliwościowych	44
3.3.3	Architektura CRNN jako Model Transkrypcji	45
3.3.4	Wykorzystane Biblioteki Programistyczne	45
3.4	Podsumowanie Rozdziału	46
4	Badania Eksperymentalne i Wyniki	47
4.1	Środowisko i Metodyka Eksperymentów	47
4.1.1	Infrastruktura Sprzętowa i Programistyczna	47
4.1.2	Reprezentacje Danych Wejściowych	48
4.1.3	Metryki Oceny	48
4.2	Szczegółowy Opis Procesu Badawczego	49
4.2.1	Faza Wstępna: Analiza Danych i Wybór Metod Reprezentacji	49
4.2.2	Projektowanie Potoku Przetwarzania Danych	50
4.2.3	Projektowanie Architektury i Procesu Treningowego	50
4.2.4	Ewaluacja, Analiza Wyników i Walidacja Końcowa	52
4.3	Analiza Wyników i Dyskusja	52
4.3.1	Porównanie Ilościowe Najlepszych Modeli	52
4.3.2	Analiza Jakościowa i Porównanie z Literaturą	53
4.3.3	Walidacja w Warunkach Rzeczywistych	59
4.3.4	Użyteczność w Praktyce	60
4.4	Podsumowanie Badań Eksperymentalnych	60

5 Podsumowanie i Wnioski	63
5.1 Streszczenie Zrealizowanych Prac	63
5.2 Wnioski Końcowe	64
5.3 Potencjalne Kierunki Dalszych Badań i Rozwoju	65
Bibliografia	70
Dokumentacja techniczna	73
Spis skrótów i symboli	75
Spis rysunków	78
Spis tabel	79

Rozdział 1

Wstęp

Automatyczna Transkrypcja Muzyczna (ATM) (ang. *Automatic Music Transcription*) stanowi jedno z kluczowych i jednocześnie najbardziej złożonych zadań w dziedzinie komputerowej analizy muzyki. W swej istocie, ATM jest procesem konwersji sygnału akustycznego, będącego fizyczną manifestacją muzyki, na jego symboliczną, strukturalną reprezentację [15, 3]. Celem tego procesu jest przekształcenie ciągłego sygnału audio w dyskretny zestaw symboli muzycznych, takich jak tradycyjne nuty określające wysokość i czas trwania dźwięku, lub – co jest przedmiotem szczególnego zainteresowania w niniejszej pracy – w zapis tabulaturowy. Interdyscyplinarny charakter Automatycznej Transkrypcji Muzycznej jest niezaprzeczalny, gdyż skuteczna realizacja jej zadań wymaga integracji wiedzy i metodologii pochodzących z wielu, pozornie odległych, dziedzin nauki i techniki. Do najważniejszych z nich należą:

- **Cyfrowe Przetwarzanie Sygnałów (CPS)** (ang. *Digital Signal Processing – DSP*): Dostarcza ono fundamentalnych narzędzi do analizy, transformacji i manipulacji sygnałem audio w dziedzinie czasu i częstotliwości. Techniki takie jak filtracja, analiza spektralna czy transformacje czasowo-częstotliwościowe są nieodzowne w procesie ekstrakcji informacji z surowego sygnału dźwiękowego [15]. Zaawansowane metody CPS pozwalają na wstępne przygotowanie sygnału, redukcję szumów oraz identyfikację podstawowych cech akustycznych, które następnie mogą być interpretowane w kontekście muzycznym. Przykładem fundamentalnego narzędzia CPS, ilustrującego przejście z dziedziny czasu do dziedziny częstotliwości, jest dyskretna transformata Fouriera (DFT) (ang. *Discrete Fourier Transform*). Dla skończonego ciągu próbek sygnału x_n o długości N , jej k -ty współczynnik X_k jest zdefiniowany jako:

$$X_k = \sum_{n=0}^{N-1} x_n \cdot e^{-i\frac{2\pi}{N}kn} \quad (1.1)$$


gdzie n jest indeksem próbki w dziedzinie czasu, k jest indeksem częstotliwości, a i jest jednostką urojoną. Wzór ten jest podstawą wielu algorytmów analizy częstotli-

wościowej stosowanych w ATM.

- **Rozpoznawanie Wzorców** (ang. *Pattern Recognition*) oraz **Uczenie Maszynowe (UM)** (ang. *Machine Learning – ML*): Te dziedziny odgrywają kluczową rolę w identyfikacji złożonych struktur muzycznych, takich jak pojedyncze nuty, akordy, rytmy czy motywy melodyczne, w często zaszumionym i polifonicznym sygnale audio [3]. Współczesne systemy ATM w coraz większym stopniu opierają się na zaawansowanych modelach uczenia maszynowego, w szczególności na sieciach neuronowych i głębokim uczeniu (ang. *Deep Learning*), które potrafią automatycznie uczyć się hierarchicznych reprezentacji cech muzycznych bezpośrednio z danych [5]. Przełomem w tej dziedzinie okazał się paradygmat „Onsets and Frames”, zaproponowany w pracy [9], w którym model uczy się jednocześnie detekcji początków nut (onsetów) oraz ich trwania (predykcji na poziomie ramek), co znacząco poprawiło jakość transkrypcji i stało się podstawą dla wielu nowoczesnych systemów, w tym rozwiązania rozwijanego w niniejszej pracy. Dynamiczny rozwój w obszarze głębokiego uczenia bezpośrednio przekłada się na postępy w ATM, umożliwiając tworzenie modeli zdolnych do przetwarzania coraz bardziej skomplikowanych sygnałów muzycznych z niespotykaną dotąd dokładnością.
- **Sztuczna Inteligencja (SI)** (ang. *Artificial Intelligence – AI*): Jako szersza dziedzina, obejmuje ona uczenie maszynowe, ale także inne aspekty, takie jak reprezentacja wiedzy muzycznej oraz procesy poznawcze związane z percepcją i wnioskowaniem w kontekście muzycznym [3]. Rozwój SI dostarcza ram koncepcyjnych i narzędziowych dla budowy inteligentnych systemów transkrypcji.
- **Muzykologia**: Dostarcza niezbędnej wiedzy teoretycznej o strukturze muzyki, notacji, harmonii, rytmie oraz praktykach wykonawczych [11]. Zrozumienie zasad muzycznych jest kluczowe nie tylko dla interpretacji wyników generowanych przez systemy ATM, ale również dla projektowania algorytmów, które uwzględniają kontekst muzyczny i dążą do tworzenia transkrypcji użytecznych z perspektywy muzykologicznej i wykonawczej.

Potencjalne obszary zastosowań systemów ATM są szerokie i różnorodne, co podkreśla ich rosnące znaczenie zarówno w badaniach naukowych, jak i w praktyce muzycznej. Do najważniejszych aplikacji należą: wsparcie w edukacji muzycznej, na przykład poprzez tworzenie systemów do automatyzacji ćwiczeń gry na instrumencie, analizę postępów ucznia czy generowanie spersonalizowanych materiałów dydaktycznych [3]. Systemy ATM mogą również znacząco ułatwić proces tworzenia i aranżacji muzyki, na przykład poprzez wspieranie modyfikacji i rearanżacji istniejących utworów [2]. Dla producentów muzycznych, ATM oferuje narzędzia do wizualizacji treści muzycznej i inteligentnej edycji nagrań [3]. Ponadto, technologie te są wykorzystywane w systemach wyszukiwania i kategoryzacji mu-

zyki w dużych zbiorach danych, na przykład poprzez umożliwienie wyszukiwania utworów na podstawie ich melodii, harmonii czy rytmu [3]. Tytuł niniejszej pracy, „Przekształcanie nagrań dźwiękowych na zapis nutowy”, odnosi się do centralnego problemu ATM. Należy jednak podkreślić, że termin „zapis nutowy” jest pojęciem szerokim, obejmującym różnorodne systemy notacji muzycznej. W kontekście niniejszego opracowania, szczególna uwaga zostanie poświęcona specyficznej formie zapisu, jaką jest tabulatura gitarowa. Tabulatura, w odróżnieniu od tradycyjnej notacji nutowej skupiającej się primarnie na wysokości i czasie trwania dźwięku, jest graficzną reprezentacją wskazującą bezpośrednio pozycje palców na gryfie instrumentu – konkretne struny i progi, które należy nacisnąć, aby uzyskać pożądaną dźwięk [24].



Rysunek 1.1: Porównanie fragmentu zapisu nutowego i odpowiadającej mu tabulatury gitarowej dla motywu muzycznego.


Wybór tabulatury jako docelowej formy zapisu w tej pracy nie jest przypadkowy. Wynika on ze specyfiki gitary jako instrumentu oraz z ogromnej popularności tej formy notacji wśród gitarzystów [24]. Rosnąca popularność tabulatur, często udostępnianych online, stwarza specyficzne zapotrzebowanie na systemy ATM zdolne do generowania tego właśnie formatu. Nie jest to jedynie kwestia preferencji użytkowników; tabulatura często zawiera informacje o charakterze performatywnym, takie jak konkretne opalcowanie czy użycie technik gitarowych, których brakuje w standardowej notacji nutowej. Skuteczne systemy ATM generujące tabulatury mogą zatem zdemokratyzować proces nauki gry na gitarze oraz tworzenia muzyki, obniżając barierę wejścia dla osób, które nie posługują się biegle tradycyjnym zapisem nutowym, ale rozumieją intuicyjny charakter tabulatury. Ten wybór stanowi naturalne przejście do dalszych, bardziej szczegółowych rozważań przedstawionych w kolejnych rozdziałach pracy.

1.1 Osadzenie problemu w dziedzinie naukowej

Przedmiotem niniejszej pracy jest zagadnienie automatycznej transkrypcji muzyki gitarowej do postaci tabulatury, co sytuuje ją w szerokim kontekście badań prowadzonych w ramach dziedziny naukowej znanej jako (ang. *Music Information Retrieval (MIR)*). MIR, czyli komputerowe pozyskiwanie informacji muzycznej, jest interdyscyplinarnym polem badawczym zajmującym się analizą, przetwarzaniem, wyszukiwaniem, organizacją

i dostępem do informacji zawartej w muzyce, zarówno w jej formie akustycznej, jak i symbolicznej. Obserwowany w ostatnich dekadach gwałtowny wzrost ilości dostępnych cyfrowych treści muzycznych, na przykład w ramach cyfrowych bibliotek muzycznych i serwisów streamingowych [3], generuje rosnące zapotrzebowanie na zautomatyzowane narzędzia do ich analizy. Narzędzia te są niezbędne do efektywnego zarządzania ogromnymi repozytoriami muzyki, ich przeszukiwania, kategoryzacji oraz personalizacji dostępu dla użytkowników. ATM jest jednym z kluczowych zadań w ramach MIR, umożliwiającym transformację sygnału audio na bogatszą, symboliczną reprezentację, która może być dalej przetwarzana i analizowana. Szczególną uwagę w kontekście niniejszej pracy należy poświęcić wyzwaniom związanym z transkrypcją muzyki gitarowej. Gitara, będąca instrumentem niezwykle popularnym i wszechstronnym, wykorzystywanym w niemal każdym gatunku muzycznym, stawia przed systemami ATM szereg specyficznych trudności:

- **Polifoniczność:** Gitara jest instrumentem polifonicznym, co oznacza zdolność do jednoczesnego wydawania wielu dźwięków (standardowo do sześciu, po jednym na każdej strunie) [5]. Nakładanie się składowych harmonicznymi wielu jednocześnie brzmiących dźwięków w sygnale audio znacząco komplikuje proces ich separacji i identyfikacji.



Rysunek 1.2: Schematyczny przykład spektrogramu polifonicznego sygnału gitarowego, ukazujący nakładające się struktury harmoniczne (prążki reprezentujące częstotliwość podstawową i jej alikwoty) dla kilku jednocześnie brzmiących nut.

- **Bogactwo technik artykulacyjnych:** Gitarzyści wykorzystują szeroki wachlarz technik artykulacyjnych, takich jak podciąganie strun (ang. *bending*), ślizgi (ang. *sliding*), młoteczkowanie (ang. *hammer-on*), odrywanie (ang. *pull-off*), wibrato (ang. *vibrato*) czy tłumienie strun dłonią (ang. *palm-muting*). Każda z tych technik w

unikalny sposób modyfikuje charakterystykę sygnału akustycznego (np. jego wysokość, amplitudę, barwę w czasie) i jest kluczowa dla wiernej transkrypcji, zwłaszcza do formatu tabulatury, który często zawiera symbole oznaczające te techniki.

- **Duża zmienność barwy dźwięku** (ang. *timbre*): Barwa dźwięku gitary jest niezwykle zróżnicowana i zależy od wielu czynników, takich jak typ instrumentu (np. gitara akustyczna, klasyczna, elektryczna), rodzaj użytych strun, sposób ich pobudzenia (kostką, palcami), a w przypadku gitar elektrycznych – od ustawień wzmacniacza i zastosowanych efektów gitarowych [24]. Ta duża wariabilność barwy stanowi poważne wyzwanie dla modeli uczenia maszynowego, które muszą generalizować swoją wiedzę na różne instancje dźwięków gitarowych.
- **Identyczność wysokości dźwięku na różnych strunach i progach**: Jedną z charakterystycznych cech gitary jest możliwość zagrania dźwięku o tej samej wysokości w wielu różnych pozycjach na gryfie (tj. na różnych kombinacjach struny i progu) [24]. O ile dla tradycyjnej notacji nutowej ta wieloznaczność nie jest problemem, o tyle dla generowania tabulatury, która musi precyzyjnie wskazać miejsce zagrania dźwięku, jest to fundamentalne wyzwanie. Wybór odpowiedniej pozycji często zależy od kontekstu muzycznego, grywalności (łatwości wykonania) i preferencji wykonawcy.

Pomimo znaczących postępów, jakie dokonały się w dziedzinie ATM w ostatnich latach, zwłaszcza dzięki zastosowaniu zaawansowanych technik uczenia maszynowego, istniejące systemy wciąż borykają się z ograniczeniami, prowadzącymi do typowych błędów, takich jak pomyłki oktawowo, niepoprawne detekcje nut czy niedokładności czasowe [3]. Człowiek, dokonując transkrypcji, opiera się nie tylko na percepcji sygnału akustycznego, ale również na swojej rozległej wiedzy muzycznej, znajomości teorii muzyki, konwencji stylistycznych oraz kontekstu kulturowego. Maszyny, mimo coraz doskonalszych algorytmów, wciąż mają trudności z pełnym uwzględnieniem tych aspektów [11]. Ograniczenia te są szczególnie widoczne w przypadku transkrypcji muzyki polifonicznej, wykonywanej na instrumentach o złożonej charakterystyce akustycznej, takich jak gitara [5]. Niedoskonałość obecnych systemów, zwłaszcza w kontekście precyzyjnego odwzorowania niuansów wykonawczych gitary i generowania użytecznych, grywalnych tabulatur, stanowi silny impuls do poszukiwania nowych, bardziej efektywnych rozwiązań. Ta luka badawcza jest główną motywacją do podjęcia tematu niniejszej pracy. Popularność gitary oraz ogromna ilość dostępnych nagrań gitarowych, często pozbawionych wiarygodnych transkrypcji, tworzą naturalne zapotrzebowanie na narzędzia MIR, w tym ATM. Postępy w tej dziedzinie mogą z kolei stymulować dalsze tworzenie i udostępnianie muzyki, tworząc pozytywną pętlę sprzężenia zwrotnego. Co więcej, rozwój precyzyjnych systemów ATM dla gitary może odegrać istotną rolę w dokumentacji i archiwizacji unikalnych stylów gitarowych oraz technik wykonawczych, stanowiących ważne elementy dziedzictwa kulturowego. Otwartym problemem

pozostaje również ocena jakości transkrypcji, zwłaszcza w kontekście tabulatur, co zostało zasygnalizowane w literaturze [26].

1.2 Cel pracy

Głównym celem niniejszej pracy magisterskiej jest zaprojektowanie, implementacja oraz weryfikacja eksperymentalna systemu służącego do automatycznej transkrypcji polifonicznych nagrań audio gitary na zapis tabulaturowy. Kluczowym elementem realizacji tego celu jest wykorzystanie publicznie dostępnego zbioru danych Guitarset. Zbiór ten, opisany i wykorzystany w badaniach nad transkrypcją gitarową (np. [24]), został specjalnie przygotowany do tego celu i charakteryzuje się unikalnymi cechami, takimi jak dostarczanie nagrań heksafonicznych (sygnału z każdej struny osobno) wraz z precyzyjnymi adnotacjami dotyczącymi wysokości dźwięku, czasu jego trwania oraz, co szczególnie istotne, informacji o strunie i progu, na którym dany dźwięk został nagrany [24]. Wybór zbioru Guitarset jest zatem nieprzypadkowy; jego struktura bezpośrednio adresuje problem niejednoznaczności przypisania dźwięku do konkretnej pozycji na gryfie, co jest fundamentalne przy tworzeniu wiarygodnych danych uczących i testowych dla zadania generowania tabulatury. System opracowany w ramach tej pracy ma dążyć do precyzyjnego odwzorowania partii gitarowych w formie tabulatury. Oznacza to nie tylko poprawną identyfikację atrybutów muzycznych takich jak wysokość i czas trwania dźwięków, ale przede wszystkim ich prawidłowe przypisanie do odpowiednich strun i progów na gryfie gitary. Dążenie do precyzji obejmuje również próbę radzenia sobie z wyzwaniami specyficznymi dla transkrypcji gitary, które zostały omówione w poprzednim podrozdziale, takimi jak wysoki stopień polifonii, zróżnicowane techniki artykulacyjne oraz konieczność generowania tabulatury uwzględniającej aspekty grywalności. Realizacja tak zdefiniowanego celu pracy, czyli stworzenie efektywnego systemu transkrypcji nagrań gitarowych do postaci tabulatury, może przyczynić się do powstania nowych narzędzi wspierających kreatywność i edukację gitarzystów. Przykładowo, taki system mógłby służyć do automatycznego generowania tabulatur z improwizowanych fragmentów muzycznych, ułatwiać analizę złożonych partii gitarowych znanych wykonawców, czy też stanowić cenne wsparcie w procesie nauki gry na instrumencie.

1.3 Zakres pracy

Realizacja postawionego celu badawczego obejmuje następujące, kluczowe etapy:

- Przeprowadzenie szczegółowej analizy literatury naukowej dotyczącej automatycznej transkrypcji muzycznej, ze szczególnym naciskiem na metody stosowane w transkrypcji muzyki gitarowej, specyfikę sygnału generowanego przez ten instrument oraz

różne aspekty notacji tabulaturowej, w tym jej strukturę i konwencje zapisu.

- Zaprojektowanie architektury systemu do automatycznej transkrypcji, która będzie uwzględniać specyfikę zadania, charakterystykę danych wejściowych (polifoniczne nagrania gitary akustycznej) i wyjściowych (zapis tabulaturowy) oraz dostępne narzędzia i technologie, w tym potencjalne wykorzystanie modeli głębokiego uczenia.
- Implementacja kluczowych modułów składowych systemu, obejmujących co najmniej:
 - Moduł przetwarzania wstępnego sygnału audio (ang. *audio preprocessing*), mający na celu przygotowanie sygnału do dalszej analizy, np. poprzez normalizację, segmentację czy redukcję szumów.
 - Moduł ekstrakcji cech akustycznych (ang. *acoustic feature extraction*), odpowiedzialny za przekształcenie przetworzonego sygnału audio w reprezentację numeryczną, która efektywnie koduje informacje istotne dla rozpoznawania dźwięków gitarowych i ich atrybutów. Rozważone zostaną zarówno klasyczne cechy akustyczne [15], jak i cechy uzyskiwane automatycznie z wykorzystaniem metod głębokiego uczenia [5].
 - Moduł predykcyjny, oparty na wybranych technikach uczenia maszynowego, którego zadaniem będzie generowanie sekwencji zdarzeń tabulaturowych (struna, próg, czas rozpoczęcia, czas trwania) na podstawie wyekstrahowanych cech akustycznych.
- Adaptacja i wykorzystanie publicznie dostępnego zbioru danych Guitarset, opisanego m.in. w [24], do procesu trenowania, walidacji oraz testowania opracowanego systemu. Etap ten będzie obejmował przygotowanie danych do formatu wymaganego przez zaimplementowany model, w tym potencjalne techniki augmentacji danych w celu zwiększenia robustości modelu.
- Zdefiniowanie i dobór odpowiednich metryk oceny jakości transkrypcji tabulaturowej. Metryki te muszą uwzględniać nie tylko poprawność wykrytych nut pod względem ich wysokości, czasu rozpoczęcia i czasu trwania, ale także, co kluczowe dla tego zadania, poprawność przypisania poszczególnych dźwięków do konkretnych strun i progów gitary.
- Przeprowadzenie kompleksowych badań eksperymentalnych mających na celu weryfikację skuteczności i wydajności zaproponowanego rozwiązania. Wyniki uzyskane przez system będą porównywane z adnotacjami referencyjnymi ze zbioru Guitarset oraz, w miarę możliwości, z wynikami innych istniejących metod lub systemów transkrypcji gitarowej, aby ocenić postęp względem aktualnego stanu wiedzy (ang. *state-of-the-art*) [3].

- Dokładna analiza uzyskanych wyników eksperymentalnych, obejmująca zarówno ocenę ilościową (na podstawie zdefiniowanych metryk), jak i jakościową (np. poprzez analizę typowych błędów popełnianych przez system). Na tej podstawie zostaną zidentyfikowane mocne i słabe strony opracowanego systemu oraz sformułowane wnioski końcowe i rekomendacje dotyczące potencjalnych ulepszeń oraz dalszych kierunków badań w tej dziedzinie.

Niniejsza praca będzie koncentrować się na rozwiązaniu konkretnego problemu o charakterze naukowo-badawczym. Osiągnięcie tego celu nastąpi poprzez opracowanie innowacyjnego rozwiązania technicznego, jakim jest system do automatycznej transkrypcji gitarowej na tabulaturę, oraz udokumentowanie kompetencji inżynierskich autora w zakresie projektowania, implementacji i weryfikacji systemów opartych na przetwarzaniu sygnałów i uczeniu maszynowym. Przedstawiony zakres pracy odzwierciedla standardowy cykl życia projektu badawczo-rozwojowego w dziedzinie uczenia maszynowego, co zapewnia metodyczne i kompleksowe podejście do postawionego problemu. Szczególny nacisk położony na adaptację zbioru Guitarset oraz zdefiniowanie specyficznych metryk oceny jakości transkrypcji tabulaturowej wskazuje na potencjalny wkład pracy nie tylko w sam system, ale również w metodykę badań nad transkrypcją gitarową.

1.4 Zwięzła charakterystyka rozdziałów

Struktura niniejszej pracy magisterskiej została zaprojektowana w sposób umożliwiający logiczne i spójne przedstawienie podjętej problematyki, przeprowadzonych badań oraz uzyskanych wyników. Poniżej przedstawiono zwięzłą charakterystykę poszczególnych rozdziałów:

Rozdział 1 (Wstęp) Prezentowany rozdział. Wprowadza on w problematykę pracy, definiuje Automatyczną Transkrypcję Muzyczną (ATM) i jej specyfikę w kontekście gitary i tabulatury. Osadza problem w dziedzinie naukowej (ang. *Music Information Retrieval (MIR)*), omawia wyzwania związane z transkrypcją gitarową. Formułuje cel i zakres pracy, przedstawia strukturę kolejnych rozdziałów oraz jednoznacznie określa wkład autora.

Rozdział 2 (Analiza Tematu) Rozdział ten poświęcony będzie dogłębnemu przedstawieniu podstaw teoretycznych niezbędnych do zrozumienia problematyki pracy. Omówione zostaną fundamentalne pojęcia dotyczące dźwięku muzycznego, jego cyfrowej reprezentacji [15] oraz podstawowych metod jego analizy. Następnie, zaprezentowane zostaną ogólne zagadnienia związane z Automatyczną Transkrypcją Muzyczną, po czym szczegółowa uwaga zostanie skupiona na specyfice transkrypcji gitarowej. Dokładnie scharakteryzowany zostanie sygnał gitary, jego cechy akustyczne oraz

notacja tabulaturowa. Rozdział ten płynnie przejdzie do sprecyzowania problematyki badawczej podejmowanej w niniejszej pracy.

Rozdział 3 (Przedmiot Pracy) W tym rozdziale opisane zostanie autorskie rozwiązanie problemu automatycznej transkrypcji polifonicznych nagrań gitarowych na zapis tabulaturowy. Zaprezentowana zostanie szczegółowa architektura zaimplementowanego systemu, wraz z opisem poszczególnych jego modułów. Dokładnie scharakteryzowany zostanie wykorzystany zbiór danych Guitarset, którego cechy i zastosowanie w badaniach opisano m.in. w [24], oraz proces jego adaptacji na potrzeby systemu. Uzasadniony zostanie również wybór zastosowanych metod przetwarzania sygnału, ekstrakcji cech, algorytmów uczenia maszynowego oraz wykorzystanych narzędzi programistycznych.

Rozdział 4 (Badania) Ten rozdział będzie poświęcony prezentacji metodyki oraz wyników przeprowadzonych badań eksperymentalnych. Opisane zostanie środowisko badawcze, sposób przygotowania danych testowych oraz zdefiniowane metryki oceny jakości transkrypcji. Uzyskane wyniki zostaną zaprezentowane w sposób ilościowy (np. w postaci tabel i wykresów) oraz jakościowy. Następnie wyniki te zostaną poddane szczegółowej analizie i dyskusji, w tym identyfikacji typowych błędów popełnianych przez system oraz porównaniu z istniejącymi rozwiązaniami lub stanem wiedzy.

Rozdział 5 (Podsumowanie) Ostatni rozdział pracy będzie zawierał syntetyczne podsumowanie wszystkich zrealizowanych prac. Zaprezentowane zostaną kluczowe wnioski końcowe wynikające z przeprowadzonych badań i analiz. Oceniony zostanie stopień realizacji postawionego celu pracy. Wskazane zostaną również potencjalne kierunki dalszego rozwoju opracowanego systemu oraz możliwe przyszłe badania w tej dziedzinie, być może w nawiązaniu do otwartych problemów i wyzwań identyfikowanych w literaturze.

Przedstawiona struktura pracy jest zgodna ze standardami pisania prac naukowo-badawczych w dziedzinach technicznych, co zapewnia jej spójność i kompletność. Wyraźne oddzielenie rozdziału poświęconego analizie tematu od rozdziału opisującego przedmiot pracy pozwala na klarowne rozróżnienie między przeglądem istniejącej wiedzy a oryginalnym wkładem autora, co jest kluczowe dla rzetelnej oceny pracy magisterskiej.

1.5 Jednoznaczne określenie wkładu autora

W tej części precyzyjnie określony zostaje indywidualny wkład autora w realizację niniejszej pracy. Obejmuje on następujące kluczowe aspekty, za które autor był samodzielnie odpowiedzialny:

- Samodzielne przeprowadzenie gruntownych studiów literaturowych oraz krytyczną analizę aktualnego stanu wiedzy i badań w dziedzinie automatycznej transkrypcji muzycznej, ze szczególnym uwzględnieniem problematyki transkrypcji muzyki gitarowej oraz specyfiki zapisu tabulaturowego.
- Opracowanie oryginalnej koncepcji oraz zaprojektowanie architektury systemu przeznaczonego do automatycznej transkrypcji polifonicznych nagrań gitarowych na postać tabulatury, uwzględniającej specyficzne wyzwania związane z tym zadaniem.
- Implementacja algorytmów przetwarzania sygnału audio, metod ekstrakcji cech akustycznych oraz modeli uczenia maszynowego, które stanowią rdzeń funkcjonalny opracowanego systemu transkrypcji.
- Adaptacja, przygotowanie oraz analiza publicznie dostępnego zbioru danych Guitarset na potrzeby procesu trenowania, walidacji i kompleksowej ewaluacji zaprojektowanego i zaimplementowanego systemu.
- Zaprojektowanie metodyki oraz samodzielne przeprowadzenie kompleksowych badań eksperymentalnych, mających na celu weryfikację skuteczności, wydajności oraz ograniczeń opracowanego rozwiązania w kontekście transkrypcji gitarowej na tabulaturę.
- Krytyczna analiza i interpretacja uzyskanych wyników eksperymentalnych, w tym identyfikacja mocnych i słabych stron systemu, oraz ocena istotności tych wyników w kontekście istniejących rozwiązań i aktualnego stanu wiedzy w dziedzinie.
- Sformułowanie wniosków końcowych podsumowujących całość przeprowadzonych prac badawczych i implementacyjnych, a także przedstawienie propozycji dotyczących potencjalnych ulepszeń systemu oraz możliwych kierunków dalszych badań.

Powyższe wyszczególnienie ma na celu jednoznaczne wyodrębnienie oryginalnego wkładu studenta w identyfikację i rozwiązanie postawionego problemu badawczego, a także w opracowanie, implementację i weryfikację opisanego systemu informatycznego. Wymienione punkty pokrywają cały proces badawczy, od fazy koncepcyjnej, poprzez realizację techniczną, aż po analizę wyników i formułowanie wniosków, co świadczy o kompleksowym i samodzielnym charakterze pracy, zgodnie z oczekiwaniami stawianymi pracom magisterskim. Nacisk na „oryginalną koncepcję” oraz „krytyczną analizę” podkreśla aspiracje pracy do wniesienia wartościowego wkładu w rozwój dziedziny, wykraczającego poza jedynie odtwórcze zastosowanie znanych metod.

Rozdział 2

Analiza Tematu: Teoretyczne Podstawy Transkrypcji Muzycznej i Specyfika Transkrypcji Gitarowej

Niniejszy rozdział stanowi dogłębną analizę problematyki automatycznej transkrypcji muzycznej (ATM), ze szczególnym uwzględnieniem jej zastosowania do muzyki gitarowej i generowania zapisu tabulaturowego. Celem jest osadzenie tematyki pracy w szerszym kontekście naukowym oraz identyfikacja kluczowych wyzwań związanych z tym zagadnieniem. Przedstawione zostaną podstawy teoretyczne, omówione główne podejścia i technologie stosowane w ATM, a także zidentyfikowane zostaną obszary wymagające dalszych badań w dziedzinie transkrypcji gitarowej, co pozwoli na pełniejsze zrozumienie złożoności podejmowanego problemu. Należy przy tym zaznaczyć, że choć celem jest identyfikacja obszarów wymagających dalszych badań, niniejszy rozdział skupia się na przeglądzie istniejącego stanu wiedzy.

2.1 Definicja Problemu Automatycznej Transkrypcji Muzycznej (ATM) i Jego Znaczenie

Automatyczna transkrypcja muzyczna jest fundamentalnym zagadnieniem w dziedzinie komputerowej analizy muzyki, którego zrozumienie wymaga precyzyjnego zdefiniowania problemu oraz określenia jego wagi w kontekście naukowym i praktycznym. Poniższe podrozdziały szczegółowo omawiają te aspekty.

2.1.1 Sformułowanie problemu

Automatyczna transkrypcja muzyczna (ATM) (ang. *Automatic Music Transcription*) jest procesem przekształcania sygnału audio zawierającego muzykę na symboliczną re-

prezentację muzyczną, najczęściej w postaci zapisu nutowego, jego odpowiednika (np. w formie piano-roll) lub bezpośrednio w formacie specyficznym dla danego instrumentu [15, 3]. W kontekście muzyki gitarowej, problem ten precyzuje się jako automatyczną transkrypcję polifonicznych nagrań gitarowych na zapis tabulaturowy (ang. *Guitar Tablature Transcription, GTT*). Zadanie to wykracza poza prostą identyfikację wysokości i czasu trwania dźwięków; obejmuje również ich precyzyjne przypisanie do konkretnych strun i progów na gryfie gitary [24]. Pełna transkrypcja tabulaturowa dąży także do rozpoznania technik artykulacyjnych charakterystycznych dla gitary, takich jak podciągnięcia strun (ang. *bends*), (ang. *hammer-on*), (ang. *pull-off*) czy (ang. *vibrato*) [21]. Techniki te są kluczowe dla wiernego odtworzenia utworu i mają istotny wpływ na jego brzmienie oraz interpretację.

2.1.2 Znaczenie badań nad ATM dla gitary

Badania nad automatyczną transkrypcją muzyki gitarowej posiadają wielowymiarowe znaczenie. Przede wszystkim, dostarczają narzędzi wspierających muzyków i proces edukacji muzycznej, ułatwiając dostęp do notacji, umożliwiając efektywniejszą naukę gry oraz pogłębioną analizę utworów [3, 2]. Mają również istotne zastosowanie w archiwizacji i dokumentacji dziedzictwa muzycznego, pozwalając na zachowanie unikalnych stylów wykonawczych i technik gitarowych, które mogłyby inaczej ulec zapomnieniu [11]. Należy jednak zauważyć, że pomimo potencjału, obecne systemy ATM mogą nie zawsze oferować przewagę ilościową dla doświadczonych transkrybentów w specyficznych kontekstach, np. etnomuzykologicznych, gdzie krytyczna jest dokładność rytmiczna i precyzja notacji [11]. Systemy ATM mogą ponadto stanowić wartościowe wsparcie dla kompozytorów i producentów muzycznych, oferując nowe możliwości w procesie twórczym i produkcyjnym [3, 2]. Nie bez znaczenia jest fakt, że rozwój GTT odpowiada na realne zapotrzebowanie rynku, wynikające z globalnej popularności gitary jako instrumentu oraz tabulatury jako preferowanej przez wielu gitarzystów formy zapisu muzycznego [24].

2.1.3 Kontekst naukowy i interdyscyplinarny charakter ATM

Automatyczna transkrypcja muzyczna jest integralną częścią szerszej dziedziny badawczej znanej jako (ang. *Music Information Retrieval (MIR)*) [3], która zajmuje się pozyskiwaniem, analizą i zarządzaniem informacją muzyczną. ATM jest jednym z najbardziej złożonych zadań w MIR, wymagającym synergii wiedzy i metod z wielu dyscyplin. Fundamentalne znaczenie ma tu cyfrowe przetwarzanie sygnałów (CPS), dostarczające narzędzi do analizy sygnału audio [15]. Równie istotne są uczenie maszynowe (UM) i szeroko pojęta sztuczna inteligencja (SI), które umożliwiają tworzenie modeli zdolnych do nauki złożonych wzorców muzycznych i podejmowania decyzji transkrypcyjnych na podstawie danych [3, 14, 5]. Wiedza z zakresu muzykologii, dotycząca teorii muzyki,

notacji i praktyk wykonawczych, jest niezbędna do projektowania systemów generujących transkrypcje poprawne i użyteczne muzycznie, a także do krytycznej oceny ich wyników [11].

2.2 Podstawy Teoretyczne: Dźwięk Muzyczny i Jego Cyfrowa Reprezentacja

Zrozumienie procesów leżących u podstaw automatycznej transkrypcji muzycznej wymaga uprzedniego zapoznania się z fundamentalnymi właściwościami dźwięku muzycznego oraz sposobami jego cyfrowej reprezentacji i analizy. Niniejsza sekcja przybliży te kluczowe koncepcje.


2.2.1 Percepcyjne i fizyczne atrybuty dźwięku muzycznego

Dźwięk muzyczny, z perspektywy percepcji, charakteryzowany jest przez cztery podstawowe atrybuty: wysokość, głośność, barwę i czas trwania [15]. Wysokość jest bezpośrednio związana z częstotliwością podstawową (F_0) drgań źródła dźwięku. Głośność to subiektywna ocena natężenia dźwięku. Barwa, określana jako „kolor” dźwięku, pozwala odróżnić dźwięki o tej samej wysokości i głośności, lecz pochodzące z różnych instrumentów lub generowane różnymi technikami; jest ona ściśle powiązana ze spektrum harmonicznym dźwięku (rozkładem i względnymi amplitudami składowych harmonicznymi) oraz jego obwiednią czasową. Czas trwania definiuje, jak długo dźwięk jest postrzegany. Obwiednia amplitudy dźwięku, często modelowana jako ADSR (ang. *Attack, Decay, Sustain, Release*), odgrywa kluczową rolę w kształtowaniu charakteru brzmieniowego, zwłaszcza dla instrumentów szarpanych, takich jak gitara [15]. Fazy ataku (narastania), początkowego zaniku, podtrzymania i końcowego wybrzmiewania definiują dynamiczny profil dźwięku, przy czym dla gitary fazy zaniku i wybrzmiewania są szczególnie złożone i zależne od instrumentu oraz techniki gry.

2.2.2 Reprezentacja sygnału audio w dziedzinie czasu i częstotliwości

Cyfrowy sygnał audio jest sekwencją próbek reprezentujących amplitudę fali akustycznej w kolejnych, dyskretnych punktach czasu [15]. Analiza wyłącznie w dziedzinie czasu nie ujawnia jednak w pełni struktury muzycznej sygnału. Kluczowa jest analiza częstotliwościowa, pozwalająca zidentyfikować składowe częstotliwościowe. Przejście z dziedziny czasu do dziedziny częstotliwości realizowane jest za pomocą transformaty Fouriera, która dekomponuje sygnał na sumę składowych sinusoidalnych o różnych częstotliwościach i

amplitudach, tworząc jego widmo częstotliwościowe [15]. Dyskretna transformata Fouriera (DFT), zdefiniowana wzorem (1.1) w Rozdziale 1, jest podstawowym narzędziem tej analizy.




Rysunek 2.1: Po lewej: fragment sygnału audio pojedynczego dźwięku gitary w dziedzinie czasu. Po prawej: odpowiadające mu widmo amplitudowe uzyskane za pomocą transformaty Fouriera, ukazujące częstotliwość podstawową (F_0) oraz jej kolejne alikwoty (składowe harmoniczne).

2.2.3 Analiza czasowo-częstotliwościowa i jej znaczenie dla ATM

Charakterystyki częstotliwościowe muzyki zmieniają się w czasie, dlatego w ATM niezbędne są metody analizy czasowo-częstotliwościowej. Krótkoczasowa transformata Fouriera (STFT) jest jedną z fundamentalnych technik, polegającą na analizie Fouriera krótkich, nakładających się segmentów sygnału [15, 5]. Wynikiem STFT jest spektrogram – dwuwymiarowa reprezentacja energii sygnału w funkcji czasu i częstotliwości, która stanowi podstawę dla wielu systemów ATM. Należy pamiętać o inherentnym kompromisie STFT między rozdzielczością czasową a częstotliwościową.

Alternatywą, często lepiej dostosowaną do percepcji muzyki, jest transformata Constant-Q (CQT) (ang. *Constant-Q Transform*) [3, 24, 26]. CQT wykorzystuje pasma częstotliwości o szerokościach proporcjonalnych do ich częstotliwości środkowych, co odpowiada logarytmicznej naturze ludzkiej percepcji wysokości dźwięku i organizacji skal muzycznych.

Skala Mel, również oparta na badaniach percepcyjnych, jest kolejną nieliniową skalą częstotliwości powszechnie stosowaną w MIR [3]. Mel-spektrogramy, czyli spektrogramy z osią częstotliwości przekształconą na skalę Mel, są standardowym wejściem dla wielu modeli głębokiego uczenia w ATM, gdyż lepiej odzwierciedlają ludzką wrażliwość na zmiany wysokości dźwięku. Ewolucja od STFT, poprzez CQT, do Mel-spektrogramów odzwierciedla dążenie do tworzenia reprezentacji cech bardziej zgodnych z ludzką percepcją i efektywniejszych dla algorytmów uczenia maszynowego.



Rysunek 2.2: Wizualizacja różnych reprezentacji czasowo-częstotliwościowych dla tego samego polifonicznego fragmentu gitarowego: (a) Spektrogram STFT z liniową skalą częstotliwości, (b) Spektrogram Constant-Q (CQT) z logarytmiczną skalą częstotliwości, (c) Mel-spektrogram z osią częstotliwości w skali Mel.


2.3 Rdzeń Automatycznej Transkrypcji Muzycznej: Zadania, Poziomy i Wyzwania

Automatyczna transkrypcja muzyczna, mimo swej pozornie prostej definicji, jest procesem wieloetapowym, obejmującym szereg skomplikowanych zadań cząstkowych. Zrozumienie tych zadań, poziomów abstrakcji, na jakich operują, oraz inherentnych wyzwań jest kluczowe dla oceny istniejących rozwiązań i projektowania nowych.

2.3.1 Definicja, zadania składowe i poziomy abstrakcji w ATM

Formalnie, ATM można zdefiniować jako proces estymacji parametrów nut, takich jak czas rozpoczęcia, wysokość i czas trwania, bezpośrednio z sygnału audio [15, 3]. Jest to

zadanie hierarchiczne, które można zdekomponować na kilka kluczowych zadań składowych. Do najważniejszych należą: estymacja wielokrotnej wysokości dźwięku (ang. *Multiple Pitch Estimation, MPE*), czyli identyfikacja wszystkich częstotliwości podstawowych obecnych w danym momencie; detekcja początku i końca dźwięku (ang. *Onset/Offset Detection*), czyli precyzyjne lokalizowanie w czasie momentów rozpoczęcia i zakończenia poszczególnych zdarzeń muzycznych; oraz, w bardziej zaawansowanych systemach, rozpoznawanie instrumentów, analiza rytmu i metrum, czy interpretacja ekspresji wykonawczej [3, 9]. Wyniki transkrypcji mogą być prezentowane na różnych poziomach abstrakcji: od predykcji na poziomie krótkich ramek czasowych (np. wskazanie aktywnych wysokości dźwięku w oknie kilkudziesięciu milisekund), przez symboliczną reprezentację nutową (zestaw nut z określonymi atrybutami), aż po bardziej złożone struktury, takie jak strumień melodyczny czy pełna partytura muzyczna uwzględniająca elementy notacji standardowej [3].



Rysunek 2.3: Uproszczony schemat potoku przetwarzania w systemie ATM: od sygnału audio, poprzez ekstrakcję cech, zadania składowe (MPE, detekcja onsetów/offsetów, estymacja instrumentu), aż po generowanie wyjściowej reprezentacji symbolicznej na różnych poziomach abstrakcji (ramki, nuty, partytura).

2.3.2 Transkrypcja monofoniczna vs. polifoniczna – złożoność i główne wyzwania

Złożoność zadania ATM znacząco wzrasta przy przejściu od transkrypcji monofonicznej (pojedyncza linia melodyczna) do polifonicznej (wiele współbrzmiących dźwięków) [15, 3]. Muzyka gitarowa, ze względu na możliwość gry akordowej i prowadzenia wielu niezależnych linii melodycznych, jest w przeważającej mierze polifoniczna, co czyni jej transkrypcję szczególnie trudną [5]. Główne wyzwania w ATM, które ulegają intensyfikacji w kontekście polifonii, to przede wszystkim: interferencja harmonicznym składowym różnych dźwięków

(szczególnie w interwałach konsonansowych), maskowanie cichszych dźwięków przez głośniejsze, trudności w precyzyjnej detekcji czasów rozpoczęcia i zakończenia dźwięków w gęstych fakturach, zmienność barwy dźwięku zależna od artykulacji i dynamiki, oraz częste błędy w estymacji wysokości, takie jak pomyłki oktawowo [3]. Dodatkowo, efektywne trenowanie modeli uczenia maszynowego wymaga dostępu do dużych, dokładnie zaanotowanych zbiorów danych, których tworzenie jest procesem czasochłonnym i kosztownym.

2.4 Przegląd Metod Stosowanych w Automatycznej Transkrypcji Muzycznej

Rzeczywisty rozwój metod automatycznej transkrypcji muzycznej jest procesem ciągłym, odzwierciedlającym postęp w dziedzinach przetwarzania sygnałów i uczenia maszynowego. Poniżej przedstawiono ewolucję tych podejść, od metod klasycznych po najnowsze techniki oparte na głębokim uczeniu.

2.4.1 Tradycyjne metody oparte na przetwarzaniu sygnałów

Historycznie pierwsze podejścia do automatycznej transkrypcji muzycznej opierały się w dużej mierze na technikach cyfrowego przetwarzania sygnałów [15]. W przypadku transkrypcji muzyki monofonicznej, gdzie w danym momencie występuje tylko jeden dźwięk, opracowano szereg metod detekcji jego częstotliwości podstawowej (F_0). Do klasycznych algorytmów należą te bazujące na analizie funkcji autokorelacji sygnału (ACF), uśrednionej funkcji różnicowej amplitudy (AMDF), technice (ang. *Harmonic Product Spectrum*, *HPS*), która wzmacnia częstotliwość podstawową poprzez mnożenie widma z jego skompresowanymi wersjami, oraz na analizie cepstralnej, pozwalającej na separację składowej związanej z pobudzeniem od składowej związanej z rezonansem instrumentu [15]. Rozwijano również systemy bazujące na modelach harmonicznym dźwięku oraz systemy ekspertowe, wykorzystujące predefiniowane reguły i wiedzę muzykologiczną. Metody te, choć wносиły istotny wkład w rozwój dziedziny, wykazywały znaczne ograniczenia w kontekście analizy złożonej muzyki polifonicznej, gdzie jednoczesne występowanie wielu dźwięków i ich alikwotów znacząco komplikuje sygnał, prowadząc m.in. do niemożności separacji nakładających się szeregów harmonicznym. Ograniczenia te stały się motywacją do poszukiwania bardziej zaawansowanych rozwiązań w ramach uczenia maszynowego.

2.4.2 Metody oparte na uczeniu maszynowym

Przełom w skuteczności systemów ATM przyniosło zastosowanie metod uczenia maszynowego, które pozwoliły na tworzenie modeli zdolnych do nauki złożonych zależności

bezpośrednio z danych [14, 5]. W ramach tego paradygmatu można wyróżnić kilka głównych kierunków.

Nienadzorowane metody faktoryzacji macierzy

Wśród metod nienadzorowanych, popularność zdobyła nieujemna faktoryzacja macierzy (ang. *Non-negative Matrix Factorization, NMF*) [3]. Technika ta polega na dekompozycji macierzy wejściowej (np. macierzy spektrogramu amplitudowego) na iloczyn dwóch macierzy o niższych wymiarach, których elementy są nieujemne. W kontekście ATM, macierze te mogą być interpretowane jako zbiór bazowych szablonów spektralnych (odpowiadających np. poszczególnym wysokościami dźwięków lub barwom instrumentów) oraz macierz kodująca aktywacje tych szablonów w czasie. Zaletą NMF jest zdolność do automatycznego odkrywania struktur w danych bez potrzeby etykietowania. Istotnym wyzwaniem jest jednak dobór odpowiedniej rangi faktoryzacji (liczby komponentów) oraz fakt, że NMF może mieć trudności z separacją źródeł o silnie nakładających się charakterystykach spektralnych. W celu rozwiązania tych problemów opracowano liczne rozszerzenia NMF, takie jak nadzorowane NMF (gdzie słownik jest predefiniowany) czy harmoniczne NMF (narzucające harmoniczną strukturę na szablony) [3].

Modele probabilistyczne i Bayesowskie

Ukryte modele Markowa (ang. *Hidden Markov Models, HMM*) były przez wiele lat intensywnie badane i stosowane w ATM, głównie ze względu na ich naturalną zdolność do modelowania sekwencyjnego charakteru muzyki [15, 6, 20]. W typowym podejściu, ukryte stany HMM mogą odpowiadać poszczególnym nutom lub stanom ciszy, a obserwacje emitowane przez te stany to wektory cech akustycznych wyekstrahowanych z kolejnych ramek sygnału audio. Prace Raphaëla (2002) [20] stanowią wczesny przykład zastosowania HMM do transkrypcji muzyki fortepianowej, gdzie modelowano proces generowania nut z uwzględnieniem prawdopodobieństw przejść między nimi. Cazau i Nuel (2017) [6] eksplorowali różne warianty HMM, w tym ich integrację z metodami dekompozycji spektralnej jak PLCA (ang. *Probabilistic Latent Component Analysis*), w celu poprawy jakości transkrypcji, np. poprzez modelowanie trwania nut lub wykorzystanie wiedzy o tonalności do modelowania przejść harmoniczych. Podejścia Bayesowskie, stanowiące szerszą klasę modeli, pozwalają na formalne włączenie do modelu wcześniejszej wiedzy (np. reguł harmonii, typowych progresji akordów) w postaci rozkładów a priori. Mimo pewnych sukcesów, modele te często wymagają starannej inżynierii cech i mogą mieć trudności z modelowaniem bardzo złożonych zależności w muzyce polifonicznej.

Głębokie sieci neuronowe (ang. *Deep Learning*)

W ostatnich latach metody oparte na głębokim uczeniu (ang. *Deep Learning*, *DL*) zdominowały badania nad ATM, osiągając wyniki stanowiące aktualny stan wiedzy w wielu aspektach tego zadania [3, 14]. Zdolność głębokich sieci neuronowych do automatycznego uczenia się hierarchicznych, wielopoziomowych reprezentacji cech bezpośrednio z danych wejściowych (np. surowych spektrogramów) okazała się kluczowa dla postępu. Wśród najczęściej wykorzystywanych architektur znajdują się splotowe sieci neuronowe (CNN), efektywnie przetwarzające dane o strukturze siatki, takie jak spektrogramy [24, 26]; rekurencyjne sieci neuronowe (RNN), w szczególności warianty LSTM (ang. *Long Short-Term Memory*) i GRU (ang. *Gated Recurrent Unit*), przystosowane do modelowania zależności czasowych w sekwencjach muzycznych [3]; oraz architektury hybrydowe, takie jak CRNN, łączące zalety obu tych podejść [9]. Najnowsze badania eksplorują również potencjał architektur opartych na mechanizmach uwagi, takich jak Transformer (ang. *Transformer*) [14, 10]. Dostępność dużych, publicznych zbiorów danych adnotowanych, takich jak MAESTRO dla muzyki fortepianowej [9, 26] (zawierający nagrania z konkursów pianistycznych wraz z precyzyjnymi plikami MIDI) oraz GuitarSet dla muzyki gitarowej [24, 26, 3] (oferujący nagrania z sześciu osobnych przetworników heksafonicznych dla każdej struny oraz zsynchronizowane adnotacje MIDI i tabulaturowe), była katalizatorem rozwoju modeli DL. To właśnie te obszerne i dokładnie zaanotowane zbiory danych umożliwiły trenowanie złożonych modeli DL na skalę niezbędną do osiągnięcia wysokiej dokładności, podkreślając, że postęp w tej dziedzinie jest równie mocno zależny od inżynierii danych, co od innowacji algorytmicznych. Model „Onsets and Frames” [9], zaprojektowany do transkrypcji muzyki fortepianowej, jest przykładem systemu DL, który osiągnął wysoką skuteczność. Wykorzystuje on architekturę konwolucyjno-rekurencyjną do jednoczesnej predykcji czasów rozpoczęcia dźwięków (ang. *onsets*) oraz aktywności poszczególnych nut w kolejnych ramkach czasowych. „Basic Pitch” [4] to z kolei narzędzie typu audio-to-MIDI, opracowane przez Spotify, które charakteryzuje się lekkością i zdolnością do detekcji zmian wysokości dźwięku (ang. *pitch bends*). Opiera się na modelach sieci neuronowych, a jego priorytetem jest szybkość działania i dostępność, co czyni je użytecznym w wielu praktycznych zastosowaniach, chociaż może nie osiągać takiej samej szczegółowości transkrypcji jak bardziej złożone systemy w przypadku skomplikowanych fragmentów polifonicznych. Mimo imponujących wyników, metody DL nie są pozbawione ograniczeń. Ich skuteczność jest silnie uzależniona od ilości i jakości danych treningowych. Modele te często działają na zasadzie „czarnej skrzynki”, co utrudnia interpretację ich wewnętrznych mechanizmów decyzyjnych. Ponadto, trening i inferencja złożonych modeli DL mogą być wymagające obliczeniowo [14].

2.5 Specyfika Transkrypcji Muzyki Gitarowej na Zapis Tabulaturowy (GTT)

Transkrypcja muzyki gitarowej, zwłaszcza z celem wygenerowania zapisu tabulaturowego, wprowadza szereg specyficznych problemów i wymagań, które odróżniają ją od ogólnego zadania ATM. Niniejsza sekcja poświęcona jest analizie tych unikalnych aspektów.

2.5.1 Akustyczna charakterystyka sygnału gitary i jej implikacje dla transkrypcji

Sygnał generowany przez gitarę posiada szereg unikalnych cech akustycznych, które czynią jego automatyczną transkrypcję zadaniem szczególnie złożonym [24, 5]. Obwiednia dźwięku gitary, zwłaszcza akustycznej, charakteryzuje się zazwyczaj bardzo szybkim atakiem i relatywnie długim, stopniowym wybrzmiewaniem, co może utrudniać precyzyjną detekcję czasów zakończenia dźwięków (ang. *offsets*). Barwa dźwięku gitary jest niezwykle zróżnicowana i zależy od wielu czynników, takich jak konstrukcja instrumentu (np. gitara akustyczna z pudłem rezonansowym, gitara elektryczna typu (ang. *solid-body*)), rodzaj i wiek strun, technika artykulacji (np. gra kostką, palcami, (ang. *slap*)), a w przypadku gitar elektrycznych – w decydującym stopniu od ustawień wzmacniacza oraz zastosowanych efektów gitarowych (np. (ang. *distortion, overdrive, chorus, flanger, delay, reverb*)) [24]. Ta inherentna zmienność i bogactwo barwowe, choć stanowią o atrakcyjności instrumentu, komplikują proces tworzenia uogólnionych modeli transkrypcyjnych. Kluczowe dla GTT jest również adekwatne uwzględnienie licznych, specyficznych dla gitary technik wykonawczych, które nie tylko znacząco wpływają na charakterystykę akustyczną sygnału, ale także mają swoje bezpośrednie odzwierciedlenie w zapisie tabulaturowym.

Tabela 2.1: Akustyczne Manifestacje Wybranych Technik Gitarowych Istotnych dla Transkrypcji na Tabulaturę

Technika	Opis	Akustyczna Manifestacja (Przykładowa)
(ang. <i>Hammer-on</i>)	Uderzenie palcem lewej ręki (dla praworęcznych gitarzystów) w strunę na wyższym progu w celu wydobycia dźwięku bez ponownego szarpania struny prawą ręką.	Zazwyczaj łagodniejszy atak spektralny w porównaniu do dźwięku szarpniętego; możliwy spadek amplitudy po wykonaniu techniki, szczególnie na cieńszych strunach [12]; poprzedzający dźwięk (jeśli był) może wybrzmiewać w tle z niższą amplitudą [12, 23]. Brak wyraźnego „dołka” w amplitudzie między nutami w sekwencji legato [21].
(ang. <i>Pull-off</i>)	Oderwanie palca lewej ręki od struny (zazwyczaj z lekkim jej szarpnięciem) w celu wydobycia niższego dźwięku, który już brzmi (np. na pustej strunie lub przytrzymywany innym palcem na niższym progu).	Podobnie jak (ang. <i>hammer-on</i>), charakteryzuje się łagodniejszym atakiem w porównaniu do dźwięku szarpniętego; zmiana wysokości następuje na niższą; może towarzyszyć krótki, szerokopasmowy szum związany z mechanicznym ruchem odrywania palca [23].
(ang. <i>Slide</i>) (ślizg)	Płynne przesunięcie palca lewej ręki wzdłuż struny pomiędzy dwoma progami, podczas gdy struna wibruje.	Ciągła, płynna zmiana częstotliwości podstawowej (F_0) i jej harmonicznych ((ang. <i>glissando</i>)) między wysokością początkową a końcową [23, 21]; zachowanie energii sygnału i jego ciągłości spektralnej; charakterystyczny profil przejścia między wysokościami, odróżniający od (ang. <i>bend</i>) [23].

Technika	Opis	Akustyczna Manifestacja (Przykładowa)
(ang. <i>Bend</i>) (podciągnięcie)	Poprzeczne podciągnięcie struny na gryfie palcem lewej ręki, co zwiększa jej napięcie i w rezultacie podwyższa wysokość dźwięku.	Płynna zmiana wysokości dźwięku (F_0) w górę, często z następującym powrotem do oryginalnej wysokości lub przejściem do innej [23, 21]; mogą pojawić się charakterystyczne zmiany w natężeniu alikwotów oraz subtelne zmiany barwy.
(ang. <i>Palm-muting</i>)	Delikatne tłumienie strun krawędzią dłoni prawej ręki (dla gitarzystów praworęcznych) w pobliżu mostka gitary, bezpośrednio po ich szarpnięciu.	Znaczne skrócenie czasu wybrzmiewania dźwięku (szybszy zanik energii); stłumiony, bardziej perkusyjny i mniej rezonujący charakter; redukcja udziału wyższych harmonicznych w spektrum, co prowadzi do „ciemniejszego”, „cichszego” brzmienia [23].
(ang. <i>Vibrato</i>)	Cykliczna, subtelna modulacja wysokości dźwięku, uzyskiwana przez oscylacyjny ruch palca przytrzymującego strunę na progu lub za pomocą ramienia tremolo.	Okresowe, stosunkowo wolne (typowo 5-7 Hz) fluktuacje częstotliwości podstawowej (F_0) i jej harmonicznych wokół centralnej wysokości dźwięku [1, 13]; może również występować sprzężona z tym modulacja amplitudy [1, 13].

Dokładne rozpoznanie tych i innych technik jest kluczowe dla stworzenia kompletnej, wiernej i użytecznej dla muzyka tabulatury.

2.5.2 Porównanie notacji standardowej i tabulaturowej dla gitary

W praktyce muzycznej gitarzyści posługują się dwoma głównymi systemami notacji: tradycyjną notacją muzyczną opartą na pięciolinii oraz tabulaturą gitarową. Każdy z tych systemów posiada swoje unikalne cechy, które determinują jego adekwatność w różnych zastosowaniach i dla różnych grup użytkowników [24]. Tabela 2.2 przedstawia zwięzłe porównanie obu systemów. Wybór tabulatury jako docelowej formy zapisu w wielu

współczesnych systemach GTT jest motywowany jej dużą popularnością, zwłaszcza wśród gitarzystów samouków i w muzyce rozrywkowej, oraz jej bezpośrednim, instruktażowym charakterem, który ułatwia naukę i wykonanie utworu na instrumencie.


Tabela 2.2: Porównanie Standardowej Notacji Muzycznej i Tabulatury Gitarowej

Cecha	Standardowa Notacja Muzyczna	Tabulatura Gitarowa
Reprezentacja wysokości	Abstrakcyjna, poprzez pozycję nuty na pięciolinii, wymagająca znajomości klucza i zasad teorii muzyki [24].	Bezpośrednia, poprzez wskazanie numeru progu na linii reprezentującej konkretną strunę gitary [24].
Reprezentacja rytmu	Precyzyjnie zdefiniowana za pomocą wartości rytmicznych nut, pauz i oznaczeń metrycznych [24].	Często uproszczona lub nieobecna; główny nacisk kładziony jest na wysokość i sposób opalcowania. Rytm bywa jednak dodawany za pomocą symboli podobnych do notacji standardowej lub poprzez odniesienie do nagrania [24].
Czytelność dla gitarzystów	Wymaga dłuższego procesu nauki i praktyki w czytaniu nut na pięciolinii [24].	Zazwyczaj bardzo intuicyjna i łatwa do szybkiego opanowania, szczególnie dla początkujących gitarzystów i samouków; bezpośrednio pokazuje, gdzie umieścić palce na gryfie [24].
Notacja technik gry	Możliwa za pomocą licznych dodatkowych symboli i oznaczeń słownych, ale czasami może być mniej jednoznaczna lub intuicyjna dla specyficznych technik gitarowych.	Bardzo dobrze przystosowana do notowania szerokiego spektrum specyficznych technik gitarowych ((ang. <i>bends</i> , <i>slides</i> , <i>hammer-ons</i> , <i>pull-offs</i> , <i>vibrato</i>) itp.) za pomocą dedykowanych symboli graficznych.
Niejednoznaczność opalcowania	Istnieje – ten sam dźwięk (wysokość) może być zagrany na gitarze na kilku różnych strunach i progach; wybór konkretnego opalcowania jest pozostawiony wykonawcy [24].	Zazwyczaj jednoznacznie określa zarówno strunę, jak i próg, na którym dany dźwięk ma być zagrany, tym samym eliminując problem wyboru opalcowania dla danej nuty [24].

2.5.3 Kluczowe wyzwania w automatycznej transkrypcji gitary na tabulaturę (GTT)

Transkrypcja na tabulaturę wprowadza szereg specyficznych wyzwań, które wykraczają poza ogólne problemy ATM:

- **Wysoka polifonia i nakładanie się dźwięków:** Gitara, jako instrument harmoniczny, często generuje złożone współbrzmienia, co intensyfikuje problem separacji i identyfikacji poszczególnych dźwięków w sygnale audio [5].
- **Niejednoznaczność reprezentacji dźwięku na gryfie (ang. *Tablature Inference / Fingering Estimation*):** Jest to jedno z fundamentalnych wyzwań w GTT. Ten sam dźwięk (o tej samej wysokości muzycznej) może być zagrany w wielu różnych pozycjach na gryfie gitary (tj. na różnych kombinacjach struny i progu) [24]. Wybór konkretnej pozycji przez gitarzystę zależy od wielu czynników, takich jak kontekst muzyczny (np. sąsiednie dźwięki), grywalność (łatwość wykonania danego pochodzenia dźwięków), preferencje stylistyczne, a nawet subtelne różnice w barwie dźwięku uzyskiwane na różnych strunach. System GTT musi więc nie tylko poprawnie zidentyfikować wysokość i czas trwania nuty, ale również podjąć decyzję co do jej najbardziej prawdopodobnego i/lub optymalnego opalcowania na gryfie.



Rysunek 2.4: Przykład tej samej nuty (E4, MIDI 64) możliwej do zagrania w wielu pozycjach na gryfie gitary standardowo strojonej. Ilustracja przedstawia dźwięk E4 na strunie G (9. próg), strunie B (5. próg) oraz pustej strunie wysokiej E. Obrazuje to fundamentalne wyzwanie estymacji opalcowania w GTT. Źródło: [8]

- **Zmienność barwy jako potencjalna wskazówka i problem:** Chociaż subtelne różnice w barwie dźwięku tej samej nuty granej na różnych strunach mogą teoretycznie dostarczać pewnych wskazówek dla algorytmów estymacji opalcowania, to wszechobecne i często intensywne stosowanie efektów gitarowych (szczególnie w muzyce rockowej, metalowej, jazzowej i elektronicznej) może całkowicie modyfikować oryginalną barwę instrumentu, maskując te subtelne różnice lub wprowadzając własne artefakty, co znacząco komplikuje analizę [24].
- **Detekcja i notacja technik wykonawczych:** Wierne odtworzenie partii gitarowej w formie tabulatury wymaga nie tylko transkrypcji samych nut, ale również

rozpoznania i odpowiedniego zanotowania licznych, specyficznych dla gitary technik artykulacyjnych (patrz Tabela 2.1) [21, 23]. Jest to zadanie trudne, gdyż akustyczne manifestacje tych technik bywają subtelne i zmienne.

- **Ograniczenia dostępnych zbiorów danych:** Rozwój systemów GTT opartych na uczeniu maszynowym, zwłaszcza na modelach głębokiego uczenia, jest w dużej mierze uzależniony od dostępności obszernych, publicznych zbiorów danych zawierających nagrania gitarowe wraz z precyzyjnymi, zsynchronizowanymi czasowo adnotacjami tabulaturowymi (obejmującymi informacje o strunie, progu, a idealnie także o zastosowanych technikach wykonawczych) [24, 26]. Tworzenie takich zbiorów jest procesem niezwykle pracochłonnym.
- **Problem „przesunięcia dziedziny”** (ang. *domain shift*): Modele GTT trenowane na danych pochodzących z jednej domeny (np. czyste, studyjne nagrania gitar akustycznych lub dane syntetyczne) mogą wykazywać znaczący spadek skuteczności, gdy są stosowane do danych z innej domeny (np. nagrania koncertowe, amatorskie, partie gitar elektrycznych z efektami) [26]. Praca Zang i in. (2023) nad zbiorem SynthTab [26] stanowi próbę zaadresowania problemu niedoboru zróżnicowanych danych rzeczywistych poprzez wykorzystanie dużych ilości danych syntetycznych do wstępnego treningu modeli, które następnie mogą być dostrajane na mniejszych zbiorach danych rzeczywistych.

2.5.4 Przegląd istniejących podejść i narzędzi do GTT

Współczesne podejścia do automatycznej transkrypcji gitary na tabulaturę można generalnie podzielić na dwuetapowe oraz zintegrowane, określane jako (ang. *end-to-end*). Każde z nich ma swoje charakterystyczne cechy i stawia czoła opisanym wyzwaniom w odmienny sposób. Podejścia dwuetapowe realizują zadanie GTT w dwóch oddzielnych krokach. W pierwszym etapie dokonuje się ogólnej transkrypcji muzycznej, czyli estymacji wielokrotnej wysokości dźwięku (MPE), w wyniku czego powstaje reprezentacja nutowa utworu (np. w formacie piano-roll lub MIDI), bez informacji o konkretnym opalcowaniu [5]. W drugim etapie, nazywanym aranżacją tabulatury lub inferencją opalcowania, system próbuje przypisać te wcześniej wykryte nuty do najbardziej prawdopodobnych lub optymalnych pozycji (strun i progów) na gryfie gitary. Ten etap często wykorzystuje modele optymalizacyjne, przeszukiwanie grafowe lub funkcje kosztu, które uwzględniają takie czynniki jak fizyczna grywalność (np. minimalizacja odległości ruchów ręki na gryfie, unikanie niemożliwych do zagrania kombinacji), typowe dla danego stylu muzycznego wzorce opalcowania, czy też subtelne różnice w barwie dźwięku między strunami. Zaletą tego podejścia jest jego modularność. Główną wadą jest natomiast ryzyko propagacji błędów z etapu MPE do etapu aranżacji tabulatury. Podejścia zintegrowane, opierające się w przeważającej mierze

na zaawansowanych modelach głębokiego uczenia, dążą do nauczenia się bezpośredniego mapowania z surowego sygnału audio (lub jego reprezentacji czasowo-częstotliwościowej) na finalną reprezentację tabulaturową w jednym, zintegrowanym kroku. Wykorzystują one złożone architektury sieci neuronowych, takie jak:

- Modele oparte na splotowych sieciach neuronowych (CNN), czego przykładem jest TabCNN [24]. Architektura ta typowo przetwarza wejściowy spektrogram (np. Constant-Q) i generuje na wyjściu predykcje dotyczące aktywności poszczególnych progów na każdej ze strun gitary, często w formie wielowymiarowej macierzy binarnej („six-hot encoding” dla sześciu strun i określonej liczby progów). Praca Zang i in. (2023) [26] również wykorzystuje architekturę zbliżoną do TabCNN jako jeden z modeli bazowych w swoich badaniach nad wykorzystaniem danych syntetycznych.
- Modele oparte na architekturze Transformer, które dzięki zastosowaniu mechanizmów uwagi (ang. *attention mechanisms*) są zdolne do efektywnego modelowania długoterminowych zależności w danych sekwencyjnych. Znalazły one zastosowanie w GTT, szczególnie w połączeniu z dużymi zbiorami danych, w tym syntetycznymi, takimi jak SynthTab [26].
- Inne architektury sieci neuronowych, w tym sieci rekurencyjne (RNN) lub ich bardziej zaawansowane warianty jak LSTM czy GRU, często stosowane w połączeniu z CNN (tworząc architektury CRNN), aby wykorzystać zdolności CNN do ekstrakcji lokalnych cech ze spektrogramów oraz zdolności RNN do modelowania kontekstu czasowego. Przykładowo, praca Burlet i Hindle (2017) [5] badała zastosowanie głębokich sieci przekonań (ang. *Deep Belief Networks*) dla transkrypcji izolowanych dźwięków gitarowych, co stanowiło wczesny przykład wykorzystania metod głębokiego uczenia w tym obszarze.

Zaletą podejść zintegrowanych jest ich potencjalna zdolność do uczenia się bardzo złożonych i subtelnych mapowań bezpośrednio z danych, co może prowadzić do lepszych wyników końcowych niż w podejściach dwuetapowych, szczególnie jeśli model jest w stanie jednocześnie uwzględniać zarówno informacje akustyczne, jak i ograniczenia wynikające z grywalności. Wymagają one jednak zazwyczaj znacznie większych i bardziej szczegółowych zbiorów danych treningowych. Niezależnie od podejścia, kluczową rolę w rozwoju systemów GTT odgrywają zbiory danych. GuitarSet [24, 26] jest jednym z najważniejszych publicznie dostępnych zbiorów, zawierającym około 3 godzin muzyki gitarowej granej w różnych stylach, z precyzyjnymi adnotacjami MIDI oraz, co unikalne, informacjami o strunie i progu dla każdej nuty, uzyskanymi dzięki zastosowaniu przetworników heksafonicznych (rejestrujących sygnał z każdej struny osobno) oraz starannej ręcznej weryfikacji. Zbiór DadaGP [26] to z kolei duży zbiór danych w formie symbolicznej (pliki Guitar Pro), który jest często wykorzystywany w badaniach nad GTT, szczególnie w kontekście modelowania i generowania tabulatur z uwzględnieniem bogatego zestawu technik wykonawczych i artykulacji.

SynthTab [26] to natomiast obszerny zbiór syntetycznych danych (par audio-tabulatura), stworzony w celu przewycięcia ograniczeń związanych z rozmiarem i różnorodnością dostępnych zbiorów danych rzeczywistych. Został on wygenerowany poprzez syntezę audio z plików Guitar Pro pochodzących ze zbioru DadaGP, z wykorzystaniem zaawansowanych symulatorów wzmacniaczy gitarowych i efektów w celu uzyskania realistycznie brzmiących nagrań. Badania wykazały, że modele GTT wstępnie trenowane na dużych zbiorach danych syntetycznych, a następnie dostrajane (ang. *fine-tuned*) na mniejszych zbiorach danych rzeczywistych, mogą osiągać znaczącą poprawę wyników transkrypcji [26]. Ten paradygmat pre-trainingu na danych syntetycznych i fine-tuningu na danych rzeczywistych staje się potężnym narzędziem poprawy odporności i generalizacji w GTT. Pomimo znaczących postępów, jakie dokonały się w dziedzinie GTT, obecne rozwiązania wciąż napotykają na istotne ograniczenia.

Do głównych nierozwiązanych problemów należą: osiągnięcie wysokiej dokładności transkrypcji w przypadku bardzo gęstych faktur polifonicznych i szybkich pasażów technicznych, opracowanie wiarygodnych metod inferencji tabulatury (opalcowania) w złożonych kontekstach muzycznych, które uwzględniałyby nie tylko poprawność nut, ale także grywalność i naturalność wykonania, precyzyjne rozpoznawanie i notacja szerokiego spektrum subtelnych technik artykulacyjnych, zapewnienie dobrej generalizacji modeli na różne style muzyczne, brzmienia gitar (w tym instrumenty z silnie zmodyfikowanym sygnałem za pomocą efektów) oraz różne jakości nagrań, a także sformułowanie obiektywnych i wszechstronnych metryk oceny jakości wygenerowanych tabulatur, które korelowałyby z percepcją i oceną przez doświadczonych gitarzystów [26, 24].

W procesie tworzenia i ewaluacji systemów ATM i GTT szeroko wykorzystuje się specjalistyczne biblioteki programistyczne do przetwarzania sygnałów audio i implementacji modeli uczenia maszynowego, takie jak Librosa, Essentia, a także frameworki głębokiego uczenia jak TensorFlow czy PyTorch.

2.6 Podsumowanie i Otwarte Problemy

Automatyczna transkrypcja muzyczna, a w jej ramach transkrypcja muzyki gitarowej na zapis tabulaturowy, pozostaje aktywnym i wymagającym obszarem badań naukowych. Znaczenie praktyczne skutecznych systemów GTT jest nie do przecenienia, obejmując wsparcie dla muzyków, edukację, archiwizację oraz przemysł muzyczny [3]. Jak wykazano w niniejszym rozdziale, główne wyzwania koncentrują się wokół przetwarzania złożonych sygnałów polifonicznych, radzenia sobie z dużą zmiennością barwy i artykulacji charakterystyczną dla gitary, a w przypadku GTT – dodatkowo wokół fundamentalnego problemu niejednoznaczności opalcowania oraz precyzyjnej detekcji i notacji specyficznych technik wykonawczych [24]. Przegląd stosowanych metod ukazuje wyraźną ewolucję od klasycznych technik opartych na przetwarzaniu sygnałów do zaawansowanych modeli uczenia

maszynowego, ze szczególnym uwzględnieniem głębokich sieci neuronowych, które obecnie definiują stan wiedzy w tej dziedzinie [15, 14]. Rozwiązania takie jak „Onsets and Frames” [9] czy „Basic Pitch” [4] dla ogólnych zadań ATM, oraz systemy dedykowane GTT, jak TabCNN [24] i nowsze podejścia wykorzystujące duże zbiory danych, w tym syntetyczne, jak w przypadku badań nad SynthTab [26], demonstrują znaczący postęp. Systemy te osiągają coraz wyższą skuteczność, jednakże wciąż istnieją liczne obszary wymagające dalszych, intensywnych badań. Do kluczowych otwartych problemów w dziedzinie GTT, które wyznaczają kierunki przyszłych prac, należą przede wszystkim:

- Dalsza poprawa dokładności i robustności transkrypcji w kontekście bardzo gęstej polifonii, szybkich pasażów muzycznych oraz sygnałów o niskiej jakości lub z silnymi zniekształceniami.
- Rozwój bardziej zaawansowanych i kontekstowych metod inferencji opalcowania na gryfie gitary, które lepiej odzwierciedlałyby rzeczywiste praktyki wykonawcze i zapewniały grywalność generowanych tabulatur.
- Zwiększenie zdolności systemów do rozpoznawania i poprawnej notacji szerokiego spektrum subtelnych technik gitarowych, które mają kluczowe znaczenie dla ekspresji muzycznej.
- Poprawa generalizacji modeli GTT na różne, nie widziane wcześniej w procesie treningu, brzmienia gitar (akustycznych, elektrycznych, z różnymi efektami), style muzyczne i warunki nagraniowe.
- Opracowanie bardziej kompleksowych i percepcyjnie adekwatnych metryk oceny jakości transkrypcji tabulaturowej, które wykraczałyby poza proste porównanie poprawności nut i uwzględniałyby aspekty takie jak grywalność, czytelność i wierność stylistyczną. Kwestia ta nawiązuje do obserwacji, że wyniki ilościowe nie zawsze w pełni odzwierciedlają praktyczną użyteczność systemu dla końcowego użytkownika [11].
- Kontynuacja prac nad tworzeniem i udostępnianiem większych, bardziej zróżnicowanych i precyzyjnie adnotowanych zbiorów danych dla GTT, w tym eksploracja metod efektywnego wykorzystania danych syntetycznych i technik transferu wiedzy.

Rozwiązanie tych problemów umożliwi stworzenie systemów GTT, które będą mogły stać się prawdziwie użytecznymi i powszechnie akceptowanymi narzędziami dla szerokiej społeczności gitarzystów.

Rozdział 3

Przedmiot Pracy: Projekt i Implementacja Systemu Transkrypcji Gitarowej

Przyjęta w ramach tej pracy strategia, polegająca na bezpośredniej predykcji progów gitarowych, jest wynikiem analizy i badań eksploracyjnych nad alternatywnymi podejściami. Początkowo rozważano adaptację istniejących modeli transkrypcji polifonicznej, w szczególności modelu Basic Pitch (w literaturze określanego jako NMP – Notes and Multipitch) [4]. Analiza tego modelu była motywowana faktem, iż w jego procesie treningowym wykorzystano zbiór danych GuitarSet, stanowiący również podstawę empiryczną dla niniejszego projektu. Basic Pitch został jednak zaprojektowany jako model agnostyczny instrumentalnie, zoptymalizowany do ogólnej transkrypcji, przewidujący momenty rozpoczęcia dźwięków (onsets), aktywacje nut oraz kontury wielodźwiękowe, a nie specyficzne informacje tabulaturowe.

Próby wytrenowania modelu Basic Pitch wyłącznie na zbiorze GuitarSet w celu generowania tabulatur okazały się niezadowalające. Stwierdzono, że oryginalna architektura osiągała wysoką skuteczność w ogólnej transkrypcji dzięki treningowi na zróżnicowanym zestawie danych (m.in. MAESTRO, Slakh), a ograniczenie go do GuitarSet uniemożliwiło wyspecjalizowanie modelu do nowego zadania. Eksplorowano również podejście dwuetapowe, polegające na predykcji zdarzeń muzycznych (nut, onsetów) i późniejszym wnioskowaniu tabulatury, podobnie do założeń systemu „Onsets and Frames” [9]. To podejście także nie przyniosło zadowalających rezultatów. Doświadczenia te jednoznacznie wskazały na konieczność opracowania dedykowanego modelu, ukierunkowanego na bezpośrednią predykcję progów gitarowych, co stało się fundamentem rozwiązania przedstawionego w dalszej części niniejszego rozdziału.

Niniejszy rozdział stanowi szczegółowe omówienie projektu i implementacji autorskiego systemu do automatycznej transkrypcji polifonicznych nagrań gitarowych na zapis ta-

bulaturowy (GTT). Celem prac było stworzenie oraz ewaluacja systemu zdolnego do przekształcania sygnału audio gitary w symboliczną reprezentację tabulaturową, z wykorzystaniem technik głębokiego uczenia. Kluczowym aspektem projektu jest możliwość eksperymentalnego porównania dwóch odmiennych metod reprezentacji sygnału wejściowego: tradycyjnych mel-spektrogramów oraz transformaty Constant-Q (CQT), celem zbadania ich efektywności w zadaniu GTT. Opierając się na fundamentach teoretycznych i przeglądzie stanu wiedzy przedstawionym w poprzednich rozdziałach, w tej części pracy opisana zostanie architektura i logika działania opracowanego rozwiązania. Prezentacja ta ma na celu nie tylko techniczny opis zrealizowanych prac, ale również analityczne osadzenie podjętych decyzji projektowych w kontekście literatury naukowej.

3.1 Opis Zaimplementowanego Rozwiązania

W tej sekcji przedstawiono szczegółowy opis systemu GTT zaimplementowanego w ramach niniejszej pracy. Opis koncentruje się na funkcjonalności poszczególnych komponentów systemu, poczynając od przygotowania danych, poprzez architekturę modelu, aż po proces treningu i ewaluacji.

3.1.1 Architektura Ogólna Systemu

Zaproponowany system GTT charakteryzuje się modułową architekturą potokową (ang. *pipeline*), co umożliwia elastyczne zarządzanie poszczególnymi etapami przetwarzania oraz systematyczne prowadzenie eksperymentów. Główny skrypt sterujący, zrealizowany w formie interaktywnego notatnika, pełni rolę centrum zarządzania całym projektem, orkiestrując proces od przygotowania danych, przez trening modelu z przeszukiwaniem hiperparametrów, aż po ewaluację i wizualizację wyników. Centralnym elementem systemu jest mechanizm konfiguracyjny, który agreguje wszystkie globalne stałe i parametry. Obejmują one definicje ścieżek dostępu do danych wejściowych, przetworzonych oraz wyników, parametry przetwarzania sygnału audio (takie jak częstotliwość próbkowania, długość kroku analizy), specyficzne ustawienia dla generowania mel-spektrogramów (rozmiar okna FFT, liczba pasm Mel) oraz dla transformaty CQT (minimalna częstotliwość, liczba prążków, liczba prążków na oktawę). Ponadto, konfiguracja zawiera parametry dotyczące tworzenia zbiorów danych, w tym ustawienia augmentacji, oczekiwane wymiary tensorów dla celów walidacyjnych, domyślne ustawienia architektury modelu (np. liczba kanałów wyjściowych w warstwach splotowych) oraz parametry procesu treningu (np. domyślna liczba epok, rozmiar wsadu, metryka wyboru najlepszego modelu) i generowania plików wynikowych w formacie tabulatur tekstowych. Taka centralizacja parametrów ułatwia ich modyfikację i zapewnia spójność w całym systemie.

3.1.2 Przetwarzanie Wstępne i Przygotowanie Danych

Staranne przygotowanie danych jest fundamentalnym etapem w procesie uczenia maszynowego. W ramach systemu obejmuje ono podział zbioru danych, ekstrakcję cech akustycznych z plików audio, przetwarzanie adnotacji oraz zapis przetworzonych danych w formacie tensorów.

Podział Zbioru Danych

System wykorzystuje publicznie dostępny zbiór danych GuitarSet [25], który zawiera nagrania gitarowe wraz z precyzyjnymi adnotacjami. Proces podziału zbioru na części treningową, walidacyjną i testową jest zautomatyzowany. Na początku, z ogólnej listy utworów eliminowane są nagrania zidentyfikowane jako problematyczne. W ramach tej pracy, zgodnie z doniesieniami społeczności, ze zbioru wyłączono dwa pliki: 04_BN3-154-E_comp oraz 04_Jazz1-200-B_comp. Powodem tej decyzji były minimalne błędy w adnotacjach, polegające na stałym przesunięciu czasowym wszystkich nut, co mogłoby negatywnie wpłynąć na proces treningu modelu [22]. Następnie, przy użyciu standardowych narzędzi do selekcji modeli, identyfikatory utworów są dzielone na trzy zbiory: treningowy, walidacyjny i testowy. Zastosowano standardowy w praktyce uczenia maszynowego podział w proporcjach 80:10:10. Użycie stałego zarodka losowości na tym etapie gwarantuje powtarzalność i porównywalność wyników eksperymentów. Wynikowe listy identyfikatorów dla każdego zbioru są zapisywane do plików tekstowych, które są następnie wykorzystywane przez komponent ładujący dane.

Ekstrakcja Cech Akustycznych i Przetwarzanie Adnotacji

Jako podstawową reprezentację czasowo-częstotliwościową sygnału wejściowego dla sieci neuronowej wybrano transformację Constant-Q (CQT). Wybór ten podyktowany jest jej korzystnymi właściwościami dla analizy sygnałów muzycznych: oś częstotliwości jest logarytmicznie skalowana, co bezpośrednio odpowiada percepcji wysokości dźwięku i ułatwia sieciom konwolucyjnym (CNN) uczenie się cech niezależnych od transpozycji [24, 15, 3].

Sygnał audio z każdego utworu jest najpierw próbkowany do częstotliwości 22050 Hz, a następnie normalizowany amplitudowo. Parametry CQT zostały ustalone zgodnie z konfiguracją projektu: 24 pasma (biny) na oktawę, obejmując 7 oktaw, co daje łącznie 168 pasm częstotliwościowych. Minimalna częstotliwość ($F_{\min}$) została dobrana tak, aby pokryć najniższy możliwy dźwięk gitary w standardowym stroju (E2, MIDI 40). Krok analizy (ang. *hop size*) ustalono na 512 próbek, co przy częstotliwości próbkowania 22050 Hz daje rozdzielczość czasową około 43 ramek na sekundę. W przeciwieństwie do niektórych architektur bazujących na stałych oknach czasowych, zaimplementowany model

CRNN przetwarza całą sekwencję ramek spektrogramu, a za analizę kontekstu czasowego odpowiadają warstwy rekurencyjne.

Równolegle do ekstrakcji cech, adnotacje ze zbioru GuitarSet (czas początku, czas końca, numer struny i numer progu) są przekształcane na format ramkowy, zgodny z wyjściem modelu [9]. Dla każdej ramki czasowej i każdej z sześciu strun gitary generowane są dwa typy etykiet:

1. **Etykieta Onsetu:** Wartość binarna (1 lub 0) wskazująca, czy w danej ramce rozpoczyna się nowa nuta na danej strunie.
2. **Etykieta Progu:** Wartość kategorialna (od 0 dla struny pustej do 20) wskazująca numer aktywnego progu na danej strunie. Dodatkowa, 22. klasa jest używana do reprezentowania ciszy. Dla każdej ramki od początku do końca trwania nuty przypisywany jest odpowiedni numer progu, ucząc model nie tylko detekcji, ale również śledzenia aktywności dźwięku.

Chociaż system, dzięki swojej modułowej budowie, umożliwia również pracę z wcześniej przetworzonymi mel-spektrogramami, główny potok eksperymentalny oparto na CQT ze względu na jej lepsze dopasowanie do natury sygnałów muzycznych oraz możliwość efektywnego łączenia z augmentacją audio w locie.

Komponent Zbioru Danych i Augmentacja

Dedykowany komponent zbioru danych, zgodny ze standardowym interfejsem frameworka PyTorch, odpowiada za ładowanie i przygotowywanie danych dla modelu. Jego kluczową cechą jest elastyczność pozwalająca na obsługę dwóch scenariuszy ekstrakcji cech:

- Wczytywanie wstępnie przetworzonych mel-spektrogramów z plików tensorowych (głównie dla zbiorów walidacyjnego i testowego).
- Generowanie spektrogramów CQT w locie z surowych plików audio (głównie dla zbioru treningowego, co umożliwia efektywne stosowanie augmentacji audio przed transformacją). Parametry CQT, takie jak minimalna częstotliwość (np. odpowiadająca dźwiękowi E2 gitary), liczba prążków (np. 168) oraz liczba prążków na oktawę (np. 24), są przekazywane podczas inicjalizacji i pochodzą z centralnej konfiguracji [24, 26]. Transformata CQT jest obliczana przy użyciu biblioteki Librosa, a jej wynik konwertowany na skalę decybelową.


Początkowe eksperymenty wykazały, że model wytrenowany na czystych, studyjnych nagraniach ma trudności z generalizacją do nagrań realizowanych w warunkach domowych. W odpowiedzi na te wyzwania, przyjęto nową strategię, której celem nie jest już dostarczenie modelowi idealnych danych, lecz nauczenie go, jak wygląda niedoskonały

świat rzeczywistych nagrań. W tym celu znacząco rozbudowano i zintensyfikowano proces augmentacji danych w locie dla zbioru treningowego, wprowadzając techniki celowo "pogarszające" czysty sygnał wejściowy. Zastosowane techniki augmentacji obejmują:

- **Augmentacje audio** (stosowane do surowego sygnału przed obliczeniem CQT) [15, 3]:
 - Rozciąganie w czasie (ang. *time stretching*): modyfikuje tempo nagrania w zdefiniowanym zakresie, z odpowiednią korektą czasów w etykietach.
 - Dodawanie szumu (ang. *noise addition*): do sygnału dodawany jest szum o losowo wybranej amplitudzie.
 - Losowe wzmocnienie (ang. *random gain*): amplituda sygnału jest mnożona przez losowy współczynnik, symulując zmiany dynamiki.
 - Symulacja pogłosu pomieszczenia (ang. *reverb*): W celu nauczania modelu ignorowania akustyki pomieszczenia, do sygnału dodawany jest sztuczny pogłos. Jest on generowany poprzez operację splotu matematycznego z syntetyczną odpowiedzią impulsową. Kluczowe parametry tego efektu, takie jak czas zanikania oraz natężenie, są losowane w każdym kroku, co symuluje nagrania w setkach różnych środowisk akustycznych – od małych, wytlumionych pokoi po większe przestrzenie z wyraźnym echem.
 - Symulacja charakterystyki mikrofonu (ang. *EQ*): Aby naśladować działanie mikrofonów niższej jakości (np. w laptopach), które słabo zbierają skrajne pasma częstotliwości, stosowany jest cyfrowy filtr pasmowo-przepustowy. Filtr ten „obcina” najniższe (bas) i najwyższe (sopran) częstotliwości, tworząc bardziej „pudełkowy”, skupiony w środku dźwięk. Model uczy się w ten sposób, że brak pełni brzmienia nie musi oznaczać braku nuty. Częstotliwości odcięcia filtru są losowane z szerokiego zakresu, co symuluje całą gamę niedoskonałych urządzeń nagrywających.
 - Symulacja przesterowania (ang. *clipping*): W warunkach domowych łatwo jest ustawić zbyt wysoki poziom głośności nagrywania, co prowadzi do cyfrowego obcinania wierzchołków fali dźwiękowej. Aby przygotować model na takie sytuacje, wprowadzono augmentację, która celowo obcina amplitudę sygnału po przekroczeniu pewnego progu. Uczy to model rozpoznawania nut nawet wtedy, gdy ich sygnał jest zniekształcony w ten sposób. Próg, przy którym następuje obcięcie, jest losowany, co naśladuje różne stopnie przesterowania sygnału.
- **Augmentacja spektrogramu** (SpecAugment) [18]: stosowana do wygenerowanych spektrogramów (Mel lub CQT). Polega na losowym maskowaniu pewnych fragmentów spektrogramu:

- Maskowanie w dziedzinie czasu (ang. *Time Masking*): Losowe zakrywanie pewnej liczby kolejnych ramek czasowych.
- Maskowanie w dziedzinie częstotliwości (ang. *Frequency Masking*): Losowe zakrywanie pewnego zakresu pasm częstotliwości.

Podczas każdej epoki treningu model otrzymuje próbki z czystego zbioru danych, na które nakładana jest unikalna, losowa kombinacja powyższych efektów z losowo dobranymi parametrami. Takie podejście zmusza model do porzucenia oczekiwania na idealny, studyjny sygnał i uczy go generalizacji do warunków znacznie odbiegających od tych, w których powstał oryginalny zbiór treningowy. Niezależnie od źródła cech (plik tensorowy lub generacja w locie), komponent zbioru danych przekształca wczytane surowe adnotacje nutowe na format ramkowy. Dla każdej ramki czasowej spektrogramu tworzone są dwie macierze etykiet (dla sześciu strun gitary): jedna dla onsetów (wartość 1.0 oznacza początek nuty na danej strunie w danej ramce, 0.0 w przeciwnym przypadku) i jedna dla numerów progów (liczba całkowita reprezentująca aktywny próg, ze specjalną wartością dla ciszy). Liczba ramek w etykietach jest synchronizowana z liczbą ramek w tensorze cech.



Rysunek 3.1: Wizualizacja etykiet ramkowych dla fragmentu utworu. Górny panel przedstawia macierz onsetów, gdzie pionowe linie oznaczają moment rozpoczęcia nuty na danej strunie. Dolny panel pokazuje macierz aktywności progów, gdzie czarne obszary reprezentują czas trwania dźwięku na danej strunie.

Przetwarzanie Wsadowe i Walidacja Danych

Do efektywnego treningu modelu, próbki danych są grupowane we wsady (ang. *batches*). Ponieważ poszczególne próbki (utwory) mogą mieć różną długość, zaimplementowano mechanizm dopełniania (ang. *padding*). Dedykowana funkcja agregująca, używana przez mechanizm ładowania danych, uzupełnia tensory cech i etykiet w ramach wsadu do długości najdłuższej sekwencji w tym wsadzie, wykorzystując standardowe narzędzia frameworka PyTorch. System zawiera również zestaw narzędzi diagnostycznych do weryfikacji poprawności i spójności przetworzonych danych. Funkcje te sprawdzają, czy kształty i typy danych tensorów (np. CQT, Mel, etykiet onsetów i progów) są zgodne z oczekiwaniami zdefiniowanymi w konfiguracji, oraz czy wartości w tensorach mieszczą się w oczekiwanych zakresach


(np. wartości binarne, brak wartości nieokreślonych). Możliwe jest przeprowadzenie pełnej walidacji na całym zbiorze danych, agregując statystyki i drukując podsumowanie.

3.1.3 Model Transkrypcji (CRNN)

Sercem systemu transkrypcji jest konwolucyjno-rekurencyjna sieć neuronowa (CRNN), zaimplementowana w frameworku PyTorch. Architektura ta, przedstawiona na rysunku 3.2, została zaprojektowana z myślą o przetwarzaniu dwuwymiarowych reprezentacji czasowo-częstotliwościowych (głównie CQT) i modelowaniu zależności czasowych. Model składa się z trzech głównych bloków:

- **Frontend konwolucyjny (CNN):** Ta część jest odpowiedzialna za ekstrakcję hierarchicznych cech z wejściowego spektrogramu. Składa się z sekwencji pięciu warstw konwolucyjnych 2D (`Conv2d`) z filtrami o rozmiarze 3x3, po których następują warstwy normalizacji wsadowej, funkcje aktywacji ReLU oraz warstwy max-pooling redukujące wymiarowość map cech [24, 5]. Liczba filtrów w kolejnych warstwach jest konfigurowalna.
- **Backend rekurencyjny (RNN):** Złożony z dwukierunkowych warstw rekurencyjnych. Zadaniem tego bloku jest modelowanie zależności czasowych w sekwencjach cech wyekstrahowanych przez CNN [3]. Dwukierunkowość pozwala na analizę każdej ramki w kontekście zarówno przeszłych, jak i przyszłych zdarzeń, co jest korzystne dla precyzji transkrypcji [9, 15]. W projekcie wykorzystano głównie bramkowane jednostki rekurencyjne (GRU, ang. *Gated Recurrent Unit*) [7]. Jednostki GRU, posiadając prostszą architekturę od tradycyjnych LSTM (ang. *Long Short-Term Memory*), są często bardziej wydajne obliczeniowo, oferując przy tym porównywalną skuteczność w modelowaniu sekwencji. Kluczowe parametry RNN, takie jak rozmiar stanu ukrytego, liczba warstw oraz współczynnik dropout dla regularyzacji, są konfigurowalnymi hiperparametrami.
- **Warstwy Wyjściowe:** Przetworzone przez RNN sekwencje cech są następnie podawane na dwie oddzielne, w pełni połączone warstwy liniowe. Jedna warstwa (`onset_fc`) generuje logity dla predykcji onsetów dla każdej z sześciu strun. Druga warstwa (`fret_fc`) generuje logity dla predykcji klas progów (włączając klasę ciszy) dla każdej struny. Takie podejście wielozadaniowe, gdzie model uczy się jednocześnie detekcji zdarzeń i klasyfikacji stanów, jest inspirowane pracą "Onsets and Frames" [9].

System zawiera również funkcję pomocniczą do ładowania zapisanego stanu modelu z pliku, tworząc nową instancję modelu z odpowiednimi parametrami i wczytując do niej zapisane wagi.



Rysunek 3.2: Schemat architektury zaimplementowanego modelu CRNN. Przedstawia przepływ danych od wejściowego tensora spektrogramu, przez frontend konwolucyjny, backend rekurencyjny, aż po rozdzielenie na dwie głowice wyjściowe dla predykcji onsetów i progów.

3.1.4 Proces Treningu Modelu

Proces treningu modelu jest zarządzany przez dedykowany moduł, który orkiestruje cały cykl dla pojedynczego zestawu hiperparametrów.

Inicjalizacja i Pętla Treningowa

Dla każdego przebiegu w ramach przeszukiwania hiperparametrów tworzony jest unikalny katalog na artefakty. Następnie inicjalizowany jest model CRNN, funkcja straty oraz optymalizator. Zdecydowano się na użycie optymalizatora AdamW [16]. Jest to udoskonalona wersja popularnego optymalizatora Adam, która inaczej implementuje mechanizm regularyzacji (zaniku wag, ang. *weight decay*). W AdamW zanik wag jest oddzielony od kroku aktualizacji gradientu, co prowadzi do bardziej stabilnego treningu i lepszej generalizacji modelu w porównaniu do standardowej implementacji L2 w Adam. Początkowy współczynnik uczenia jest kluczowym hiperparametrem. Na podstawie tych parametrów inicjowany jest również, opcjonalnie, mechanizm harmonogramowania współczynnika uczenia (np. ReduceLROnPlateau), który redukuje współczynnik uczenia o konfigurowalny czynnik, gdy metryka walidacyjna przestaje się poprawiać przez określoną liczbę epok.

Główna pętla treningowa iteruje przez zdefiniowaną liczbę epok. W każdej epoce wykonywane są dwie fazy:

- **Faza treningowa:** Model jest ustawiany w tryb treningowy. Dla każdego wsadu danych ze zbioru treningowego zerowane są gradienty, wykonywane jest przejście w przód przez model, obliczana jest złożona funkcja straty, a następnie wykonywana jest propagacja wsteczna i aktualizacja wag modelu przez optymalizator.
- **Faza walidacyjna:** Model jest ustawiany w tryb ewaluacyjny, a obliczanie gradientów jest wyłączane. Dla każdego wsadu danych ze zbioru walidacyjnego wykonywane jest przejście w przód, obliczana jest funkcja straty oraz szeroki zestaw metryk wydajności.

Wszystkie straty i metryki są zapisywane w historii treningu. Postępy są logowane do pliku tekstowego oraz wyświetlane na konsoli. Stosowany jest mechanizm wczesnego zatrzymywania (ang. *early stopping*), który przerywa trening, jeśli ślędzona metryka walidacyjna nie poprawia się przez zadaną, większą liczbę epok, aby zapobiec przeuczeniu i zaoszczędzić zasoby obliczeniowe [3]. Najlepszy model (na podstawie metryki walidacyjnej) jest zapisywany. Na koniec generowany jest wykres historii treningu. Zastosowano również techniki regularyzacji w celu zapobiegania przeuczeniu: dropout w warstwach LSTM [7, 15] oraz regularyzację L2 (weight decay) [16, 15]. Wartość współczynnika zaniku wag jest kolejnym istotnym hiperparametrem.

Funkcja Straty i Próg Decyzyjny

Zastosowano złożoną funkcję straty ($\mathcal{L}_{\text{total}}$), która jest ważoną sumą dwóch komponentów: straty dla predykcji onsetów ($\mathcal{L}_{\text{onset}}$) oraz straty dla predykcji progów ($\mathcal{L}_{\text{fret}}$), co przedstawia wzór 3.1:

$$\mathcal{L}_{\text{total}} = w_{\text{onset}} \cdot \mathcal{L}_{\text{onset}} + w_{\text{fret}} \cdot \mathcal{L}_{\text{fret}} \quad (3.1)$$

gdzie w_{onset} i w_{fret} to wagi poszczególnych komponentów straty. Wartość w_{onset} jest konfigurowalnym hiperparametrem, natomiast w_{fret} przyjęto jako 1.0.

Stratę $\mathcal{L}_{\text{onset}}$ oblicza się przy użyciu ważonej binarnej entropii krzyżowej z logitami (`BCEWithLogitsLoss`), aby przeciwdziałać niezbalansowaniu klas (onety są zdarzeniami rzadkimi w porównaniu do braku onsetu). Waga dla pozytywnych przykładów (onety) jest określana przez konfigurowalny hiperparametr. Dla pojedynczej struny s i ramki t , strata onsetu jest dana wzorem:

$$\mathcal{L}_{\text{onset},s,t} = -[w_{\text{pos}} \cdot y_{s,t}^{\text{onset}} \lg(\sigma(\hat{z}_{s,t}^{\text{onset}})) + (1 - y_{s,t}^{\text{onset}}) \lg(1 - \sigma(\hat{z}_{s,t}^{\text{onset}}))] \quad (3.2)$$

gdzie $y_{s,t}^{\text{onset}} \in \{0, 1\}$ to etykieta referencyjna, $\hat{z}_{s,t}^{\text{onset}}$ to logit wyjściowy modelu dla onsetu, $\sigma(\cdot)$ to funkcja sigmoid, a w_{pos} to waga dla pozytywnych przykładów. Całkowita $\mathcal{L}_{\text{onset}}$ jest średnią $\mathcal{L}_{\text{onset},s,t}$ po wszystkich strunach i ramkach wsadu, z uwzględnieniem maskowania dla ramek dopełniających.

Stratę $\mathcal{L}_{\text{fret}}$ oblicza się przy użyciu standardowej entropii krzyżowej (`CrossEntropyLoss`) dla klasyfikacji progów na każdej strunie. Wykorzystuje się ignorowanie określonego indeksu (`ignore_index`) do pomijania wartości dopełniających. Dla pojedynczej struny s i ramki t :

$$\mathcal{L}_{\text{fret},s,t} = - \sum_{c=0}^{N_{\text{klas}} \text{ prog} - 1} y_{s,t,c}^{\text{fret}} \lg(p_{s,t,c}^{\text{fret}}) \quad (3.3)$$

gdzie $y_{s,t,c}^{\text{fret}}$ jest wskaźnikiem (0 lub 1), czy klasa progów c jest poprawna, a $p_{s,t,c}^{\text{fret}}$ jest prawdopodobieństwem predykcji klasy c (wyjście funkcji softmax). Całkowita $\mathcal{L}_{\text{fret}}$ jest średnią $\mathcal{L}_{\text{fret},s,t}$ po wszystkich strunach i ramkach.

W celu zapewnienia szybkości i spójności procesu treningu, podczas fazy walidacyjnej w każdej epoce stosowany jest stały próg decyzyjny dla predykcji onsetów. Predykcja jest uznawana za pozytywną (wystąpienie onsetu), jeśli zwrócone przez model prawdopodobieństwo przekracza wartość 0.5. Bardziej zaawansowany proces wyszukiwania optymalnego progów, który maksymalizuje docelową metrykę (np. TDR F1-score), jest celowo odroczone i wykonywany jest tylko jednokrotnie, w ramach finalnej analizy na zbiorze testowym, co zostało szczegółowo opisane w sekcji 3.1.5.

3.1.5 Ewaluacja i Generowanie Wyników

Po zakończeniu treningu, najlepszy model jest poddawany finalnej ewaluacji na zbiorze testowym. System umożliwia również generowanie wyników w formatach ułatwiających analizę jakościową.

Konwersja Predykcji na Nuty i Metryki Ewaluacyjne

Ramkowe predykcje modelu, składające się z prawdopodobieństw onsetów i rozkładów prawdopodobieństwa dla klas progów, są w pierwszym kroku przekształcane w listę dyskretnych zdarzeń nutowych. Proces ten, zrealizowany w module `note_conversion_utils.py`, iteruje po każdej z sześciu strun, wykorzystując logikę maszyny stanów do identyfikacji początków i końców nut. Wykrycie onetu (prawdopodobieństwo powyżej progu) dla aktywnego progu inicjuje nową nutę, która jest kontynuowana do momentu spełnienia warunku terminacji (np. kolejny onet na tej samej strunie). Wynikiem jest symboliczna reprezentacja transkrypcji, gotowa do oceny ilościowej.

Podejście do ewaluacji opiera się na zestawie trzech komplementarnych metryk, które oceniają różne aspekty jakości transkrypcji, od precyzji czasowej po poprawność tonalną. Wszystkie metryki bazują na fundamentalnych pojęciach:

- **True Positives (TP):** Poprawnie zidentyfikowane zdarzenia (nuty, onety, aktywne ramki).
- **False Positives (FP):** Zdarzenia przewidziane przez model, które nie mają odpowiednika w danych referencyjnych („fałszywe alarmy”).
- **False Negatives (FN):** Zdarzenia obecne w danych referencyjnych, które zostały pominięte przez model.

Na ich podstawie obliczane są standardowe wskaźniki: Precyzja, Czułość oraz miara F1-Score, zdefiniowane następującymi wzorami:

$$\text{Precyzja} = \frac{TP}{TP + FP} \quad (3.4)$$

$$\text{Czułość (Recall)} = \frac{TP}{TP + FN} \quad (3.5)$$

$$\text{F1-Score} = 2 \cdot \frac{\text{Precyzja} \cdot \text{Czułość}}{\text{Precyzja} + \text{Czułość}} \quad (3.6)$$

Kluczowe jest jednak to, jak TP, FP i FN są definiowane dla każdej z poszczególnych metryk.

Metryka Główna: Tablature Detection Rate (TDR) TDR jest najważniejszą metryką, oceniającą finalną jakość wygenerowanej tabulatury. Nuta jest uznawana za

poprawną (TP) tylko wtedy, gdy predykcja jest zgodna z adnotacją referencyjną we wszystkich trzech wymiarach:

- **Zgodność Czasu Rozpoczęcia:** Czas onsetu predykcji mieści się w oknie tolerancji ± 50 ms wokół onsetu referencyjnego.
- **Zgodność Struny:** Predykcja i adnotacja wskazują na ten sam numer struny.
- **Zgodność Progu:** Predykcja i adnotacja wskazują na ten sam numer progu.

Każda przewidziana nuta, która nie spełnia tych kryteriów, jest liczona jako FP, a każda nuta referencyjna, dla której nie znaleziono dopasowania, jako FN [24].

Metryka Diagnostyczna Timing: Onset F1-Score Ta metryka w izolacji ocenia zdolność modelu do precyzyjnego lokalizowania w czasie momentów rozpoczęcia dźwięków. Do jej obliczenia wykorzystano standardową w badaniach MIR bibliotekę `mir_eval`. Zdarzenie jest tu uznawane za poprawne (TP), jeśli spełniony jest tylko jeden warunek:

- **Zgodność Czasu Rozpoczęcia:** Czas onsetu predykcji mieści się w oknie tolerancji ± 50 ms wokół onsetu referencyjnego.

Poprawność progu i struny jest na tym etapie ignorowana. Implementacja w `mir_eval` zapewnia poprawne, jedno-do-jednego dopasowanie zdarzeń, co jest kluczowe dla wiarygodności tej metryki [3].

Metryka Diagnostyczna Wysokości Dźwięku: MPE F1-Score Metryka Multi-Pitch Estimation (MPE) na poziomie ramek ocenia, czy model poprawnie rozpoznaje, jaki dźwięk (próg) jest aktywny w danym, krótkim momencie. W przeciwieństwie do TDR, nie analizuje ona nut jako zdarzeń, lecz ciągłą aktywność dźwięków. Dla każdej ramki czasowej i każdej struny:

- **TP:** Ramka, w której zarówno etykieta referencyjna, jak i predykcja wskazują na aktywny dźwięk (nie ciszę) ORAZ numer progu jest w nich identyczny.
- **FP:** Ramka, w której model przewidział aktywny dźwięk, podczas gdy w etykiecie była cisza, LUB model przewidział zły numer progu dla aktywnej nuty.
- **FN:** Ramka, w której etykieta wskazywała na aktywny dźwięk, podczas gdy model przewidział ciszę, LUB model przewidział zły numer progu dla aktywnej nuty.

Ta metryka pozwala precyzyjnie zdiagnozować problemy z rozpoznawaniem wysokości dźwięków, niezależnie od dokładności detekcji onsetów [4].

Generowanie Wyników i Analiza Końcowa

Finalny etap pracy z modelem obejmuje szczegółową analizę jego działania na niewidzianych wcześniej danych testowych oraz generowanie czytelnych dla człowieka wyników. W tym celu, po zakończeniu całego procesu przeszukiwania hiperparametrów i wyborze najlepszego modelu (na podstawie metryki walidacyjnej), uruchamiany jest dedykowany skrypt analityczny.

Proces ten przebiega w kilku krokach. Najpierw, najlepszy model jest uruchamiany na całym zbiorze testowym w celu zebrania kompletnych predykcji (prawdopodobieństw onsetów i macierzy progów) dla każdego utworu. Następnie, system przeprowadza procedurę optymalizacyjną, aby znaleźć optymalny próg decyzyjny dla onsetów, który maksymalizuje uśrednioną metrykę TDR F1-score na zbiorze testowym.

Kluczowym elementem analizy jest ocena jakości transkrypcji dla każdego pliku z osobna. Używając znalezionej optymalnej progów, system oblicza TDR F1-score dla każdego utworu testowego, a następnie tworzy ranking plików od tych z najlepszym wynikiem (najwyższy F1-score) do tych z najgorszym. Na podstawie tego rankingu, generowane są pliki tabulatur w formacie tekstowym (ASCII) dla kilku najlepszych i kilku najgorszych przypadków. Takie podejście pozwala na dogłębną, jakościową analizę błędów modelu, ułatwiając zrozumienie, w jakich warunkach radzi on sobie najlepiej, a gdzie popełnia najwięcej błędów.

3.1.6 Wizualizacja

System zawiera zestaw funkcji do tworzenia różnego rodzaju wykresów przy użyciu biblioteki Matplotlib. Umożliwiają one wizualizację:

- Spektrogramów wejściowych (Mel lub CQT).
- Etykiet i predykcji onsetów w formie grafu typu "piano roll".
- Etykiet i predykcji progów w formie kolorowej mapy.
- Zbiorczych wykresów dla pojedynczych próbek, pokazujących spektrogram oraz odpowiadające mu etykiety i predykcje.
- Ewolucji strat i metryk wydajności w kolejnych epokach treningu.

Te narzędzia wizualizacyjne są wykorzystywane zarówno do weryfikacji poprawności danych, jak i do analizy wyników działania modelu i procesu treningu.

3.2 Analiza Teoretyczna Rozwiązania

W tej sekcji dokonano analizy teoretycznej zaimplementowanego systemu, odnosząc poszczególne komponenty do ugruntowanych koncepcji teoretycznych i literatury naukowej, bazując na przedstawionych faktach implementacyjnych.

3.2.1 Wybór Architektury CRNN w Kontekście GTT

Zastosowanie architektury konwolucyjno-rekurencyjnej (CRNN) jest dobrze uzasadnione specyfiką zadania automatycznej transkrypcji tabulatur gitarowych (GTT). Połączenie spłotowych sieci neuronowych (CNN) jako ekstraktora cech z wejściowych reprezentacji czasowo-częstotliwościowych oraz rekurencyjnych sieci neuronowych (RNN) do modelowania sekwencji czasowych tych cech jest sprawdzonym podejściem w dziedzinie transkrypcji muzycznej [9, 24].

- Warstwy konwolucyjne (CNN), zaimplementowane jako TabCNN, efektywnie uczą się hierarchicznych, lokalnych cech z dwuwymiarowych spektrogramów (Mel lub CQT). Są zdolne do identyfikacji wzorców istotnych dla rozpoznawania dźwięków gitarowych, takich jak struktury harmoniczne czy transjenty [24, 3].
- Warstwy rekurencyjne, w tym przypadku dwukierunkowe LSTM, są wyspecjalizowane w modelowaniu zależności czasowych w sekwencjach cech dostarczonych przez CNN [3]. Dwukierunkowość pozwala na analizę każdej ramki w kontekście zarówno przeszłych, jak i przyszłych zdarzeń, co jest korzystne dla precyzji transkrypcji [9]. Ich alternatywą są jednostki GRU, które dzięki prostszej budowie mogą być bardziej efektywne obliczeniowo, jednak LSTM często wykazują przewagę w modelowaniu zależności długoterminowych [7].

Podejście wielozadaniowe, polegające na jednoczesnej predykcji onsetów i progów przez oddzielne głowice wyjściowe, inspirowane pracą [9], pozwala modelowi uczyć się bardziej kompletnych reprezentacji.

3.2.2 Reprezentacja Sygnału Wejściowego

System umożliwia eksperymentalne porównanie dwóch typów reprezentacji czasowo-częstotliwościowych, co stanowi istotny element badawczy.

- **Mel-spektrogramy** są standardowym wyborem w wielu zadaniach MIR ze względu na ich psychoakustyczną motywację – skala Mel aproksymuje ludzką percepcję wysokości dźwięku [3, 15].
- **Spektrogramy Constant-Q (CQT)** oferują logarytmiczne skalowanie osi częstotliwości, co bezpośrednio odpowiada strukturze skal muzycznych. Taka reprezentacja,

gdzie rozdzielczość częstotliwościowa jest proporcjonalna do częstotliwości (np. stała liczba prążków na oktawę), może być bardziej naturalna dla modeli CNN w zadaniach muzycznych, potencjalnie ułatwiając naukę cech niezmienniczych względem wysokości dźwięku [24, 26, 15]. Użycie parametrów CQT (np. 168 prążków, 24 prążki na oktawę) jest zgodne z praktykami stosowanymi w literaturze dla transkrypcji gitarowej [24].

Możliwość generowania CQT w locie dla zbioru treningowego, w połączeniu z augmentacją audio, pozwala na efektywne wykorzystanie tej reprezentacji bez konieczności wstępnego przetwarzania i przechowywania dużych ilości danych.

3.2.3 Funkcja Straty i Optymalizacja Wielozadaniowa

Zastosowanie złożonej funkcji straty, będącej ważoną sumą strat dla predykcji onsetów i progów, jest przykładem uczenia wielozadaniowego (ang. *multi-task learning*). Takie podejście często prowadzi do poprawy jakości predykcji, ponieważ model uczy się współdzielonych reprezentacji, które są korzystne dla obu powiązanych zadań [9].

- Użycie binarnej entropii krzyżowej dla predykcji onsetów jest standardem dla zadań klasyfikacji binarnej.
- Użycie entropii krzyżowej dla predykcji progów jest odpowiednie dla zadań klasyfikacji wieloklasowej.

Maskowanie strat w celu ignorowania dopełnionych części sekwencji oraz możliwość ważenia poszczególnych komponentów straty są istotnymi elementami zapewniającymi stabilny i efektywny trening. Optymalizacja progu decyzyjnego dla onsetów na zbiorze walidacyjnym pozwala na dostosowanie modelu do specyfiki danych i maksymalizację wybranej metryki (np. F1-score).

3.2.4 Techniki Augmentacji Danych

Zastosowane techniki augmentacji danych odgrywają kluczową rolę w procesie treningu, szczególnie przy pracy ze zbiorami danych o ograniczonej wielkości, takimi jak Guitar-Set [24, 26]. Rozbudowany zestaw augmentacji został wprowadzony w odpowiedzi na niezadowalającą skuteczność modelu na nagraniach domowych. Przyjęta filozofia zakłada celowe "pogarszanie" idealnych danych treningowych, aby nauczyć model generalizacji do niedoskonałych warunków rzeczywistych.

- Augmentacje audio, takie jak rozciąganie w czasie, dodawanie szumu czy losowe wzmocnienie, symulują naturalne wariacje w grze [23, 15]. Zostały one uzupełnione o trzy kluczowe techniki modelujące specyficzne problemy nagrań amatorskich:

symulacja pogłosu pomieszczenia uczy model odporności na zróżnicowaną akustykę, symulacja charakterystyki słabszych mikrofonów za pomocą filtracji pasmowej uczy go rozpoznawania nut w sygnałach o ograniczonym paśmie, a symulacja cyfrowego przesterowania (clipping) uodparnia go na zniekształcenia. Stosowanie tych technik z losowymi parametrami w sposób probabilistyczny tworzy wirtualnie nieskończoną liczbę unikalnych, trudniejszych przykładów treningowych z ograniczonego zbioru źródłowego.

- Augmentacja spektrogramu (SpecAugment), polegająca na maskowaniu fragmentów w dziedzinie czasu i częstotliwości, zmusza model do nauki bardziej robustnych i rozproszonych cech, zwiększając jego odporność na częściowe zakłócenia sygnału lub niewielkie zmiany w artykulacji [26, 18].

Stosowanie tych technik wyłącznie na zbiorze treningowym i w locie jest efektywnym sposobem na zwiększenie efektywnego rozmiaru zbioru treningowego bez konieczności generowania i przechowywania dodatkowych danych.

3.3 Uzasadnienie Wyboru Zastosowanych Metod, Algorytmów i Narzędzi

W tej sekcji przedstawiono uzasadnienie decyzji dotyczących wyboru konkretnych metod, algorytmów i narzędzi programistycznych, opierając się na przedstawionych faktach implementacyjnych.

3.3.1 Zbiór Danych GuitarSet

Wybór zbioru danych GuitarSet [25] jest podyktowany jego unikalnymi cechami, które są kluczowe dla zadania automatycznej transkrypcji na tabulaturę. GuitarSet dostarcza nie tylko nagrania audio, ale przede wszystkim precyzyjne adnotacje na poziomie strun, określające numer struny i progu dla każdej zagranej nuty. Te informacje, uzyskane dzięki zastosowaniu przetworników heksafonicznych, są niezbędne do uczenia modelu zdolnego do rozwiązywania problemu niejednoznaczności opalcowania [24, 8]. Mimo ograniczeń co do rozmiaru i zidentyfikowanych drobnych błędów w adnotacjach niektórych plików [22], GuitarSet pozostaje standardem w badaniach nad GTT.

3.3.2 Wybór Reprezentacji Czasowo-Częstotliwościowych

Decyzja o zaimplementowaniu i umożliwieniu porównania mel-spektrogramów oraz spektrogramów CQT jest motywowana chęcią empirycznej weryfikacji skuteczności tych dwóch popularnych reprezentacji w kontekście GTT. Mel-spektrogramy są standardem

w wielu zadaniach MIR ze względu na ich psychoakustyczną motywację [3, 15]. Z kolei CQT, z logarytmiczną skalą częstotliwości, jest teoretycznie lepiej dopasowana do natury muzyki i może ułatwiać modelom CNN naukę cech istotnych dla transkrypcji gitarowej [24, 26, 15]. Możliwość eksperymentowania z obiema reprezentacjami w ramach jednego systemu jest jego istotną zaletą badawczą.

3.3.3 Architektura CRNN jako Model Transkrypcji

Wybór architektury CRNN, łączącej konwolucyjny front-end (TabCNN) z rekurencyjnym back-endem (LSTM), jest uzasadniony jej udokumentowaną skutecznością w zadaniach transkrypcji muzycznej [9, 24]. CNN efektywnie ekstrahują cechy z dwuwymiarowych spektrogramów, podczas gdy dwukierunkowe LSTM modelują zależności czasowe w tych cechach. Takie połączenie pozwala na kompleksową analizę sygnału audio. Architektura ta oferuje dobry kompromis między zdolnościami modelowania a złożonością obliczeniową, co jest istotne przy ograniczonych zasobach i rozmiarze zbioru danych, w porównaniu do bardziej zasobożernych modeli, np. opartych w całości na Transformerach [10]. Zastosowanie optymalizatora AdamW zamiast Adam jest motywowane jego lepszą obsługą zaniku wag, co często przekłada się na lepszą generalizację modelu [16].

3.3.4 Wykorzystane Biblioteki Programistyczne

Dobór narzędzi programistycznych odzwierciedla aktualne standardy w badaniach z zakresu MIR i uczenia maszynowego.

- **PyTorch** został wybrany jako główny framework do głębokiego uczenia ze względu na jego elastyczność, dynamiczne grafy obliczeniowe oraz bogaty ekosystem narzędzi wspierających rozwój modeli uczenia maszynowego [19].
- **Librosa** jest standardową biblioteką do analizy sygnałów audio i muzyki w Pythonie, dostarczającą implementacje funkcji do wczytywania audio, ekstrakcji cech (STFT, mel-spektrogramy, CQT) oraz augmentacji [17].
- **Mirdata** ułatwia standaryzowaną pracę ze zbiorami danych MIR, takimi jak GuitarSet, promując powtarzalność badań [4].
- Inne biblioteki, takie jak NumPy, Scikit-learn, Matplotlib, JAMS i PrettyMIDI, dostarczają niezbędnych narzędzi na różnych etapach projektu, od operacji numerycznych, przez podział danych i wizualizację, po pracę z adnotacjami i generowanie plików MIDI. Do implementacji zaawansowanych augmentacji audio wykorzystano również bibliotekę **SciPy** ze względu na jej wydajne i stabilne funkcje przetwarzania sygnałów, w tym filtry cyfrowe i operację splotu.

Korzystanie z tych sprawdzonych narzędzi pozwoliło na skupienie się na aspektach badawczych projektu.

3.4 Podsumowanie Rozdziału

W niniejszym rozdziale szczegółowo przedstawiono projekt i implementację autorskiego systemu do transkrypcji gitarowej. Omówiono jego architekturę, której trzon stanowi konwolucyjno-rekurencyjna sieć neuronowa (CRNN), uzasadniając jej wybór zdolnością do jednoczesnego przetwarzania cech czasowo-częstotliwościowych i modelowania sekwencji. Kluczowym elementem przedstawionego rozwiązania, stanowiącym odpowiedź na wyzwania związane z przetwarzaniem nagrań amatorskich, jest zaawansowana strategia augmentacji danych. W rozdziale opisano, jak odejście od standardowych technik na rzecz celowego symulowania niedoskonałości sygnału – takich jak pogłos, zniekształcenia charakterystyki mikrofonu czy przesterowanie – pozwoliło na zbudowanie modelu o większej odporności i zdolności do generalizacji. Zaprezentowano również kompletny potok przetwarzania, od przygotowania danych ze zbioru GuitarSet, poprzez wielozadaniowy proces treningu, aż po kompleksowy system ewaluacji oparty na metrykach branżowych. Zaimplementowany system, ze szczególnym uwzględnieniem jego innowacyjnego podejścia do augmentacji, stanowi w pełni przygotowaną i uzasadnioną teoretycznie platformę, gotową do przeprowadzenia finalnych badań eksperymentalnych opisanych w kolejnym rozdziale.

Rozdział 4

Badania Eksperymentalne i Wyniki

Niniejszy rozdział stanowi szczegółowe sprawozdanie z iteracyjnego procesu badawczego, którego celem była weryfikacja, optymalizacja i ocena systemu do automatycznej transkrypcji tabulatur gitarowych (GTT), opisanego w Rozdziale 3. Proces ten, udokumentowany w postaci serii ponad 70 eksperymentów, został przeprowadzony w sposób metodyczny, aby zrozumieć wpływ poszczególnych komponentów i hiperparametrów na finalną jakość transkrypcji. Proces ten wpisuje się w szeroki kontekst badań nad Automatyczną Transkrypcją Muzyczną (ATM), która, jak wskazują prace przeglądowe [3] oraz [14], pozostaje jednym z fundamentalnych i wciąż otwartych wyzwań w dziedzinie przetwarzania sygnałów muzycznych.

Proces badawczy został zaprojektowany jako ewolucyjna ścieżka, gdzie wnioski z każdej serii eksperymentów stanowiły podstawę do formułowania hipotez i projektowania kolejnych, bardziej świadomych kroków optymalizacyjnych. Kluczowym momentem w procesie badawczym okazało się odkrycie, iż dalsza optymalizacja architektury i hiperparametrów przynosi jedynie marginalne korzyści. Przełom nastąpił po radykalnej zmianie filozofii podejścia do danych treningowych, co doprowadziło do opracowania zaawansowanej strategii augmentacji, która ostatecznie umożliwiła osiągnięcie wyników przewyższających stan wiedzy.

4.1 Środowisko i Metodyka Eksperymentów

4.1.1 Infrastruktura Sprzętowa i Programistyczna

Badania eksperymentalne zostały przeprowadzone z wykorzystaniem infrastruktury sprzętowej i programistycznej przedstawionej w Tabeli 4.1.

Tabela 4.1: Parametry środowiska eksperymentalnego.

Komponent	Specyfikacja / Wersja
Sprzęt	
System Operacyjny	Windows 11
Procesor (CPU)	12th Gen Intel(R) Core(TM) i5-12600KF 3.69 GHz
Karta Graficzna (GPU)	NVIDIA GeForce RTX 3070 (8 GB VRAM)
Pamięć RAM	64 GB DDR4
Oprogramowanie	
Python	3.9
PyTorch	2.3.1+cu121 [19]
Librosa	0.11.0 [17]
Mirdata	0.3.9 [4]

4.1.2 Reprezentacje Danych Wejściowych

W ramach badań porównano skuteczność dwóch reprezentacji czasowo-częstotliwościowych, których parametry ekstrakcji przedstawiono w Tabeli 4.2. Wybór transformaty Constant-Q (CQT) jako jednej z głównych reprezentacji był podyktowany jej korzystnymi właściwościami dla analizy sygnałów muzycznych, takimi jak logarytmiczne skalowanie osi częstotliwości, co odpowiada ludzkiej percepcji wysokości dźwięku i ułatwia sieciom konwulucyjnym (CNN) uczenie się cech niezależnych od transpozycji [24, 15, 26].

Tabela 4.2: Parametry ekstrakcji cech dla badanych reprezentacji sygnału.

Parametr	Reprezentacja Mel	CQT (wys. rozdzielczość)
Częstotliwość próbkowania	22050 Hz	22050 Hz
Długość kroku analizy	512 próbek	512 próbek
Rozmiar okna FFT	2048 próbek	Nie dotyczy
Liczba pasm (binów)	128 (pasm Mel)	168 (biny CQT)
Liczba pasm na oktawę	Nie dotyczy	24
Minimalna częstotliwość	Nie dotyczy	E2 (~ 82.41 Hz)

4.1.3 Metryki Oceny

Do oceny jakości modeli wykorzystano metryki opisane szczegółowo w sekcji 3.1.5. Wartości miary F1 dla zbioru walidacyjnego, obliczane przy stałym progu decyzyjnym dla onsetów wynoszącym 0.5, były podstawą do wyboru najlepszej wersji modelu w każdym przebiegu. W finalnej ewaluacji na zbiorze testowym, próg ten był optymalizowany w celu maksymalizacji TDR F1-Score.

Jak zostanie to szczegółowo omówione w sekcji 4.3.2, kluczowe dla rzetelnej oceny i porównania z literaturą okazało się rozróżnienie dwóch typów metryk: metryki na poziomie nut (TDR F1-Score), używanej jako główny wskaźnik praktycznej jakości transkrypcji, oraz metryki na poziomie ramek (MPE F1-Score), która umożliwiła bezpośrednie, metodologicznie poprawne porównanie z wynikami z kluczowych prac w tej dziedzinie.

4.2 Szczegółowy Opis Procesu Badawczego

Przeprowadzony projekt badawczy był złożonym, wieloetapowym procesem, który obejmował nie tylko implementację, ale przede wszystkim dogłębną analizę, eksperymenty i iteracyjne doskonalenie każdego z komponentów. Poniższa metodologia opisuje kluczowe fazy prac, od eksploracji danych po finalną walidację modelu. Cały proces, udokumentowany w postaci ponad 70 eksperymentów, miał charakter ewolucyjny, gdzie wnioski z każdej serii badań stanowiły podstawę do formułowania hipotez i projektowania kolejnych kroków.

4.2.1 Faza Wstępna: Analiza Danych i Wybór Metod Reprezentacji

Punktem wyjścia projektu nie było natychmiastowe przystąpienie do kodowania, lecz faza badawcza mająca na celu zrozumienie natury problemu i dostępnych danych.

Dogłębna Analiza Zbioru GuitarSet

Pierwszym krokiem było szczegółowe zapoznanie się ze strukturą zbioru danych GuitarSet [25]. Analizowano format plików audio, a przede wszystkim strukturę plików adnotacji JAMS. Badano, w jaki sposób przechowywane są informacje o wysokości dźwięku (wartości MIDI), czasie trwania, momencie ataku (onsecie) oraz, co kluczowe dla zadania transkrypcji tabulaturowej, o przypisaniu nuty do konkretnej struny i progu gitary. Zrozumienie tych niuansów, w tym sposobu kodowania informacji o artykulacjach czy specyficznych technikach gitarowych, było fundamentalne dla zaprojektowania poprawnego potoku przetwarzania danych oraz interpretacji wyników modelu.

Badanie Metod Reprezentacji Sygnału Audio

Następnie przeprowadzono analizę porównawczą różnych metod transformacji sygnału audio na reprezentację czasowo-częstotliwościową, która miała służyć jako wejście do sieci neuronowej. Rozważano standardowe spektrogramy Mel, często stosowane w zadaniach MIR [3, 15]. Jednakże, szczególną uwagę poświęcono transformacie Constant-Q (CQT). Stwierdzono, w oparciu o literaturę [24, 26, 15] oraz własne analizy, że jej logarytmiczna skala częstotliwości znacznie lepiej odwzorowuje ludzką percepcję muzyki oraz strukturę

harmoniczną gitary, co potencjalnie ułatwia modelom CNN naukę cech niezależnych od transpozycji. W tej fazie wykorzystano dedykowane skrypty do wizualizacji i porównania różnych typów spektrogramów dla próbek z GuitarSet, co ostatecznie potwierdziło wybór CQT jako optymalnej cechy wejściowej dla modelu.

4.2.2 Projektowanie Potoku Przetwarzania Danych

Na podstawie wniosków z fazy analitycznej zaprojektowano i zaimplementowano potok przetwarzania danych.

Implementacja Przekształceń i Tworzenie Etykiet

Stworzono mechanizm, który w sposób zautomatyzowany wczytywał pliki audio oraz odpowiadające im pliki adnotacji JAMS ze zbioru GuitarSet. Następnie dla każdego utworu:

- Obliczano spektrogramy CQT zgodnie ze specyfikacją ustaloną w Tabeli 4.2.
- Generowano macierze referencyjne (ang. *ground truth*) dla onsetów i progów, precyzyjnie mapując ciągłe dane czasowe z adnotacji na dyskretne ramki spektrogramu. Proces ten był inspirowany podejściem ramkowym, znanym m.in. z pracy [9]. Dla każdej ramki czasowej i każdej z sześciu strun gitary tworzone etykiety binarne dla onsetu oraz etykiety kategorialną dla aktywnego progu (z osobną klasą dla ciszy).

Eksperymenty z Augmentacją Danych

Proces rozwoju technik augmentacji miał charakter iteracyjny. Początkowo wdrożono standardowe techniki, takie jak losowa zmiana głośności i dodawanie szumu [15, 3]. Jednak obserwacja, że model wciąż ma trudności z generalizacją do nagrań realizowanych w warunkach domowych, doprowadziła do fundamentalnej zmiany strategii. Zamiast dostarczać modelowi idealnych danych, postanowiono nauczyć go, jak wygląda niedoskonały świat rzeczywistych nagrań. W tym celu, jak szczegółowo opisano w Rozdziale 3 (sekcja 3.1.2), zaimplementowano i zastosowano zaawansowany zestaw augmentacji audio, które celowo "pogarszały" czysty sygnał wejściowy, symulując pogłos pomieszczenia, ograniczenia tanich mikrofonów oraz cyfrowe przesterowanie. To właśnie ta strategia okazała się kluczowa dla osiągnięcia finalnych, przełomowych wyników.

4.2.3 Projektowanie Architektury i Procesu Treningowego

Ta faza miała charakter wysoce iteracyjny i była kluczowa dla sukcesu projektu. Obejmowała zarówno projektowanie architektury modelu, jak i całego procesu jego uczenia.

Definicja i Automatyzacja Potoku Uczenia

Zaprojektowano w pełni zautomatyzowany potok treningowy, który integrował wszystkie niezbędne komponenty: ładowanie i augmentację danych, inicjalizację modelu CRNN, obliczanie złożonej funkcji straty, optymalizację wag modelu przy użyciu optymalizatora AdamW [16], oraz regularną walidację na zbiorze walidacyjnym. Automatyzacja ta umożliwiła efektywne przeprowadzenie licznych i systematycznych eksperymentów z różnymi konfiguracjami.

Eksperymenty z Funkcją Straty

Dobór odpowiedniej funkcji straty był przedmiotem osobnych badań. Ze względu na znaczną dysproporcję między liczbą ramek z onsetem a tymi bez niego (problem niezbalansowanych klas w predykcji onsetów), standardowa binarna entropia krzyżowa okazała się niewystarczająca. Ostatecznie, po analizie wyników i stabilności treningu, zaimplementowano ważoną wersję binarnej entropii krzyżowej z logitami (`BCEWithLogitsLoss`) dla zadania predykcji onsetów, oraz standardową entropię krzyżową dla wieloklasowej predykcji progów (szczegółowo opisane w Rozdziale 3, sekcja 3.1.4).

Optymalizacja Architektury i Hiperparametrów

Zamiast przyjmować jedną, stałą architekturę, przeprowadzono szeroko zakrojone wyszukiwanie hiperparametrów oraz testowanie różnych wariantów architektury modelu. Zautomatyzowany potok treningowy był wielokrotnie uruchamiany w celu przetestowania:

- **Reprezentacji wejściowej:** Początkowe eksperymenty (Etap I procesu badawczego) koncentrowały się na modelu bazowym wykorzystującym spektrogramy Mel [15]. Następnie (Etap II) dokonano transformacji na CQT o wyższej rozdzielczości (168 pasm), co przyniosło znaczącą poprawę wyników, zgodnie z doniesieniami z literatury [24, 26].
- **Rozmiarów modelu:** Testowano różne wielkości warstw ukrytych w komponencie RNN (np. 512, 768, 1024 jednostek).
- **Struktury modelu (komponent RNN):** Porównywano skuteczność komórek LSTM z komórkami GRU [7] (Etap III). Badano wpływ liczby warstw rekurencyjnych (jedna vs. dwie) oraz zastosowania mechanizmu dwukierunkowości (BiLSTM/BiGRU), który pozwala modelowi na analizę kontekstu zarówno z przeszłych, jak i przyszłych ramek [9, 3].
- **Parametrów regularyzacji:** Eksperymentowano z różnymi wartościami współczynnika dropout w warstwach rekurencyjnych oraz wartością zaniku wag (ang. *weight decay*) w optymalizatorze AdamW [16].

- **Parametrów treningowych:** Testowano różne strategie dla współczynnika uczenia (ang. *learning rate*) i jego harmonogramu (np. `ReduceLROnPlateau`), a także różne rozmiary wsadu (ang. *batch size*).

Każdy eksperyment był traktowany jako osobny "przebieg" (run), a jego konfiguracja, wyniki na zbiorze walidacyjnym oraz wagi najlepszego modelu były skrupulatnie zapisywane. Zapewniło to pełną odtwarzalność badań i umożliwiło późniejszą analizę porównawczą oraz wybór finalnej, optymalnej konfiguracji. We wszystkich przebiegach stosowano mechanizm wczesnego zatrzymywania, przerywając trening po 25 epokach bez poprawy metryki TDR F1-Score na zbiorze walidacyjnym.

4.2.4 Ewaluacja, Analiza Wyników i Walidacja Końcowa

Po zakończeniu fazy eksperymentalnej i wyborze najlepszego modelu na podstawie wyników na zbiorze walidacyjnym, przystąpiono do jego finalnej oceny i analizy.

Analiza Ilościowa i Jakościowa

Przeprowadzono wielopoziomową ewaluację najlepszego modelu na niewidzianym wcześniej zbiorze testowym. Obejmowała ona nie tylko obliczenie i analizę metryk obiektywnych (TDR F1-Score, TDR Precyzja, TDR Czułość, Onset F1-Score, MPE F1-Score), ale przede wszystkim dogłębną analizę jakościową. Wizualne porównanie wygenerowanych transkrypcji z tabulaturami referencyjnymi dla wybranych, reprezentatywnych próbek pozwoliło na odkrycie i zrozumienie złożonych zjawisk. Szczegółowe wyniki tej analizy przedstawiono w sekcji 4.3.

Walidacja na Danych Zewnętrznych (Koncepcyjna)

Chociaż główny nacisk położono na ewaluację na zbiorze GuitarSet, zaprojektowano również potok inferencyjny, który umożliwiałby transkrypcję dowolnego nagrania gitarowego dostarczonego przez użytkownika. Potok ten obejmował opcjonalny krok preprocessingu w postaci redukcji szumów, a następnie aplikację wytrenowanego modelu do wygenerowania tabulatury. Ten krok, choć nie był przedmiotem formalnej, ilościowej ewaluacji w ramach niniejszej pracy ze względu na brak adnotowanych danych zewnętrznych, stanowił koncepcyjne potwierdzenie praktycznej użyteczności opracowanego rozwiązania.

4.3 Analiza Wyników i Dyskusja

4.3.1 Porównanie Ilościowe Najlepszych Modeli

Tabela 4.3 przedstawia kompleksowe porównanie metryk dla pięciu kluczowych modeli zidentyfikowanych w procesie badawczym, ocenionych na zbiorze testowym. Przebiegi te

ilustrują ewolucję modelu, której kulminacją był **przebieg 72**. Model ten, wytrenowany z wykorzystaniem radykalnie ulepszonej strategii augmentacji danych opisanej w Rozdziale 3, osiągnął najlepsze wyniki. Co istotne, wprowadzenie augmentacji symulujących niedoskonałości nagrań domowych pozwoliło modelowi stać się bardziej "wrażliwym" na subtelne cechy sygnału. W efekcie, optymalny próg decyzyjny dla detekcji onsetów na zbiorze testowym dla przebiegu 72 spadł do wartości **0.35**, w porównaniu do wyższych wartości (np. 0.63 dla przebiegu 71) w modelach trenowanych bez tych zaawansowanych technik. Świadczy to o tym, że model nauczył się poprawnie identyfikować nuty nawet wtedy, gdy ich sygnał jest cichszy i mniej wyraźny, co jest kluczowe dla analizy nagrań amatorskich.

Tabela 4.3: Kompleksowe porównanie metryk dla kluczowych modeli na zbiorze testowym.

Metryka / Konfiguracja	Przebieg 23 (Mel-LSTM)	Przebieg 59 (CQT-LSTM)	Przebieg 67 (CQT-BiGRU)	Przebieg 71 (CQT-BiGRU L2)	Przebieg 72 (Finalny) (CQT-BiGRU L2 + Aug v2)
Konfiguracja Modelu					
Reprezentacja Wejściowa	Mel-spektrogram	CQT (168)	CQT (168)	CQT (168)	CQT (168)
Architektura RNN	1-warstwowa LSTM	1-warstwowa LSTM	1-warstwowa BiGRU	2-warstwowa BiGRU	2-warstwowa BiGRU
Metryki na Poziomie Nut (TDR)					
TDR F1-Score	0.7953	0.8305	0.8449	0.8472	0.8569
TDR Precyzja	0.8201	0.8687	0.8759	0.8803	0.8757
TDR Czułość	0.7720	0.8013	0.8202	0.8210	0.8436
Metryki Diagnostyczne					
Onset F1-Score (event)	0.7589	0.7891	0.8003	0.8043	0.8072
MPE F1-Score (ramki)	0.8234	0.8598	0.8614	0.8736	0.8736
Dane Treningowe					
Czas treningu (min)	120.5	155.2	90.1	209.9	205.6
Epoka zatrzymania	85	92	79	75	90

4.3.2 Analiza Jakościowa i Porównanie z Literaturą

Porównanie osiągniętych wyników z kluczowymi pracami w dziedzinie transkrypcji gitarowej, takimi jak [24] i [26], wymaga szczególnej staranności metodologicznej. Bezpośrednie zestawienie wartości liczbowych F1-Score jest nieprecyzyjne, ponieważ w niniejszej pracy i w literaturze stosowano fundamentalnie różne sposoby oceny jakości transkrypcji.

Kluczowe Rozróżnienie Metryk: Poziom Ramek vs. Poziom Nut

Podstawowa różnica leży w poziomie, na którym obliczana jest metryka:

- **Metryka na poziomie ramek (ang. *frame-level*):** Stosowana w pracach [24] (metryka f_{tab}) oraz [26]. Jest to bardzo rygorystyczna miara, która dla każdej pojedynczej, krótkiej ramki czasowej (ok. 43 na sekundę) sprawdza, czy predykcja idealnie zgadza się z prawdą referencyjną (ang. *ground truth*). Błąd w jednej ramce (np. chwilowe, błędne przypisanie progu w środku długo trwającej nuty) jest liczony jako pomyłka. W niniejszej pracy odpowiednikiem tej metryki jest **MPE F1-Score**.

- **Metryka na poziomie nut (ang. *note-level*):** Główna metryka stosowana w tym projekcie, czyli **TDR F1-Score**. Jest ona obliczana po etapie post-processingu, w którym ciągle predykcje ramkowe są konwertowane na listę dyskretnych zdarzeń nutowych. Nuta jest uznawana za poprawnie wykrytą, jeśli jej czas rozpoczęcia (w oknie tolerancji 50 ms), numer struny i numer progu są jednocześnie poprawne. Metryka ta jest mniej rygorystyczna, ale często bardziej praktyczna z perspektywy muzyka, którego interesują całe nuty, a nie pojedyncze ramki.

Metodologicznie Poprawne Porównanie Wyników

Aby przeprowadzić uczciwe porównanie, należy zestawić ze sobą metryki tego samego typu. Dlatego do porównania z literaturą należy użyć metryki na poziomie ramek (MPE F1-Score):

- **Wynik niniejszej pracy (Przebieg 72):** MPE F1-Score = **0.8736**
- Wynik w [24]: F1-Score (f_{tab}) = 0.76
- Wynik w [26] (dla modelu trenowanego tylko na GuitarSet): F1-Score $\approx$ 0.835

Powyższe zestawienie, które jest metodologicznie poprawne, jednoznacznie pokazuje, że finalny model opracowany w ramach niniejszej pracy **osiąga wyniki znacząco przewyższające** te zaraportowane w kluczowych publikacjach dla modeli trenowanych wyłącznie na zbiorze GuitarSet. Ten sukces jest bezpośrednim rezultatem zastosowania innowacyjnej, zaawansowanej strategii augmentacji danych.

Równocześnie, osiągnięty w finalnym modelu (przebieg 72) wynik praktycznej metryki na poziomie nut, **TDR F1-Score**, na poziomie **0.8569**, świadczy o bardzo wysokiej jakości i użyteczności generowanych tabulatur.

W celu głębszej analizy jakościowej, przeanalizowano próbki, które uzyskały najlepsze i najgorsze wyniki w finalnej ewaluacji przebiegu 72. Trzy najlepsze wyniki pod względem TDR F1-Score uzyskano dla plików: 04_BN1–147–Gb_comp (0.9676), 05_Rock3–148–C_solo (0.9667) oraz 02_Jazz1–200–B_solo (0.9647). Z kolei trzy najgorsze wyniki to: 05_SS3–84–Bb_comp (0.7090), 04_SS3–98–C_comp (0.7054) oraz 00_SS3–84–Bb_comp (0.6760).

Szczegółowa Analiza Wybranych Przypadków (przebieg 72)

Przypadek Najwyższej Jakości Transkrypcji: Paradoks Akompaniamentu (04_BN1–147–Gb_comp) Co ciekawe, najwyższą jakość transkrypcji (TDR F1-Score: 0.9676) uzyskano nie dla partii solowej, lecz dla akompaniamentu, co może wydawać się paradoksalne, biorąc pod uwagę jego polifoniczny (akordowy) charakter. Analiza tego przypadku dostarcza jednak cennych wniosków. Jak widać na Rysunku 4.1, predykcja

modelu jest niezwykle zbliżona do prawdy referencyjnej. Sukces w tym przypadku wynika z kilku kluczowych cech nagrania:

- **Regularność rytmiczna:** Partie akompaniamentu charakteryzują się często stałym, powtarzalnym rytmem. Ta przewidywalność znacząco ułatwia modelowi zadanie detekcji onsetów, które są wyraźne i niezachodzące na siebie w skomplikowany sposób.
- **Klarowność harmoniczna:** Akordy, mimo że są zdarzeniami wielodźwiękowymi, są grane w sposób czysty i oddzielony. Brak tu szybkich przejść, ozdobników czy technik artykulacyjnych (jak *vibrato* czy *bend*), które wprowadzają dodatkową złożoność do sygnału w partiach solowych.
- **Stabilność sygnału:** Model nie musi radzić sobie ze złożonymi zmianami w dynamice i barwie, typowymi dla ekspresyjnych solówek.

Zdolność modelu do tak precyzyjnego rozłożenia akordów na poszczególne nuty na odpowiednich strunach i progach, przy jednoczesnej niemal bezbłędnej detekcji onsetów, świadczy o jego sile w zadaniu wielodźwiękowej estymacji (MPE). Paradoksalnie, to właśnie "nuda" i powtarzalność partii akompaniamentu sprawiają, że staje się ona dla algorytmu zadaniem łatwiejszym do rozwiązania niż partia solowa, która może być bardziej chaotyczna i pełna niuansów.

Rysunek 4.1: Porównanie fragmentu tabulatury wygenerowanej przez model (góra) i tabulatury referencyjnej (dół) dla utworu 04_BN1–147–Gb_comp.

Predykcja modelu (Przebieg 72, Onset Thresh: 0.35):

```

e|-----|-----|-----|-----|-----|-----|-----|-----
B|2-----2--|-----2--|-----2--|-----2--|2-----2--|-----2--|-----2--|-----
G|-----|-----3--|-----3--|-----|3-----3--|-----3--|-----3--|-----
D|3-----|-----3--|-----3--|-----3--|3-----3--|-----3--|-----3--|-----
A|-----|-----|-----|-----|-----|-----|-----|-----
E|2-----|-----2--|-----2--|-----2--|-----2--|-----0--2--|-----2--|-----

e|-----|-----|-----|-----|-----|-----|-----|-----
B|2-----2--|-----2--|-----2--|2-----|-----4--4--|-----4--4--|-----
G|3-----3--|-----3--|-----3--|3-----|-----3--3--|-----3--3--|-----
D|3-----3--|-----3--|-----3--|3-----|-----4--4--|-----4--4--|-----
A|-----|-----|-----|-----|-----2-----|-----2-----|-----
E|2-----2--|-----2--|-----2--|2-----|-----|-----|-----|-----

```

Tabulatura referencyjna (Ground Truth):

```

e|-----|-----|-----|-----|-----|-----|-----|-----
B|2-----2--|-----2--|-----2--|-----2--|2-----2--|-----2--|-----2--|-----
G|3-----3--|-----3--|-----3--|-----3--|3-----3--|-----3--|-----3--|-----
D|3-----3--|-----3--|-----3--|-----3--|3-----3--|-----3--|-----3--|-----
A|-----|-----|-----|-----|-----|-----|-----|-----
E|2-----2--|-----2--|-----2--|-----2--|2-----2--|-----0--2--|-----2--|-----

e|-----|-----|-----|-----|-----|-----|-----|-----
B|2-----2--|-----2--|-----2--|2-----|-----4--4--|-----4--4--|-----
G|3-----3--|-----3--|-----3--|3-----|-----3--3--|-----3--3--|-----
D|3-----3--|-----3--|-----3--|3-----|-----5--4--|-----4--4--|-----
A|-----|-----|-----|-----0--|2-----2--|-----2-----|-----2--|-----
E|2-----2--|-----2--|-----2--|2-----|-----|-----|-----|-----

```

Przypadek Wysokiej Jakości Transkrypcji Partii Solowej (05_Rock3–148–C_solo) Nagranie 05_Rock3–148–C_solo (TDR F1-Score: 0.9667), drugi najlepszy wynik w ewaluacji, jest doskonałym przykładem wysokiej skuteczności finalnego modelu dla partii melodycznych. Jak widać na Rysunku 4.2, wygenerowana tabulatura jest niemal identyczna z referencyjną. Model poprawnie zidentyfikował zarówno wysokość dźwięków, jak i ich przypisanie do odpowiednich strun i progów, nawet w przypadku szybszych fraz. Ten przypadek pokazuje, że dla czystych, wyraźnie zagranych partii solowych, system osiąga dokładność zbliżoną do ludzkiej, co stanowi solidne potwierdzenie jego praktycznej użyteczności w najbardziej typowym scenariuszu zastosowania.

Rysunek 4.2: Porównanie fragmentu tabulatury wygenerowanej przez model (góra) i tabulatury referencyjnej (dół) dla utworu 05_Rock3–148–C_solo.

Predykcja modelu (Przebieg 72, Onset Thresh: 0.35):

```

e|-----|8-----7-----|-----|-----|-----|-----5--|-----
B|-----|-----|10----8-----|-----|-----|-----|-----8--|-----
G|-----|-----|-----|-----|-----|-----|-----|-----
D|-----|-----|-----|-----|-----|-----|-----|-----
A|-----|-----|-----|-----|-----|-----|-----|-----
E|-----|-----|-----|-----|-----|-----|-----|-----

e|-----|-----|-----|-----|-----|-----|-----|-----
B|---6---5--|-----|-----|-----|-----5-----|-----|-----
G|-----|-----|-----|-----|-----|-----|7-----5-----|-----
D|-----|-----|-----|-----|-----|-----|-----|-----
A|-----|-----|-----|-----|-----|-----|-----|-----
E|-----|-----|-----|-----|-----|-----|-----|-----

```

Tabulatura referencyjna (Ground Truth):

```

e|-----|8-----7-----|-----|-----|-----|-----5--|-----
B|-----|-----|10----8-----|-----|-----|-----|-----8--|-----
G|-----|-----|-----|-----|-----|-----|-----|-----
D|-----|-----|-----|-----|-----|-----|-----|-----
A|-----|-----|-----|-----|-----|-----|-----|-----
E|-----|-----|-----|-----|-----|-----|-----|-----

e|-----|-----|-----|-----|-----|-----|-----|-----
B|---6---5--|-----|-----|-----|-----6-----5-----|-----|-----
G|-----|-----|-----|-----|-----|-----|7-----5-----|-----
D|-----|-----|-----|-----|-----|-----|-----|-----
A|-----|-----|-----|-----|-----|-----|-----|-----
E|-----|-----|-----|-----|-----|-----|-----|-----

```

Przypadek Stanowiący Wyzwanie dla Modelu: 00_SS3–84–Bb_comp Analiza najtrudniejszego przypadku, nagrania 00_SS3–84–Bb_comp (TDR F1-Score: 0.6760), ujawnia typowe błędy popełniane przez model. Porównanie predykcji z tabulaturą referencyjną na Rysunku 4.3 pokazuje, że choć ogólny zarys harmoniczny i rytmiczny jest często zachowany, pojawiają się błędy w dokładnym umiejscowieniu nut. Model w tym przypadku wygenerował dodatkowe nuty (fałszywe alarmy, FP), pominął niektóre istniejące (fałszywe negatywy, FN) oraz błędnie zidentyfikował część progów. Tego typu utwory, charakteryzujące się grą akordową i gęstszą fakturą, stanowią większe wyzwanie ze względu na zjawisko maskowania harmonicznego, gdzie cichsze dźwięki są "przykrywane" przez głośniejsze. Mimo to, nawet w tak trudnym przykładzie, wygenerowana transkrypcja wciąż może stanowić użyteczny punkt wyjścia do dalszej, manualnej korekty.

Rysunek 4.3: Porównanie fragmentu tabulatury wygenerowanej przez model (góra) i tabulatury referencyjnej (dół) dla utworu 00_SS3–84–Bb_comp, ilustrujące wyzwania w transkrypcji gęstych faktur.

Predykcja modelu (Przebieg 72, Onset Thresh: 0.35):

```
e|-----|---6-----|-----|-----|-----|-----|-----|
B|-----|-----|-----|-----|-----|-----|-----|6-----
G|-----|-----|7-----|---7--7-----|-----|-----|-----|
D|-----8--|---8-----|-----8-----|-----8--|-----|---7---7--|---7-----|
A|-----|-----|-----8-----|-----|-----|---8-----|-----|
E|6-----|-----|-----|-----|-----|-----|-----|

e|-----|-----|-----|-----|-----|-----|-----10-|
B|-----|-----|-----|-----|---11-----|-----|-----11-11-|
G|-----|5-----|---6-6-----|-----12-----|7-----12-|---12-----|---12-----|---10-
D|-----|7-----7-----|7-----|-----|-----|-----|-----|---10-
A|-----|-----|-----10-|-----|-----|-----|-----|
E|-----|-----|-----|-----|-----|-----|-----|
```

Tabulatura referencyjna (Ground Truth):

```
e|-----|6-----|-----|-----6--|-----|---5-----|-----|5-----
B|-----|---6-----|-----|-----6--|-----|---6-----|-----|6-----
G|7-----|-----|7-----|---7-----|-----|-----5-|-----|
D|8-----|8-----|-----|-----8--|-----|-----|---7-----|
A|-----|-----|-----8-----|-----|-----|---8-----|-----|
E|6-----|-----|-----|-----|-----|-----|-----|

e|-----|-----|-----|-----|-----|---10-----|-----|
B|-----|-----|-----|-----|10-11-----|-----|-----11-|---10-
G|-----5--|-----|---8-----|-----12-----|-----12-|-----|---12-----|---10-
D|-----|---7-----|-----|-----|12-----|---12-----|-----|---10-
A|-----|-----|-----10-|-----|-----|-----|-----|
E|-----|-----|-----|-----|-----|-----|-----|
```

Główne Wyzwania i Ograniczenia Modelu

Analiza trudniejszych przypadków, takich jak 00_SS3–84–Bb_comp (TDR F1-Score: 0.6760), pozwala zidentyfikować kluczowe wyzwania dla modelu:

- **Niejednoznaczność opalcowania:** W złożonych partiach polifonicznych model może poprawnie zidentyfikować wysokość dźwięku, ale błędnie przypisać ją do pary (struna, próg). Jest to fundamentalny problem GTT, szeroko opisywany w pracach [2, 24] oraz zilustrowany w [8].
- **Techniki artykulacyjne i złożoność rytmiczna:** Model napotyka trudności w detekcji cichych lub bardzo szybko następujących po sobie nut (tzw. (ang. *ghost notes*)), co jest typowe dla stylów funk i jazz. Problemy z detekcją nut granych technikami takimi jak (ang. *hammer-on*) czy (ang. *pull-off*) są zgodne z obserwacjami z pracy [12].

- **Gęstość faktury i maskowanie:** W utworach o dużej gęstości faktury, gdzie wiele dźwięków występuje jednocześnie, zjawisko maskowania może utrudniać detekcję poszczególnych nut, zwłaszcza tych o niższej amplitudzie [3].

4.3.3 Walidacja w Warunkach Rzeczywistych

Kluczowym testem praktycznej użyteczności i zdolności do generalizacji każdego systemu transkrypcji jest jego ocena na danych, które znacząco odbiegają od sterylnych warunków zbioru treningowego. W tym celu przeprowadzono dodatkowy eksperyment polegający na ewaluacji finalnego modelu na nagraniach zrealizowanych w typowych warunkach domowych.

Metodyka Eksperymentu

Przygotowano dedykowany, niestandardowy zbiór czterech nagrań audio, zrealizowanych przy użyciu dwóch różnych gitar: **akustycznej** (struny stalowe, jasna barwa) oraz **klasycznej** (struny nylonowe, cieplejsza barwa). Nagrania przeprowadzono za pomocą wbudowanego mikrofonu w laptopie i oprogramowania Audacity, zachowując parametry techniczne (mono, 22050 Hz, 16-bit WAV) zgodne z danymi treningowymi, aby zminimalizować tzw. przesunięcie dziedziny (ang. *domain shift*). Dla każdego instrumentu nagrano dwa wzorce muzyczne:

- **Wzorzec "123"(wielostrunowy):** Sekwencyjne zagranie progów 1, 2, 3 na każdej z sześciu strun, testujące zdolność do rozróżniania barwy strun.
- **Wzorzec "1234567"(jednostrunowy):** Zagranie sekwencji chromatycznej od 1 do 7 progu na najcieńszej strunie (e^1), weryfikujące precyzję rozpoznawania wysokości dźwięku.

Analiza Wyników Jakościowych

Analiza wygenerowanych tabulatur pozwoliła na zidentyfikowanie kilku kluczowych zjawisk, które charakteryzują działanie modelu w warunkach rzeczywistych.

Zdolność do Rozpoznawania Wysokości Dźwięku Model wykazał wysoką skuteczność w rozpoznawaniu podstawowej częstotliwości dźwięku, co przekłada się na poprawną identyfikację numeru granego progu. Najlepszym tego dowodem jest wynik dla nagrania *akustyczna_1234567*, gdzie model niemal bezbłędnie odtworzył graną sekwencję:

- **Oczekiwano:** $e|-1-2-3-4-5-6-7-|$
- **Przewidziano (fragment):** $e|-2-2-3-3-4-4-5-5-5-7-|$

Większość progów została rozpoznana poprawnie, co świadczy o solidnym działaniu części modelu odpowiedzialnej za analizę częstotliwości.

Wyzwanie: Rozpoznawanie Barwy i Problem Wieloznaczności Gryfu Największą zidentyfikowaną słabością jest niska zdolność modelu do precyzyjnego rozpoznawania barwy dźwięku (ang. *timbre*), co jest niezbędne do poprawnego przypisania dźwięku do konkretnej struny. Słabość ta prowadzi do powszechnego zjawiska **błędu wieloznaczności gryfu gitarowego**. Model, poprawnie identyfikując wysokość dźwięku, często umieszcza go na niewłaściwej strunie, ale na progu, który odpowiada tej samej nucie. Jest to doskonale widoczne w wynikach dla nagrania `klasyczna_1234567`:

- **Oczekiwano:** `e|-1-2-3-4-5-6-7-|`
- **Przewidziano (fragmenty):** `e|-4-5-5-6-7-|` oraz `B|-6-7-8-12-|`

Ten "inteligentny" błąd dowodzi, że model poprawnie analizuje ton podstawowy (przewidywany próg 6 na strunie B to ten sam dźwięk F4 co próg 1 na strunie e), lecz zawodzi w analizie subtelnych składowych harmoniczych, które odróżniają barwę struny e od B.

Wnioski z Testów w Warunkach Rzeczywistych

Eksperyment potwierdził, że głównym problemem modelu nie jest rozpoznawanie wysokości dźwięku, lecz klasyfikacja barwy. Aby system stał się narzędziem o praktycznym zastosowaniu dla nagrań domowych, kluczowy jest rozwój w kierunku lepszego różnicowania barwy lub implementacja zaawansowanych algorytmów post-processingu, które na podstawie wiedzy o technice gry korygowałyby błędy wieloznaczności.

4.3.4 Użyteczność w Praktyce

Mimo pewnych błędów, osiągnięty poziom dokładności otwiera drogę do praktycznego zastosowania systemu. Praca [11] badała użyteczność systemów AMT w praktyce muzykologicznej, wskazując, że nawet niedoskonałe transkrypcje mogą znacząco przyspieszyć pracę ekspertów. Można postawić tezę, że opracowany system, mimo iż nie jest idealny, mógłby być użyteczny np. dla amatorów gitary jako narzędzie pomocnicze do nauki utworów, oferując "wystarczająco dobrą" pierwszą wersję tabulatury do dalszej weryfikacji i nauki.

4.4 Podsumowanie Badań Eksperymentalnych

Przeprowadzony w ramach niniejszego rozdziału szczegółowy proces badawczy, obejmujący ponad 70 eksperymentów, pozwolił na systematyczną weryfikację i optymalizację zaproponowanego systemu transkrypcji. Analiza ilościowa i jakościowa wykazała, że finalna

konfiguracja modelu (przebieg 72) osiąga wyniki na najwyższym poziomie, co zostało potwierdzone przez metodologicznie poprawne porównanie z kluczowymi pracami w dziedzinie. Wynik **MPE F1-Score na poziomie 0.8736** oraz **TDR F1-Score wynoszący 0.8569** dowodzą wysokiej skuteczności opracowanego rozwiązania.

Potwierdzono, że kluczowym czynnikiem, który umożliwił osiągnięcie tak wysokich wyników, była innowacyjna strategia augmentacji danych. Świadome nauczanie modelu, jak interpretować niedoskonałe sygnały audio, okazało się znacznie skuteczniejsze niż dążenie do optymalizacji architektury na idealnych, studyjnych danych. Dodatkowa walidacja w warunkach rzeczywistych pokazała, że choć model doskonale radzi sobie z rozpoznawaniem wysokości dźwięku, jego głównym ograniczeniem pozostaje precyzyjna klasyfikacja barwy, prowadząca do błędów wieloznaczności. Ten rozdział dostarczył empirycznych dowodów na słuszność przyjętych założeń projektowych i skuteczność zaimplementowanych metod, stanowiąc solidną podstawę dla finalnych wniosków z całej pracy, które zostaną przedstawione w kolejnym rozdziale.

Rozdział 5

Podsumowanie i Wnioski

Niniejsza praca magisterska podjęła się realizacji kompleksowego zadania, jakim było zaprojektowanie, zaimplementowanie i weryfikacja eksperymentalna systemu do automatycznej transkrypcji polifonicznych nagrań gitarowych na zapis tabulaturowy (GTT) przy użyciu metod głębokiego uczenia. Praca stanowiła pełny cykl projektu naukowo-badawczego, od studiów literaturowych i analizy problemu, poprzez projektowanie i implementację innowacyjnego rozwiązania, aż po jego wszechstronną ewaluację i analizę wyników.

5.1 Streszczenie Zrealizowanych Prac

Realizację postawionych celów rozpoczęto od szczegółowej analizy literatury (Rozdział 2), która pozwoliła na ugruntowanie teoretycznych podstaw dotyczących cyfrowego przetwarzania sygnałów, metod uczenia maszynowego w kontekście Automatycznej Transkrypcji Muzycznej (ATM) oraz zidentyfikowanie specyficznych wyzwań związanych z transkrypcją gitary. Analiza ta potwierdziła, że GTT, ze względu na polifonię, zmienność barwy, techniki artykulacyjne i problem niejednoznaczności opalcowania, pozostaje jednym z otwartych i wymagających problemów w dziedzinie *Music Information Retrieval* (MIR) [3, 24].

W oparciu o te fundamenty, w Rozdziale 3 zaprojektowano i zaimplementowano autor-ski system oparty na konwolucyjno-rekurencyjnej sieci neuronowej (CRNN). System ten, zrealizowany w środowisku PyTorch, został zaprojektowany w sposób modułowy, umożliwiając elastyczne zarządzanie potokiem przetwarzania danych, treningiem i ewaluacją. Kluczowym elementem rozwiązania była zdolność do przetwarzania różnych reprezentacji czasowo-częstotliwościowych (Mel-spektrogramy, CQT) oraz implementacja wielozadaniowego uczenia, polegającego na jednoczesnej predykcji momentów rozpoczęcia nut (onsetów) i aktywności progów na poszczególnych strunach.

Rozdział 4 stanowił dokumentację iteracyjnego procesu badawczego, w ramach którego przeprowadzono ponad 70 eksperymentów. Proces ten ujawnił, że kluczem do osiągnięcia przełomowych wyników nie była dalsza optymalizacja architektury, lecz radykalna

zmiana w podejściu do danych treningowych. Zaimplementowano zaawansowaną strategię augmentacji, symulującą niedoskonałości nagrań domowych, takie jak pogłos, zniekształcenia mikrofonowe czy przesterowanie sygnału. Finalnie, najlepszy model został poddany wszechstronnej ewaluacji ilościowej i jakościowej na zbiorze testowym GuitarSet.

5.2 Wnioski Końcowe

Przeprowadzone badania i analiza wyników pozwalają na sformułowanie następujących, kluczowych wniosków, które syntetyzują wkład niniejszej pracy w dziedzinę automatycznej transkrypcji gitarowej.

1. **Osiągnięcie wyników przewyższających stan wiedzy w ramkowej estymacji tabulatur:** Zaimplementowany i wytrenowany system transkrypcji gitarowej osiągnął na zbiorze testowym GuitarSet wynik **MPE F1-Score na poziomie 0.8736**. Jest to rezultat, który, przy zachowaniu metodologicznej poprawności porównania na poziomie ramek, przewyższa wyniki raportowane w kluczowych pracach w tej dziedzinie dla modeli trenowanych wyłącznie na tym zbiorze danych, takich jak TabCNN (F1-Score 0.76) [24] czy modele bazowe z pracy nad SynthTab (F1-Score ok. 0.835) [26]. Uzyskany wynik praktycznej metryki na poziomie nut, **TDR F1-Score, wynoszący 0.8569**, świadczy o bardzo wysokiej jakości i użyteczności generowanych tabulatur. **Tym samym, główny cel pracy, polegający na zaprojektowaniu i weryfikacji skutecznego systemu GTT, został w pełni zrealizowany i udokumentowany.**
2. **Decydujący wpływ zaawansowanej, data-centrycznej strategii augmentacji:** Najważniejszym i najbardziej fundamentalnym wnioskiem płynącym z procesu badawczego jest stwierdzenie, że kluczem do sukcesu i przełamania barier wydajnościowych nie okazały się subtelne modyfikacje architektury sieci neuronowej, lecz innowacyjna i agresywna strategia augmentacji danych. Świadome "pogarszanie" idealnych, studyjnych danych treningowych poprzez symulację realistycznych, niedoskonałych warunków nagraniowych (pogłos, zniekształcenia mikrofonowe, przesterowanie) zmusiło model do nauki znacznie bardziej robustnych i uogólnionych cech. Potwierdza to rosnące w dziedzinie uczenia maszynowego przekonanie, że podejście data-centryczne (skupione na jakości i różnorodności danych) często przynosi lepsze rezultaty niż podejście model-centryczne (skupione wyłącznie na architekturze) [14].
3. **Identyfikacja głównego wyzwania GTT jako problemu klasyfikacji barwy dźwięku:** Analiza jakościowa błędów, w tym testy na nagraniach zewnętrznych, jednoznacznie wykazała, że głównym ograniczeniem opracowanego modelu nie jest estymacja wysokości dźwięku (rozpoznawanie numeru progu), lecz jego zdolność

do precyzyjnej klasyfikacji barwy (ang. *timbre*) w celu poprawnego przypisania dźwięku do właściwej struny. Model często popełnia "inteligentne" błędy, prawidłowo identyfikując nutę, ale umieszczając ją na niewłaściwej strunie (ale na progu, który odpowiada tej samej wysokości muzycznej). Zjawisko to potwierdza, że problem inferencji opalcowania (ang. *fingering estimation*), wynikający z wieloznaczności gryfu gitarowego, pozostaje centralnym i w dużej mierze nierozwiązanym wyzwaniem GTT [24].

4. **Wysoka skuteczność w transkrypcji partii akompaniamentu jako wskaźnik siły modelu w MPE:** Zaobserwowano, że model osiąga paradoksalnie najwyższą skuteczność dla regularnych, rytmicznych partii akompaniamentu, nawet tych o złożonej fakturze akordowej. Klarowność rytmiczna i harmoniczna oraz stabilność dynamiczna takich partii czynią je dla algorytmu zadaniem łatwiejszym niż transkrypcja ekspresyjnych i zmiennych partii solowych, obfitujących w subtelne techniki artykulacyjne. Wysoka precyzja w dekompozycji akordów na poszczególne nuty na właściwych strunach i progach świadczy o sile modelu w podstawowym zadaniu wielodźwiękowej estymacji (MPE) dla sygnałów o przewidywalnej strukturze.

5.3 Potencjalne Kierunki Dalszych Badań i Rozwoju

Mimo osiągnięcia bardzo dobrych wyników, niniejsza praca otwiera szereg potencjalnych ścieżek dla dalszych badań i rozwoju opracowanego systemu, adresując zidentyfikowane ograniczenia i wyzwania.

- **Rozwój metod inferencji opalcowania:** Biorąc pod uwagę zidentyfikowane ograniczenia w klasyfikacji barwy, przyszłe prace powinny skupić się na rozwiązaniu problemu wieloznaczności gryfu. Możliwe kierunki obejmują:
 - Wzbogacenie architektury sieci o mechanizmy lepiej modelujące subtelne cechy barwy (np. przez zastosowanie bardziej zaawansowanych cech wejściowych lub specjalizowanych warstw w sieci).
 - Opracowanie modułów post-processingu, które na podstawie wyjścia obecnego modelu stosowałyby optymalizację opartą na wiedzy muzycznej, np. modelach grywalności (ang. *playability models*) czy typowych wzorcach opalcowania, korygując błędy w przypisaniu nut do strun.
- **Eksploracja transferu wiedzy i danych syntetycznych:** Rozwój GTT jest hamowany przez ograniczoną dostępność dużych, adnotowanych zbiorów danych rzeczywistych. Obiecującym kierunkiem jest wykorzystanie ogromnych zbiorów danych syntetycznych, takich jak SynthTab [26], do wstępnego treningu modeli (pre-training),

a następnie ich dostrajanie (ang. *fine-tuning*) na mniejszych, ale autentycznych zbiorach, jak GuitarSet. Taki transfer wiedzy może znacząco poprawić zdolności generalizacyjne modeli, ucząc je najpierw ogólnych zasad akustyki gitary, a następnie adaptując do niuansów rzeczywistych nagrań.

- **Rozpoznawanie technik artykulacyjnych:** Obecny system koncentruje się na transkrypcji podstawowych zdarzeń nutowych. Istotnym rozszerzeniem funkcjonalnym byłoby dodanie zdolności do rozpoznawania i notowania specyficznych technik gitarowych, takich jak podciągnięcia strun (ang. *bends*), ślizgi (ang. *slides*), techniki legato (ang. *hammer-ons*, *pull-offs*) czy wibrato (ang. *vibrato*). Wymagałoby to rozszerzenia modelu o dodatkowe głowice predykcyjne oraz wykorzystania bardziej szczegółowo adnotowanych zbiorów danych, a także pogłębionej analizy akustycznych manifestacji tych technik, opisanych w literaturze [23, 21].
- **Optymalizacja pod kątem zastosowań czasu rzeczywistego:** Zaimplementowany system działa w trybie offline. Adaptacja i optymalizacja architektury modelu (np. poprzez zastąpienie dwukierunkowych warstw RNN jednokierunkowymi, redukcję liczby parametrów, kwantyzację modelu) pod kątem przetwarzania w czasie rzeczywistym otworzyłaby drogę do szeregu praktycznych zastosowań, takich jak interaktywne narzędzia edukacyjne, systemy do ćwiczeń czy wtyczki do cyfrowych stacji roboczych audio (DAW).

Podsumowując, niniejsza praca nie tylko z powodzeniem zrealizowała postawiony cel badawczy, ale również wniosła wkład w dziedzinę GTT, demonstrując, że strategiczne i zaawansowane podejście do augmentacji danych może być kluczem do przełamania istniejących barier wydajnościowych. Wyniki te potwierdzają ogromny potencjał metod głębokiego uczenia w rozwiązywaniu złożonych problemów z zakresu przetwarzania sygnałów muzycznych i wskazują obiecujące kierunki dla przyszłych innowacji.

Bibliografia

- [1] Supraja Anand, Judith M. Wingate, Brenda Smith i Rahul Shrivastav. „Acoustic Parameters Critical for an Appropriate Vibrato”. W: t. 26. 6. 2012, 820.e19–820.e25. DOI: 10.1016/j.jvoice.2012.06.004.
- [2] Carl-Fredrik Arndt i Lewis Li. *Automated Transcription of Guitar Music*. Spraw. tech. CS229 (Machine Learning) Project Report. Stanford University, 2012. URL: https://www.academia.edu/73426275/Automated_Transcription_of_Guitar_Music?hb-sb-sw=4413367.
- [3] Emmanouil Benetos, Simon Dixon, Zhiyao Duan i Sebastian Ewert. „Automatic Music Transcription: An Overview”. W: *IEEE Signal Processing Magazine* 36.1 (2019), s. 20–30. DOI: 10.1109/MSP.2018.2869928.
- [4] Rachel M. Bittner, Gabriel Meseguer-Brocal, Adam Ragheb i Juan José Bosch. „A Lightweight Instrument-Agnostic Model for Polyphonic Note Transcription and Multipitch Estimation”. W: 2022, s. 750–757. URL: <https://ieeexplore.ieee.org/document/9746549>.
- [5] Gregory Burlet i Abram Hindle. „Isolated guitar transcription using a deep belief network”. W: *PeerJ Computer Science* 3 (2017), e109. DOI: 10.7717/peerj-cs.109.
- [6] D. Cazau i G. Nuel. „Investigation on the use of Hidden-Markov Models in automatic transcription of music”. W: *arXiv preprint* (2017). eprint: 1704.03711. URL: <https://arxiv.org/pdf/1704.03711.pdf>.
- [7] Junyoung Chung, Caglar Gulcehre, Kyunghyun Cho i Yoshua Bengio. „Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling”. W: *Proceedings of the NIPS 2014 Workshop on Deep Learning*. 2014. URL: <https://arxiv.org/abs/1412.3555>.
- [8] Google Image Search Result. *Ilustracja niejednoznaczności opalcowania na gryfie gitary*. http://googleusercontent.com/image_collection/image_retrieval/6630293268132984900. Adres URL obrazu dostarczony przez narzędzie wyszukiwania Google. Dostęp: 5 czerwca 2025. 2025.

- [9] Curtis Hawthorne, Erich Elsen, Jialin Song, Adam Roberts, Ian Simon, Colin Raffel, Jesse Engel, Sageev Oore i Douglas Eck. „Onsets and frames: Dual-objective piano transcription”. W: *Proceedings of the 19th International Society for Music Information Retrieval Conference (ISMIR)*. Paris, France, 2018, s. 50–57. URL: <https://archives.ismir.net/ismir2018/paper/000019.pdf>.
- [10] Curtis Hawthorne, Ian Simon, Rigel Swavely, Ethan Manilow i Jesse Engel. „Sequence-to-Sequence Piano Transcription with Transformers”. W: *Proceedings of the 22nd International Society for Music Information Retrieval Conference (ISMIR)*. Online: ISMIR, 2021, s. 240–247. URL: <https://archives.ismir.net/ismir2021/paper/000027.pdf>.
- [11] Andre Holzapfel i Emmanouil Benetos. „Automatic Music Transcription and Ethnomusicology: A User Study”. W: *Proceedings of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. Delft, The Netherlands, 2019, s. 677–684. URL: <https://archives.ismir.net/ismir2019/paper/000082.pdf>.
- [12] Abd Husin, Koharudin Koharudin, Sidikrubadi Pramudito, Sitti Yani i Rima Fitria Adiati. „Analysis and Synthesis of Guitar Sounds with Hammer on Strumming Technique”. W: *Pillar of Physics* 16.2 (2023), s. 162–168. DOI: 10.24036/15354171074.
- [13] Jeremy Hyrkas i Tamara Smyth. „On Vibrato and Frequency (De)Modulation in Musical Sounds”. W: *Proceedings of the 27th International Conference on Digital Audio Effects (DAFx24)*. Guildford, United Kingdom, 2024. URL: <https://dafx.de/paper-archive/details/vta7009LDd8QNZLW70eEXw>.
- [14] Fatemeh Jamshidi, Gary Pike, Amit Das i Richard Chapman. „Machine Learning Techniques in Automatic Music Transcription: A Systematic Survey”. W: *arXiv preprint* (2024). eprint: 2406.15249. URL: <https://arxiv.org/pdf/2406.15249.pdf>.
- [15] Anssi Klapuri i Manuel Davy, red. *Signal Processing Methods for Music Transcription*. Springer, 2006. ISBN: 978-0387306674. DOI: 10.1007/0-387-32845-9.
- [16] Ilya Loshchilov i Frank Hutter. „Decoupled Weight Decay Regularization”. W: *International Conference on Learning Representations (ICLR)*. 2019. URL: <https://arxiv.org/abs/1711.05101>.
- [17] Brian McFee, Colin Raffel, Dawen Liang, Daniel P. W. Ellis, Matt McVicar, Eric Battenberg i Oriol Nieto. „librosa: Audio and Music Signal Analysis in Python”. W: *Proceedings of the 14th Python in Science Conference (SciPy 2015)*. SciPy, 2015, s. 18–25. DOI: 10.25080/Majora-7b98e3ed-003. URL: <https://proceedings.scipy.org/articles/Majora-7b98e3ed-003.pdf>.

- [18] Daniel S. Park, William Chan, Yu Zhang, Chung-Cheng Chiu, Barret Zoph, Ekin D. Cubuk i Quoc V. Le. „SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition”. W: *Proceedings of Interspeech*. 2019, s. 2613–2617. DOI: 10.21437/Interspeech.2019-2680. URL: <http://arxiv.org/abs/1904.08779>.
- [19] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Kopf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai i Soumith Chintala. „PyTorch: An Imperative Style, High-Performance Deep Learning Library”. W: *Advances in Neural Information Processing Systems 32 (NeurIPS 2019)*. <https://pytorch.org>. Curran Associates, Inc., 2019, s. 8024–8035. URL: https://papers.neurips.cc/paper_files/paper/2019/file/bdbca288fee7f92f2bfa9f7012727740-Paper.pdf.
- [20] Christopher Raphael. „Automatic Transcription of Piano Music”. W: *Proceedings of the 3rd International Society for Music Information Retrieval Conference (ISMIR)*. Paris, France, 2002, s. 177–184. URL: https://music.informatics.indiana.edu/~craphael/papers/ismir02_rev.pdf.
- [21] Loic Reboursiere, Otso Tapio Lähdeoja, Ricardo Chessini, Thomas Drugman, Stéphane Dupont, Cécile Picard i Nicolas Riche. „Guitar As Controller”. W: *Numediart Research Program QPSR 3* (2011). URL: https://www.researchgate.net/publication/235678844_Guitar_As_Controller.
- [22] Xavier Riley. *Incorrect timings in two annotations*. GitHub issue comment. marl/GuitarSet issue #5. 2023. URL: <https://github.com/marl/GuitarSet/issues/5>.
- [23] Li Su, Li-Fan Yu i Yi-Hsuan Yang. „Sparse Cepstral and Phase Codes for Guitar Playing Technique Classification”. W: *Proceedings of the 15th International Society for Music Information Retrieval Conference (ISMIR)*. Taipei, Taiwan, 2014, s. 9–14. URL: <https://archives.ismir.net/ismir2014/paper/000213.pdf>.
- [24] Andrew Wiggins i Youngmoo Kim. „Guitar Tablature Estimation with a Convolutional Neural Network”. W: *Proceedings of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. Delft, The Netherlands, 2019, s. 284–291. URL: <https://archives.ismir.net/ismir2019/paper/000033.pdf>.
- [25] Qing Xi, Rachel M. Bittner, Joren Pauwels, Xiaoxuan Ye i Juan P. Bello. „GuitarSet: A Dataset for Guitar Transcription”. W: *Proceedings of the 19th International Society for Music Information Retrieval Conference (ISMIR)*. Paris, France, 2018, s. 453–460. URL: <https://archives.ismir.net/ismir2018/paper/000188.pdf>.

- [26] Yongyi Zang, Yi Zhong, Frank Cwitkowitz i Zhiyao Duan. „SynthTab: Leveraging Synthesized Data for Guitar Tablature Transcription”. W: *Proceedings of the 24th International Society for Music Information Retrieval Conference (ISMIR)*. Milan, Italy, 2023. URL: <https://arxiv.org/abs/2309.09085>.

Dodatki

Dokumentacja techniczna

Spis skrótów i symboli

Skróty

- ATM – Automatyczna Transkrypcja Muzyczna (ang. *Automatic Music Transcription*)
- CNN – Splotowa Sieć Neuronowa (ang. *Convolutional Neural Network*)
- CQT – Transformata Constant-Q (ang. *Constant-Q Transform*)
- CPS – Cyfrowe Przetwarzanie Sygnałów (ang. *Digital Signal Processing – DSP*)
- CRNN – Konwolucyjno-Rekurencyjna Sieć Neuronowa (ang. *Convolutional Recurrent Neural Network*)
- DAW – Cyfrowa stacja robocza audio (ang. *Digital Audio Workstation*)
- DFT – Dyskretna Transformata Fouriera (ang. *Discrete Fourier Transform*)
- DL – Głębokie Uczenie (ang. *Deep Learning*)
- FN – Fałszywe negatywy (ang. *False Negatives*)
- FP – Fałszywe pozytywy (ang. *False Positives*)
- GRU – Bramkowana Jednostka Rekurencyjna (ang. *Gated Recurrent Unit*)
- GTT – Transkrypcja Gitarowa na Tabulaturę (ang. *Guitar Tablature Transcription*)
- HMM – Ukryte Modele Markowa (ang. *Hidden Markov Models*)
- JAMS – JSON Annotated Music Specification
- LSTM – Długa Pamięć Krótkoterminowa (ang. *Long Short-Term Memory*)
- MIR – Komputerowe Pozyskiwanie Informacji Muzycznej (ang. *Music Information Retrieval*)
- MPE – Estymacja Wielokrotnej Wysokości Dźwięku (ang. *Multiple Pitch Estimation*)
- NMF – Nieujemna Faktoryzacja Macierzy (ang. *Non-negative Matrix Factorization*)

- PLCA – Probabilistyczna Analiza Składowych Ukrytych (ang. *Probabilistic Latent Component Analysis*)
- RNN – Rekurencyjna Sieć Neuronowa (ang. *Recurrent Neural Network*)
- SI – Sztuczna Inteligencja (ang. *Artificial Intelligence – AI*)
- STFT – Krótkoczasowa Transformata Fouriera (ang. *Short-Time Fourier Transform*)
- TDR – Współczynnik Detekcji Tabulatury (ang. *Tablature Detection Rate*)
- TP – Prawdziwe pozytywy (ang. *True Positives*)
- UM – Uczenie Maszynowe (ang. *Machine Learning – ML*)

Symbole Matematyczne

- F_0 – Częstotliwość podstawowa
- X_k – k -ty współczynnik dyskretnej transformaty Fouriera
- x_n – n -ta próbka sygnału w dziedzinie czasu
- N – Długość ciągu próbek sygnału (w kontekście DFT)
- i – Jednostka urojona
- $\mathcal{L}_{\text{total}}$ – Całkowita funkcja straty modelu
- $\mathcal{L}_{\text{onset}}$ – Komponent funkcji straty dla predykcji onsetów
- $\mathcal{L}_{\text{fret}}$ – Komponent funkcji straty dla predykcji progów
- $w_{\text{onset}}, w_{\text{fret}}$ – Wagi dla komponentów funkcji straty
- $\sigma(\cdot)$ – Funkcja aktywacji sigmoid

Spis rysunków

1.1	Porównanie fragmentu zapisu nutowego i odpowiadającej mu tabulatury gitarowej dla motywu muzycznego.	3
1.2	Schematyczny przykład spektrogramu polifonicznego sygnału gitarowego, ukazujący nakładające się struktury harmoniczne (prążki reprezentujące częstotliwość podstawową i jej alikwoty) dla kilku jednocześnie brzmiących nut.	4
2.1	Po lewej: fragment sygnału audio pojedynczego dźwięku gitary w dziedzinie czasu. Po prawej: odpowiadające mu widmo amplitudowe uzyskane za pomocą transformaty Fouriera, ukazujące częstotliwość podstawową (F_0) oraz jej kolejne alikwoty (składowe harmoniczne).	14
2.2	Wizualizacja różnych reprezentacji czasowo-częstotliwościowych dla tego samego polifonicznego fragmentu gitarowego: (a) Spektrogram STFT z liniową skalą częstotliwości, (b) Spektrogram Constant-Q (CQT) z logarytmiczną skalą częstotliwości, (c) Mel-spektrogram z osią częstotliwości w skali Mel.	15
2.3	Uproszczony schemat potoku przetwarzania w systemie ATM: od sygnału audio, poprzez ekstrakcję cech, zadania składowe (MPE, detekcja onsetów/offsetów, estymacja instrumentu), aż po generowanie wyjściowej reprezentacji symbolicznej na różnych poziomach abstrakcji (ramki, nuty, partytura).	16
2.4	Przykład tej samej nuty (E4, MIDI 64) możliwej do zagrania w wielu pozycjach na gryfie gitary standardowo strojonej. Ilustracja przedstawia dźwięk E4 na strunie G (9. próg), strunie B (5. próg) oraz pustej strunie wysokiej E. Obrazuje to fundamentalne wyzwanie estymacji opalcowania w GTT. Źródło: [8]	24
3.1	Wizualizacja etykiet ramkowych dla fragmentu utworu. Górny panel przedstawia macierz onsetów, gdzie pionowe linie oznaczają moment rozpoczęcia nuty na danej strunie. Dolny panel pokazuje macierz aktywności progów, gdzie czarne obszary reprezentują czas trwania dźwięku na danej strunie.	34

3.2	Schemat architektury zaimplementowanego modelu CRNN. Przedstawia przepływ danych od wejściowego tensora spektrogramu, przez frontend konwolucyjny, backend rekurencyjny, aż po rozdzielenie na dwie głowice wyjściowe dla predykcji onsetów i progów.	36
4.1	Porównanie fragmentu tabulatury wygenerowanej przez model (góra) i tabulatury referencyjnej (dół) dla utworu 04_BN1–147–Gb_comp.	56
4.2	Porównanie fragmentu tabulatury wygenerowanej przez model (góra) i tabulatury referencyjnej (dół) dla utworu 05_Rock3–148–C_solo.	57
4.3	Porównanie fragmentu tabulatury wygenerowanej przez model (góra) i tabulatury referencyjnej (dół) dla utworu 00_SS3–84–Bb_comp, ilustrujące wyzwania w transkrypcji gęstych faktur.	58

Spis tabel

2.1	Wybrane techniki gitarowe i ich manifestacje akustyczne	21
2.2	Porównanie Standardowej Notacji Muzycznej i Tabulatury Gitarowej . . .	23
4.1	Parametry środowiska eksperymentalnego.	48
4.2	Parametry ekstrakcji cech dla badanych reprezentacji sygnału.	48
4.3	Kompleksowe porównanie metryk dla kluczowych modeli na zbiorze testowym.	53