



**Politechnika
Śląska**

PRACA MAGISTERSKA

Przekształcanie nagrań dźwiękowych na zapis nutowy

Łukasz KRAWCZYK

Nr albumu: 296657

Kierunek: Informatyka

Specjalność: Internet i technologie sieciowe

PROWADZĄCY PRACĘ

Dr inż. Paweł Benecki

**KATEDRA Katedra Informatyki Stosowanej
Wydział Automatyki, Elektroniki i Informatyki**

Gliwice 2025

Tytuł pracy

Przekształcanie nagrań dźwiękowych na zapis nutowy

Streszczenie

Niniejsza praca magisterska porusza problematykę przekształcania nagrań dźwiękowych na zapis nutowy, koncentrując się na automatycznej transkrypcji polifonicznych nagrań gitarowych na zapis tabulaturowy (ang. *Guitar Tablature Transcription*, GTT). W ramach pracy zaprojektowano, zaimplementowano i zweryfikowano eksperymentalnie system oparty na architekturze konwolucyjno-rekurencyjnej sieci neuronowej (ang. *Convolutional Recurrent Neural Network*, CRNN), która uczy się bezpośredniego mapowania z reprezentacji czasowo-częstotliwościowej sygnału audio na symboliczną postać tabulatury. Kluczowym elementem projektu jest wielozadaniowe uczenie, w którym model jednocześnie przewiduje momenty rozpoczęcia dźwięków (ang. *onsets*) oraz numery aktywnych progów na poszczególnych strunach gitary.

Proces badawczy, przeprowadzony na publicznie dostępnym zbiorze danych GuitarSet, obejmował ponad 70 eksperymentów. Wykazały one, że decydujący wpływ na skuteczność modelu miała innowacyjna i zaawansowana strategia augmentacji danych, symulująca niedoskonałości nagrań realizowanych w warunkach amatorskich, takie jak pogłos, szum czy zniekształcenia mikrofonowe. Zastosowanie tej strategii ukierunkowanej na dane pozwoliło na osiągnięcie wyników przewyższających aktualny stan wiedzy.

Finalny model, oceniany na zbiorze testowym, uzyskał wynik MPE F1-Score (metryki estymacji wielodźwiękowej na poziomie ramek) na poziomie 0.8736, co jest wynikiem lepszym od rezultatów raportowanych w kluczowych publikacjach w tej dziedzinie dla modeli trenowanych wyłącznie na zbiorze GuitarSet. Analiza jakościowa potwierdziła wysoką zdolność modelu do poprawnej estymacji wysokości dźwięków, jednocześnie wskazując, że głównym pozostałym wyzwaniem jest precyzyjne rozwiązywanie problemu wieloznaczności opalcowania, wynikającego z trudności w klasyfikacji subtelnych różnic w barwie dźwięku między strunami. Praca dowodzi, że opracowane rozwiązanie stanowi skuteczną i obiecującą metodę dla GTT, otwierając nowe kierunki dalszych badań.

Słowa kluczowe

przekształcanie sygnału audio, automatyczna transkrypcja muzyczna, notacja muzyczna, transkrypcja gitary, tabulatura

Thesis title

Converting audio recordings to musical notation

Abstract

This master's thesis addresses the problem of transforming audio recordings into musical notation, focusing on the specific case of automatic transcription of polyphonic guitar recordings into tablature notation (Guitar Tablature Transcription, GTT). The project involved the design, implementation, and experimental verification of a system based on a Convolutional Recurrent Neural Network (CRNN) architecture, which learns to directly map a time-frequency representation of an audio signal to a symbolic tablature format. A key element of the project is multi-task learning, where the model simultaneously predicts note onsets and the corresponding fret numbers on individual guitar strings.

The research process, conducted on the publicly available GuitarSet dataset, comprised over 70 iterative experiments. These revealed that the decisive factor for the model's effectiveness was an innovative and aggressive data augmentation strategy. This strategy simulated imperfections of amateur recordings, such as reverb, noise, and microphone distortions. The application of this data-centric approach led to results surpassing the current state-of-the-art.

The final model, evaluated on the test set, achieved an MPE (Multi-pitch Estimation) F1-Score of 0.8736, which is superior to results reported in key publications for models trained exclusively on the GuitarSet dataset. Qualitative analysis confirmed the model's high accuracy in pitch estimation, while also indicating that the main remaining challenge is the precise resolution of fingering ambiguity, stemming from the difficulty in classifying subtle timbre differences between strings. The thesis demonstrates that the developed solution constitutes an effective and promising method for GTT, opening new avenues for future research.

Key words

audio signal processing, automatic music transcription, music notation, guitar transcription, tablature

Spis treści

1	Wstęp	1
1.1	Osadzenie problemu w dziedzinie naukowej	3
1.2	Cel pracy	5
1.3	Zakres pracy	6
1.4	Charakterystyka rozdziałów	8
1.5	Określenie wkładu autora	9
2	Analiza tematu: podstawy i specyfika transkrypcji gitarowej	11
2.1	Sprecyzowanie problemu badawczego	11
2.2	Podstawy teoretyczne: dźwięk muzyczny i jego cyfrowa reprezentacja . . .	12
2.2.1	Percepcyjne i fizyczne atrybuty dźwięku muzycznego	12
2.2.2	Reprezentacja sygnału audio w dziedzinie czasu i częstotliwości . .	13
2.2.3	Analiza czasowo-częstotliwościowa i jej znaczenie dla ATM	14
2.3	Automatyczna transkrypcja muzyczna: zadania, poziomy i wyzwania . . .	16
2.3.1	Definicja, zadania składowe i poziomy abstrakcji w ATM	16
2.3.2	Transkrypcja monofoniczna vs polifoniczna – złożoność i główne wyzwania	18
2.4	Przegląd metod stosowanych w automatycznej transkrypcji muzycznej . . .	18
2.4.1	Metody tradycyjne oparte na przetwarzaniu sygnałów	18
2.4.2	Metody oparte na uczeniu maszynowym	19
2.5	Specyfika transkrypcji muzyki gitarowej na zapis tabulaturowy (GTT) . .	21
2.5.1	Akustyczna charakterystyka sygnału gitary i jej implikacje dla transkrypcji	21
2.5.2	Porównanie notacji standardowej i tabulaturowej dla gitary	23
2.5.3	Kluczowe wyzwania w automatycznej transkrypcji gitary na tabulaturę (GTT)	25
2.5.4	Przegląd istniejących podejść i narzędzi do GTT	26
2.6	Podsumowanie i otwarte problemy badawcze	27
3	Projekt i implementacja systemu transkrypcji gitarowej	29
3.1	Architektura ogólna i potok przetwarzania	30

3.2	Przygotowanie danych i sygnału wejściowego	30
3.2.1	Zbiór danych: GuitarSet	31
3.2.2	Reprezentacja czasowo-częstotliwościowa sygnału	32
3.2.3	Augmentacja danych: strategia zwiększania odporności modelu . . .	33
3.2.4	Przetwarzanie etykiet i tworzenie wsadów	34
3.3	Architektura i implementacja modelu transkrypcji	35
3.4	Proces treningu i optymalizacji modelu	39
3.4.1	Wielozadaniowa funkcja straty	39
3.4.2	Pętla treningowa i optymalizator	40
3.5	Metodyka ewaluacji i generowanie wyników	41
3.5.1	Konwersja predykcji na postać symboliczną i metryki ewaluacyjne .	41
3.5.2	Generowanie wyników i analiza końcowa	43
3.6	Wykorzystane technologie i biblioteki	43
3.7	Podsumowanie rozdziału	44
4	Badania eksperymentalne i wyniki	47
4.1	Metodyka i środowisko badawcze	47
4.1.1	Infrastruktura eksperymentalna	47
4.1.2	Zbiór danych i metryki oceny	48
4.2	Proces badawczy: ewolucja modelu transkrypcyjnego	48
4.2.1	Eksperyment bazowy i wybór reprezentacji sygnału	48
4.2.2	Optymalizacja architektury i hiperparametrów	50
4.2.3	Wpływ strategii augmentacji danych	54
4.3	Analiza wyników i dyskusja	55
4.3.1	Porównanie ilościowe najlepszych modeli	55
4.3.2	Walidacja w warunkach rzeczywistych	62
4.4	Podsumowanie badań eksperymentalnych	63
5	Podsumowanie i Wnioski	65
5.1	Podsumowanie zrealizowanych prac	65
5.2	Wnioski	66
5.3	Potencjalne kierunki dalszych badań i rozwoju	67
	Bibliografia	72
	Dokumentacja techniczna	75
	Spis skrótów i symboli	83
	Spis rysunków	88

Rozdział 1

Wstęp

Automatyczna Transkrypcja Muzyczna (ATM) (ang. *Automatic Music Transcription*) stanowi jedno z kluczowych i jednocześnie najbardziej złożonych zadań w dziedzinie komputerowej analizy muzyki. W swej istocie, ATM jest procesem konwersji sygnału akustycznego, będącego fizyczną manifestacją muzyki, na jego symboliczną, strukturalną reprezentację [15, 3]. Celem tego procesu jest przekształcenie ciągłego sygnału audio w dyskretny zestaw symboli muzycznych, takich jak tradycyjne nuty określające wysokość i czas trwania dźwięku, lub – co jest przedmiotem szczególnego zainteresowania w niniejszej pracy – w zapis tabulaturowy. Interdyscyplinarny charakter ATM jest niezaprzeczalny, gdyż skuteczna realizacja jej zadań wymaga integracji wiedzy i metodologii pochodzących z wielu, pozornie odległych, dziedzin nauki i techniki. Do najważniejszych z nich należą:


- **Cyfrowe przetwarzanie sygnałów (CPS)** (ang. *Digital Signal Processing, DSP*): Dostarcza ono narzędzi do analizy, transformacji i manipulacji sygnałem audio w dziedzinie czasu i częstotliwości. Techniki takie jak filtracja, analiza spektralna czy transformacje czasowo-częstotliwościowe są nieodzowne w procesie ekstrakcji informacji z surowego sygnału dźwiękowego [15]. Zaawansowane metody CPS pozwalają na wstępne przygotowanie sygnału, redukcję szumów oraz identyfikację podstawowych cech akustycznych, które następnie mogą być interpretowane w kontekście muzycznym. Przykładem narzędzia CPS jest dyskretna transformata Fouriera (DFT).
- **Rozpoznawanie wzorców** (ang. *Pattern Recognition*) oraz **uczenie maszynowe (UM)** (ang. *Machine Learning, ML*): Te dziedziny odgrywają kluczową rolę w identyfikacji struktur muzycznych, takich jak pojedyncze nuty, akordy, rytmy czy motywy melodyczne, w często zaszumionym i polifonicznym sygnale audio [3]. Współczesne systemy ATM w coraz większym stopniu opierają się na zaawansowanych modelach uczenia maszynowego, w szczególności na sieciach neuronowych i głębokim uczeniu (ang. *Deep Learning, DL*), które potrafią automatycznie uczyć się hierarchicznych reprezentacji cech muzycznych bezpośrednio z danych [5]. Przełomem w tej dziedzinie

okazał się paradygmat „Onsets and Frames”, zaproponowany w pracy [9], w którym model uczy się jednocześnie detekcji początków nut (onsetów) oraz ich trwania (predykcji na poziomie ramek), co znacząco poprawiło jakość transkrypcji i stało się podstawą dla wielu nowoczesnych systemów, w tym rozwiązania rozwijanego w niniejszej pracy. Dynamiczny rozwój w obszarze głębokiego uczenia bezpośrednio przekłada się na postępy w ATM, umożliwiając tworzenie modeli zdolnych do przetwarzania coraz bardziej skomplikowanych sygnałów muzycznych z niespotykaną dotąd dokładnością.

- **Sztuczna inteligencja (SI)** (ang. *Artificial Intelligence*, AI): Jako szersza dziedzina, obejmuje ona uczenie maszynowe, ale także inne aspekty, takie jak reprezentacja wiedzy muzycznej oraz procesy poznawcze związane z percepcją i wnioskowaniem w kontekście muzycznym [3]. Rozwój SI dostarcza ram koncepcyjnych i narzędziowych dla budowy inteligentnych systemów transkrypcji.
- **Muzykologia**: Dostarcza niezbędnej wiedzy teoretycznej o strukturze muzyki, notacji, harmonii, rytmie oraz praktykach wykonawczych [11]. Zrozumienie zasad muzycznych jest kluczowe nie tylko dla interpretacji wyników generowanych przez systemy ATM, ale również dla projektowania algorytmów, które uwzględniają kontekst muzyczny i dążą do tworzenia transkrypcji użytecznych z perspektywy muzykologicznej i wykonawczej.

Potencjalne obszary zastosowań systemów ATM są szerokie i różnorodne, co podkreśla ich rosnące znaczenie zarówno w badaniach naukowych, jak i w praktyce muzycznej. Do najważniejszych aplikacji należą: wsparcie w edukacji muzycznej [3]. Systemy ATM mogą również znacząco ułatwić proces tworzenia i aranżacji muzyki, na przykład poprzez wspieranie modyfikacji i rearanżacji istniejących utworów [2]. Dla producentów muzycznych, ATM oferuje narzędzia do wizualizacji treści muzycznej i inteligentnej edycji nagrań [3]. Ponadto, technologie te są wykorzystywane w systemach wyszukiwania i kategoryzacji muzyki w dużych zbiorach danych, na przykład poprzez umożliwienie wyszukiwania utworów na podstawie ich melodii, harmonii czy rytmu [3].

Tytuł niniejszej pracy, „Przekształcanie nagrań dźwiękowych na zapis nutowy”, odnosi się do centralnego problemu ATM. Należy jednak podkreślić, że termin „zapis nutowy” jest pojęciem szerokim, obejmującym różnorodne systemy notacji muzycznej. W kontekście niniejszego opracowania, szczególna uwaga zostanie poświęcona specyficznej formie zapisu, jaką jest tabulatura gitarowa. Tabulatura, w odróżnieniu od tradycyjnej notacji nutowej skupiającej się głównie na wysokości i czasie trwania dźwięku, jest graficzną reprezentacją muzyki. Wskazuje ona bezpośrednio pozycje palców na gryfie instrumentu – konkretne struny i progi, które należy nacisnąć, aby uzyskać pożądaną dźwięk [24]. Porównanie obu form notacji przedstawiono na rysunku 1.1.



Rysunek 1.1: Porównanie fragmentu zapisu nutowego (góra) i odpowiadającej mu tabulatury gitarowej (dół) dla tego samego motywu muzycznego.

Wybór tabulatury jako docelowej formy zapisu w tej pracy nie jest przypadkowy. Wynika on ze specyfiki gitary jako instrumentu oraz z ogromnej popularności tej formy notacji wśród gitarzystów [24]. Rosnąca popularność tabulatur, często udostępnianych online, stwarza specyficzne zapotrzebowanie na systemy ATM zdolne do generowania tego właśnie formatu. Nie jest to jedynie kwestia preferencji użytkowników; tabulatura często zawiera informacje, takie jak konkretny sposób palcowania czy użycie technik gitarowych, których brakuje w standardowej notacji nutowej. Skuteczne systemy ATM generujące tabulatury mogą zatem uczynić bardziej dostępnym proces nauki gry na gitarze oraz tworzenia muzyki, obniżając barierę wejścia dla osób, które nie posługują się biegle tradycyjnym zapisem nutowym, ale rozumieją intuicyjny charakter tabulatury. Ten wybór stanowi naturalne przejście do dalszych, bardziej szczegółowych rozważań przedstawionych w kolejnych rozdziałach pracy.


1.1 Osadzenie problemu w dziedzinie naukowej

Przedmiotem niniejszej pracy jest zagadnienie automatycznej transkrypcji muzyki gitarowej do postaci tabulatury, co sytuuje ją w szerokim kontekście badań prowadzonych w ramach dziedziny naukowej znanej jako (ang. *Music Information Retrieval*, MIR). MIR, czyli komputerowe pozyskiwanie informacji muzycznej, jest interdyscyplinarnym polem badawczym zajmującym się analizą, przetwarzaniem, wyszukiwaniem, organizacją i dostępem do informacji zawartej w muzyce, zarówno w jej formie akustycznej, jak i symbolicznej. Obserwowany w ostatnich dekadach gwałtowny wzrost ilości dostępnych cyfrowych treści muzycznych, na przykład w ramach cyfrowych bibliotek muzycznych i serwisów streamingowych [3], generuje rosnące zapotrzebowanie na zautomatyzowane narzędzia do ich analizy. Narzędzia te są niezbędne do efektywnego zarządzania ogromnymi repozytoriami muzyki, ich przeszukiwania, kategoryzacji oraz personalizacji dostępu dla użytkowników. ATM jest jednym z kluczowych zadań w ramach MIR, umożliwiającym transformację sygnału audio na symboliczną reprezentację, która może być dalej przetwarzana i analizowana.

Szczególną uwagę w kontekście niniejszej pracy należy poświęcić wyzwaniom związanym z transkrypcją muzyki gitarowej. Gitara, będąca instrumentem niezwykle popularnym

i wszechstronnym, wykorzystywanym w niemal każdym gatunku muzycznym, stawia przed systemami ATM szereg specyficznych trudności:

- **Polifoniczność:** Gitara jest instrumentem polifonicznym, co oznacza zdolność do jednoczesnego wydawania wielu dźwięków (standardowo do sześciu, po jednym na każdej strunie) [5]. Nakładanie się składowych harmonicznymi wielu jednocześnie brzmiących dźwięków w sygnale audio znacząco komplikuje proces ich separacji i identyfikacji. Problem ten ilustruje przykład mel-spektrogramu na rysunku 1.2. Jest to reprezentacja, w której oś częstotliwości jest wyrażona w skali Mel – percepcyjnej skali wysokości dźwięków, szerzej omówionej w rozdziale 2.



Rysunek 1.2: Schematyczny przykład mel-spektrogramu polifonicznego sygnału gitarowego, ukazujący nakładające się struktury harmoniczne (prążki reprezentujące częstotliwość podstawową i jej alikwoty) dla kilku jednocześnie brzmiących nut.

- **Bogactwo technik artykulacyjnych:** Gitarzyści wykorzystują szeroki wachlarz technik artykulacyjnych, takich jak podciąganie strun (ang. *bending*), ślizgi (ang. *sliding*), młoteczkowanie (ang. *hammer-on*), odrywanie (ang. *pull-off*), wibrato (ang. *vibrato*) czy tłumienie strun dłonią (ang. *palm-muting*). Każda z tych technik w unikalny sposób modyfikuje charakterystykę sygnału akustycznego (np. jego wysokość, amplitudę, barwę w czasie) i jest kluczowa dla wiernej transkrypcji, zwłaszcza do formatu tabulatury, który często zawiera symbole oznaczające te techniki.
- **Duża zmienność barwy dźwięku** (ang. *timbre*): Barwa dźwięku gitary jest niezwykle zróżnicowana i zależy od wielu czynników, takich jak typ instrumentu (np. gitara akustyczna, klasyczna, elektryczna), rodzaj użytych strun, sposób ich pobudzenia

(kostką, palcami), a w przypadku gitar elektrycznych – od ustawień wzmacniacza i zastosowanych efektów gitarowych [24]. Ta duża zmienność barwy stanowi poważne wyzwanie dla modeli uczenia maszynowego, które muszą generalizować swoją wiedzę na różne instancje dźwięków gitarowych.

- **Niejednoznaczność opalcowania:** Jedną z charakterystycznych cech gitary jest możliwość zagrania dźwięku o tej samej wysokości w wielu różnych pozycjach na gryfie (tj. na różnych kombinacjach struny i progu) [24]. O ile dla tradycyjnej notacji nutowej ta wieloznaczność nie jest problemem, o tyle dla generowania tabulatury, która musi precyzyjnie wskazać miejsce zagrania dźwięku, jest to wyzwanie. Wybór odpowiedniej pozycji często zależy od kontekstu muzycznego, grywalności (łatwości wykonania) i preferencji wykonawcy.

Pomimo znaczących postępów, jakie dokonały się w dziedzinie ATM w ostatnich latach, zwłaszcza dzięki zastosowaniu zaawansowanych technik uczenia maszynowego, istniejące systemy wciąż borykają się z ograniczeniami, prowadzącymi do typowych błędów, takich jak pomyłki oktawowo, niepoprawne detekcje nut czy niedokładności czasowe [3]. Człowiek, dokonując transkrypcji, opiera się nie tylko na percepcji sygnału akustycznego, ale również na swojej rozległej wiedzy muzycznej, znajomości teorii muzyki, konwencji stylistycznych oraz kontekstu kulturowego. Maszyny, mimo coraz doskonalszych algorytmów, wciąż mają trudności z pełnym uwzględnieniem tych aspektów [11]. Ograniczenia te są szczególnie widoczne w przypadku transkrypcji muzyki polifonicznej, wykonywanej na instrumentach o charakterystyce akustycznej, takich jak gitara [5]. Niedoskonałość obecnych systemów, zwłaszcza w kontekście precyzyjnego odwzorowania niuansów wykonawczych gitary i generowania użytecznych, grywalnych tabulatur, stanowi silny impuls do poszukiwania nowych, bardziej efektywnych rozwiązań. Ta luka badawcza jest główną motywacją do podjęcia tematu niniejszej pracy. Popularność gitary oraz ogromna ilość dostępnych nagrań gitarowych, często pozbawionych wiarygodnych transkrypcji, tworzą naturalne zapotrzebowanie na narzędzia MIR, w tym ATM. Postępy w tej dziedzinie mogą z kolei stymulować dalsze tworzenie i udostępnianie muzyki, tworząc pozytywną pętlę sprzężenia zwrotnego. Co więcej, rozwój precyzyjnych systemów ATM dla gitary może odegrać istotną rolę w dokumentacji i archiwizacji unikalnych stylów gitarowych oraz technik wykonawczych, stanowiących ważne elementy dziedzictwa kulturowego. Otwartym problemem pozostaje również ocena jakości transkrypcji, zwłaszcza w kontekście tabulatur, co zostało zasygnalizowane w literaturze [27].

1.2 Cel pracy

Głównym celem niniejszej pracy magisterskiej jest zaprojektowanie, implementacja oraz weryfikacja eksperymentalna systemu służącego do automatycznej transkrypcji poli-

fonicznych nagrań audio gitary na zapis tabulaturowy. Kluczowym elementem realizacji tego celu jest wykorzystanie publicznie dostępnego zbioru danych Guitarset. Zbiór ten, opisany i wykorzystany w badaniach nad transkrypcją gitarową (np. [24]), został specjalnie przygotowany do tego celu i charakteryzuje się unikalnymi cechami, takimi jak dostarczanie nagrań heksafonicznych (sygnału z każdej struny osobno) wraz z precyzyjnymi adnotacjami dotyczącymi wysokości dźwięku, czasu jego trwania oraz, co szczególnie istotne, informacji o strunie i progu, na którym dany dźwięk został zagrany [24]. Wybór zbioru Guitarset jest zatem nieprzypadkowy; jego struktura bezpośrednio adresuje problem niejednoznaczności przypisania dźwięku do konkretnej pozycji na gryfie, co jest fundamentalne przy tworzeniu wiarygodnych danych uczących i testowych dla zadania generowania tabulatury.

System opracowany w ramach tej pracy ma dążyć do precyzyjnego odwzorowania partii gitarowych w formie tabulatury. Oznacza to nie tylko poprawną identyfikację atrybutów muzycznych takich jak wysokość i czas trwania dźwięków, ale przede wszystkim ich prawidłowe przypisanie do odpowiednich strun i progów na gryfie gitary. Dążenie do precyzji obejmuje również próbę radzenia sobie z wyzwaniami specyficznymi dla transkrypcji gitary, które zostały omówione w poprzednim podrozdziale, takimi jak wysoki stopień polifonii, zróżnicowane techniki artykulacyjne oraz konieczność generowania tabulatury uwzględniającej aspekty grywalności. Realizacja tak zdefiniowanego celu pracy, czyli stworzenie efektywnego systemu transkrypcji nagrań gitarowych do postaci tabulatury, może przyczynić się do powstania nowych narzędzi wspierających kreatywność i edukację gitarzystów. Przykładowo, taki system mógłby służyć do automatycznego generowania tabulatur z improwizowanych fragmentów muzycznych, ułatwiać analizę partii gitarowych znanych wykonawców, czy też stanowić cenne wsparcie w procesie nauki gry na instrumencie.

1.3 Zakres pracy

Realizacja postawionego celu badawczego obejmuje następujące, kluczowe etapy:

- Przeprowadzenie szczegółowej analizy literatury naukowej dotyczącej ATM, ze szczególnym naciskiem na metody stosowane w transkrypcji muzyki gitarowej, specyfikę sygnału generowanego przez ten instrument oraz różne aspekty notacji tabulaturowej, w tym jej strukturę i konwencje zapisu.
- Zaprojektowanie architektury systemu do ATM, która będzie uwzględniać specyfikę zadania, charakterystykę danych wejściowych (polifoniczne nagrania gitary akustycznej) i wyjściowych (zapis tabulaturowy) oraz dostępne narzędzia i technologie, w tym potencjalne wykorzystanie modeli głębokiego uczenia.
- Implementacja kluczowych modułów składowych systemu, obejmujących co najmniej:

- Moduł przetwarzania wstępnego sygnału audio (ang. *audio preprocessing*), mający na celu przygotowanie sygnału do dalszej analizy, np. poprzez normalizację, segmentację czy redukcję szumów.
 - Moduł ekstrakcji cech akustycznych (ang. *acoustic feature extraction*), odpowiedzialny za przekształcenie przetworzonego sygnału audio w reprezentację numeryczną, która efektywnie koduje informacje istotne dla rozpoznawania dźwięków gitarowych i ich atrybutów. Rozważone zostaną zarówno klasyczne cechy akustyczne [15], jak i cechy uzyskiwane automatycznie z wykorzystaniem metod głębokiego uczenia [5].
 - Moduł predykcyjny, oparty na wybranych technikach uczenia maszynowego, którego zadaniem będzie generowanie sekwencji zdarzeń tabulaturowych (struna, próg, czas rozpoczęcia, czas trwania) na podstawie wyekstrahowanych cech akustycznych.
- Wykorzystanie publicznie dostępnego zbioru danych Guitarset, opisanego m.in. w [24], do procesu trenowania, walidacji oraz testowania opracowanego systemu. Etap ten będzie obejmował przygotowanie danych do formatu wymaganego przez zaimplementowany model, w tym potencjalne techniki augmentacji danych w celu zwiększenia odporności modelu.
 - Zdefiniowanie i dobór odpowiednich metryk oceny jakości transkrypcji tabulaturowej. Metryki te muszą uwzględniać nie tylko poprawność wykrytych nut pod względem ich wysokości, czasu rozpoczęcia i czasu trwania, ale także, co kluczowe dla tego zadania, poprawność przypisania poszczególnych dźwięków do konkretnych strun i progów gitary.
 - Przeprowadzenie kompleksowych badań eksperymentalnych mających na celu weryfikację skuteczności i wydajności zaproponowanego rozwiązania. Wyniki uzyskane przez system będą porównywane z adnotacjami referencyjnymi ze zbioru Guitarset oraz, w miarę możliwości, z wynikami innych istniejących metod lub systemów transkrypcji gitarowej, aby ocenić postęp względem aktualnego stanu wiedzy (ang. *state-of-the-art*) [3].
 - Analiza uzyskanych wyników eksperymentalnych, obejmująca zarówno ocenę ilościową (na podstawie zdefiniowanych metryk), jak i jakościową (np. poprzez analizę typowych błędów popełnianych przez system). Na tej podstawie zostaną zidentyfikowane mocne i słabe strony opracowanego systemu oraz sformułowane wnioski końcowe i rekomendacje dotyczące potencjalnych ulepszeń oraz dalszych kierunków badań w tej dziedzinie.

1.4 Charakterystyka rozdziałów

Struktura niniejszej pracy magisterskiej została zaprojektowana w sposób umożliwiający logiczne i spójne przedstawienie podjętej problematyki, przeprowadzonych badań oraz uzyskanych wyników. Poniżej przedstawiono charakterystykę poszczególnych rozdziałów:

Rozdział 1 (Wstęp) Prezentowany rozdział. Wprowadza on w problematykę pracy, definiuje ATM i jej specyfikę w kontekście gitary i tabulatury. Osadza problem w dziedzinie naukowej MIR, omawia wyzwania związane z transkrypcją gitarową. Formułuje cel i zakres pracy, przedstawia strukturę kolejnych rozdziałów oraz określa wkład autora.

Rozdział 2 (Analiza tematu) Rozdział ten poświęcony będzie przedstawieniu podstaw teoretycznych niezbędnych do zrozumienia problematyki pracy. Omówione zostaną pojęcia dotyczące dźwięku muzycznego, jego cyfrowej reprezentacji [15] oraz podstawowych metod jego analizy. Następnie, zaprezentowane zostaną ogólne zagadnienia związane z ATM, po czym szczegółowa uwaga zostanie skupiona na specyfice transkrypcji gitarowej. Dokładnie scharakteryzowany zostanie sygnał gitary, jego cechy akustyczne oraz notacja tabulaturowa. Rozdział ten płynnie przejdzie do sprecyzowania problematyki badawczej podejmowanej w niniejszej pracy.

Rozdział 3 (Przedmiot pracy) W tym rozdziale opisane zostanie autorskie rozwiązanie problemu automatycznej transkrypcji polifonicznych nagrań gitarowych na zapis tabulaturowy. Zaprezentowana zostanie szczegółowa architektura zaimplementowanego systemu, wraz z opisem poszczególnych jego modułów. Dokładnie scharakteryzowany zostanie wykorzystany zbiór danych Guitarset, którego cechy i zastosowanie w badaniach opisano m.in. w [24], oraz proces jego adaptacji na potrzeby systemu. Uzasadniony zostanie również wybór zastosowanych metod przetwarzania sygnału, ekstrakcji cech, algorytmów uczenia maszynowego oraz wykorzystanych narzędzi programistycznych.

Rozdział 4 (Badania) Ten rozdział będzie poświęcony prezentacji metodyki oraz wyników przeprowadzonych badań eksperymentalnych. Opisane zostanie środowisko badawcze, sposób przygotowania danych testowych oraz zdefiniowane metryki oceny jakości transkrypcji. Uzyskane wyniki zostaną zaprezentowane w sposób ilościowy (np. w postaci tabel i wykresów) oraz jakościowy. Następnie wyniki te zostaną poddane szczegółowej analizie i dyskusji, w tym identyfikacji typowych błędów popełnianych przez system oraz porównaniu z istniejącymi rozwiązaniami lub stanem wiedzy.

Rozdział 5 (Podsumowanie) Ostatni rozdział pracy będzie zawierał syntetyczne podsumowanie wszystkich zrealizowanych prac. Zaprezentowane zostaną kluczowe wnioski końcowe wynikające z przeprowadzonych badań i analiz. Oceniony zostanie stopień

realizacji postawionego celu pracy. Wskazane zostaną również potencjalne kierunki dalszego rozwoju opracowanego systemu oraz możliwe przyszłe badania w tej dziedzinie, być może w nawiązaniu do otwartych problemów i wyzwań identyfikowanych w literaturze.

1.5 Określenie wkładu autora

W tej części precyzyjnie określony zostaje indywidualny wkład autora w realizację niniejszej pracy. Obejmuje on następujące kluczowe aspekty, za które autor był samodzielnie odpowiedzialny:

- Samodzielne przeprowadzenie gruntownych studiów literaturowych oraz krytyczną analizę aktualnego stanu wiedzy i badań w dziedzinie ATM, ze szczególnym uwzględnieniem problematyki transkrypcji muzyki gitarowej oraz specyfiki zapisu tabulaturowego.
- Opracowanie oryginalnej koncepcji oraz zaprojektowanie architektury systemu przeznaczonego do ATM polifonicznych nagrań gitarowych na postać tabulatury, uwzględniającej specyficzne wyzwania związane z tym zadaniem.
- Wykorzystanie publicznie dostępnego zbioru danych Guitarset na potrzeby procesu trenowania, walidacji i kompleksowej ewaluacji zaprojektowanego i zaimplementowanego systemu.
- Implementacja algorytmów przetwarzania sygnału audio, metod ekstrakcji cech akustycznych oraz modeli uczenia maszynowego, które stanowią rdzeń funkcjonalny opracowanego systemu transkrypcji.
- Zaprojektowanie metodyki oraz samodzielne przeprowadzenie kompleksowych badań eksperymentalnych, mających na celu weryfikację skuteczności, wydajności oraz ograniczeń opracowanego rozwiązania w kontekście transkrypcji gitarowej na tabulaturę.
- Krytyczna analiza i interpretacja uzyskanych wyników eksperymentalnych, w tym identyfikacja mocnych i słabych stron systemu, oraz ocena istotności tych wyników w kontekście istniejących rozwiązań i aktualnego stanu wiedzy w dziedzinie.
- Sformułowanie wniosków końcowych podsumowujących całość przeprowadzonych prac badawczych i implementacyjnych, a także przedstawienie propozycji dotyczących potencjalnych ulepszeń systemu oraz możliwych kierunków dalszych badań.

Rozdział 2

Analiza tematu: teoretyczne podstawy transkrypcji muzycznej i specyfika transkrypcji gitarowej

Rozdział pierwszy wprowadził w ogólną problematykę automatycznej transkrypcji muzycznej (ATM) oraz zarysował specyficzne wyzwania związane z muzyką gitarową. Niniejszy rozdział stanowi rozwinięcie podstaw teoretycznych, które są niezbędne do pełnego zrozumienia podejmowanego problemu oraz zaprojektowanego rozwiązania. Skupia się on na szczegółowej analizie dźwięku muzycznego, jego cyfrowej reprezentacji oraz metodach stosowanych w ATM, kładąc fundament pod dalsze, bardziej techniczne części pracy.

2.1 Sprecyzowanie problemu badawczego

Jak wskazano we wstępie, proces ATM polega na przekształceniu sygnału audio na jego symboliczną reprezentację, taką jak format piano-roll czy standardowy zapis nutowy [15, 3]. W kontekście niniejszej pracy, problem ten zostaje sprecyzowany jako **automatyczna transkrypcja gitarowa na zapis tabulaturowy (GTT)** (ang. *Guitar Tablature Transcription*). Zadanie GTT wykracza poza prostą identyfikację wysokości i czasu trwania dźwięków, ponieważ obejmuje również ich precyzyjne przypisanie do konkretnych strun i progów na gryfie gitary [24]. Ponadto, pełna transkrypcja tabulaturowa dąży do rozpoznania technik artykulacyjnych charakterystycznych dla gitary, takich jak podciągnięcia strun (ang. *bends*), młoteczkowanie (ang. *hammer-on*), odrywanie (ang. *pull-off*) czy wibrato (ang. *vibrato*) [21], które są kluczowe dla wiernego odtworzenia utworu.

Mimo znaczącego potencjału aplikacyjnego, należy zauważyć, że obecne systemy ATM mogą nie zawsze oferować przewagę w każdym scenariuszu, np. w kontekstach etnomuzy-


kologicznych, gdzie dla doświadczonych transkrybentów krytyczna jest precyzja notacji rytmicznej [11].

2.2 Podstawy teoretyczne: dźwięk muzyczny i jego cyfrowa reprezentacja

Zrozumienie procesów leżących u podstaw automatycznej transkrypcji muzycznej wymaga uprzedniego zapoznania się z właściwościami dźwięku muzycznego oraz sposobami jego cyfrowej reprezentacji i analizy. Niniejsza sekcja przybliży te kluczowe koncepcje.

2.2.1 Percepcyjne i fizyczne atrybuty dźwięku muzycznego

Dźwięk muzyczny, z perspektywy percepcji, charakteryzowany jest przez cztery podstawowe atrybuty: wysokość, głośność, barwę i czas trwania [15]. Wysokość jest bezpośrednio związana z częstotliwością podstawową (F_0) drgań źródła dźwięku. Głośność to subiektywna ocena natężenia dźwięku. Barwa pozwala odróżnić dźwięki o tej samej wysokości i głośności, lecz pochodzące z różnych instrumentów lub generowane różnymi technikami; jest ona ściśle powiązana ze spektrum harmonicznym dźwięku (rozkładem i względnymi amplitudami składowych harmonicznymi) oraz jego obwiednią czasową. Czas trwania definiuje, jak długo dźwięk jest postrzegany. Obwiednia amplitudy dźwięku, często modelowana jako ADSR (ang. *Attack*, *Decay*, *Sustain*, *Release*; atak, zanikanie, podtrzymanie, wybrzmiewanie), odgrywa kluczową rolę w kształtowaniu charakteru brzmieniowego, zwłaszcza dla instrumentów szarpanych, takich jak gitara [15]. Jej schematyczną wizualizację przedstawia rysunek 2.1. Fazy ataku (narastania), początkowego zaniku, podtrzymania i końcowego wybrzmiewania definiują dynamiczny profil dźwięku, przy czym dla gitary fazy zaniku i wybrzmiewania są szczególnie złożone i zależne od instrumentu oraz techniki gry.




Rysunek 2.1: Schematyczna wizualizacja obwiedni dźwięku ADSR (oś pionowa: amplituda, oś pozioma: czas) [25].

2.2.2 Reprezentacja sygnału audio w dziedzinie czasu i częstotliwości

Cyfrowy sygnał audio jest sekwencją próbek reprezentujących amplitudę fali akustycznej w kolejnych, dyskretnych punktach czasu [15]. Analiza wyłącznie w dziedzinie czasu nie ujawnia jednak w pełni struktury muzycznej sygnału. Kluczowa jest analiza częstotliwościowa, pozwalająca zidentyfikować składowe częstotliwościowe. Przejście z dziedziny czasu do dziedziny częstotliwości realizowane jest za pomocą transformaty Fouriera, która dekomponuje sygnał na sumę składowych sinusoidalnych o różnych częstotliwościach i amplitudach, tworząc jego widmo częstotliwościowe [15]. Dyskretna transformata Fouriera (DFT) jest podstawowym narzędziem tej analizy. Dla skończonego ciągu próbek sygnału x_n o długości N , jej k -ty współczynnik X_k jest zdefiniowany wzorem (2.1):

$$X_k = \sum_{n=0}^{N-1} x_n \cdot e^{-i\frac{2\pi}{N}kn} \quad (2.1)$$

gdzie n jest indeksem próbki w dziedzinie czasu, k jest indeksem częstotliwości, a i jest jednostką urojoną. Działanie transformaty ilustruje rysunek 2.2.



Rysunek 2.2: Po lewej: fragment sygnału audio pojedynczego dźwięku gitary w dziedzinie czasu (oś pionowa: amplituda (wartość znormalizowana), oś pozioma: czas w próbkach). Po prawej: odpowiadające mu widmo amplitudowe (oś pionowa: magnituda (jednostki względne), oś pozioma: częstotliwość w Hz), ukazujące częstotliwość podstawową (F_0) oraz jej kolejne alikwoty (składowe harmoniczne).

2.2.3 Analiza czasowo-częstotliwościowa i jej znaczenie dla ATM


Charakterystyki częstotliwościowe muzyki zmieniają się w czasie, dlatego w zastosowaniach ATM niezbędne są metody analizy czasowo-częstotliwościowej. Podstawową techniką jest krótkoczasowa transformata Fouriera (ang. *Short-Time Fourier Transform*, STFT), która polega na sekwencyjnej analizie Fouriera krótkich, najczęściej nakładających się na siebie segmentów sygnału [15, 5]. Wynikiem STFT jest spektrogram – dwuwymiarowa reprezentacja energii sygnału w funkcji czasu i częstotliwości, która stanowi podstawę dla wielu systemów ATM. Należy pamiętać o nieodłącznym kompromisie STFT między rozdzielczością czasową a częstotliwościową, wynikającym z zasady nieoznaczoności. Kluczowym ograniczeniem tej metody w kontekście muzycznym jest jej stała rozdzielczość częstotliwościowa, co oznacza, że pasma częstotliwości mają identyczną szerokość (np. w hercach) na całej skali. Nie odpowiada to logarytmicznej naturze ludzkiej percepcji wysokości dźwięku.

W odpowiedzi na to ograniczenie opracowano alternatywne reprezentacje, lepiej dostosowane do specyfiki sygnału muzycznego. Jedną z nich jest transformata Constant-Q (ang. *Constant-Q Transform*, CQT) [3, 24, 27]. Jej fundamentalną cechą jest zastosowanie logarytmicznej skali częstotliwości, która naśladuje strukturę skal muzycznych. W praktyce, CQT dzieli oś częstotliwości na pasma (tzw. prążki), których szerokości są geometrycznie rozmieszczone, co skutkuje stałą liczbą pasm na oktawę. Taka organizacja zapewnia zmienną rozdzielczość: wysoką w dziedzinie częstotliwości dla niskich tonów, co ułatwia rozróżnianie nut podstawowych, oraz wysoką w dziedzinie czasu dla tonów wysokich, co jest korzystne dla analizy szybkich transjentów i alikwotów.

Inną powszechnie stosowaną nieliniową skalą częstotliwości jest skala Mel, której geneza

również leży w badaniach psychoakustycznych nad ludzką percepcją [3]. Skala ta nie jest czysto logarytmiczna; jej charakterystyka jest zbliżona do liniowej dla częstotliwości poniżej 1 kHz, a dopiero powyżej tej granicy staje się coraz bardziej logarytmiczna, odzwierciedlając mniejszą wrażliwość ludzkiego ucha na zmiany wysokości dla wyższych dźwięków. Mel-spektrogramy, czyli spektrogramy z osią częstotliwości przekształconą na skalę Mel, tworzy się poprzez przetworzenie standardowego spektrogramu STFT za pomocą banku nakładających się na siebie filtrów trójkątnych, których rozmieszczenie odpowiada skali Mel. Proces ten prowadzi do redukcji wymiarowości przy jednoczesnym zachowaniu informacji kluczowych z punktu widzenia percepcji, co czyni mel-spektrogramy standardowym wejściem dla wielu modeli głębokiego uczenia.

Ewolucja od STFT, poprzez CQT, do mel-spektrogramów odzwierciedla dążenie do tworzenia reprezentacji cech bardziej zgodnych z ludzką percepcją i efektywniejszych dla algorytmów uczenia maszynowego. Różne reprezentacje czasowo-częstotliwościowe dla tego samego fragmentu muzycznego wizualizuje rysunek 2.3.



Rysunek 2.3: Wizualizacja różnych reprezentacji czasowo-częstotliwościowych dla tego samego polifonicznego fragmentu gitarowego: (a) Spektrogram STFT z liniową skalą częstotliwości, (b) Spektrogram Constant-Q (CQT) z logarytmiczną skalą częstotliwości, (c) Mel-spektrogram z osią częstotliwości w skali Mel.

2.3 Automatyczna transkrypcja muzyczna: zadania, poziomy i wyzwania

ATM, jest procesem wieloetapowym, obejmującym szereg skomplikowanych zadań cząstkowych. Zrozumienie tych zadań, poziomów abstrakcji, na jakich operują, oraz nieodłącznych wyzwań jest kluczowe dla oceny istniejących rozwiązań i projektowania nowych.

2.3.1 Definicja, zadania składowe i poziomy abstrakcji w ATM


Formalnie, ATM można zdefiniować jako proces estymacji parametrów nut, takich jak czas rozpoczęcia, wysokość i czas trwania, bezpośrednio z sygnału audio [15, 3]. Jest to

zadanie hierarchiczne, które można zdekomponować na kilka kluczowych zadań składowych. Do najważniejszych z nich należą [3, 9]:

- **estymacja wielokrotnej wysokości dźwięku** (ang. *Multiple Pitch Estimation*, MPE), czyli identyfikacja wszystkich częstotliwości podstawowych obecnych w danym momencie;
- **detekcja początku i końca dźwięku** (ang. *Onset/Offset Detection*), czyli precyzyjne lokalizowanie w czasie momentów rozpoczęcia i zakończenia poszczególnych zdarzeń muzycznych;
- **zadania zaawansowane**, takie jak rozpoznawanie instrumentów, analiza rytmu i metrum czy interpretacja ekspresji wykonawczej.

Wyniki transkrypcji mogą być prezentowane na różnych poziomach abstrakcji [3]:

- **na poziomie krótkich ramek czasowych**, np. poprzez wskazanie aktywnych wysokości dźwięku w oknie kilkudziesięciu milisekund;
- **na poziomie symbolicznym**, jako zestaw nut z określonymi atrybutami;
- **na poziomie strukturalnym**, jako bardziej złożone obiekty, takie jak strumienie melodyczne czy pełna partytura muzyczna.



Rysunek 2.4: Uproszczony schemat potoku przetwarzania w systemie ATM: od sygnału audio, poprzez ekstrakcję cech, zadania składowe (MPE, detekcja onsetów/offsetów, estymacja instrumentu), aż po generowanie wyjściowej reprezentacji symbolicznej na różnych poziomach abstrakcji (ramki, nuty, partytura) [3].

2.3.2 Transkrypcja monofoniczna vs polifoniczna – złożoność i główne wyzwania

Złożoność zadania ATM znacząco wzrasta przy przejściu od transkrypcji monofonicznej (pojedyncza linia melodyczna) do polifonicznej (wiele współbrzmiących dźwięków) [15, 3]. Muzyka gitarowa, ze względu na możliwość gry akordowej i prowadzenia wielu niezależnych linii melodycznych, jest w przeważającej mierze polifoniczna, co czyni jej transkrypcję szczególnie trudną [5]. Główne wyzwania w ATM, które ulegają intensyfikacji w kontekście polifonii, to przede wszystkim: interferencja harmoniczných składowych różnych dźwięków (szczególnie w interwałach konsonansowych), maskowanie cichszych dźwięków przez głośniejsze, trudności w precyzyjnej detekcji czasów rozpoczęcia i zakończenia dźwięków w gęstych fakturach, zmienność barwy dźwięku zależna od artykulacji i dynamiki, oraz częste błędy w estymacji wysokości, takie jak pomyłki oktawowo [3]. Dodatkowo, efektywne trenowanie modeli uczenia maszynowego wymaga dostępu do dużych, dokładnie zaanotowanych zbiorów danych, których tworzenie jest procesem czasochłonnym i kosztownym.

2.4 Przegląd metod stosowanych w automatycznej transkrypcji muzycznej

Rozwój metod ATM jest procesem ciągłym, odzwierciedlającym postęp w dziedzinach przetwarzania sygnałów i uczenia maszynowego. Poniżej przedstawiono ewolucję tych podejść, od metod klasycznych po najnowsze techniki oparte na głębokim uczeniu.

2.4.1 Metody tradycyjne oparte na przetwarzaniu sygnałów

Historycznie pierwsze podejścia do ATM opierały się w dużej mierze na technikach CPS [15]. W przypadku transkrypcji muzyki monofonicznej, gdzie w danym momencie występuje tylko jeden dźwięk, opracowano szereg metod detekcji jego częstotliwości podstawowej (F_0). Do klasycznych algorytmów należą te bazujące na analizie funkcji autokorelacji (ang. *Auto-Correlation Function*, ACF), uśrednionej funkcji różnicowej amplitudy (ang. *Average Magnitude Difference Function*, AMDF), technice spektrum harmonicznego iloczynu (ang. *Harmonic Product Spectrum*, HPS), która wzmacnia częstotliwość podstawową poprzez mnożenie widma z jego wersjami skompresowanymi w dziedzinie częstotliwości (tj. widmami poddanymi decymacji), oraz na analizie cepstralnej (ang. *cepstral analysis*). Cepstrum, będące wynikiem odwrotnej transformaty Fouriera z logarytmu widma mocy sygnału, pozwala na separację składowej związanej ze źródłem dźwięku (pobudzeniem) od składowej związanej z charakterystyką filtra rezonansowego instrumentu [15]. Rozwijano również systemy bazujące na modelach harmoniczných dźwięku oraz systemy ekspertowe, wykorzystujące predefiniowane reguły i wiedzę muzykologiczną [15]. Metody te wykazy-

wały znaczne ograniczenia w kontekście analizy muzyki polifonicznej, gdzie jednoczesne występowanie wielu dźwięków i ich alikwotów znacząco komplikuje sygnał, prowadząc m.in. do niemożności separacji nakładających się szeregów harmoniczných. Ograniczenia te stały się motywacją do poszukiwania bardziej zaawansowanych rozwiązań w ramach uczenia maszynowego.

2.4.2 Metody oparte na uczeniu maszynowym

Przełom w skuteczności systemów ATM przyniosło zastosowanie metod uczenia maszynowego, które pozwoliły na tworzenie modeli zdolnych do nauki złożonych zależności bezpośrednio z danych [14, 5]. W ramach tego paradygmatu można wyróżnić kilka głównych kierunków.

Nienadzorowane metody faktoryzacji macierzy

Wśród metod nienadzorowanych, popularność zdobyła nieujemna faktoryzacja macierzy (ang. *Non-negative Matrix Factorization*, NMF) [3]. W kontekście muzycznym, technika ta polega na dekompozycji (rozłożeniu) macierzy wejściowej, którą jest spektrogram, na iloczyn dwóch macierzy o mniejszych wymiarach, również posiadających wyłącznie wartości nieujemne.

Pierwsza z nich, **macierz szablonów** (słownika), zawiera zbiór charakterystycznych profili spektralnych. Każdy taki profil można interpretować jako “dźwiękowy odcisk palca” pojedynczej nuty, ukazujący rozkład energii na jej częstotliwość podstawową i kolejne harmoniczne. Druga macierz, **macierz aktywacji**, określa z kolei, z jaką głośnością i w którym momencie każdy z tych szablonów pojawia się w oryginalnym nagraniu. W ten sposób spektrogram całego utworu jest reprezentowany jako suma ważona podstawowych komponentów muzycznych.

Zaletą NMF jest jej zdolność do automatycznego, nienadzorowanego odkrywania tych fundamentalnych struktur w danych. Istotnym wyzwaniem jest jednak fakt, że podstawowa wersja NMF może mieć trudności z separacją źródeł o silnie nakładających się charakterystykach spektralnych – na przykład dźwięków w konsonansowych interwałach, których harmoniczne pokrywają się. W celu rozwiązania tych problemów opracowano liczne rozszerzenia NMF, takie jak nadzorowane NMF (gdzie szablony są predefiniowane i stałe) czy harmoniczne NMF (które narzucają harmoniczną strukturę na szablony, zapewniając ich muzyczną poprawność) [3].

Modele probabilistyczne i bayesowskie

Ukryte modele Markowa (ang. *Hidden Markov Models*, HMM) były przez wiele lat intensywnie badane i stosowane w ATM, głównie ze względu na ich naturalną zdolność do modelowania sekwencyjnego charakteru muzyki [15, 6, 20]. W typowym podejściu,

ukryte stany HMM mogą odpowiadać poszczególnym nutom lub stanom ciszy, a obserwacje emitowane przez te stany to wektory cech akustycznych wyekstrahowanych z kolejnych ramek sygnału audio. Prace Raphaëla [20] stanowią wczesny przykład zastosowania HMM do transkrypcji muzyki fortepianowej, gdzie modelowano proces generowania nut z uwzględnieniem prawdopodobieństw przejść między nimi. Cazau i Nuel [6] eksplorowali różne warianty HMM, w tym ich integrację z metodami dekompozycji spektralnej, jak probabilistyczna analiza składowych ukrytych (ang. *Probabilistic Latent Component Analysis*, PLCA), w celu poprawy jakości transkrypcji, np. poprzez modelowanie trwania nut lub wykorzystanie wiedzy o tonalności do modelowania przejść harmonicznych. Podejścia bayesowskie, stanowiące szerszą klasę modeli, pozwalają na formalne włączenie do modelu wcześniejszej wiedzy (np. reguł harmonii, typowych progresji akordów) w postaci rozkładów a priori. Mimo pewnych sukcesów, modele te często wymagają starannej inżynierii cech i mogą mieć trudności z modelowaniem bardzo złożonych zależności w muzyce polifonicznej.

Głębokie sieci neuronowe

W ostatnich latach metody oparte na głębokim uczeniu (DL) zdominowały badania nad ATM, osiągając wyniki stanowiące aktualny stan wiedzy w wielu aspektach tego zadania [3, 14]. Zdolność głębokich sieci neuronowych do automatycznego uczenia się hierarchicznych, wielopoziomowych reprezentacji cech bezpośrednio z danych wejściowych (np. surowych spektrogramów) okazała się kluczowa dla postępu. Wśród najczęściej wykorzystywanych architektur znajdują się konwolucyjne sieci neuronowe (ang. *Convolutional Neural Networks*, CNN), efektywnie przetwarzające dane o strukturze siatki, takie jak spektrogramy [24, 27]; rekurencyjne sieci neuronowe (ang. *Recurrent Neural Networks*, RNN), w szczególności warianty z długą krótkotrwałą pamięcią (ang. *Long Short-Term Memory*, LSTM) i bramkowanymi jednostkami rekurencyjnymi (ang. *Gated Recurrent Unit*, GRU), przystosowane do modelowania zależności czasowych w sekwencjach muzycznych [3]; oraz architektury hybrydowe, takie jak konwolucyjno-rekurencyjne sieci neuronowe (ang. *Convolutional Recurrent Neural Network*, CRNN), łączące zalety obu tych podejść [9]. Najnowsze badania eksplorują również potencjał architektur opartych na mechanizmach uwagi, takich jak Transformer (ang. *Transformer*) [14, 10]. Dostępność dużych, publicznych zbiorów danych adnotowanych, takich jak MAESTRO dla muzyki fortepianowej [9, 27] (zawierający nagrania z konkursów pianistycznych wraz z odpowiadającymi im plikami MIDI) oraz GuitarSet dla muzyki gitarowej [24, 27, 3] (oferujący nagrania z sześciu osobnych przetworników dla każdej struny oraz zsynchronizowane adnotacje MIDI i tabulaturowe), była katalizatorem rozwoju modeli DL. To właśnie te obszerne i zaanotowane zbiory danych umożliwiły trenowanie złożonych modeli DL na skalę niezbędną do osiągnięcia wysokiej dokładności, podkreślając, że postęp w tej dziedzinie jest równie mocno zależny od inżynierii danych, co od innowacji algorytmicznych. Model „Onsets and Frames” [9], zaprojektowany do transkrypcji muzyki fortepianowej, jest przykładem systemu DL, który

osiągnął wysoką skuteczność. Wykorzystuje on architekturę CRNN do jednoczesnej predykcji czasów rozpoczęcia dźwięków (ang. *onsets*) oraz aktywności poszczególnych nut w kolejnych ramkach czasowych. „Basic Pitch” [4] to z kolei narzędzie typu audio-to-MIDI, opracowane przez Spotify, które charakteryzuje się lekkością i zdolnością do detekcji zmian wysokości dźwięku (ang. *pitch bends*). Opiera się na modelach CNN, a jego priorytetem jest szybkość działania i dostępność, co czyni je użytecznym w wielu praktycznych zastosowaniach, chociaż może nie osiągać takiej samej szczegółowości transkrypcji jak bardziej złożone systemy w przypadku skomplikowanych fragmentów polifonicznych. Mimo imponujących wyników, metody DL nie są pozbawione ograniczeń. Ich skuteczność jest silnie uzależniona od ilości i jakości danych treningowych, a trening i inferencja złożonych modeli DL mogą być wymagające obliczeniowo [14].

2.5 Specyfika transkrypcji muzyki gitarowej na zapis tabulaturowy (GTT)

Transkrypcja muzyki gitarowej, zwłaszcza z celem wygenerowania zapisu tabulaturowego, wprowadza szereg specyficznych problemów i wymagań, które odróżniają ją od ogólnego zadania ATM. Niniejsza sekcja poświęcona jest analizie tych unikalnych aspektów.

2.5.1 Akustyczna charakterystyka sygnału gitary i jej implikacje dla transkrypcji

Sygnał generowany przez gitarę posiada szereg unikalnych cech akustycznych, które czynią jego automatyczną transkrypcję zadaniem szczególnie złożonym [24, 5]. Obwiednia dźwięku gitary, zwłaszcza akustycznej, charakteryzuje się zazwyczaj bardzo szybkim atakiem i relatywnie długim, stopniowym wybrzmiewaniem, co może utrudniać precyzyjną detekcję czasów zakończenia dźwięków (ang. *offsets*). Barwa dźwięku gitary jest niezwykle zróżnicowana i zależy od wielu czynników, takich jak konstrukcja instrumentu (np. gitara akustyczna z pudłem rezonansowym, gitara elektryczna typu *solid-body*), rodzaj i wiek strun, technika artykulacji (np. gra kostką, palcami, techniką *slap*), a w przypadku gitar elektrycznych – w decydującym stopniu od ustawień wzmacniacza oraz zastosowanych efektów gitarowych (np. *distortion*, *overdrive*, *chorus*, *flanger*, *delay*, *reverb*) [24]. Ta nieodłączna zmienność i bogactwo barwowe, choć stanowią o atrakcyjności instrumentu, komplikują proces tworzenia uogólnionych modeli transkrypcyjnych. Kluczowe dla GTT jest również adekwatne uwzględnienie licznych, specyficznych dla gitary technik wykonawczych, których manifestacje akustyczne przedstawia Tabela 2.1. Techniki te nie tylko znacząco wpływają na charakterystykę sygnału, ale także mają swoje bezpośrednie odzwierciedlenie w zapisie tabulaturowym.

Tabela 2.1: Akustyczne manifestacje wybranych technik gitarowych istotnych dla transkrypcji na tabulaturę.

Technika	Opis	Akustyczna Manifestacja (Przykładowa)
(ang. <i>Hammer-on</i>)	Uderzenie palcem lewej ręki (dla praworęcznych gitarzystów) w strunę na wyższym progu w celu wydobycia dźwięku bez ponownego szarpania struny prawą ręką.	Zazwyczaj łagodniejszy atak spektralny w porównaniu do dźwięku szarpniętego; możliwy spadek amplitudy po wykonaniu techniki, szczególnie na cieńszych strunach [12]; poprzedzający dźwięk (jeśli był) może wybrzmiewać w tle z niższą amplitudą [12, 23]. Brak wyraźnego „dołka” w amplitudzie między nutami w sekwencji legato [21].
(ang. <i>Pull-off</i>)	Oderwanie palca lewej ręki od struny (zazwyczaj z lekkim jej szarpnięciem) w celu wydobycia niższego dźwięku, który już brzmi (np. na pustej strunie lub przytrzymywany innym palcem na niższym progu).	Podobnie jak <i>hammer-on</i> , charakteryzuje się łagodniejszym atakiem w porównaniu do dźwięku szarpniętego; zmiana wysokości następuje na niższą; może towarzyszyć krótki, szerokopasmowy szum związany z mechanicznym ruchem odrywania palca [23].
(ang. <i>Slide</i>) (ślizg)	Płynne przesunięcie palca lewej ręki wzdłuż struny pomiędzy dwoma progami, podczas gdy struna wibruje.	Ciągła, płynna zmiana częstotliwości podstawowej (F_0) i jej harmoniczných (tzw. <i>glissando</i>) między wysokością początkową a końcową [23, 21]; zachowanie energii sygnału i jego ciągłości spektralnej; charakterystyczny profil przejścia między wysokościami, odróżniający od techniki <i>bend</i> [23].

Technika	Opis	Akustyczna Manifestacja (Przykładowa)
(ang. <i>Bend</i>) (podciągnięcie)	Poprzeczne podciągnięcie struny na gryfie palcem lewej ręki, co zwiększa jej napięcie i w rezultacie podwyższa wysokość dźwięku.	Płynna zmiana wysokości dźwięku (F_0) w górę, często z następującym powrotem do oryginalnej wysokości lub przejściem do innej [23, 21]; mogą pojawić się charakterystyczne zmiany w natężeniu alikwotów oraz subtelne zmiany barwy.
(ang. <i>Palm-muting</i>)	Delikatne tłumienie strun krawędzią dłoni prawej ręki (dla gitarzystów praworęcznych) w pobliżu mostka gitary, bezpośrednio po ich szarpnięciu.	Znaczne skrócenie czasu wybrzmiewania dźwięku (szybszy zanik energii); stłumiony, bardziej perkusyjny i mniej rezonujący charakter; redukcja udziału wyższych harmoniczych w spektrum, co prowadzi do „ciemniejszego”, „cichszego” brzmienia [23].
(ang. <i>Vibrato</i>)	Cykliczna, subtelna modulacja wysokości dźwięku, uzyskiwana przez oscylacyjny ruch palca przytrzymującego strunę na progu lub za pomocą ramienia tremolo.	Okresowe, stosunkowo wolne (typowo 5-7 Hz) fluktuacje częstotliwości podstawowej (F_0) i jej harmoniczych wokół centralnej wysokości dźwięku [1, 13]; może również występować sprzężona z tym modulacja amplitudy [1, 13].

2.5.2 Porównanie notacji standardowej i tabulaturowej dla gitary

W praktyce muzycznej gitarzyści posługują się dwoma głównymi systemami notacji: tradycyjną notacją muzyczną opartą na pięciolinii oraz tabulaturą gitarową. Każdy z tych systemów posiada swoje unikalne cechy, które determinują jego adekwatność w różnych zastosowaniach i dla różnych grup użytkowników [24]. Tabela 2.2 przedstawia zwięzłe porównanie obu systemów. Wybór tabulatury jako docelowej formy zapisu w wielu współczesnych systemach GTT jest motywowany jej dużą popularnością, zwłaszcza wśród gitarzystów samouków i w muzyce rozrywkowej, oraz jej bezpośrednim, instruktażowym charakterem, który ułatwia naukę i wykonanie utworu na instrumencie.


Tabela 2.2: Porównanie standardowej notacji muzycznej i tabulatury gitarowej.

Cecha	Standardowa Notacja Muzyczna	Tabulatura Gitarowa
Reprezentacja wysokości	Abstrakcyjna, poprzez pozycję nuty na pięciolinii, wymagająca znajomości klucza i zasad teorii muzyki [24].	Bezpośrednia, poprzez wskazanie numeru progu na linii reprezentującej konkretną strunę gitary [24].
Reprezentacja rytmu	Precyzyjnie zdefiniowana za pomocą wartości rytmicznych nut, pauz i oznaczeń metrycznych [24].	Często uproszczona lub nieobecna; główny nacisk kładziony jest na wysokość i sposób opalcowania. Rytm bywa jednak dodawany za pomocą symboli podobnych do notacji standardowej lub poprzez odniesienie do nagrania [24].
Czytelność dla gitarzystów	Wymaga dłuższego procesu nauki i praktyki w czytaniu nut na pięciolinii [24].	Zazwyczaj bardzo intuicyjna i łatwa do szybkiego opanowania, szczególnie dla początkujących gitarzystów i samouków; bezpośrednio pokazuje, gdzie umieścić palce na gryfie [24].
Notacja technik gry	Możliwa za pomocą licznych dodatkowych symboli i oznaczeń słownych, ale czasami może być mniej jednoznaczna lub intuicyjna dla specyficznych technik gitarowych.	Bardzo dobrze przystosowana do notowania szerokiego spektrum specyficznych technik gitarowych (np. <i>bends</i> , <i>slides</i> , <i>hammer-ons</i> , <i>pull-offs</i> , <i>vibrato</i>) za pomocą dedykowanych symboli graficznych.
Niejednoznaczność opalcowania	Istnieje – ten sam dźwięk (wysokość) może być zagrany na gitarze na kilku różnych strunach i progach; wybór konkretnego opalcowania jest pozostawiony wykonawcy [24].	Zazwyczaj jednoznacznie określa zarówno strunę, jak i próg, na którym dany dźwięk ma być zagrany, tym samym eliminując problem wyboru opalcowania dla danej nuty [24].

2.5.3 Kluczowe wyzwania w automatycznej transkrypcji gitary na tabulaturę (GTT)

Transkrypcja na tabulaturę wprowadza szereg specyficznych wyzwań, które wykraczają poza ogólne problemy ATM:

- **Wysoka polifonia i nakładanie się dźwięków:** Gitara, jako instrument harmoniczny, często generuje złożone współbrzmienia, co intensyfikuje problem separacji i identyfikacji poszczególnych dźwięków w sygnale audio [5].
- **Niejednoznaczność reprezentacji dźwięku na gryfie** (ang. *Tablature Inference / Fingering Estimation*): Jest to jedno z fundamentalnych wyzwań w GTT. Ten sam dźwięk (o tej samej wysokości muzycznej) może być zagrany w wielu różnych pozycjach na gryfie gitary (tj. na różnych kombinacjach struny i progu) [24]. Wybór konkretnej pozycji przez gitarzystę zależy od wielu czynników, takich jak kontekst muzyczny (np. sąsiednie dźwięki), grywalność (łatwość wykonania danego pochodzenia dźwięków), preferencje stylistyczne, a nawet subtelne różnice w barwie dźwięku uzyskiwane na różnych strunach. System GTT musi więc nie tylko poprawnie zidentyfikować wysokość i czas trwania nuty, ale również podjąć decyzję co do jej najbardziej prawdopodobnego i/lub najlepszego opalcowania na gryfie. Ilustruje to rysunek 2.5.



Rysunek 2.5: Przykład tej samej nuty (E4, MIDI 64) możliwej do zagrania w wielu pozycjach na gryfie gitary standardowo strojonej. Ilustracja przedstawia dźwięk E4 na strunie G (9. próg), strunie B (5. próg) oraz pustej strunie wysokiej E. O obrazuje to wyzwanie estymacji opalcowania w GTT [8].

- **Zmienność barwy jako potencjalna wskazówka i problem:** Chociaż subtelne różnice w barwie dźwięku tej samej nuty granej na różnych strunach mogą teoretycznie dostarczać pewnych wskazówek dla algorytmów estymacji opalcowania, to wszechobecne i często intensywne stosowanie efektów gitarowych (szczególnie w muzyce rockowej, metalowej, jazzowej i elektronicznej) może całkowicie modyfikować oryginalną barwę instrumentu, maskując te subtelne różnice lub wprowadzając własne artefakty, co znacząco komplikuje analizę [24].
- **Detekcja i notacja technik wykonawczych:** Wierne odtworzenie partii gitarowej w formie tabulatury wymaga nie tylko transkrypcji samych nut, ale również

rozpoznania i odpowiedniego zanotowania licznych, specyficznych dla gitary technik artykulacyjnych (patrz Tabela 2.1) [21, 23]. Jest to zadanie trudne, gdyż akustyczne manifestacje tych technik bywają subtelne i zmienne.

- **Problem „przesunięcia dziedziny”** (ang. *domain shift*): Modele GTT trenowane na danych pochodzących z jednej domeny (np. czyste, studyjne nagrania gitar akustycznych lub dane syntetyczne) mogą wykazywać znaczący spadek skuteczności, gdy są stosowane do danych z innej domeny (np. nagrania koncertowe, amatorskie, partie gitar elektrycznych z efektami) [27]. Praca Zang i współpracowników [27] nad zbiorem SynthTab stanowi próbę zaadresowania problemu niedoboru zróżnicowanych danych rzeczywistych poprzez wykorzystanie dużych ilości danych syntetycznych do wstępnego treningu modeli, które następnie mogą być dostrajane na mniejszych zbiorach danych rzeczywistych.

2.5.4 Przegląd istniejących podejść i narzędzi do GTT

Współczesne podejścia do GTT można generalnie podzielić na dwuetapowe oraz zintegrowane, określane jako (ang. *end-to-end*). Podejścia dwuetapowe realizują zadanie GTT w dwóch oddzielnych krokach: najpierw dokonuje się ogólnej transkrypcji MPE, a następnie w osobnym kroku (inferencji opalcowania) przypisuje się wykryte nuty do pozycji na gryfie [5]. Zaletą tego podejścia jest jego modularność, a wadą ryzyko propagacji błędów z pierwszego etapu.

Podejścia zintegrowane, opierające się w przeważającej mierze na zaawansowanych modelach DL, dążą do nauczenia się bezpośredniego mapowania z reprezentacji czasowo-częstotliwościowej na finalną reprezentację tabulaturową. Wykorzystują one złożone architektury sieci neuronowych, takie jak:

- Modele oparte na CNN, czego przykładem jest TabCNN [24]. Architektura ta typowo przetwarza wejściowy spektrogram (np. Constant-Q) i generuje na wyjściu predykcje dotyczące aktywności poszczególnych progów na każdej ze strun gitary, często w formie wielowymiarowej macierzy binarnej (tzw. „six-hot encoding”). Praca Zang i współpracowników [27] również wykorzystuje architekturę zbliżoną do TabCNN jako jeden z modeli bazowych w swoich badaniach nad wykorzystaniem danych syntetycznych.
- Modele oparte na architekturze Transformer, które dzięki zastosowaniu mechanizmów uwagi (ang. *attention mechanisms*) są zdolne do efektywnego modelowania długoterminowych zależności w danych sekwencyjnych. Znalazły one zastosowanie w GTT, szczególnie w połączeniu z dużymi zbiorami danych, w tym syntetycznymi, takimi jak SynthTab [27].

- Inne architektury, w tym RNN (np. LSTM czy GRU), często stosowane w połączeniu z CNN (tworząc architektury CRNN), aby wykorzystać zdolności CNN do ekstrakcji lokalnych cech ze spektrogramów oraz zdolności RNN do modelowania kontekstu czasowego [5]. Przykładowo, praca Burlet i Hindle [5] badała zastosowanie głębokich sieci przekonań (ang. *Deep Belief Networks*) dla transkrypcji izolowanych dźwięków gitarowych, co stanowiło wczesny przykład wykorzystania metod DL w tym obszarze.

Zaletą podejść zintegrowanych jest ich potencjalna zdolność do uczenia się bardzo złożonych i subtelnych mapowań bezpośrednio z danych, co może prowadzić do lepszych wyników końcowych niż w podejściach dwuetapowych. Wymagają one jednak zazwyczaj znacznie większych i bardziej szczegółowych zbiorów danych treningowych. Niezależnie od podejścia, kluczową rolę w rozwoju systemów GTT odgrywają zbiory danych, które zostaną szerzej omówione w kolejnych rozdziałach.

2.6 Podsumowanie i otwarte problemy badawcze

Automatyczna transkrypcja muzyczna, a w jej ramach transkrypcja muzyki gitarowej na zapis tabulaturowy, pozostaje aktywnym i wymagającym obszarem badań naukowych. Znaczenie praktyczne skutecznych systemów GTT jest nie do przecenienia, obejmując wsparcie dla muzyków, edukację, archiwizację oraz przemysł muzyczny [3]. Analiza przeprowadzona w niniejszym rozdziale wykazała, że główne wyzwania koncentrują się wokół przetwarzania złożonych sygnałów polifonicznych, radzenia sobie z dużą zmiennością barwy i artykulacji charakterystyczną dla gitary, a w przypadku GTT – dodatkowo wokół problemu niejednoznaczności opalcowania oraz detekcji i notacji specyficznych technik wykonawczych [24].

Przegląd stosowanych metod ukazuje wyraźną ewolucję od klasycznych technik opartych na przetwarzaniu sygnałów do zaawansowanych modeli uczenia maszynowego, które obecnie definiują stan wiedzy w tej dziedzinie [15, 14]. Rozwiązania takie jak „Onsets and Frames” [9] czy „Basic Pitch” [4] dla ogólnych zadań ATM, oraz systemy dedykowane GTT, jak TabCNN [24] i nowsze podejścia wykorzystujące duże zbiory danych, w tym syntetyczne, jak w przypadku badań nad SynthTab [27], demonstrują znaczący postęp. Mimo to, wciąż istnieją liczne obszary wymagające dalszych, intensywnych badań. Do kluczowych otwartych problemów w dziedzinie GTT, które wyznaczają kierunki przyszłych prac, należą przede wszystkim:

1. Dalsza poprawa dokładności i odporności transkrypcji w kontekście gęstych faktur polifonicznych, szybkich pasaży muzycznych oraz sygnałów o niskiej jakości lub z silnymi zniekształceniami.
2. Rozwój bardziej zaawansowanych i kontekstowych metod inferencji opalcowania

na gryfie gitary, które lepiej odzwierciedlałyby rzeczywiste praktyki wykonawcze i zapewniały grywalność generowanych tabulatur.

3. Zwiększenie zdolności systemów do rozpoznawania i poprawnej notacji szerokiego spektrum technik gitarowych, które mają kluczowe znaczenie dla ekspresji muzycznej.
4. Poprawa generalizacji modeli GTT na różne, nie widziane wcześniej w procesie treningu, brzmienia gitar (akustycznych, elektrycznych, z różnymi efektami), style muzyczne i warunki nagraniowe.
5. Opracowanie bardziej kompleksowych i percepcyjnie adekwatnych metryk oceny jakości transkrypcji tabulaturowej, które wykraczałyby poza proste porównanie poprawności nut i uwzględniałyby aspekty takie jak grywalność, czytelność i wierność stylistyczną. Kwestia ta nawiązuje do obserwacji, że wyniki ilościowe nie zawsze w pełni odzwierciedlają praktyczną użyteczność systemu dla końcowego użytkownika [11].
6. Kontynuacja prac nad tworzeniem i udostępnianiem większych, bardziej zróżnicowanych i precyzyjnie adnotowanych zbiorów danych dla GTT, w tym eksploracja metod efektywnego wykorzystania danych syntetycznych i technik transferu wiedzy.

Niniejsza praca magisterska stanowi próbę odpowiedzi na niektóre z wymienionych wyzwań. W kolejnych rozdziałach przedstawiony zostanie projekt i implementacja systemu, który w szczególności skupia się na problemach wyszczególnionych w punktach (1) i (2), czyli na poprawie ogólnej dokładności transkrypcji oraz rozwoju metod inferencji opalcowania.

Rozdział 3

Projekt i implementacja systemu transkrypcji gitarowej

Przyjęta w ramach tej pracy strategia, polegająca na bezpośredniej predykcji progów gitarowych, jest wynikiem analizy i badań eksploracyjnych nad alternatywnymi podejściami. Wstępna faza projektu obejmowała próby adaptacji istniejących, zaawansowanych modeli transkrypcji polifonicznej, w szczególności modelu Basic Pitch (w literaturze określanego jako NMP – Notes and Multipitch) [4] oraz koncepcji „Onsets and Frames” [9]. Celem tych eksperymentów było zbadanie, czy modele zoptymalizowane do ogólnej transkrypcji (predykcji nut i onsetów) można z powodzeniem wyspecjalizować do zadania generowania tabulatur (GTT) wyłącznie na zbiorze danych GuitarSet.

Doświadczenia te, choć nie przyniosły zadowalających rezultatów w postaci gotowego rozwiązania, dostarczyły kluczowych wniosków. Skuteczność referencyjnych architektur okazała się silnie uzależniona od treningu na bardzo dużych i zróżnicowanych zbiorach danych (takich jak MAESTRO czy Slakh), a ich ograniczenie do specyfiki GuitarSet było niewystarczające. Co więcej, modele te są zoptymalizowane do generowania ogólnego zapisu nutowego (np. w formacie MIDI), a nie tabulatury. Ich ocena przy użyciu metryk dedykowanych dla GTT, które wymagają precyzyjnej informacji o strunie i progu, była zatem niemożliwa bez implementacji dodatkowego, złożonego modułu do inferencji opalcowania. Taki dwuetapowy proces wprowadziłby własne źródła błędów, uniemożliwiając rzetelną ocenę samego modelu transkrypcyjnego. Z tego względu, przedstawianie wyników ilościowych na tym etapie uznano za bezcelowe. Analiza jakościowa jednoznacznie wykazała niedopasowanie tych architektur do specyfiki zadania GTT, co wskazało na konieczność opracowania dedykowanego modelu, uczącego się bezpośredniej predykcji tabulatury.

3.1 Architektura ogólna i potok przetwarzania

Zaprojektowany system GTT opiera się na modułowej architekturze potokowej (ang. *pipeline*), co zapewnia elastyczność i ułatwia systematyczne prowadzenie eksperymentów. Całość rozwiązania została podzielona na cztery główne, niezależne od siebie moduły, których pracą orkiestruje centralny skrypt sterujący.

- **Moduł Konfiguracji i Sterowania:** Sercem systemu jest centralny mechanizm konfiguracyjny, agregujący wszystkie globalne stałe i hiperparametry – od ścieżek dostępu do danych, przez parametry przetwarzania sygnału, aż po architekturę sieci i ustawienia treningu. Procesem badawczym zarządza interaktywny notatnik, który pełni rolę wysokopoziomowego kontrolera, wywołując funkcje z pozostałych modułów. Taka separacja logiki zapewnia wysoką kontrolę nad przebiegiem badań i ich pełną powtarzalność.
- **Moduł Przetwarzania Danych:** Odpowiada za cały proces przygotowania danych wejściowych. Jego zadania obejmują wczytywanie plików audio i adnotacji, podział na zbiory, ekstrakcję cech czasowo-częstotliwościowych (CQT, Mel), zaawansowaną augmentację danych oraz tworzenie gotowych do treningu wsadów (ang. *batches*) z odpowiednimi etykietami.
- **Moduł Modelu i Treningu:** Zawiera implementację architektury sieci neuronowej CRNN oraz całą logikę związaną z jej treningiem. Obejmuje definicję modelu, implementację wielozadaniowej funkcji straty, pętlę treningową z optymalizatorem, a także mechanizmy takie jak wczesne zatrzymywanie i zapisywanie najlepszych wag modelu.
- **Moduł Ewaluacji i Analizy:** Służy do oceny jakości wytrenowanego modelu. Po załadowaniu najlepszych wag, moduł ten przeprowadza predykcję na zbiorze testowym, konwertuje wyjścia sieci na format nutowy, oblicza zdefiniowane metryki (np. TDR F1-Score), a także generuje wyniki w czytelnej formie, takiej jak wizualizacje czy pliki tabulatur tekstowych.

3.2 Przygotowanie danych i sygnału wejściowego

Staranne przygotowanie danych jest fundamentalnym etapem w procesie uczenia maszynowego. W ramach systemu obejmuje ono wybór i podział zbioru danych, ekstrakcję cech akustycznych z plików audio oraz innowacyjną strategię augmentacji.

3.2.1 Zbiór danych: GuitarSet

Prezentowane badania oparto na publicznie dostępnym zbiorze danych GuitarSet [26]. Jego wybór był podyktowany unikalnymi cechami technicznymi, które czynią go kluczowym i wszechstronnym zasobem w badaniach nad automatyczną transkrypcją gitarową (GTT), a w szczególności nad problemem niejednoznaczności opalcowania. Od momentu publikacji, GuitarSet stał się de facto standardem i podstawowym zbiorem benchmarkowym, służącym do ewaluacji i porównywania nowych modeli w dziedzinie analizy muzyki gitarowej.

GuitarSet składa się z 360 trzydziestosekundowych fragmentów audio, nagranych przez sześciu różnych gitarzystów na gitarze akustyczno-elektrycznej. Zbiór charakteryzuje się starannie zaplanowaną strukturą, zapewniającą dużą różnorodność muzyczną. Każdy muzyk nagrał ten sam zestaw 30 partii, obejmujących dwa style wykonania (akompaniament oraz solo), pięć gatunków muzycznych (rock, jazz, funk, bossa nova, styl piosenki autorskiej) oraz trzy progresje akordów (dwunastotaktowy blues, „Autumn Leaves” i Kanon Pachelbela), wykonane w dwóch różnych tempach. Taka konstrukcja zapewnia szerokie spektrum kontekstów muzycznych i technik gry.

Kluczowym elementem, który wyróżnia GuitarSet, jest metoda rejestracji sygnału. Każda z sześciu strun gitary została wyposażona w osobny przetwornik heksafoniczny, co pozwoliło na nagranie sygnału z każdej struny niezależnie. Równocześnie z nagraniem heksafonicznym, dźwięk rejestrowano za pomocą wysokiej jakości mikrofonu pojemnościowego. W rezultacie zbiór udostępnia dane audio w czterech wariantach:

- `audio_hex-pickup_original`: surowe, 6-kanałowe nagrania z przetwornika heksafonicznego, zawierające naturalne przesłuchy międzykanałowe.
- `audio_hex-pickup_debleeded`: wersja powyższych nagrań poddana cyfrowej obróbce w celu usunięcia przesłuchów, co skutkuje niemal idealną separacją sygnału dla każdej struny.
- `audio_mono-pickup_mix`: monofoniczny miks sygnałów z przetwornika heksafonicznego, symulujący standardowe wyjście liniowe gitary.
- `audio_mono-mic`: monofoniczne nagranie z mikrofonu, reprezentujące najbardziej realistyczny, a zarazem najtrudniejszy scenariusz dla algorytmów GTT.

Wykorzystanie nagrań heksafonicznych drastycznie uprościło proces adnotacji, który w dużej mierze mógł zostać zautomatyzowany, a następnie poddany jedynie ręcznej weryfikacji i korekcie. Pozwoliło to na osiągnięcie niespotykanej dotąd precyzji na dużą skalę. Adnotacje, dostępne w formacie JAMS (JSON Annotated Music Specification), są wyjątkowo bogate. Dla każdej nuty zawierają one nie tylko jej wysokość, czas rozpoczęcia i czas trwania, ale również – co jest unikalne na tle innych zbiorów – dokładną informację o strunie i progu, na których została zagrana [24, 26]. Ponadto zbiór zawiera kontury

wysokości dźwięku dla każdej struny, pozycje uderzeń rytmicznych (beat) oraz dwa rodzaje adnotacji harmoniczných: akordy, które muzyk miał zagrać (z nut), oraz te, które faktycznie zagrał (wynioskowane na podstawie analizy wykonania).

Ta szczegółowa struktura danych jest niezbędna do trenowania i wiarygodnej ewaluacji modeli GTT, które mają za zadanie nauczyć się nie tylko „co” zostało zagrane, ale również „jak” i „gdzie” na gryfie gitary. Wszechstronność zbioru sprawia, że jest on wykorzystywany również w innych zadaniach badawczych, takich jak analiza stylu gry, rozpoznawanie zaawansowanych technik artykulacyjnych czy klasyfikacja gatunków muzycznych. Mimo relatywnie niewielkiego rozmiaru w porównaniu do zbiorów danych dla innych instrumentów (np. MAESTRO dla fortepianu), GuitarSet pozostaje fundamentalnym zasobem w swojej dziedzinie. Należy jednak zaznaczyć, że w ramach przygotowania danych do treningu, zgodnie z doniesieniami społeczności, ze zbioru wyłączono dwa pliki: `04_BN3-154-E_comp` oraz `04_Jazz1-200-B_comp`, ze względu na minimalne błędy w synchronizacji czasowej adnotacji [22].

Po wykluczeniu wspomnianych plików, pozostałe 358 nagrań podzielono na zbiory: treningowy, walidacyjny i testowy. Zastosowano standardowy podział w proporcjach 80:10:10, co w wartościach bezwzględnych odpowiada: 286 plikom w zbiorze treningowym, 36 plikom w zbiorze walidacyjnym oraz 36 plikom w zbiorze testowym. Użycie stałego zarodka losowości na tym etapie gwarantuje pełną powtarzalność i porównywalność wyników wszystkich przeprowadzonych eksperymentów.

3.2.2 Reprezentacja czasowo-częstotliwościowa sygnału

Jako podstawową reprezentację sygnału wejściowego dla sieci neuronowej wybrano transformatę Constant-Q (CQT). Jej logarytmiczna skala częstotliwości bezpośrednio odpowiada ludzkiej percepcji wysokości dźwięku i strukturze skal muzycznych, co może ułatwiać modelom CNN naukę cech niezmienniczych względem transpozycji [24, 15, 3]. W ramach badań porównawczych testowano również standardowe mel-spektrogramy.

Przed ekstrakcją cech, sygnał audio z każdego utworu jest próbkowany do częstotliwości 22050 Hz, a następnie normalizowany amplitudowo. Parametry CQT zostały dobrane tak, aby stworzyć reprezentację bogatą w informacje muzyczne:

- **Liczba prążków na oktawę:** Ustalono na 24. W kontekście CQT, prążek to wąskie pasmo częstotliwości. Wybór 24 prążków na oktawę oznacza, że każdy półton w dwunastotonowej skali temperowanej jest reprezentowany przez dwa oddzielne pasma. Daje to modelowi bardzo wysoką rozdzielczość, pozwalającą odróżnić precyzyjnie zagrany dźwięk od nieznacznie podciągniętego (technika *bend*) lub rozstrojonego.
- **Zakres i liczba pasm:** Analiza obejmuje zakres 7 oktaw, co przy 24 prążkach na oktawę daje łącznie 168 pasm częstotliwości. Minimalna częstotliwość ($F_{\min}$) została

dobrana tak, aby pokryć najniższy dźwięk gitary w stroju standardowym (E2, ok. 82.4 Hz). Tak szeroki zakres gwarantuje, że wszystkie podstawowe częstotliwości i kluczowe harmoniczne zostaną uchwycone.

- **Rozdzielczość czasowa:** Krok analizy (ang. *hop size*) ustalono na 512 próbek, co przy częstotliwości próbkowania 22050 Hz daje rozdzielczość czasową około 43 ramek na sekundę, wystarczającą do analizy szybkich pasażów muzycznych.

3.2.3 Augmentacja danych: strategia zwiększania odporności modelu

Analiza jakościowa, polegająca na odsłuchu i wizualnej inspekcji transkrypcji wygenerowanych przez model we wczesnej fazie projektu, wykazała jego niską zdolność do generalizacji. Model, wytrenowany wyłącznie na czystych, studyjnych nagraniach z GuitarSet, nie radził sobie z sygnałami audio zawierającymi typowe niedoskonałości nagrań amatorskich. W odpowiedzi na to kluczowe spostrzeżenie, przyjęto data-centriczną strategię, której celem jest poprawa odporności modelu poprzez uczenie go na danych symulujących realistyczne, niedoskonałe warunki. W tym celu zaimplementowano rozbudowany potok augmentacji, wprowadzający do danych treningowych kontrolowane zakłócenia.

Kluczową decyzją projektową jest rozróżnienie sposobu przygotowania danych. Dla zbiorów walidacyjnego i testowego cechy są obliczane jednorazowo, co zapewnia spójność oceny. Natomiast dla zbioru treningowego spektrogramy CQT są generowane „w locie” w każdej epoce. Umożliwia to stosowanie dynamicznej augmentacji na poziomie sygnału audio, znacząco zwiększając różnorodność danych treningowych. Zastosowane techniki obejmują:

- **Augmentacje audio** (stosowane do surowego sygnału przed obliczeniem CQT) [15, 3]:
 - Rozciąganie w czasie (ang. *time stretching*): modyfikuje tempo nagrania w zdefiniowanym zakresie, z odpowiednią korektą czasów w etykietach.
 - Dodawanie szumu (ang. *noise addition*): do sygnału dodawany jest szum o losowo wybranej amplitudzie.
 - Losowe wzmocnienie (ang. *random gain*): amplituda sygnału jest mnożona przez losowy współczynnik, symulując zmiany dynamiki.
 - Symulacja pogłosu pomieszczenia (ang. *reverb*): W celu nauczania modelu ignorowania akustyki pomieszczenia, do sygnału dodawany jest sztuczny pogłos. Jest on generowany poprzez operację splotu matematycznego z syntetyczną odpowiedzią impulsową. Kluczowe parametry tego efektu, takie jak czas zanikania oraz natężenie, są losowane w każdym kroku, co symuluje nagrania w setkach

różnych środowisk akustycznych – od małych, wytlumionych pokoi po większe przestrzenie z wyraźnym echem.

- Symulacja charakterystyki mikrofonu (ang. *EQ*): Aby naśladować działanie mikrofonów niższej jakości (np. w laptopach), które słabo zbierają skrajne pasma częstotliwości, stosowany jest cyfrowy filtr pasmowo-przepustowy. Filtr ten „obcina” najniższe (bas) i najwyższe (sopran) częstotliwości, tworząc bardziej „pudełkowy”, skupiony w środku dźwięk. Model uczy się w ten sposób, że brak pełni brzmienia nie musi oznaczać braku nuty. Częstotliwości odcięcia filtru są losowane z szerokiego zakresu, co symuluje całą gamę niedoskonałych urządzeń nagrywających.
- Symulacja przesterowania (ang. *clipping*): W warunkach domowych łatwo jest ustawić zbyt wysoki poziom głośności nagrywania, co prowadzi do cyfrowego obcinania wierzchołków fali dźwiękowej. Aby przygotować model na takie sytuacje, wprowadzono augmentację, która celowo obcina amplitudę sygnału po przekroczeniu pewnego progu. Uczy to model rozpoznawania nut nawet wtedy, gdy ich sygnał jest zniekształcony w ten sposób. Próg, przy którym następuje obcięcie, jest losowany, co naśladuje różne stopnie przesterowania sygnału.
- **Augmentacja spektrogramu** (SpecAugment) [18]: stosowana do wygenerowanych spektrogramów (Mel lub CQT). Polega na losowym maskowaniu pewnych fragmentów spektrogramu:
 - Maskowanie w dziedzinie czasu (ang. *Time Masking*): Losowe zakrywanie pewnej liczby kolejnych ramek czasowych.
 - Maskowanie w dziedzinie częstotliwości (ang. *Frequency Masking*): Losowe zakrywanie pewnego zakresu pasm częstotliwości.


Podczas każdej epoki treningu model otrzymuje próbki poddane unikalnej, losowej kombinacji powyższych transformacji. Takie podejście zmusza model do nauki bardziej niezmiennych cech sygnału, co przekłada się na lepszą generalizację.

3.2.4 Przetwarzanie etykiet i tworzenie wsadów

Równolegle do ekstrakcji cech, adnotacje ze zbioru GuitarSet są przekształcane na format ramkowy, zgodny z wyjściem modelu [9]. Dla każdej ramki czasowej i każdej z sześciu strun gitary generowane są dwa typy etykiet, co ilustruje rysunek 3.1:

1. **Etykieta onetu:** Wartość binarna (1 lub 0) wskazująca, czy w danej ramce rozpoczyna się nowa nuta na danej strunie.

2. **Etykieta progów:** Wartość kategorialna (od 0 dla struny pustej do 20) wskazująca numer aktywnego progu na danej strunie. Dodatkowa, 22. klasa jest używana do reprezentowania ciszy. Dla każdej ramki od początku do końca trwania nuty przypisywany jest odpowiedni numer progu, ucząc model nie tylko detekcji, ale również śledzenia aktywności dźwięku.



Rysunek 3.1: Wizualizacja etykiet ramkowych dla fragmentu utworu. Górny panel przedstawia macierz onsetów, gdzie pionowe linie oznaczają moment rozpoczęcia nuty na danej strunie. Dolny panel pokazuje macierz aktywności progów, gdzie czarne obszary reprezentują czas trwania dźwięku na danej strunie.

W celu efektywnego treningu modelu, próbki danych są grupowane we wsady (ang. *batches*). Ponieważ poszczególne nagrania w zbiorze danych mają różną długość, zaimplementowano mechanizm dopełniania (ang. *padding*). Dedykowana funkcja agregująca, używana przez mechanizm ładowania danych, uzupełnia tensory cech i etykiet w ramach danego wsadu do długości najdłuższej sekwencji w tym wsadzie. Proces ten wykorzystuje standardowe narzędzia frameworka PyTorch. System wyposażono również w zestaw narzędzi diagnostycznych, służących do weryfikacji poprawności i spójności przetworzonych danych.

3.3 Architektura i implementacja modelu transkrypcji

Sercem zaimplementowanego systemu transkrypcji jest sieć neuronowa o architekturze konwolucyjno-rekurencyjnej, zrealizowana w środowisku PyTorch. Wybór tej architektury jest ugruntowany w literaturze naukowej i wynika z jej udokumentowanej skuteczności w złożonych zadaniach transkrypcji muzycznej [9]. Architektura ta w sposób synergiczny łączy zdolności sieci konwolucyjnych (CNN) do ekstrakcji hierarchicznych cech z dwuwymiarowych reprezentacji czasowo-częstotliwościowych z możliwościami sieci rekurencyjnych (RNN) do modelowania zależności czasowych w sekwencjach muzycznych [24].


Model został zaprojektowany w sposób modułowy i składa się z trzech głównych, logicznych bloków: frontendu konwolucyjnego, backendu rekurencyjnego oraz dwóch głowic

wyjściowych realizujących podejście wielozadaniowe. Schemat tej architektury przedstawia rysunek 3.2.

- **Frontend konwolucyjny (CNN):** Ta część modelu jest odpowiedzialna za ekstrakcję lokalnych, hierarchicznych cech z wejściowego spektrogramu CQT. Jej architektura jest inspirowana rozwiązaniem znanym jako TabCNN, czyli siecią konwolucyjną dedykowaną do estymacji tabulatur [24, 5]. Frontend składa się z sekwencji bloków, z których każdy zawiera operację splotu 2D (zaimplementowaną przy użyciu klasy `Conv2d` z biblioteki PyTorch), normalizację wsadową (ang. *batch normalization*, klasa `BatchNorm2d`), funkcję aktywacji ReLU (ang. *Rectified Linear Unit*) oraz operację próbkowania w dół (ang. *max pooling*, klasa `MaxPool2d`). Funkcja aktywacji ReLU wprowadza do modelu nieliniowość, pozwalając na uczenie się bardziej złożonych zależności w danych, podczas gdy pozostałe operacje służą do ekstrakcji cech i redukcji wymiarowości. Kluczowym aspektem implementacji jest jej elastyczność: liczba bloków konwolucyjnych, a także liczba filtrów, rozmiar jądra, krok (ang. *stride*) oraz parametry warstwy *pooling* dla każdego z nich są w pełni parametryzowane. Umożliwiło to eksperymentowanie z różnymi wariantami głębokości i szerokości tej części sieci.
- **Backend rekurencyjny (RNN):** Cechy wyekstrahowane przez frontend konwolucyjny są przekształcane do formatu sekwencyjnego i przekazywane do backendu rekurencyjnego. Jego zadaniem jest modelowanie zależności czasowych w muzyce, co jest kluczowe dla poprawnej transkrypcji. W ramach badań testowano dwa typy komórek rekurencyjnych: LSTM oraz GRU, przy czym te drugie, ze względu na prostszą budowę i porównywalną skuteczność, były często preferowane w finalnych eksperymentach [7]. Architektura tego bloku jest wysoce konfigurowalna i stanowiła główny przedmiot przeszukiwania hiperparametrów. Zmiennymi parametrami były: typ komórki, liczba warstw rekurencyjnych, rozmiar stanu ukrytego, współczynnik *dropout* dla regularyzacji oraz zastosowanie mechanizmu dwukierunkowości. Użycie dwukierunkowego RNN pozwala modelowi na analizę każdej ramki czasowej w kontekście zarówno przeszłych, jak i przyszłych zdarzeń, co znacząco poprawia precyzję transkrypcji [9, 15].
- **Główce wyjściowe (podejście wielozadaniowe):** Przetworzona przez RNN sekwencja cech jest kierowana do dwóch oddzielnych, w pełni połączonych warstw liniowych, które pełnią rolę głowic predykcyjnych. Taka struktura realizuje podejście uczenia wielozadaniowego, inspirowane pracą „Onsets and Frames” [9]. Każda głowica jest odpowiedzialna za predykcję innego typu etykiety, zdefiniowanej w sekcji 3.2.4:
 - Pierwsza głowica generuje logity dla etykiet onsetów, określając prawdopodobieństwo rozpoczęcia się nowej nuty dla każdej ze strun.

- Druga głowica generuje logity dla etykiet progów, przewidując dla każdej struny, który próg jest aktualnie aktywny lub czy panuje cisza.

System zawiera również funkcję pomocniczą do wczytywania zapisanego stanu modelu z pliku, która automatycznie odtwarza instancję modelu z parametrami zapisanymi podczas danego przebiegu eksperymentalnego i ładuje do niej nauczone wagi.



Rysunek 3.2: Schemat architektury zaimplementowanego modelu. Przedstawia przepływ danych od wejściowego tensora spektrogramu, przez frontend konwolucyjny, backend rekurencyjny, aż po rozdzielenie na dwie głowice wyjściowe dla predykcji onsetów i progów.

3.4 Proces treningu i optymalizacji modelu

Proces treningu modelu jest zarządzany przez dedykowany moduł, który orkiestruje cały cykl dla pojedynczego zestawu hiperparametrów. Poniższe podrozdziały szczegółowo opisują kluczowe komponenty tego procesu: wielozadaniową funkcję straty, która kieruje nauką modelu, oraz pętlę treningową wraz z zastosowanymi technikami optymalizacyjnymi.

3.4.1 Wielozadaniowa funkcja straty

Zastosowanie złożonej funkcji straty, będącej ważoną sumą strat dla predykcji onsetów i progów, jest przykładem uczenia wielozadaniowego (ang. *multi-task learning*). Takie podejście, w którym model jest zmuszony do jednoczesnego rozwiązywania dwóch powiązanych ze sobą zadań, często prowadzi do poprawy jakości predykcji. Dzieje się tak, ponieważ model uczy się bardziej kompletnych, współdzielonych reprezentacji, które są korzystne dla obu zadań składowych [9]. Całkowita funkcja straty ($\mathcal{L}_{\text{total}}$) jest zdefiniowana jako:

$$\mathcal{L}_{\text{total}} = w_{\text{onset}} \cdot \mathcal{L}_{\text{onset}} + w_{\text{fret}} \cdot \mathcal{L}_{\text{fret}} \quad (3.1)$$

gdzie w_{onset} i w_{fret} to wagi poszczególnych komponentów straty. Wartość w_{onset} jest konfigurowalnym hiperparametrem, natomiast w_{fret} przyjęto jako 1.0.

Stratę dla predykcji onsetów ($\mathcal{L}_{\text{onset}}$) oblicza się przy użyciu ważonej binarnej entropii krzyżowej, aby przeciwdziałać problemowi niebalansowanych klas (onety są zdarzeniami rzadkimi w porównaniu do braku onetu). Dla pojedynczej struny s i ramki t , strata ta jest dana rozwiniętym wzorem:

$$\mathcal{L}_{\text{onset},s,t} = -[w_{\text{pos}} \cdot y_{s,t}^{\text{onset}} \lg(\sigma(\hat{z}_{s,t}^{\text{onset}})) + (1 - y_{s,t}^{\text{onset}}) \lg(1 - \sigma(\hat{z}_{s,t}^{\text{onset}}))] \quad (3.2)$$

gdzie $y_{s,t}^{\text{onset}} \in \{0, 1\}$ to etykieta referencyjna, $\hat{z}_{s,t}^{\text{onset}}$ to logit wyjściowy modelu dla onetu, $\sigma(\cdot)$ to funkcja sigmoidalna, a w_{pos} to waga dla przykładów pozytywnych (klasy 1), będąca konfigurowalnym hiperparametrem. Całkowita strata $\mathcal{L}_{\text{onset}}$ jest średnią z wartości $\mathcal{L}_{\text{onset},s,t}$ po wszystkich strunach i ramkach wsadu, z pominięciem ramek dopełniających.

Stratę dla predykcji progów ($\mathcal{L}_{\text{fret}}$) oblicza się przy użyciu standardowej entropii krzyżowej dla klasyfikacji wieloklasowej. Dla pojedynczej struny s i ramki t jest ona zdefiniowana jako:

$$\mathcal{L}_{\text{fret},s,t} = - \sum_{c=0}^{N_{\text{klas}} \text{ prog} - 1} y_{s,t,c}^{\text{fret}} \lg(p_{s,t,c}^{\text{fret}}) \quad (3.3)$$

gdzie $y_{s,t,c}^{\text{fret}}$ jest binarnym wskaźnikiem (0 lub 1) informującym, czy klasa progów c jest poprawna dla danej ramki, a $p_{s,t,c}^{\text{fret}}$ jest prawdopodobieństwem predykcji tej klasy (wyjście funkcji softmax). Całkowita strata $\mathcal{L}_{\text{fret}}$ jest średnią z wartości $\mathcal{L}_{\text{fret},s,t}$ po wszystkich strunach i ramkach.

3.4.2 Pętla treningowa i optymalizator

Proces treningu modelu został zautomatyzowany w ramach dedykowanego modułu. Wybór optymalizatora oraz strategii dostosowywania współczynnika uczenia został podyktowany wynikami wstępnych eksperymentów. Zdecydowano się na użycie optymalizatora AdamW [16], który w porównaniu do standardowego optymalizatora Adam oferował stabilniejszy przebieg treningu i lepszą generalizację modelu dzięki odsprężeniu mechanizmu regularyzacji (zaniku wag, ang. *weight decay*) od kroku aktualizacji gradientu. Współczynnik uczenia był dynamicznie dostosowywany przy użyciu harmonogramu *ReduceLROnPlateau*, który empirycznie okazał się skuteczniejszy niż stała wartość, redukując współczynnik uczenia, gdy metryka walidacyjna przestawała się poprawiać.

Główna pętla treningowa iteruje przez zdefiniowaną liczbę epok. W każdej epoce wykonywane są dwie fazy: treningowa i walidacyjna, co w sposób sformalizowany przedstawia Algorytm 1. W celu zapobiegania przeuczeniu, zastosowano techniki regularyzacji: *dropout* w warstwach rekurencyjnych [7, 15] oraz wspomniany zanik wag (L2) [16, 15]. Ponadto, stosowany jest mechanizm wczesnego zatrzymywania (ang. *early stopping*), który przerywa trening, jeśli metryka F1-Score na zbiorze walidacyjnym nie poprawia się przez zadaną liczbę epok [3]. Najlepszy model (na podstawie tej metryki) jest zapisywany na dysku.

Algorithm 1 Pseudokod pętli treningowej i walidacyjnej

```

1: Inicjalizuj model  $M$ , optymalizator  $O$ , harmonogram  $S$ 
2: for każda epoka  $e$  od 1 do  $N_{epok}$  do
3:    $M.train()$  ▷ Ustaw model w tryb treningowy
4:   for każdy wsad  $B$  ze zbioru treningowego  $D_{train}$  do
5:      $O.zero\_grad()$  ▷ Wyzeruj gradienty
6:      $Predykcje_{onset}, Predykcje_{fret} \leftarrow M(B_{dane})$ 
7:      $Strata \leftarrow ObliczFunkcjeStraty(Predykcje_{onset}, Predykcje_{fret}, B_{etykiety})$ 
8:      $Strata.backward()$  ▷ Propagacja wsteczna
9:      $O.step()$  ▷ Aktualizacja wag
10:  end for
11:   $M.eval()$  ▷ Ustaw model w tryb ewaluacyjny
12:   $Wyniki_{walidacja} \leftarrow []$ 
13:  with torch.no_grad(): ▷ Wyłącz obliczanie gradientów
14:    for każdy wsad  $B$  ze zbioru walidacyjnego  $D_{val}$  do
15:       $Predykcje_{onset}, Predykcje_{fret} \leftarrow M(B_{dane})$ 
16:       $Strata_{val} \leftarrow ObliczFunkcjeStraty(Predykcje_{onset}, Predykcje_{fret}, B_{etykiety})$ 
17:       $Metryki_{val} \leftarrow ObliczMetryki(Predykcje_{onset}, Predykcje_{fret}, B_{etykiety})$ 
18:      Dodaj  $Metryki_{val}$  do  $Wyniki_{walidacja}$ 
19:    end for
20:     $SrednieMetryki \leftarrow Uśrednij(Wyniki_{walidacja})$ 
21:    Zaktualizuj harmonogram  $S$  na podstawie  $SrednieMetryki$ 
22:    Zapisz  $M$  jeśli  $SrednieMetryki$  są najlepsze do tej pory
23:    Zastosuj wczesne zatrzymywanie, jeśli brak poprawy
24: end for

```

W celu zapewnienia szybkości i spójności procesu treningu, podczas fazy walidacyjnej w każdej epoce stosowany jest stały próg decyzyjny (0.5) dla predykcji onsetów. Bardziej zaawansowany proces wyszukiwania progu, który maksymalizuje docelową metrykę F1-Score, jest celowo odroczony i wykonywany jednokrotnie, w ramach finalnej analizy na zbiorze testowym.

3.5 Metodyka ewaluacji i generowanie wyników

Po zakończeniu treningu, najlepszy model jest poddawany finalnej, rygorystycznej ewaluacji na zbiorze testowym, który nie brał udziału w procesie uczenia. System umożliwia przeprowadzenie kompleksowej oceny ilościowej oraz generowanie wyników w formatach ułatwiających szczegółową analizę jakościową.

3.5.1 Konwersja predykcji na postać symboliczną i metryki ewaluacyjne

Ramkowe predykcje modelu, składające się z prawdopodobieństw onsetów i rozkładów prawdopodobieństwa dla klas progów, są w pierwszym kroku przekształcane w listę dyskretnych zdarzeń nutowych. Proces ten, zrealizowany w dedykowanym module, iteruje po każdej z sześciu strun, wykorzystując logikę maszyny stanów do identyfikacji początków i końców nut. Wykrycie onsetu (prawdopodobieństwo powyżej progu) dla aktywnego progu inicjuje nową nutę, która jest kontynuowana do momentu spełnienia warunku terminacji (np. kolejny onset na tej samej strunie). Wynikiem jest symboliczna reprezentacja transkrypcji, gotowa do oceny ilościowej.

Podejście do ewaluacji opiera się na zestawie trzech komplementarnych metryk. Wszystkie bazują na fundamentalnych pojęciach statystycznych, takich jak wyniki prawdziwie pozytywne (ang. *True Positives*, TP), fałszywie pozytywne (ang. *False Positives*, FP) oraz fałszywie negatywne (ang. *False Negatives*, FN). Na ich podstawie obliczane są standardowe wskaźniki:

$$\text{Precyzja} = \frac{TP}{TP + FP} \quad (3.4)$$

$$\text{Czułość (ang. Recall)} = \frac{TP}{TP + FN} \quad (3.5)$$

$$\text{F1-Score} = 2 \cdot \frac{\text{Precyzja} \cdot \text{Czułość}}{\text{Precyzja} + \text{Czułość}} \quad (3.6)$$

Miara F1-Score jest średnią harmoniczną precyzji i czułości, stanowiąc zbalansowaną ocenę wydajności modelu, szczególnie użyteczną w przypadku nie zrównoważonych zbiorów danych. Kluczowe jest jednak to, jak wartości TP, FP i FN są definiowane dla każdej z poszczególnych metryk.

Metryka główna: Współczynnik Detekcji Tabulatury (ang. Tablature Detection Rate, TDR) TDR jest najważniejszą metryką, oceniającą finalną jakość wygenerowanej tabulatury. Nuta jest uznawana za TP tylko wtedy, gdy predykcja jest zgodna z adnotacją referencyjną we wszystkich trzech wymiarach:

- **Zgodność czasu rozpoczęcia:** Czas onsetu predykcji mieści się w oknie tolerancji ± 50 ms wokół onsetu referencyjnego.
- **Zgodność struny:** Predykcja i adnotacja wskazują na ten sam numer struny.
- **Zgodność progu:** Predykcja i adnotacja wskazują na ten sam numer progu.

Każda przewidziana nuta, która nie spełnia tych kryteriów, jest liczona jako FP, a każda nuta referencyjna, dla której nie znaleziono dopasowania, jako FN [24].

Metryka diagnostyczna timingu Miara F1-Score dla detekcji onsetów w izolacji ocenia zdolność modelu do precyzyjnego lokalizowania w czasie momentów rozpoczęcia dźwięków. Do jej obliczenia wykorzystano standardową w badaniach MIR bibliotekę `mir_eval`. Zdarzenie jest tu uznawane za TP, jeśli spełniony jest tylko jeden warunek:

- **Zgodność czasu rozpoczęcia:** Czas onsetu predykcji mieści się w oknie tolerancji ± 50 ms wokół onsetu referencyjnego.

Poprawność progu i struny jest na tym etapie ignorowana. Implementacja w `mir_eval` zapewnia poprawne, jedno-do-jednego dopasowanie zdarzeń, co jest kluczowe dla wiarygodności tej metryki [3].

Metryka diagnostyczna wysokości dźwięku Miara F1-Score dla MPE na poziomie ramek ocenia, czy model poprawnie rozpoznaje, jaki dźwięk (próg) jest aktywny w danym, krótkim momencie. W przeciwieństwie do TDR, nie analizuje ona nut jako zdarzeń, lecz ciągłą aktywność dźwięków. Dla każdej ramki czasowej i każdej struny:

- **TP:** Ramka, w której zarówno etykieta referencyjna, jak i predykcja wskazują na aktywny dźwięk (nie ciszę) i jednocześnie numer progu jest w nich identyczny.
- **FP:** Ramka, w której model przewidział aktywny dźwięk, podczas gdy w etykiecie była cisza, lub model przewidział zły numer progu dla aktywnej nuty.
- **FN:** Ramka, w której etykieta wskazywała na aktywny dźwięk, podczas gdy model przewidział ciszę, lub model przewidział zły numer progu dla aktywnej nuty.

Ta metryka pozwala precyzyjnie zdiagnozować problemy z rozpoznawaniem wysokości dźwięków, niezależnie od dokładności detekcji onsetów [4].

3.5.2 Generowanie wyników i analiza końcowa

Finalny etap pracy z modelem obejmuje szczegółową analizę jego działania na niewidzianych wcześniej danych testowych oraz generowanie czytelnych dla człowieka wyników. W tym celu, po zakończeniu całego procesu przeszukiwania hiperparametrów i wyborze najlepszego modelu, uruchamiany jest dedykowany skrypt analityczny.

Proces ten przebiega w kilku krokach. Najpierw, najlepszy model jest uruchamiany na całym zbiorze testowym w celu zebrania kompletnych predykcji. Następnie, system przeprowadza procedurę optymalizacyjną, aby znaleźć odpowiedni próg decyzyjny dla onsetów, który maksymalizuje uśrednioną metrykę TDR F1-Score na zbiorze testowym.

Kluczowym elementem analizy jest ocena jakości transkrypcji dla każdego pliku z osobna. Używając znalezionej progów, system oblicza TDR F1-Score dla każdego utworu testowego, a następnie tworzy ranking plików od tych z najlepszym wynikiem do tych z najgorszym. Na podstawie tego rankingu, generowane są pliki tabulatur w formacie tekstowym dla kilku najlepszych i kilku najgorszych przypadków. Takie podejście pozwala na, jakościową analizę błędów modelu, ułatwiając zrozumienie, w jakich warunkach radzi on sobie najlepiej, a gdzie popełnia najwięcej błędów.

Dodatkowo, proces analizy wspierany jest przez zestaw narzędzi wizualizacyjnych. Umożliwiają one tworzenie różnorodnych wykresów, takich jak: spektrogramy wejściowe, grafy typu „piano roll” dla etykiet i predykcji onsetów, kolorowe mapy aktywności progów, a także zbiorcze wizualizacje dla pojedynczych próbek. Narzędzia te są wykorzystywane zarówno do weryfikacji poprawności danych, jak i do analizy wyników działania modelu.

3.6 Wykorzystane technologie i biblioteki

Dobór narzędzi programistycznych odzwierciedla aktualne standardy w badaniach z zakresu MIR i uczenia maszynowego. Korzystanie ze sprawdzonych, otwartych bibliotek pozwoliło na skupienie się na aspektach badawczych projektu, zamiast na implementacji fundamentalnych algorytmów od podstaw.

- **PyTorch** został wybrany jako główny framework do głębokiego uczenia ze względu na jego elastyczność oraz bogaty ekosystem narzędzi [19]. Kluczową zaletą, która okazała się niezwykle pomocna w trakcie badań, jest wykorzystanie dynamicznych grafów obliczeniowych. W sieciach neuronowych każda operacja matematyczna (np. mnożenie macierzy, funkcja aktywacji) może być reprezentowana jako węzeł w grafie, przez który przepływają dane (tensory). W podejściu dynamicznym, stosowanym przez PyTorch, ten graf jest tworzony „w locie”, w trakcie wykonywania kodu. Oznacza to, że struktura obliczeń może zmieniać się w każdej iteracji, co było kluczowe przy przetwarzaniu sygnałów audio o różnej długości bez konieczności ich sztucznego ujednolicania. Takie podejście znacząco uprościło również proces

debugowania, pozwalając na inspekcję wartości pośrednich w dowolnym punkcie, tak jak w standardowym kodzie Python.

- **Librosa** jest popularną i wszechstronną biblioteką do analizy sygnałów audio i muzyki w Pythonie. W ramach projektu była ona kluczowym narzędziem, dostarczającym implementacje funkcji do wczytywania plików audio, ekstrakcji cech – w tym transformaty Constant-Q – oraz podstawowych technik augmentacji [17].
- **Mirdata** to biblioteka ułatwiająca standaryzowaną pracę ze zbiorami danych z dziedziny MIR, takimi jak GuitarSet. Jej użycie zapewniło spójny i powtarzalny sposób dostępu do plików audio i adnotacji, wspierając tym samym odtwarzalność przeprowadzonych badań [4].
- **SciPy** wykorzystano do implementacji zaawansowanych augmentacji audio ze względu na jej wydajne i stabilne funkcje przetwarzania sygnałów, w tym implementacje filtrów cyfrowych oraz operacji splotu, które były niezbędne do symulacji charakterystyki mikrofonu i pogłosu.
- Inne biblioteki, takie jak **NumPy**, **Scikit-learn**, **Matplotlib**, **JAMS** i **Pretty-MIDI**, dostarczyły niezbędnych narzędzi na różnych etapach projektu, od operacji numerycznych, przez podział danych i wizualizację, po pracę z adnotacjami i generowanie plików w formacie MIDI.

3.7 Podsumowanie rozdziału

W niniejszym rozdziale przedstawiono kompleksowy proces projektowania i implementacji autorskiego systemu do automatycznej transkrypcji tabulatur gitarowych. Wybory technologiczne i metodologiczne były podyktowane zarówno aktualnym stanem wiedzy w dziedzinie, jak i wnioskami płynącymi z iteracyjnego procesu badawczego.

Decyzja o opracowaniu dedykowanego modelu opartego na architekturze CRNN, zamiast adaptacji istniejących rozwiązań, wynikała bezpośrednio z obserwacji, że ogólne modele transkrypcyjne nie radzą sobie ze specyfiką zadania GTT, w szczególności z koniecznością predykcji na poziomie strun i progów. Fundamentem systemu stało się staranne przygotowanie danych, jednak kluczowym czynnikiem decydującym o skuteczności rozwiązania okazała się data-centriczna strategia augmentacji. Jej wdrożenie było świadomą odpowiedzią na wyzwania związane z przetwarzaniem nagrań amatorskich, co stanowiło priorytet projektu.

Proces treningu został zaprojektowany z myślą o efektywności i powtarzalności, wykorzystując wielozadaniową funkcję straty do jednoczesnej optymalizacji detekcji onsetów i progów. Zwieńczeniem prac było stworzenie rygorystycznej metodyki ewaluacyjnej, opartej na zestawie komplementarnych metryk, która umożliwiła wielowymiarową ocenę jakości

transkrypcji. W rezultacie powstała w pełni przygotowana i uzasadniona teoretycznie platforma, gotowa do przeprowadzenia finalnych badań eksperymentalnych opisanych w kolejnym rozdziale.

Rozdział 4

Badania eksperymentalne i wyniki

Niniejszy rozdział stanowi szczegółowe sprawozdanie z procesu badawczego, którego celem była weryfikacja, optymalizacja i ocena systemu do GTT, opisanego w Rozdziale 3. Proces ten, udokumentowany w postaci serii ponad 70 eksperymentów, został zaplanowany tak, by systematycznie badać wpływ poszczególnych komponentów i hiperparametrów na finalną jakość transkrypcji.

Badania miały charakter ewolucyjny, gdzie wnioski z każdego etapu stanowiły podstawę do formułowania hipotez i projektowania kolejnych kroków optymalizacyjnych. W toku prac stwierdzono, że dalsza, intensywna optymalizacja samej architektury sieci neuronowej przynosiła coraz mniejsze korzyści. Istotna poprawa jakości modelu nastąpiła po zmianie podejścia i skupieniu się na danych treningowych, co doprowadziło do opracowania zaawansowanej strategii augmentacji. To właśnie ta strategia, przygotowująca model do pracy z niedoskonałym sygnałem audio, umożliwiła osiągnięcie finalnych, wysokich wyników.

4.1 Metodyka i środowisko badawcze

Wszystkie eksperymenty zostały przeprowadzone w ujednoliconym środowisku sprzętowo-programistycznym, aby zapewnić powtarzalność i porównywalność wyników.

4.1.1 Infrastruktura eksperymentalna

Badania zostały przeprowadzone z wykorzystaniem infrastruktury sprzętowej i programistycznej przedstawionej w Tabeli 4.1.

Tabela 4.1: Parametry środowiska eksperymentalnego.

Komponent	Specyfikacja / Wersja
Sprzęt	
System Operacyjny	Windows 11
Procesor (CPU)	12th Gen Intel(R) Core(TM) i5-12600KF 3.69 GHz
Karta Graficzna (GPU)	NVIDIA GeForce RTX 3070 (8 GB VRAM)
Pamięć RAM	64 GB DDR4
Oprogramowanie	
Python	3.9
PyTorch	2.3.1+cu121 [19]
Librosa	0.11.0 [17]
Mirdata	0.3.9 [4]

4.1.2 Zbiór danych i metryki oceny

Wszystkie eksperymenty przeprowadzono na zbiorze danych GuitarSet [26], którego szczegółową charakterystykę oraz sposób podziału na zbiory treningowy, walidacyjny i testowy przedstawiono w sekcji 3.2.1. Do oceny jakości modeli wykorzystano metryki zdefiniowane w sekcji 3.5.1. Wybór najlepszej wersji modelu w każdym eksperymencie opierał się na wartości metryki TDR F1-Score uzyskanej na zbiorze walidacyjnym. W finalnej ocenie na zbiorze testowym próg decyzyjny dla detekcji onsetów był optymalizowany w celu maksymalizacji tej samej metryki.

4.2 Proces badawczy: ewolucja modelu transkrypcyjnego

Poniższe podrozdziały przedstawiają chronologiczny przebieg prac, które doprowadziły do opracowania finalnej wersji systemu. Proces ten został zaimplementowany w ramach modułowego potoku badawczego, który umożliwił systematyczne testowanie hipotez i mierzenie wpływu kolejnych modyfikacji. Opisane zostaną kluczowe decyzje projektowe, począwszy od wyboru reprezentacji sygnału, przez optymalizację architektury, aż po wdrożenie zaawansowanych technik przygotowania danych.

4.2.1 Eksperyment bazowy i wybór reprezentacji sygnału

Punktem wyjścia procesu badawczego było zdefiniowanie eksperymentu bazowego oraz wybór adekwatnej reprezentacji czasowo-częstotliwościowej sygnału, która miała stanowić wejście do sieci neuronowej. Wstępne eksperymenty polegały na testowaniu


różnych wariantów architektury i hiperparametrów dla dwóch popularnych reprezentacji [3]: mel-spektrogramów oraz transformaty Constant-Q (CQT). Parametry ekstrakcji obu z nich przedstawiono w Tabeli 4.2.

Tabela 4.2: Parametry ekstrakcji cech dla badanych reprezentacji sygnału.

Parametr	Reprezentacja Mel	CQT (wysoka rozdzielczość)
Częstotliwość próbkowania	22050 Hz	22050 Hz
Długość kroku analizy	512 próbek	512 próbek
Rozmiar okna FFT	2048 próbek	Nie dotyczy
Liczba pasm	128 (pasm Mel)	168 (pasm CQT)
Liczba pasm na oktawę	Nie dotyczy	24
Minimalna częstotliwość	Nie dotyczy	E2 (~ 82.41 Hz)

Analiza literatury wskazywała na teoretyczną przewagę CQT w zadaniach muzycznych ze względu na jej logarytmiczną skalę częstotliwości, która lepiej odzwierciedla strukturę skal muzycznych [24, 15]. W celu empirycznej weryfikacji tej tezy przeprowadzono analizę wizualną. Jak zilustrowano na Rysunku 4.1, logarytmiczna skala CQT sprawia, że składowe harmoniczne (aliquoty) dźwięku gitary tworzą regularny wzorec równoległych, równo oddalonych od siebie linii. Taka struktura jest niezmiennicza względem transpozycji i potencjalnie łatwiejsza do nauczenia przez filtry konwolucyjne sieci neuronowej. W przypadku skali Mel, mimo jej psychoakustycznej motywacji, odległości między alikwotami nie są stałe, co tworzy bardziej złożony wzorec wizualny.

Te obserwacje, poparte wstępnymi wynikami eksperymentów, w których modele trenowane na CQT konsekwentnie osiągały lepsze wyniki, stanowiły podstawę do wyboru transformaty Constant-Q jako preferowanej reprezentacji sygnału wejściowego w dalszych, zaawansowanych etapach badań.



Rysunek 4.1: Porównanie reprezentacji czasowo-częstotliwościowych dla tego samego fragmentu gitarowego. (a) Spektrogram w skali Mel. (b) Spektrogram CQT, gdzie widoczna jest regularna struktura harmoniczna. (c) Odpowiadająca fragmentowi tablatura referencyjna.

4.2.2 Optymalizacja architektury i hiperparametrów

Proces optymalizacji modelu był metodyczną, wieloetapową procedurą, której celem było znalezienie najlepszej kombinacji reprezentacji danych, architektury sieci oraz kluczowych hiperparametrów uczenia. Poniższe podrozdziały opisują ewolucję modelu od początkowej koncepcji do finalnej, wysoce wyspecjalizowanej architektury.

Ewolucja architektury i reprezentacji sygnału

Punktem wyjścia dla eksperymentów były modele oparte na standardowych Mel-spektrogramach. W tej fazie (przebiegi 1-36) testowano podstawowe konfiguracje sieci rekurencyjnych, co pozwoliło osiągnąć solidną, lecz ograniczoną wydajność. Jak pokazano w Tabeli 4.3, najlepszy rezultat dla tej reprezentacji danych uzyskano w przebiegu 23, który stał się punktem odniesienia i potwierdzeniem osiągnięcia limitu dla cech Mel.

Dostrzegając tę barierę, w przebiegu 37 podjęto kluczową decyzję o zmianie paradygmatu i przejściu na transformatę CQT (*Constant-Q Transform*). Jej logarytmiczna skala częstotliwości jest znacznie lepiej dopasowana do percepcji muzyki niż skala Mel. Dalsza

ewolucja, już na bazie CQT, przebiegała zgodnie z etapami przedstawionymi w drugiej części Tabeli 4.3.

Tabela 4.3: Kluczowe etapy ewolucji architektury modelu (ocena na zbiorze testowym).

Etap	Reprezentacja i Faza	ID Przebiegu	TDR F1-Score	Kluczowa Modyfikacja i Wnioski
Faza I: Eksperymenty z Mel-spektrogramami				
I	Linia bazowa (Mel)	9	0.7812	Ustalenie stabilnej wydajności dla jednokierunkowej sieci LSTM na Mel-spektrogramach.
II	Najlepszy model (Mel)	23	0.7953	Osiągnięcie limitu wydajności dla reprezentacji Mel; dalsze skalowanie nie przynosiło już znaczącej poprawy.
Faza II: Eksperymenty z reprezentacją CQT				
III	Linia bazowa (CQT)	40	0.8247	Potwierdzenie potencjału CQT; wynik od razu przewyższył najlepsze modele oparte na Mel.
IV	Zmiana komórek na GRU	64	0.8279	Wprowadzenie komórek GRU, które okazały się wydajniejsze i skuteczniejsze od standardowych LSTM.
V	Wprowadzenie dwukierunkowości	67	0.8365	Skokowy wzrost wydajności dzięki zastosowaniu mechanizmu dwukierunkowości (ang. bidirectionality), pozwalającego na analizę przyszłego kontekstu.
VI	Finalna architektura (przed zaawansowaną augmentacją)	71	0.8428	Pogłębienie sieci do 2 warstw Bi-GRU, co stanowiło kompromis między złożonością modelu a jego zdolnością do generalizacji.

Po przejściu na CQT (Etap III), kolejnym krokiem było zastąpienie komórek LSTM komórkami GRU (Etap IV). Istotny postęp nastąpił jednak w Etapie V, gdy wdrożono architekturę dwukierunkową. Umożliwiło to modelowi przetwarzanie każdej ramki spektrogramu w kontekście nie tylko przeszłych, ale i przyszłych zdarzeń. Ostatni etap (VI) polegał na precyzyjnym dostrojeniu głębokości sieci, gdzie dwuwarstwowa architektura z przebiegu 71 została uznana za właściwą i stała się podstawą do dalszych badań.

Dostrajanie hiperparametrów procesu uczenia

Równolegle do zmian w architekturze, prowadzono intensywne prace nad optymalizacją hiperparametrów sterujących samym procesem uczenia. Miały one kluczowy wpływ na stabilność, szybkość zbieżności i finalną jakość modelu.

Wpływ rozmiaru wsadu (ang. batch size) Ważnym elementem w strojeniu procesu uczenia jest dobór odpowiedniego rozmiaru wsadu danych, który wpływa zarówno na jakość predykcji, jak i na czas treningu. Jednym z pierwszych badanych hiperparametrów był właśnie rozmiar wsadu. Jak pokazano w Tabeli 4.4, przeprowadzono serię eksperymentów, w których testowano wartości 2, 4 i 8. Zaobserwowano, że zwiększanie rozmiaru wsadu nie przynosiło poprawy metryk, a wręcz prowadziło do ich pogorszenia, nie skutkując przy tym znaczącym skróceniem czasu treningu. Wyniki te jednoznacznie wskazały, że małe rozmiary wsadu są właściwe dla tego zadania, prawdopodobnie ze względu na większą stochastyczność procesu uczenia, która pomaga unikać minimów lokalnych. We wszystkich późniejszych, kluczowych eksperymentach stosowano rozmiar wsadu równy 2, co stanowiło ekstrapolację tego wniosku.

Tabela 4.4: Porównanie wpływu rozmiaru wsadu na wyniki (wybrane przebiegi).

ID Przebiegu	Rozmiar Wsadu	TDR F1-Score	Czas Treningu (min)
8	2	0.8400	108.2
9	4	0.8290	108.5
10	8	0.8140	100.2

Dostrajanie funkcji straty Kolejnym etapem była optymalizacja funkcji straty, która kieruje procesem uczenia. Zastosowano złożoną funkcję, będącą sumą ważoną dwóch komponentów, co jest podejściem inspirowanym przez architekturę "Onsets and Frames" [9]. Kluczowe dla skuteczności modelu okazało się precyzyjne dostrojenie wag obu komponentów.

- **Waga straty dla onsetów:** Parametr ten, określający priorytet dla zadania detekcji początków dźwięków, był systematycznie badany. Jak widać w Tabeli 4.5, wyższa waga (9.0 lub 10.0) prowadziła do lepszych lub porównywalnych wyników w porównaniu do niższej wartości (8.0). Wartość 9.0 została wybrana jako podstawa do dalszych badań, ponieważ priorytetyzowała precyzyjną lokalizację zdarzeń w czasie.

Tabela 4.5: Analiza wpływu wagi straty dla detekcji onsetów.

ID Przebiegu	Waga straty dla onsetów	TDR F1-Score
13	8.0	0.8260
16	9.0	0.8280
76	10.0	0.8230

- **Waga klasy pozytywnej w detekcji onsetów:** Ten parametr przeciwdziałał problemowi silnego niezbalansowania klas, ponieważ ramki z onsestem stanowią mniejszość. Eksperymenty (Tabela 4.6) pokazały, że wartość 6.0 dawała najlepsze rezultaty.

Tabela 4.6: Analiza wpływu wagi dla przykładów pozytywnych w detekcji onsetów.

ID Przebiegu	Waga klasy pozytywnej	TDR F1-Score
16	5.0	0.8280
19	6.0	0.8360
13	7.0	0.8260

Parametry optymalizatora i harmonogramu Zastosowano optymalizator AdamW [16] oraz harmonogram współczynnika uczenia *ReduceLROnPlateau*. Iteracyjne dostrajanie ich parametrów było kluczowe dla stabilności i efektywności treningu.

- **Współczynnik uczenia (ang. *learning rate*):** Testowano różne startowe wartości, co podsumowuje Tabela 4.7. Wartość 3×10^{-4} stanowiła kompromis między szybkością zbieżności a ryzykiem niestabilności treningu.

Tabela 4.7: Porównanie wpływu początkowego współczynnika uczenia.

ID Przebiegu	Początkowy współczynnik uczenia	TDR F1-Score
14	2.0×10^{-4}	0.8270
19	3.0×10^{-4}	0.8360
18	3.5×10^{-4}	0.8310

- **Cierpliwość harmonogramu (ang. *scheduler patience*):** Parametr ten określa, po ilu epokach bez poprawy na zbiorze walidacyjnym należy zmniejszyć współczynnik uczenia. Analiza wielu przebiegów (Tabela 4.8) pokazała, że właściwy zakres to 10-12 epok. Wartości w tym przedziale pozwalały modelowi na cierpliwą eksplorację przestrzeni parametrów bez przedwczesnego obniżania współczynnika uczenia.

Tabela 4.8: Analiza wpływu cierpliwości harmonogramu.

ID Przebiegu	Cierpliwość harmonogramu (epoki)	TDR F1-Score
67	8	0.8365
71	10	0.8428
75	12	0.8280

Optymalizacja progu decyzyjnego Ostatnim, lecz kluczowym krokiem w procesie ewaluacji było dostrojenie progu decyzyjnego dla detekcji onsetów. Model na wyjściu generuje wartości prawdopodobieństwa, które muszą zostać przekształcone na binarne decyzje o wystąpieniu dźwięku. Domyślna wartość progu (0.5) rzadko jest zadowalająca, dlatego zgodnie z metodyką, dla każdego kluczowego modelu przeprowadzono na zbiorze testowym poszukiwanie takiej wartości progu, która maksymalizuje finalną metrykę TDR F1-Score.

Ta procedura okazała się istotna dla uzyskania najlepszych możliwych wyników. Przykładowo, dla finalnego modelu z przebiegu 72, zastosowanie domyślnego progu 0.5 dało wynik TDR F1-Score na poziomie 0.855. Dopiero jego optymalizacja do wartości 0.35 pozwoliła osiągnąć ostateczny, wyższy wynik 0.8569. Co ciekawe, dobierany próg był silnie zależny od strategii treningowej: dla modelu z przebiegu 71 (bez zaawansowanej augmentacji) wynosił on 0.74, podczas gdy dla modelu 72 (z zaawansowaną augmentacją) był znacznie niższy. Sugeruje to, że model nauczony na zróżnicowanych, zaszumionych danych wykazywał większą czułość i był zdolny do poprawnego identyfikowania onsetów nawet przy niższych wartościach pewności predykcji.

4.2.3 Wpływ strategii augmentacji danych

Po zoptymalizowaniu architektury i hiperparametrów, ostatnim i kluczowym etapem była intensyfikacja strategii augmentacji danych. Wprowadzono zaawansowany zestaw augmentacji audio, w tym popularną metodę SpecAugment [18], symulujących realistyczne warunki nagraniowe. Wpływ tej strategii na finalną skuteczność modelu został zmierzony i przedstawiony w Tabeli 4.9.

Tabela 4.9: Porównanie wpływu różnych strategii augmentacji na wynik TDR F1-Score (zbiór testowy).

Poziom	Opis strategii augmentacji	ID Eksperymentu	TDR F1-Score
1	Brak augmentacji (na reprezentacji Mel)	27	0.7785
2	Augmentacja podstawowa (zmiana tempa, szum, <i>SpecAugment</i>)	71	0.8428
3	Augmentacja zaawansowana (podstawowa + pogłos, EQ, przester)	72	0.8569

Dane przedstawione w Tabeli 4.9 jednoznacznie wskazują na decydującą rolę augmentacji. Już wdrożenie podstawowych technik (Poziom 2) przyniosło skokowy wzrost skuteczności. Jednak kluczowy przyrost, który pozwolił na osiągnięcie najlepszych wyników, nastąpił po wprowadzeniu zaawansowanych, specyficznych dla domeny audio augmentacji (Poziom 3). Różnica w wynikach między eksperymentem 71 a 72, które wykorzystywały identyczną architekturę, dowodzi, że to właśnie nauczanie modelu odporności na niedoskonałości sygnału było niezbędnym krokiem do osiągnięcia najwyższej jakości transkrypcji, co jest zgodne z obserwacjami w nowszych badaniach nad rolą danych syntetycznych i augmentowanych [27].

4.3 Analiza wyników i dyskusja

Po zakończeniu etapu ewolucji modelu i dostrajania hiperparametrów, przeprowadzono dogłębną analizę uzyskanych wyników. Niniejszy podrozdział przedstawia zarówno ilościowe porównanie kluczowych modeli, jak i jakościową ocenę działania finalnej wersji systemu na wybranych, reprezentatywnych przykładach.

4.3.1 Porównanie ilościowe najlepszych modeli

Tabela 4.10 przedstawia kompleksowe porównanie metryk dla pięciu kluczowych modeli zidentyfikowanych w procesie badawczym, ocenionych na zbiorze testowym. Przebiegi te ilustrują ewolucję systemu, której kulminacją był przebieg 72. Model ten, wytrenowany z wykorzystaniem radykalnie ulepszonej strategii augmentacji danych, osiągnął najlepsze wyniki we wszystkich kluczowych metrykach.

Co istotne, wprowadzenie zaawansowanych augmentacji, symulujących niedoskonałości nagrań domowych, pozwoliło modelowi stać się bardziej czułym na subtelne cechy sygnału. W efekcie, jak opisano w poprzedniej sekcji, właściwy próg decyzyjny dla detekcji onsetów


na zbiorze testowym dla przebiegu 72 spadł do wartości 0.35, w porównaniu do wyższych wartości (np. 0.74 dla przebiegu 71) w modelach trenowanych bez tych technik. Świadczy to o tym, że model nauczył się poprawnie identyfikować nuty nawet wtedy, gdy ich sygnał jest cichszy i mniej wyraźny, co jest kluczowe dla analizy nagrań amatorskich.

Tabela 4.10: Kompleksowe porównanie metryk dla kluczowych modeli na zbiorze testowym. Pogrubione wartości wskazują najlepszy wynik uzyskany dla danej metryki.

Metryka/Konfiguracja	Przebieg 23 (Mel-LSTM)	Przebieg 59 (CQT-LSTM)	Przebieg 67 (CQT-BiGRU)	Przebieg 71 (CQT-BiGRU L2)	Przebieg 72 (Finalny) (CQT-BiGRU L2 + Aug v2)
Konfiguracja Modelu					
Reprezentacja	Mel	CQT	CQT	CQT	CQT
Architektura RNN	1-w. LSTM	1-w. LSTM	1-w. BiGRU	2-w. BiGRU	2-w. BiGRU
Metryki na Poziomie Nut (TDR)					
TDR F1-Score	0.7953	0.8305	0.8449	0.8472	0.8569
TDR Precyzja	0.8201	0.8687	0.8759	0.8803	0.8757
TDR Czułość	0.7720	0.8013	0.8202	0.8210	0.8436
Metryki Diagnostyczne					
Onset F1-Score	0.7589	0.7891	0.8003	0.8043	0.8072
MPE F1-Score	0.8234	0.8598	0.8614	0.8736	0.8736
Dane Treningowe					
Czas (min)	120.5	155.2	90.1	209.9	205.6
Epoka zatrzym.	85	92	79	75	90

Analiza krzywej uczenia uczenia modelu finalnego

Przebieg procesu uczenia dostarcza cennych informacji na temat stabilności i efektywności modelu. Rysunek 4.2 przedstawia historię treningu dla finalnej konfiguracji z przebiegu 72. Analiza poszczególnych wykresów pozwala sformułować następujące wnioski: krzywe straty (górny lewy panel) wykazują prawidłową zbieżność, przy czym strata treningowa systematycznie maleje, a strata walidacyjna stabilizuje się na niskim poziomie bez wyraźnych oznak przeuczenia. Harmonogram współczynnika uczenia (górny prawy panel) działał zgodnie z założeniami, redukując wartość LR w odpowiedzi na plateau metryki walidacyjnej. Co najważniejsze, zarówno metryki nutowe (dolny lewy panel), jak i ramkowe (dolny prawy panel) szybko osiągają wysokie wartości i pozostają stabilne przez większość procesu treningu, co świadczy o solidności i dobrej generalizacji wyuczonego modelu.



Rysunek 4.2: Historia procesu uczenia dla finalnego modelu (przebieg 72). Górne wykresy przedstawiają przebieg funkcji straty oraz zmiany współczynnika uczenia. Dolne wykresy obrazują ewolucję kluczowych metryk (nutowych i ramkowych) w kolejnych epokach.

Analiza jakościowa wybranych przypadków

W celu głębszej oceny działania modelu, wykraczającej poza uśrednione metryki, przeprowadzono szczegółową analizę jakościową transkrypcji dla konkretnych utworów ze zbioru testowego. Tabela 4.11 zestawia pliki, dla których finalny model (przebieg 72) uzyskał najlepsze i najgorsze wyniki. Taki dobór próbek pozwala zidentyfikować zarówno mocne strony systemu, jak i warunki, w których jego działanie ulega pogorszeniu.

Tabela 4.11: Zestawienie najlepszych i najgorszych wyników transkrypcji (TDR F1-Score) uzyskanych przez model finalny (przebieg 72) na zbiorze testowym.

Kategoria	Nazwa Pliku	TDR F1-Score
Najlepsze wyniki		
1.	04_BN1-147-Gb_comp	0.9676
2.	05_Rock3-148-C_solo	0.9667
3.	02_Jazz1-200-B_solo	0.9647
Najgorsze wyniki		
1.	05_SS3-84-Bb_comp	0.7090
2.	04_SS3-98-C_comp	0.7054
3.	00_SS3-84-Bb_comp	0.6760

Przypadek najwyższej jakości transkrypcji: paradoks akompaniamentu

Co ciekawe, najwyższą jakość transkrypcji dla pliku 04_BN1-147-Gb_comp (TDR F1-Score: 0.9676) uzyskano nie dla partii solowej, lecz dla akompaniamentu, co może wydawać się paradoksalne, biorąc pod uwagę jego polifoniczny (akordowy) charakter. Analiza tego przypadku, którego wynik wizualizuje Rysunek 4.3, dostarcza jednak cennych wniosków. Sukces w tym przypadku wynika z kilku kluczowych cech nagrania:

- **Regularność rytmiczna:** Partie akompaniamentu charakteryzują się często stałym, powtarzalnym rytmem. Ta przewidywalność znacząco ułatwia modelowi zadanie detekcji onsetów, które są wyraźne i niezachodzące na siebie w skomplikowany sposób.
- **Klarowność harmoniczna:** Akordy, mimo że są zdarzeniami wielodźwiękowymi, są grane w sposób czysty i oddzielony. Brak tu szybkich przejść, ozdobników czy technik artykulacyjnych, które wprowadzają dodatkową złożoność do sygnału.
- **Stabilność sygnału:** Model nie musi radzić sobie ze złożonymi zmianami w dynamice i barwie, typowymi dla ekspresyjnych solówek.

Zdolność modelu do tak precyzyjnego rozłożenia akordów na poszczególne nuty na odpowiednich strunach i progach, przy jednoczesnej niemal bezbłędnej detekcji onsetów, świadczy o jego sile w zadaniu wielodźwiękowej estymacji (MPE).

Rysunek 4.3: Porównanie fragmentu tabulatury wygenerowanej przez model (góra) i tabulatury referencyjnej (dół) dla utworu 04_BN1-147-Gb_comp.

Predykcja modelu (Przebieg 72, Onset Thresh: 0.35):

```

e|-----|-----|-----|-----|-----|-----|-----|-----
B|2-----2--|-----2--|-----2--|-----2--|2-----2--|-----2--|-----2--|-----
G|-----|-----3--|-----3--|-----|3-----3--|-----3--|-----3--|-----
D|3-----|-----3--|-----3--|-----3--|3-----3--|-----3--|-----3--|-----
A|-----|-----|-----|-----|-----|-----|-----|-----
E|2-----|-----2--|-----2--|-----2--|-----2--|-----0--2--|-----2--|-----

e|-----|-----|-----|-----|-----|-----|-----|-----
B|2-----2--|-----2--|-----2--|2-----|-----4--4--|-----4--4--|-----
G|3-----3--|-----3--|-----3--|3-----|-----3--3--|-----3--3--|-----
D|3-----3--|-----3--|-----3--|3-----|-----4--4--|-----4--4--|-----
A|-----|-----|-----|-----|-----2-----|-----2-----|-----
E|2-----2--|-----2--|-----2--|2-----|-----|-----|-----|-----

```

Tabulatura referencyjna (Ground Truth):

```

e|-----|-----|-----|-----|-----|-----|-----|-----
B|2-----2--|-----2--|-----2--|-----2--|2-----2--|-----2--|-----2--|-----
G|3-----3--|-----3--|-----3--|-----3--|3-----3--|-----3--|-----3--|-----
D|3-----3--|-----3--|-----3--|-----3--|3-----3--|-----3--|-----3--|-----
A|-----|-----|-----|-----|-----|-----|-----|-----
E|2-----2--|-----2--|-----2--|-----2--|2-----2--|-----0--2--|-----2--|-----

e|-----|-----|-----|-----|-----|-----|-----|-----
B|2-----2--|-----2--|-----2--|2-----|-----4--4--|-----4--4--|-----
G|3-----3--|-----3--|-----3--|3-----|-----3--3--|-----3--3--|-----
D|3-----3--|-----3--|-----3--|3-----|-----5--4--|-----4--4--|-----
A|-----|-----|-----|-----0--|2-----2--|-----2-----|-----2--
E|2-----2--|-----2--|-----2--|2-----|-----|-----|-----|-----

```

Przypadek wysokiej jakości transkrypcji partii solowej

Nagranie 05_Rock3-148-C_solo (TDR F1-Score: 0.9667), drugi najlepszy wynik w ewaluacji, jest doskonałym przykładem wysokiej skuteczności finalnego modelu dla partii melodycznych. Jak widać na Rysunku 4.4, wygenerowana tabulatura jest niemal identyczna z referencyjną. Model poprawnie zidentyfikował zarówno wysokość dźwięków, jak i ich przypisanie do odpowiednich strun i progów, nawet w przypadku szybszych fraz. Ten przypadek pokazuje, że dla czystych, wyraźnie zagranych partii solowych, system osiąga dokładność zbliżoną do ludzkiej, co stanowi solidne potwierdzenie jego praktycznej użyteczności w najbardziej typowym scenariuszu zastosowania.

Rysunek 4.4: Porównanie fragmentu tabulatury wygenerowanej przez model (góra) i tabulatury referencyjnej (dół) dla utworu 05_Rock3-148-C_solo.

Predykcja modelu (Przebieg 72, Onset Thresh: 0.35):

```

e|-----|8-----7-----|-----|-----|-----|-----5--|-----
B|-----|-----|10---8-----|-----|-----|-----|-----8--
G|-----|-----|-----|-----|-----|-----|-----|-----
D|-----|-----|-----|-----|-----|-----|-----|-----
A|-----|-----|-----|-----|-----|-----|-----|-----
E|-----|-----|-----|-----|-----|-----|-----|-----

e|-----|-----|-----|-----|-----|-----|-----|-----
B|---6---5--|-----|-----|-----|-----5-----|-----|-----
G|-----|-----|-----|-----|-----|-----|7---5-----|-----
D|-----|-----|-----|-----|-----|-----|-----|-----
A|-----|-----|-----|-----|-----|-----|-----|-----
E|-----|-----|-----|-----|-----|-----|-----|-----

```

Tabulatura referencyjna (Ground Truth):

```

e|-----|8-----7-----|-----|-----|-----|-----5--|-----
B|-----|-----|10---8-----|-----|-----|-----|-----8--
G|-----|-----|-----|-----|-----|-----|-----|-----
D|-----|-----|-----|-----|-----|-----|-----|-----
A|-----|-----|-----|-----|-----|-----|-----|-----
E|-----|-----|-----|-----|-----|-----|-----|-----

e|-----|-----|-----|-----|-----|-----|-----|-----
B|---6---5--|-----|-----|-----|-----6---5-----|-----|-----
G|-----|-----|-----|-----|-----|-----|7---5-----|-----
D|-----|-----|-----|-----|-----|-----|-----|-----
A|-----|-----|-----|-----|-----|-----|-----|-----
E|-----|-----|-----|-----|-----|-----|-----|-----

```

Przypadek stanowiący wyzwanie dla modelu

Analiza najtrudniejszego przypadku, nagrania 00_SS3-84-Bb_comp (TDR F1-Score: 0.6760), ujawnia typowe błędy popełniane przez model. Porównanie predykcji z tabulaturą referencyjną na Rysunku 4.5 pokazuje, że choć ogólny zarys harmoniczny i rytmiczny jest często zachowany, pojawiają się błędy w dokładnym umiejscowieniu nut. Model w tym przypadku wygenerował dodatkowe nuty (fałszywe alarmy), pominął niektóre istniejące (fałszywe negatywy) oraz błędnie zidentyfikował część progów. Tego typu utwory, charakteryzujące się grą akordową i gęstszą fakturą, stanowią większe wyzwanie ze względu na zjawisko maskowania harmonicznego, gdzie cichsze dźwięki są maskowane przez głośniejsze. Mimo to, nawet w tak trudnym przykładzie, wygenerowana transkrypcja wciąż może stanowić użyteczny punkt wyjścia do dalszej, manualnej korekty.

Rysunek 4.5: Porównanie fragmentu tabulatury wygenerowanej przez model (góra) i tabulatury referencyjnej (dół) dla utworu 00_SS3-84-Bb_comp, ilustrujące wyzwania w transkrypcji gęstych faktur.

Predykacja modelu (Przebieg 72, Onset Thresh: 0.35):

```

e|-----|---6-----|-----|-----|-----|-----|-----|
B|-----|-----|-----|-----|-----|-----|-----|6-----
G|-----|-----|7-----|---7--7---|-----|-----|-----|-----
D|-----8--|---8-----|-----8---|-----8--|-----|---7---7---|---7-----|
A|-----|-----|-----8---|-----|-----|---8-----|-----|
E|6-----|-----|-----|-----|-----|-----|-----|

e|-----|-----|-----|-----|-----|-----|-----10-|-----
B|-----|-----|-----|-----|---11-----|-----|-----11-11-|-----
G|-----|5-----|---6--6---|-----12---|7-----12-|---12-----|---12-----|---10-
D|-----|7---7---|7-----|-----|-----|-----|-----|---10-
A|-----|-----|-----10-|-----|-----|-----|-----|
E|-----|-----|-----|-----|-----|-----|-----|

```

Tabulatura referencyjna (Ground Truth):

```

e|-----|6-----|-----|-----6--|-----|---5-----|-----5-----
B|-----|---6-----|-----|-----6--|-----|---6-----|-----6-----
G|7-----|-----|7-----|---7-----|-----|-----5---|-----|
D|8-----|8-----|-----|-----8--|-----|-----|---7-----|
A|-----|-----|-----8---|-----|-----|---8-----|-----|
E|6-----|-----|-----|-----|-----|-----|-----|

e|-----|-----|-----|-----|-----|---10-----|-----|
B|-----|-----|-----|-----|10-11-----|-----|-----11-----|---10-
G|-----5---|-----|---8-----|-----12---|-----12-|-----|---12-----|---10-
D|-----|-----7---|-----|-----|12-----|12-----|-----|---10-
A|-----|-----|-----10-|-----|-----|-----|-----|
E|-----|-----|-----|-----|-----|-----|-----|

```

Główne wyzwania i ograniczenia modelu

Analiza trudniejszych przypadków, takich jak 00_SS3-84-Bb_comp, pozwala zidentyfikować kluczowe wyzwania i ograniczenia, które wciąż stoją przed opracowanym modelem:

- **Niejednoznaczność opalcowania:** W złożonych partiach polifonicznych model może poprawnie zidentyfikować wysokość dźwięku, ale błędnie przypisać ją do pary (struna, próg). Jest to fundamentalny problem GTT, szeroko opisywany w pracach [2, 24] oraz zilustrowany w [8].
- **Techniki artykulacyjne i złożoność rytmiczna:** Model napotyka trudności w detekcji cichych lub bardzo szybko następujących po sobie nut (tzw. *ghost notes*), co jest typowe dla stylów funk i jazz. Problemy z detekcją nut granych technikami takimi jak *hammer-on* czy *pull-off* są zgodne z obserwacjami z pracy [12].

- **Gęstość faktury i maskowanie:** W utworach o dużej gęstości faktury, gdzie wiele dźwięków występuje jednocześnie, zjawisko maskowania może utrudniać detekcję poszczególnych nut, zwłaszcza tych o niższej amplitudzie [3].

4.3.2 Walidacja w warunkach rzeczywistych

Kluczowym testem praktycznej użyteczności i zdolności do generalizacji każdego systemu transkrypcji jest jego ocena na danych, które znacząco odbiegają od sterylnych warunków zbioru treningowego. W tym celu przeprowadzono dodatkowy eksperyment polegający na ewaluacji finalnego modelu na nagraniach zrealizowanych w typowych warunkach domowych.

Metodyka eksperymentu

Przygotowano dedykowany, niestandardowy zbiór czterech nagrań audio, zrealizowanych przy użyciu dwóch różnych gitar: **akustycznej** (struny stalowe, jasna barwa) oraz **klasycznej** (struny nylonowe, cieplejsza barwa). Nagrania przeprowadzono za pomocą wbudowanego mikrofonu w laptopie i oprogramowania Audacity, zachowując parametry techniczne (mono, 22050 Hz, 16-bit WAV) zgodne z danymi treningowymi, aby zminimalizować tzw. przesunięcie dziedziny (ang. *domain shift*). Dla każdego instrumentu nagrano dwa wzorce muzyczne:

- **Wzorzec "123"(wielostrunowy):** Sekwencyjne zagranie progów 1, 2, 3 na każdej z sześciu strun, testujące zdolność do rozróżniania barwy strun.
- **Wzorzec "12345678"(jednostrunowy):** Zagranie sekwencji chromatycznej od 1 do 8 progu na najcieńszej strunie (e^1), weryfikujące precyzję rozpoznawania wysokości dźwięku.

Analiza wyników jakościowych

Analiza wygenerowanych tabulatur pozwoliła na zidentyfikowanie kilku kluczowych zjawisk, które charakteryzują działanie modelu w warunkach rzeczywistych.

Zdolność do rozpoznawania wysokości dźwięku

Model wykazał wysoką skuteczność w rozpoznawaniu podstawowej częstotliwości dźwięku, co przekłada się na poprawną identyfikację numeru granego progu. Najlepszym tego dowodem jest wynik dla nagrania `akustyczna_12345678`, gdzie model niemal bezbłędnie odtworzył graną sekwencję:

- **Oczekiwano:** `e|-1-2-3-4-5-6-7-8-|`

- **Przewidziano (fragment):** e|-2-2-3-3-4-4-5-5-5-7-8-|

Większość progów została rozpoznana poprawnie, co świadczy o solidnym działaniu części modelu odpowiedzialnej za analizę częstotliwości.

Wyzwanie: rozpoznawanie barwy i problem wieloznaczności gryfu

Największą zidentyfikowaną słabością jest niska zdolność modelu do precyzyjnego rozpoznawania barwy dźwięku (ang. *timbre*), co jest niezbędne do poprawnego przypisania dźwięku do konkretnej struny. Słabość ta prowadzi do powszechnego zjawiska **błędu wieloznaczności gryfu gitarowego**. Model, poprawnie identyfikując wysokość dźwięku, często umieszcza go na niewłaściwej strunie, ale na progu, który odpowiada tej samej nucie. Jest to doskonale widoczne w wynikach dla nagrania `klasyczna_12345678`:

- **Oczekiwano:** e|-1-2-3-4-5-6-7-8-|
- **Przewidziano (fragmenty):** e|-4-5-5-6-7-8-| oraz B|-6-7-8-12-|

Ten rodzaj błędu dowodzi, że model poprawnie analizuje ton podstawowy (przewidziany próg 6 na strunie B to ten sam dźwięk F4 co próg 1 na strunie e), lecz zawodzi w analizie subtelnych składowych harmonicznym, które odróżniają barwę struny e od B.

Wnioski z testów w warunkach rzeczywistych

Eksperyment potwierdził, że głównym problemem modelu nie jest rozpoznawanie wysokości dźwięku, lecz klasyfikacja barwy. Aby system stał się narzędziem o praktycznym zastosowaniu dla nagrań domowych, kluczowy jest rozwój w kierunku lepszego różnicowania barwy lub implementacja zaawansowanych algorytmów post-processingu, które na podstawie wiedzy o technice gry korygowałyby błędy wieloznaczności.

Użyteczność w praktyce

Mimo pewnych błędów, osiągnięty poziom dokładności otwiera drogę do praktycznego zastosowania systemu. Praca [11] badała użyteczność systemów AMT w praktyce muzykologicznej, wskazując, że nawet niedoskonałe transkrypcje mogą znacząco przyspieszyć pracę ekspertów. Można postawić tezę, że opracowany system, mimo iż nie jest idealny, mógłby być użyteczny np. dla amatorów gitary jako narzędzie pomocnicze do nauki utworów, oferując wstępną wersję tabulatury o wystarczającej jakości do dalszej weryfikacji i nauki.

4.4 Podsumowanie badań eksperymentalnych

Przeprowadzony w ramach niniejszego rozdziału szczegółowy proces badawczy, obejmujący ponad 70 eksperymentów, pozwolił na systematyczną weryfikację i optymalizację

zapropowanego systemu transkrypcji. Analiza ilościowa i jakościowa wykazała, że finalna konfiguracja modelu (eksperyment 72) osiąga wyniki na najwyższym poziomie. Wynik **MPE F1-Score na poziomie 0.8736** oraz **TDR F1-Score wynoszący 0.8569** dowodzą wysokiej skuteczności opracowanego rozwiązania.

Potwierdzono, że kluczowym czynnikiem, który umożliwił osiągnięcie tak wysokich wyników, była innowacyjna strategia augmentacji danych. Świadome nauczanie modelu, jak interpretować niedoskonałe sygnały audio, okazało się znacznie skuteczniejsze niż dążenie do optymalizacji architektury na idealnych, studyjnych danych. Dodatkowa walidacja w warunkach rzeczywistych pokazała, że choć model doskonale radzi sobie z rozpoznawaniem wysokości dźwięku, jego głównym ograniczeniem pozostaje precyzyjna klasyfikacja barwy, prowadząca do błędów wieloznaczności. Ten rozdział dostarczył empirycznych dowodów na słuszność przyjętych założeń projektowych i skuteczność zaimplementowanych metod, stanowiąc solidną podstawę dla finalnych wniosków z całej pracy, które zostaną przedstawione w kolejnym rozdziale.

Rozdział 5

Podsumowanie i Wnioski

Niniejsza praca magisterska stanowiła realizację zadania polegającego na zaprojektowaniu, zaimplementowaniu i weryfikacji eksperymentalnej systemu do automatycznej transkrypcji polifonicznych nagrań gitarowych na zapis tabulaturowy GTT przy użyciu metod głębokiego uczenia. Praca obejmowała pełny cykl projektu naukowo-badawczego, od studiów literaturowych i analizy problemu, poprzez projektowanie i implementację rozwiązania, aż po jego ewaluację i analizę wyników.

5.1 Podsumowanie zrealizowanych prac

Realizację postawionych celów rozpoczęto od analizy literatury (Rozdział 2), która pozwoliła na ugruntowanie podstaw teoretycznych dotyczących cyfrowego przetwarzania sygnałów i metod uczenia maszynowego w kontekście Automatycznej Transkrypcji Muzycznej ATM oraz na zidentyfikowanie specyficznych wyzwań związanych z transkrypcją gitary. Analiza ta potwierdziła, że GTT, ze względu na polifonię, zmienność barwy, techniki artykulacyjne i problem niejednoznaczności opalcowania, pozostaje jednym z otwartych i wymagających problemów w dziedzinie MIR [3, 24].

W oparciu o te podstawy, w Rozdziale 3 zaprojektowano i zaimplementowano autorski system oparty na konwolucyjno-rekurencyjnej sieci neuronowej CRNN. System ten, zrealizowany w środowisku PyTorch, został zaprojektowany w sposób modułowy, umożliwiając elastyczne zarządzanie potokiem przetwarzania danych, treningiem i ewaluacją. Kluczowym elementem rozwiązania była zdolność do przetwarzania różnych reprezentacji czasowo-częstotliwościowych (Mel-spektrogramy, CQT) oraz implementacja wielozadaniowego uczenia, polegającego na jednoczesnej predykcji momentów rozpoczęcia nut i aktywności progów na poszczególnych strunach.

Rozdział 4 dokumentował iteracyjny proces badawczy, w którym przeprowadzono ponad 70 eksperymentów. Kluczowym wnioskiem było stwierdzenie, że dalsza optymalizacja architektury sieci (przejście z LSTM na dwukierunkowe GRU) przynosiła jedynie marginalne poprawy. Przełom nastąpił dopiero po zmianie podejścia do danych treningowych

- implementacja zaawansowanej strategii augmentacji (w tym SpecAugment, symulacja pogłosu i zniekształceń) pozwoliła osiągnąć TDR F1-Score na poziomie 0.8569. Finalny model, oparty na reprezentacji CQT i dwuwarstwowej architekturze BiGRU, został poddany kompleksowej ewaluacji na zbiorze GuitarSet, wykazując szczególnie wysoką skuteczność w transkrypcji partii solowych (do 0.9667 TDR F1-Score).

5.2 Wnioski

Przeprowadzone badania i analiza wyników pozwalają na sformułowanie następujących wniosków, które syntetyzują wkład niniejszej pracy w dziedzinę automatycznej transkrypcji gitarowej.

1. **Wyniki przewyższające stan wiedzy w ramkowej estymacji tabulatur:** Zaimplementowany i wytrenowany system transkrypcji gitarowej osiągnął na zbiorze testowym GuitarSet wynik MPE F1-Score na poziomie 0.8736. Jest to rezultat, który, przy zachowaniu metodologicznej poprawności porównania na poziomie ramek, przewyższa wyniki raportowane w kluczowych pracach w tej dziedzinie dla modeli trenowanych wyłącznie na tym zbiorze danych, takich jak TabCNN (F1-Score 0.76) [24] czy modele bazowe z pracy nad SynthTab (F1-Score ok. 0.835) [27]. Uzyskany wynik praktycznej metryki na poziomie nut, TDR F1-Score, wynoszący 0.8569, świadczy o wysokiej jakości i użyteczności generowanych tabulatur.
2. **Kluczowy wpływ strategii augmentacji zorientowanej na dane (ang. *data-centric*):** Istotnym wnioskiem płynącym z procesu badawczego jest stwierdzenie, że kluczem do sukcesu i przełamania barier wydajnościowych nie okazały się modyfikacje architektury sieci neuronowej, lecz strategia augmentacji danych. Celowe wprowadzanie zakłóceń do idealnych, studyjnych danych treningowych poprzez symulację realistycznych, niedoskonałych warunków nagraniowych (pogłos, zniekształcenia mikrofonowe, przesterowanie) zmusiło model do nauki znacznie bardziej odpornych i uogólnionych cech. Potwierdza to rosnące w dziedzinie uczenia maszynowego przekonanie, że podejście zorientowane na dane często przynosi lepsze rezultaty niż podejście zorientowane na model (ang. *model-centric*) [14].
3. **Główne wyzwanie GTT jako problem klasyfikacji barwy dźwięku:** Analiza jakościowa błędów, w tym testy na nagraniach zewnętrznych, wykazała, że głównym ograniczeniem opracowanego modelu nie jest estymacja wysokości dźwięku (rozpoznawanie numeru progu), lecz jego zdolność do precyzyjnej klasyfikacji barwy (ang. *timbre*) w celu poprawnego przypisania dźwięku do właściwej struny. Model często popełnia błędy polegające na prawidłowej identyfikacji nuty, ale umieszczeniu jej na niewłaściwej strunie (na progu, który odpowiada tej samej wysokości muzycznej).

Zjawisko to potwierdza, że problem identyfikacji opalcowania, wynikający z wieloznaczności gryfu gitarowego, pozostaje kluczowym i w dużej mierze nierozwiązanym wyzwaniem GTT [24].

4. **Skuteczność w transkrypcji partii akompaniamentu jako wskaźnik wydajności modelu w MPE:** Zaobserwowano, że model osiąga wysoką skuteczność dla regularnych, rytmicznych partii akompaniamentu, nawet tych o złożonej fakturze akordowej. Klarowność rytmiczna i harmoniczna oraz stabilność dynamiczna takich partii czynią je dla algorytmu zadaniem łatwiejszym niż transkrypcja ekspresyjnych i zmiennych partii solowych, obfitujących w subtelne techniki artykulacyjne. Wysoka precyzja w dekompozycji akordów na poszczególne nuty na właściwych strunach i progach świadczy o wydajności modelu w podstawowym zadaniu wielodźwiękowej estymacji (MPE) dla sygnałów o przewidywalnej strukturze.

5.3 Potencjalne kierunki dalszych badań i rozwoju

Mimo osiągnięcia wysokich wyników, niniejsza praca otwiera szereg ścieżek dla dalszych badań i rozwoju opracowanego systemu, adresując zidentyfikowane ograniczenia i wyzwania.

- **Rozwój metod identyfikacji opalcowania:** Biorąc pod uwagę zidentyfikowane ograniczenia w klasyfikacji barwy, przyszłe prace powinny skupić się na rozwiązaniu problemu wieloznaczności gryfu. Możliwe kierunki obejmują:
 - Wzbogacenie architektury sieci o mechanizmy lepiej modelujące subtelne cechy barwy (np. przez zastosowanie bardziej zaawansowanych cech wejściowych lub specjalizowanych warstw w sieci).
 - Opracowanie modułów post-processingu, które na podstawie wyjścia obecnego modelu stosowałyby optymalizację opartą na wiedzy muzycznej, np. modelach grywalności (ang. *playability models*) czy typowych wzorcach opalcowania, korygując błędy w przypisaniu nut do strun.
- **Eksploracja transferu wiedzy i danych syntetycznych:** Rozwój GTT jest hamowany przez ograniczoną dostępność dużych, adnotowanych zbiorów danych rzeczywistych. Obiecującym kierunkiem jest wykorzystanie ogromnych zbiorów danych syntetycznych, takich jak SynthTab [27], do wstępnego treningu modeli (pre-training), a następnie ich dostrajanie (ang. *fine-tuning*) na mniejszych, ale autentycznych zbiorach, jak GuitarSet. Taki transfer wiedzy może znacząco poprawić zdolności generalizacyjne modeli, ucząc je najpierw ogólnych zasad akustyki gitary, a następnie adaptując do niuansów rzeczywistych nagrań.

- **Rozpoznawanie technik artykulacyjnych:** Obecny system koncentruje się na transkrypcji podstawowych zdarzeń nutowych. Istotnym rozszerzeniem funkcjonalnym byłoby dodanie zdolności do rozpoznawania i notowania specyficznych technik gitarowych, takich jak podciągnięcia strun (ang. *bends*), ślizgi (ang. *slides*), techniki legato (ang. *hammer-ons*, *pull-offs*) czy vibrato (ang. *vibrato*). Wymagałoby to rozszerzenia modelu o dodatkowe głowice predykcyjne oraz wykorzystania bardziej szczegółowo adnotowanych zbiorów danych, a także pogłębionej analizy akustycznych manifestacji tych technik, opisanych w literaturze [23, 21].
- **Optymalizacja pod kątem zastosowań czasu rzeczywistego:** Zaimplementowany system działa w trybie offline. Adaptacja i optymalizacja architektury modelu (np. poprzez zastąpienie dwukierunkowych warstw RNN jednokierunkowymi, redukcję liczby parametrów, kwantyzację modelu) pod kątem przetwarzania w czasie rzeczywistym otworzyłaby drogę do szeregu praktycznych zastosowań, takich jak interaktywne narzędzia edukacyjne, systemy do ćwiczeń czy wtyczki do cyfrowych stacji roboczych audio (DAW).

Podsumowując, niniejsza praca zrealizowała postawiony cel badawczy i wniosła wkład w dziedzinę GTT. Wykazano, że podejście do augmentacji danych jest kluczowe dla przełamania istniejących barier wydajnościowych. Wyniki te potwierdzają potencjał metod głębokiego uczenia w rozwiązywaniu problemów z zakresu przetwarzania sygnałów muzycznych i wskazują kierunki dla przyszłych badań.

Bibliografia

- [1] Supraja Anand, Judith M. Wingate, Brenda Smith i Rahul Shrivastav. „Acoustic Parameters Critical for an Appropriate Vibrato”. W: t. 26. 6. 2012, 820.e19–820.e25. DOI: 10.1016/j.jvoice.2012.06.004.
- [2] Carl-Fredrik Arndt i Lewis Li. *Automated Transcription of Guitar Music*. Spraw. tech. CS229 (Machine Learning) Project Report. Stanford University, 2012. URL: https://www.academia.edu/73426275/Automated_Transcription_of_Guitar_Music?hb-sb-sw=4413367.
- [3] Emmanouil Benetos, Simon Dixon, Zhiyao Duan i Sebastian Ewert. „Automatic Music Transcription: An Overview”. W: *IEEE Signal Processing Magazine* 36.1 (2019), s. 20–30. DOI: 10.1109/MSP.2018.2869928.
- [4] Rachel M. Bittner, Gabriel Meseguer-Brocal, Adam Ragheb i Juan José Bosch. „A Lightweight Instrument-Agnostic Model for Polyphonic Note Transcription and Multipitch Estimation”. W: 2022, s. 750–757. URL: <https://ieeexplore.ieee.org/document/9746549>.
- [5] Gregory Burlet i Abram Hindle. „Isolated guitar transcription using a deep belief network”. W: *PeerJ Computer Science* 3 (2017), e109. DOI: 10.7717/peerj-cs.109.
- [6] D. Cazau i G. Nuel. „Investigation on the use of Hidden-Markov Models in automatic transcription of music”. W: *arXiv preprint* (2017). eprint: 1704.03711. URL: <https://arxiv.org/pdf/1704.03711.pdf>.
- [7] Junyoung Chung, Caglar Gulcehre, Kyunghyun Cho i Yoshua Bengio. „Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling”. W: *Proceedings of the NIPS 2014 Workshop on Deep Learning*. 2014. URL: <https://arxiv.org/abs/1412.3555>.
- [8] Google Image Search Result. *Ilustracja niejednoznaczności opalcowania na gryfie gitary*. http://googleusercontent.com/image_collection/image_retrieval/6630293268132984900. Adres URL obrazu dostarczony przez narzędzie wyszukiwania Google. Dostęp: 5 czerwca 2025. 2025.

- [9] Curtis Hawthorne, Erich Elsen, Jialin Song, Adam Roberts, Ian Simon, Colin Raffel, Jesse Engel, Sageev Oore i Douglas Eck. „Onsets and frames: Dual-objective piano transcription”. W: *Proceedings of the 19th International Society for Music Information Retrieval Conference (ISMIR)*. Paris, France, 2018, s. 50–57. URL: <https://archives.ismir.net/ismir2018/paper/000019.pdf>.
- [10] Curtis Hawthorne, Ian Simon, Rigel Swavely, Ethan Manilow i Jesse Engel. „Sequence-to-Sequence Piano Transcription with Transformers”. W: *Proceedings of the 22nd International Society for Music Information Retrieval Conference (ISMIR)*. Online: ISMIR, 2021, s. 240–247. URL: <https://archives.ismir.net/ismir2021/paper/000027.pdf>.
- [11] Andre Holzapfel i Emmanouil Benetos. „Automatic Music Transcription and Ethnomusicology: A User Study”. W: *Proceedings of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. Delft, The Netherlands, 2019, s. 677–684. URL: <https://archives.ismir.net/ismir2019/paper/000082.pdf>.
- [12] Abd Husin, Koharudin Koharudin, Sidikrubadi Pramudito, Sitti Yani i Rima Fitria Adiati. „Analysis and Synthesis of Guitar Sounds with Hammer on Strumming Technique”. W: *Pillar of Physics* 16.2 (2023), s. 162–168. DOI: 10.24036/15354171074.
- [13] Jeremy Hyrkas i Tamara Smyth. „On Vibrato and Frequency (De)Modulation in Musical Sounds”. W: *Proceedings of the 27th International Conference on Digital Audio Effects (DAFx24)*. Guildford, United Kingdom, 2024. URL: <https://dafx.de/paper-archive/details/vta7009LDd8QNZLW70eEXw>.
- [14] Fatemeh Jamshidi, Gary Pike, Amit Das i Richard Chapman. „Machine Learning Techniques in Automatic Music Transcription: A Systematic Survey”. W: *arXiv preprint* (2024). eprint: 2406.15249. URL: <https://arxiv.org/pdf/2406.15249.pdf>.
- [15] Anssi Klapuri i Manuel Davy, red. *Signal Processing Methods for Music Transcription*. Springer, 2006. ISBN: 978-0387306674. DOI: 10.1007/0-387-32845-9.
- [16] Ilya Loshchilov i Frank Hutter. „Decoupled Weight Decay Regularization”. W: *International Conference on Learning Representations (ICLR)*. 2019. URL: <https://arxiv.org/abs/1711.05101>.
- [17] Brian McFee, Colin Raffel, Dawen Liang, Daniel P. W. Ellis, Matt McVicar, Eric Battenberg i Oriol Nieto. „librosa: Audio and Music Signal Analysis in Python”. W: *Proceedings of the 14th Python in Science Conference (SciPy 2015)*. SciPy, 2015, s. 18–25. DOI: 10.25080/Majora-7b98e3ed-003. URL: <https://proceedings.scipy.org/articles/Majora-7b98e3ed-003.pdf>.

- [18] Daniel S. Park, William Chan, Yu Zhang, Chung-Cheng Chiu, Barret Zoph, Ekin D. Cubuk i Quoc V. Le. „SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition”. W: *Proceedings of Interspeech*. 2019, s. 2613–2617. DOI: 10.21437/Interspeech.2019-2680. URL: <http://arxiv.org/abs/1904.08779>.
- [19] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Kopf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai i Soumith Chintala. „PyTorch: An Imperative Style, High-Performance Deep Learning Library”. W: *Advances in Neural Information Processing Systems 32 (NeurIPS 2019)*. <https://pytorch.org>. Curran Associates, Inc., 2019, s. 8024–8035. URL: https://papers.neurips.cc/paper_files/paper/2019/file/bdbca288fee7f92f2bfa9f7012727740-Paper.pdf.
- [20] Christopher Raphael. „Automatic Transcription of Piano Music”. W: *Proceedings of the 3rd International Society for Music Information Retrieval Conference (ISMIR)*. Paris, France, 2002, s. 177–184. URL: https://music.informatics.indiana.edu/~craphael/papers/ismir02_rev.pdf.
- [21] Loic Reboursiere, Otso Tapio Lähdeoja, Ricardo Chessini, Thomas Drugman, Stéphane Dupont, Cécile Picard i Nicolas Riche. „Guitar As Controller”. W: *Numediart Research Program QPSR 3* (2011). URL: https://www.researchgate.net/publication/235678844_Guitar_As_Controller.
- [22] Xavier Riley. *Incorrect timings in two annotations*. GitHub issue comment. marl/GuitarSet issue #5. 2023. URL: <https://github.com/marl/GuitarSet/issues/5>.
- [23] Li Su, Li-Fan Yu i Yi-Hsuan Yang. „Sparse Cepstral and Phase Codes for Guitar Playing Technique Classification”. W: *Proceedings of the 15th International Society for Music Information Retrieval Conference (ISMIR)*. Taipei, Taiwan, 2014, s. 9–14. URL: <https://archives.ismir.net/ismir2014/paper/000213.pdf>.
- [24] Andrew Wiggins i Youngmoo Kim. „Guitar Tablature Estimation with a Convolutional Neural Network”. W: *Proceedings of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. Delft, The Netherlands, 2019, s. 284–291. URL: <https://archives.ismir.net/ismir2019/paper/000033.pdf>.
- [25] Wikipedia. *Obwiednia dźwięku*. https://pl.wikipedia.org/wiki/Obwiednia_dźwięku. Dostęp: 16 lipca 2025. 2024.

- [26] Qing Xi, Rachel M. Bittner, Joren Pauwels, Xiaoxuan Ye i Juan P. Bello. „GuitarSet: A Dataset for Guitar Transcription”. W: *Proceedings of the 19th International Society for Music Information Retrieval Conference (ISMIR)*. Paris, France, 2018, s. 453–460. URL: <https://archives.ismir.net/ismir2018/paper/000188.pdf>.
- [27] Yongyi Zang, Yi Zhong, Frank Cwitkowitz i Zhiyao Duan. „SynthTab: Leveraging Synthesized Data for Guitar Tablature Transcription”. W: *Proceedings of the 24th International Society for Music Information Retrieval Conference (ISMIR)*. Milan, Italy, 2023. URL: <https://arxiv.org/abs/2309.09085>.

Dodatki

Dokumentacja techniczna

Architektura systemu

Zaprojektowany system do automatycznej transkrypcji gitarowej na zapis tabulaturowy GTT opiera się na modułowej architekturze potokowej (*pipeline*), co zapewniało elastyczność i ułatwiało systematyczne prowadzenie ponad 70 eksperymentów. Poniżej przedstawiono schematycznie główne komponenty systemu oraz przepływ danych, który pozostawał spójny w całym procesie badawczym.

```
[Sygnał Audio .wav] -> [1. Przetwarzanie wstępne] -> [2. Model Neuronowy]
-> [3. Przetwarzanie końcowe] -> [Tabulatura]
```

1. Przetwarzanie wstępne (*Preprocessing*): Surowy sygnał audio jest ładowany i transformowany do postaci spektrogramu. Ta reprezentacja czasowo-częstotliwościowa jest znacznie bardziej informatywna dla sieci neuronowej niż surowe próbki sygnału.
2. Model sieci neuronowej (Inferencja): Przetworzone dane są wprowadzane do wytrenowanego modelu głębokiego uczenia. Model analizuje spektrogram segment po segmencie i generuje predykcje dotyczące aktywności poszczególnych nut (kombinacji struna-próg) w każdej ramce czasowej.
3. Przetwarzanie końcowe (*Post-processing*): Surowe predykcje z modelu (wartości prawdopodobieństwa) są przetwarzane w celu wygenerowania finalnej, czytelnej tabulatury. Ten etap obejmuje progowanie binarne, odrzucanie krótkotrwałych, błędnych detekcji oraz formatowanie danych wyjściowych.

Środowisko i zależności technologiczne

System został zaimplementowany w języku **Python 3.9**. Do jego uruchomienia oraz treningu modelu niezbędne są następujące biblioteki, wyszczególnione w pliku `requirements.txt`:

- PyTorch: Główny *framework* do budowy i trenowania modeli głębokiego uczenia.

- **Librosa**: Specjalistyczna biblioteka do analizy i przetwarzania sygnałów audio, wykorzystywana do wczytywania plików, ekstrakcji cech i generowania spektrogramów.
- **NumPy**: Fundamentalna biblioteka do obliczeń naukowych, używana do operacji na macierzach i danych numerycznych.
- **Pandas**: Biblioteka do manipulacji i analizy danych, przydatna w zarządzaniu metadanymi i wynikami.
- **Matplotlib**: Biblioteka do tworzenia wizualizacji i wykresów, używana do analizy wyników i debugowania.
- **Jupyter Notebook/Lab**: Interaktywne środowisko (`guitar_ATM.ipynb`) używane do orkiestracji procesu badawczego, demonstracji i wizualizacji działania systemu.

Trening modelu, ze względu na jego złożoność obliczeniową, został przeprowadzony z wykorzystaniem akceleracji sprzętowej GPU (NVIDIA), co znacząco skróciło czas potrzebny na eksperymenty.

Przetwarzanie danych

Jakość i sposób przygotowania danych były kluczowe dla skuteczności modelu. Proces ten, podlegający ewolucji w toku badań, został podzielony na kilka etapów.

Źródło danych

Model został wytrenowany na publicznie dostępnym zbiorze danych **GuitarSet**, który zawiera 360 fragmentów muzycznych nagranych na gitarze akustycznej. Kluczową zaletą tego zbioru jest precyzyjna adnotacja, zawierająca nie tylko informacje o wysokości i czasie trwania dźwięków, ale również dokładne dane o numerze struny i progu, co jest niezbędne do treningu modelu generującego tabulatury.

Preprocessing sygnału audio

Celem preprocessingu jest konwersja sygnału audio do postaci, która jest optymalna dla modelu konwolucyjnej sieci neuronowej. Kroki te są zaimplementowane w module `data_processing/preparation.py`.

1. Wczytanie i resampling: Pliki audio w formacie `.wav` są wczytywane przy użyciu biblioteki `librosa`. Następnie ich częstotliwość próbkowania jest standaryzowana do **22050 Hz**, aby zapewnić spójność danych wejściowych.

2. Ekstrakcja cech – Spektrogram CQT: W wyniku eksperymentów bazowych, jako preferowaną reprezentację sygnału wybrano **transformatę Constant-Q (CQT)**. Wykazała ona wyższą skuteczność niż standardowy spektrogram STFT, ponieważ jej logarymiczna skala częstotliwości lepiej odpowiada percepcji muzyki i tworzy wzorce harmoniczne niezmiennicze względem transpozycji.
3. Normalizacja: Amplitudy spektrogramu są normalizowane do zakresu $[0, 1]$, co stabilizuje proces uczenia.
4. Segmentacja i augmentacja: Spektrogramy i odpowiadające im adnotacje są dzielone na krótkie, nakładające się na siebie segmenty (ramki). Kluczowym elementem, który wyewoluował w trakcie badań, była data-centriczna strategia augmentacji, stosowana dynamicznie na etapie tworzenia wsadów treningowych.

Reprezentacja etykiet (*ground truth*)

Etykiety ze zbioru GuitarSet są konwertowane do formatu macierzowego, tzw. "*piano rolla*" lub w tym przypadku "*guitar rolla*". Jest to macierz, w której:

- Jedna oś reprezentuje czas (w korelacji z ramkami spektrogramu).
- Druga oś reprezentuje wszystkie możliwe do zagrania nuty na gitarze.

Wyjście modelu ma postać **wektora multi-hot**. Dla standardowej 6-strunowej gitary z 20 progami (plus struny puste), wektor wyjściowy ma długość $6 \times (20 + 1) = 126$. Każdy element wektora odpowiada jednej konkretnej nucie (kombinacji struna-próg). Wartość '1' na danej pozycji oznacza, że nuta jest aktywna w danej ramce czasowej, a '0' – że jest nieaktywna.

Architektura modelu

Centralnym komponentem systemu jest głęboka sieć neuronowa, której finalna architektura, zdefiniowana w pliku `model/architecture.py`, została wyłoniona w drodze iteracyjnego procesu badawczego. Jest to model hybrydowy, łączący w sobie cechy **Konwolucyjnych Sieci Neuronowych** oraz **Rekurencyjnych Sieci Neuronowych**.

Struktura warstw

1. Warstwa wejściowa (*Input Layer*): Przyjmuje segmenty spektrogramu CQT o predefiniowanym wymiarze (np. (`liczba_binow_CQT`, `dlugosc_segmentu`, 1)).
2. Bloki konwolucyjne:

- Kilka następujących po sobie warstw **Conv2D** z aktywacją **ReLU**. Ich zadaniem jest ekstrakcja hierarchicznych cech z obrazu spektrogramu – od prostych krawędzi i tekstur po bardziej złożone wzorce odpowiadające atakom dźwięku, harmonicznym i barwie instrumentu.
 - Po warstwach konwolucyjnych następują warstwy **MaxPooling2D**, które redukują wymiarowość map cech, zwiększając pole recepcyjne i zapewniając pewną niezmienność na drobne przesunięcia.
3. Reorganizacja tensora dla RNN: Po przejściu przez bloki CNN, mapy cech są przekształcane do postaci sekwencyjnej, aby przygotować dane dla warstw rekurencyjnych.
 4. Bloki rekurencyjne:
 - W finalnej, zoptymalizowanej architekturze zastosowano **dwuwarstwowe, dwukierunkowe warstwy GRU**. Wybór ten był wynikiem eksperymentów, które wykazały przewagę komórek GRU nad LSTM oraz kluczowe znaczenie mechanizmu dwukierunkowego, pozwalającego sieci analizować kontekst zarówno z przeszłych, jak i przyszłych ramek czasowych.
 5. Warstwy gęste (*Dense Layers*): Wyjście z warstw RNN jest przetwarzane przez kilka w pełni połączonych warstw **Dense**, które dokonują finalnej klasyfikacji.
 6. Warstwa wyjściowa (*Output Layer*): Ostatnia warstwa **Dense** ma **126 neuronów** (dla 6 strun i 21 stanów progów) z funkcją aktywacji **Sigmoid**. Sigmoid na wyjściu każdej jednostki zwraca wartość z zakresu $[0, 1]$, którą można interpretować jako prawdopodobieństwo, że dana nuta (struna-próg) jest aktywna w analizowanej ramce czasowej.

Proces treningu

Proces uczenia modelu, zaimplementowany w modułach w katalogu **training**, stanowił elastyczną ramę dla przeprowadzonych eksperymentów. Kluczowe hiperparametry, takie jak wagi funkcji straty czy ustawienia optymalizatora, były systematycznie dostrajane w celu maksymalizacji wydajności.

- Funkcja straty (*Loss Function*): Ze względu na charakter problemu (klasyfikacja wieloetykietowa), jako funkcję straty zastosowano **binarną entropię krzyżową**. Jest ona obliczana niezależnie dla każdej z 126 nut wyjściowych i następnie uśredniana.
- Optymalizator: W wyniku testów porównawczych, do minimalizacji funkcji straty wybrano optymalizator **AdamW**, który w połączeniu z harmonogramem **ReduceLROnPlateau** zapewniał stabilniejszy przebieg treningu i lepszą generalizację niż standardowy Adam.

- **Metryki monitorujące:** Podczas treningu monitorowano kluczowe metryki, takie jak precyzja, pełność oraz miara F1, zaimplementowane w `evaluation/metrics.py`. Pozwoliło to na bieżąco śledzić postępy w uczeniu i diagnozować problemy, takie jak przeuczenie (*overfitting*).
- **Przebieg trenowania:** Trening odbywał się w pętli przez zadaną liczbę epok. W każdej epoce model przetwarzał cały zbiór treningowy w losowych partiach (*batches*). Po każdej epoce przeprowadzano walidację na osobnym zbiorze walidacyjnym, aby ocenić zdolność modelu do generalizacji.

Ewaluacja i inferencja

Metryki ewaluacyjne

Do końcowej oceny jakości modelu na zbiorze testowym wykorzystano metryki zdefiniowane w `evaluation/performance_metrics.py`, specyficzne dla zadania AMT:

- *Note-Based Metrics:* Ocena na poziomie pojedynczych nut, biorąca pod uwagę poprawność wysokości dźwięku, czasu rozpoczęcia i opcjonalnie czasu trwania.
 - Precision: Jaki procent wykrytych nut był poprawny?
 - Recall: Jaki procent nut z oryginalnego nagrania został wykryty?
 - F1-Score: Średnia harmoniczna precyzji i pełności.
- *Tablature-Based Metrics:* Bardziej rygorystyczna ocena, która uznaje nutę za poprawnie zidentyfikowaną tylko wtedy, gdy zarówno jej wysokość, jak i **lokalizacja na gryfie (struna i próg)** są zgodne z etykietą.

Proces inferencji i post-processingu

Transkrypcja nowego pliku audio (`.wav`) przebiega zgodnie z logiką przedstawioną w `guitar_ATM.ipynb`, wykorzystując finalnie wytrenowany model:

1. Wczytanie modelu: Załadowanie wag wytrenowanego modelu.
2. Preprocessing: Nowy plik audio przechodzi przez ten sam potok przetwarzania wstępnego, co dane treningowe (resampling, CQT, segmentacja).
3. Predykcja: Segmenty spektrogramu są kolejno podawane na wejście modelu, który zwraca macierz prawdopodobieństw o wymiarach (`liczba_segmentow`, 126).
4. Post-processing:

- Progowanie: Na macierzy prawdopodobieństw stosowany jest próg, którego optymalna wartość jest zależna od strategii treningowej i jest dobierana na zbiorze walidacyjnym/testowym.
 - Konwersja na listę nut: Macierz binarna jest konwertowana na listę zdarzeń muzycznych, zawierających informacje o (czasie rozpoczęcia, strunie, progu, czasie trwania).
5. Eksport tabulatury: Finalna lista nut jest formatowana i eksportowana do czytelnego pliku tekstowego, co realizuje moduł `evaluation/tablature_export.py`.

Struktura i opis kodu

Projekt został zorganizowany w sposób modułowy, aby zapewnić czytelność i łatwość w utrzymaniu kodu. Poniższy wykaz przedstawia strukturę katalogów, a w kolejnej sekcji opisano rolę kluczowych skryptów.

Listing 1: Wykaz struktury katalogów projektu.

```
1 /
2 |-- _mir_datasets_storage/
3 |   |-- annotation/
4 |   |-- audio_hex-pickup_debleeded/
5 |   |-- audio_hex-pickup_original/
6 |   |-- audio_mono-mic/
7 |   |-- audio_mono-pickup_mix/
8 |-- _processed_guitarset_data/
9 |   |-- test/
10 |   |-- train/
11 |   |-- validation/
12 |   |-- test_ids.txt
13 |   |-- train_ids.txt
14 |   |-- validation_ids.txt
15 |-- data_processing/
16 |   |-- preparation.py
17 |   |-- dataset.py
18 |-- evaluation/
19 |   |-- metrics.py
20 |   |-- performance_metrics.py
21 |   |-- tablature_export.py
22 |-- model/
23 |   |-- architecture.py
```



```
24 |-- results /
25 |-- test /
26 |-- training /
27 |   |-- pipeline.py
28 |   |-- loss_functions.py
29 |-- vizualization /
30 |   |-- plotting.py
31 |-- config.py
32 |-- guitar_ATM.ipynb
33 |-- requirements.txt
```

Opis kluczowych skryptów i modułów

- **guitar_ATM.ipynb**: Główny notatnik Jupyter, pełniący rolę centrum sterowania dla całego procesu badawczego. Umożliwia on definiowanie, uruchamianie i monitorowanie pojedynczych eksperymentów, a także przeprowadzanie analizy wyników i generowanie wizualizacji.
- **config.py**: Centralny plik konfiguracyjny, w którym zdefiniowano wszystkie globalne stałe i hiperparametry, takie jak ścieżki do danych, parametry ekstrakcji cech CQT, ustawienia augmentacji oraz domyślne konfiguracje architektury sieci i procesu treningu.
- **data_processing/**: Moduł odpowiedzialny za przygotowanie danych. Zawiera on skrypt **preparation.py**, implementujący logikę wczytywania sygnału, ekstrakcji cech i augmentacji, oraz **dataset.py**, który definiuje niestandardową klasę zbioru danych PyTorch.
- **model/**: Zawiera definicję architektury sieci neuronowej. Plik **architecture.py** implementuje elastyczną klasę modelu CRNN, której parametry (np. liczba warstw, typ komórek rekurencyjnych) mogą być dynamicznie konfigurowane.
- **training/**: Moduł grupujący logikę związaną z procesem uczenia. Skrypt **pipeline.py** zawiera główną pętlę treningową i walidacyjną, a **loss_functions.py** implementuje wielozadaniową funkcję straty.
- **evaluation/**: Zestaw narzędzi do oceny modelu. Implementacje metryk TDR i MPE znajdują się w skryptach **metrics.py** oraz **performance_metrics.py**. Moduł zawiera również skrypt **tablature_export.py**, odpowiadający za konwersję predykcji na czytelny format tabulatury tekstowej.

- `vizualization/`: Moduł pomocniczy do generowania wykresów i wizualizacji, takich jak spektrogramy czy historie treningu, używany w notatniku głównym.

Spis skrótów i symboli

Skróty

- ATM – Automatyczna Transkrypcja Muzyczna (ang. *Automatic Music Transcription*)
- BiGRU – Dwukierunkowa rekurencyjna sieć neuronowa z jednostkami GRU (ang. *Bidirectional Gated Recurrent Unit*)
- CNN – Splotowa Sieć Neuronowa (ang. *Convolutional Neural Network*)
- CPS – Cyfrowe Przetwarzanie Sygnałów (ang. *Digital Signal Processing – DSP*)
- CRNN – Konwolucyjno-Rekurencyjna Sieć Neuronowa (ang. *Convolutional Recurrent Neural Network*)
- CQT – Transformata Constant-Q (ang. *Constant-Q Transform*)
- DAW – Cyfrowa stacja robocza audio (ang. *Digital Audio Workstation*)
- DFT – Dyskretna Transformata Fouriera (ang. *Discrete Fourier Transform*)
- DL – Głębokie Uczenie (ang. *Deep Learning*)
- EQ – Korekcja barwy dźwięku (ang. *Equalization*)
- FN – Fałszywie negatywne (ang. *False Negatives*)
- FP – Fałszywie pozytywne (ang. *False Positives*)
- GRU – Bramkowana Jednostka Rekurencyjna (ang. *Gated Recurrent Unit*)
- GTT – Transkrypcja Gitarowa na Tabulaturę (ang. *Guitar Tablature Transcription*)
- HMM – Ukryte Modele Markowa (ang. *Hidden Markov Models*)
- HPS – Spektrum harmoniczne iloczynu (ang. *Harmonic Product Spectrum*)
- JAMS – JSON Annotated Music Specification
- LR – Współczynnik uczenia (ang. *Learning Rate*)

- LSTM – Długa Pamięć Krótkoterminowa (ang. *Long Short-Term Memory*)
- MIR – Komputerowe Pozyskiwanie Informacji Muzycznej (ang. *Music Information Retrieval*)
- MPE – Estymacja Wielokrotnej Wysokości Dźwięku (ang. *Multiple Pitch Estimation*)
- NMP – Noty i multipitch (ang. *Notes and Multipitch*)
- NMF – Nieujemna Faktoryzacja Macierzy (ang. *Non-negative Matrix Factorization*)
- PLCA – Probabilistyczna Analiza Składowych Ukrytych (ang. *Probabilistic Latent Component Analysis*)
- RNN – Rekurencyjna Sieć Neuronowa (ang. *Recurrent Neural Network*)
- SI – Sztuczna Inteligencja (ang. *Artificial Intelligence – AI*)
- STFT – Krótkoczasowa Transformata Fouriera (ang. *Short-Time Fourier Transform*)
- TDR – Współczynnik Detekcji Tabulatury (ang. *Tablature Detection Rate*)
- TP – Prawdziwie pozytywne (ang. *True Positives*)
- UM – Uczenie Maszynowe (ang. *Machine Learning – ML*)
- VRAM – Pamięć graficzna (ang. *Video Random-Access Memory*)

Symbole Matematyczne

- F_0 – Częstotliwość podstawowa
- X_k – k -ty współczynnik dyskretnej transformaty Fouriera
- x_n – n -ta próbka sygnału w dziedzinie czasu
- k – Indeks częstotliwości (w kontekście DFT)
- n – Indeks próbki w dziedzinie czasu (w kontekście DFT)
- N – Długość ciągu próbek sygnału (w kontekście DFT)
- i – Jednostka urojona
- $\mathcal{L}_{\text{total}}$ – Całkowita funkcja straty modelu
- $\mathcal{L}_{\text{onset}}$ – Komponent funkcji straty dla predykcji onsetów
- $\mathcal{L}_{\text{fret}}$ – Komponent funkcji straty dla predykcji progów

- $w_{\text{onset}}, w_{\text{fret}}$ – Wagi dla komponentów funkcji straty
- w_{pos} – Waga dla przykładów pozytywnych w detekcji onsetów
- $y_{s,t}^{\text{onset}}$ – Etykieta referencyjna dla onsetu (binarna)
- $\hat{z}_{s,t}^{\text{onset}}$ – Logit wyjściowy modelu dla onsetu
- $\sigma(\cdot)$ – Funkcja aktywacji sigmoid
- F_{min} – Minimalna częstotliwość (w kontekście CQT)
- $y_{s,t,c}^{\text{fret}}$ – Binarny wskaźnik dla klasy progu c dla struny s i ramki t
- $p_{s,t,c}^{\text{fret}}$ – Prawdopodobieństwo predykcji dla klasy progu c dla struny s i ramki t
- $N_{\text{klas progu}}$ – Liczba klas progów (z uwzględnieniem ciszy)

Spis rysunków

1.1	Porównanie fragmentu zapisu nutowego (góra) i odpowiadającej mu tabulatury gitarowej (dół) dla tego samego motywu muzycznego.	3
1.2	Schematyczny przykład mel-spektrogramu polifonicznego sygnału gitarowego, ukazujący nakładające się struktury harmoniczne (prążki reprezentujące częstotliwość podstawową i jej alikwoty) dla kilku jednocześnie brzmiących nut.	4
2.1	Schematyczna wizualizacja obwiedni dźwięku ADSR (oś pionowa: amplituda, oś pozioma: czas) [25].	13
2.2	Po lewej: fragment sygnału audio pojedynczego dźwięku gitary w dziedzinie czasu (oś pionowa: amplituda (wartość znormalizowana), oś pozioma: czas w próbkach). Po prawej: odpowiadające mu widmo amplitudowe (oś pionowa: magnituda (jednostki względne), oś pozioma: częstotliwość w Hz), ukazujące częstotliwość podstawową (F_0) oraz jej kolejne alikwoty (składowe harmoniczne).	14
2.3	Wizualizacja różnych reprezentacji czasowo-częstotliwościowych dla tego samego polifonicznego fragmentu gitarowego: (a) Spektrogram STFT z liniową skalą częstotliwości, (b) Spektrogram Constant-Q (CQT) z logarytmiczną skalą częstotliwości, (c) Mel-spektrogram z osią częstotliwości w skali Mel.	16
2.4	Uproszczony schemat potoku przetwarzania w systemie ATM: od sygnału audio, poprzez ekstrakcję cech, zadania składowe (MPE, detekcja onsetów/offsetów, estymacja instrumentu), aż po generowanie wyjściowej reprezentacji symbolicznej na różnych poziomach abstrakcji (ramki, nuty, partytura) [3].	17
2.5	Przykład tej samej nuty (E4, MIDI 64) możliwej do zagrania w wielu pozycjach na gryfie gitary standardowo strojonej. Ilustracja przedstawia dźwięk E4 na strunie G (9. próg), strunie B (5. próg) oraz pustej strunie wysokiej E. Obrazuje to wyzwanie estymacji opalcowania w GTT [8].	25

3.1	Wizualizacja etykiet ramkowych dla fragmentu utworu. Górny panel przedstawia macierz onsetów, gdzie pionowe linie oznaczają moment rozpoczęcia nuty na danej strunie. Dolny panel pokazuje macierz aktywności progów, gdzie czarne obszary reprezentują czas trwania dźwięku na danej strunie. .	35
3.2	Schemat architektury zaimplementowanego modelu. Przedstawia przepływ danych od wejściowego tensora spektrogramu, przez frontend konwolucyjny, backend rekurencyjny, aż po rozdzielenie na dwie głowice wyjściowe dla predykcji onsetów i progów.	38
4.1	Porównanie reprezentacji czasowo-częstotliwościowych dla tego samego fragmentu gitarowego. (a) Spektrogram w skali Mel. (b) Spektrogram CQT, gdzie widoczna jest regularna struktura harmoniczna. (c) Odpowiadająca fragmentowi tabulatura referencyjna.	50
4.2	Historia procesu uczenia dla finalnego modelu (przebieg 72). Górne wykresy przedstawiają przebieg funkcji straty oraz zmiany współczynnika uczenia. Dolne wykresy obrazują ewolucję kluczowych metryk (nutowych i ramkowych) w kolejnych epokach.	57
4.3	Porównanie fragmentu tabulatury wygenerowanej przez model (góra) i tabulatury referencyjnej (dół) dla utworu 04_BN1-147-Gb_comp.	59
4.4	Porównanie fragmentu tabulatury wygenerowanej przez model (góra) i tabulatury referencyjnej (dół) dla utworu 05_Rock3-148-C_solo.	60
4.5	Porównanie fragmentu tabulatury wygenerowanej przez model (góra) i tabulatury referencyjnej (dół) dla utworu 00_SS3-84-Bb_comp, ilustrujące wyzwania w transkrypcji gęstych faktur.	61

Spis tabel

2.1	Wybrane techniki gitarowe i ich manifestacje akustyczne	22
2.2	Porównanie standardowej notacji muzycznej i tabulatury gitarowej.	24
4.1	Parametry środowiska eksperymentalnego.	48
4.2	Parametry ekstrakcji cech dla badanych reprezentacji sygnału.	49
4.3	Kluczowe etapy ewolucji architektury modelu (ocena na zbiorze testowym).	51
4.4	Porównanie wpływu rozmiaru wsadu na wyniki (wybrane przebiegi).	52
4.5	Analiza wpływu wagi straty dla detekcji onsetów.	53
4.6	Analiza wpływu wagi dla przykładów pozytywnych w detekcji onsetów.	53
4.7	Porównanie wpływu początkowego współczynnika uczenia.	53
4.8	Analiza wpływu cierpliwości harmonogramu.	54
4.9	Porównanie wpływu różnych strategii augmentacji na wynik TDR F1-Score (zbiór testowy).	55
4.10	Kompleksowe porównanie metryk dla kluczowych modeli na zbiorze testowym. Pogrubione wartości wskazują najlepszy wynik uzyskany dla danej metryki.	56
4.11	Zestawienie najlepszych i najgorszych wyników transkrypcji (TDR F1-Score) uzyskanych przez model finalny (przebieg 72) na zbiorze testowym.	57